機械学習

信川創

2026 年 11 月 1 日

Copyright © 2026 Sou Nobukawa. All rights reserved.

Permission is granted to students to download and use this material for personal educational purposes.

Redistribution, modification, republication, or commercial use without prior written permission from the author is prohibited.

Copyright © 2026 信川創. 無断転載を禁じます.

受講生が個人の学習目的で本資料をダウンロードし，利用することを許可します.

著者の書面による事前の許可なく，本資料を再配布，改変，転載，または商用利用することを禁じます.

目次

0 本講義の概要 9
0.1 科目概要 . . . 9
0.2 到達目標 . . . 9
0.3 授業計画 . . . 9
0.4 評価方法 . . . 10

1 機械学習とは何か 11
1.1 学習問題の定式化 . . . 11
1.1.1 例 1：1 変数の線形関数 . . . 11
1.1.2 例 2：多変数の線形関数 . . . 11
1.1.3 例 3：非線形関数 . . . 12
1.2 仮説空間 . . . 12
1.2.1 関数の集合という考え方 . . . 12
1.2.2 仮説空間の定義 . . . 12
1.2.3 例：線形仮説空間 . . . 13
1.2.4 例：多項式仮説空間 . . . 14
1.3 損失関数 . . . 14
1.3.1 二乗損失（回帰問題） . . . 14
1.3.2 0-1 損失（分類問題） . . . 15
1.4 経験損失と汎化誤差 . . . 15
1.4.1 経験損失 . . . 15
1.4.2 汎化誤差 . . . 15
1.5 過学習と未学習 . . . 15
1.6 学習アルゴリズムの概要 . . . 16
1.7 演習問題 . . . 17

2 ベクトルと内積 19
2.1 ベクトルとは何か . . . 19
2.1.1 データの表現としてのベクトル . . . 19
2.1.2 ベクトルの演算 . . . 19
2.2 ノルム . . . 20
2.2.1 ベクトルの長さ . . . 20
2.2.2 ノルムの性質 . . . 20
2.2.3 距離と単位ベクトル . . . 21
2.3 内積 . . . 22
2.3.1 内積の定義 . . . 22
2.3.2 内積の性質 . . . 23

2.3.3 線形モデルの再解釈 . . . 24
2.4 内積の幾何学的解釈 . . . 25
2.4.1 コーシー・シュワルツの不等式 . . . 25
2.4.2 内積と角度 . . . 27
2.4.3 正射影 . . . 27
2.5 内積と類似度 . . . 28
2.5.1 コサイン類似度 . . . 28
2.5.2 例：文書の類似度 . . . 29
2.6 発展：内積と Attention . . . 30
2.6.1 単語をベクトルで表す . . . 30
2.6.2 Query, Key, Value . . . 31
2.6.3 注目度を内積で測る . . . 32
2.6.4 スコアを重みに変換する . . . 32
2.6.5 数値例 . . . 33
2.6.6 行列表記と $\sqrt{d_k}$ . . . 34
2.6.7 まとめ . . . 34
2.7 発展：内積とニューラルネットワーク . . . 34
2.7.1 ニューロン 1 個の計算 . . . 35
2.7.2 ニューロンは何を検出しているのか . . . 35
2.7.3 決定境界と法線ベクトル . . . 36
2.7.4 なぜ非線形が必要か . . . 36
2.7.5 数値例：AND を計算するニューロン . . . 36
2.7.6 層：内積を並べたもの . . . 37
2.7.7 まとめ . . . 38
2.8 まとめ . . . 38
2.9 演習問題 . . . 39

3 行列と線形変換 41
3.1 行列とは何か . . . 41
3.1.1 行列の定義 . . . 41
3.1.2 転置 . . . 42
3.1.3 行列の和とスカラー倍 . . . 42
3.2 行列とベクトルの積 . . . 43
3.2.1 定義と 2 つの見方 . . . 43
3.2.2 例 . . . 44
3.2.3 線形独立と張られる空間 . . . 45
3.2.4 行列の積 . . . 46
3.3 線形写像 . . . 47
3.3.1 行列は写像である . . . 47
3.3.2 線形性が意味すること . . . 48

3.4 計画行列 . . . 49
3.4.1 データをまとめる . . . 49
3.4.2 予測の全体を一つの式で表す . . . 50
3.5 列空間とランク . . . 51
3.5.1 予測は列の線形結合である . . . 51
3.5.2 列空間 . . . 52
3.5.3 仮説空間の正体 . . . 53
3.5.4 ランク . . . 54
3.5.5 ランク落ちと多重共線性 . . . 54
3.5.6 数値例 . . . 57
3.6 行列のノルム . . . 57
3.6.1 定義 . . . 57
3.6.2 列ベクトルとの関係 . . . 57
3.6.3 どのような場面で使うか . . . 58
3.6.4 他の行列ノルムとの違い . . . 58
3.7 固有値と固有ベクトル（概念） . . . 59
3.7.1 幾何学的な意味 . . . 59
3.7.2 特性方程式 . . . 59
3.7.3 機械学習での現れ方 . . . 61
3.7.4 ランクとの関係 . . . 61
3.8 まとめ . . . 62
3.9 演習問題 . . . 62

4 最小二乗法（幾何学） 64
4.1 問題の確認 . . . 64
4.1.1 これまでの到達点 . . . 64
4.1.2 本章の進め方 . . . 65
4.2 幾何学による導出 . . . 65
4.2.1 最小化問題の言い換え . . . 65
4.2.2 直交性の原理 . . . 65
4.2.3 証明：三平方の定理が効く . . . 65
4.2.4 直交条件を行列の式に直す . . . 68
4.3 微分による導出 . . . 69
4.3.1 1 変数の場合の復習 . . . 69
4.3.2 勾配 . . . 69
4.3.3 必要な 2 つの公式 . . . 70
4.3.4 経験損失を展開して微分する . . . 71
4.3.5 停留点が最小値である理由 . . . 72
4.4 2 つの導出の対応 . . . 75
4.5 正規方程式を解く . . . 75

4.5.1 $\boldsymbol{X}^\top \boldsymbol{X}$ の性質 . . . 75
4.5.2 逆行列 . . . 76
4.5.3 解が一意に定まる条件 . . . 76
4.5.4 数値例 . . . 77
4.5.5 解いた後の確認 . . . 77
4.6 ハット行列（射影行列） . . . 78
4.6.1 定義と意味 . . . 78
4.6.2 射影行列の 2 つの性質 . . . 78
4.6.3 トレースと自由度 . . . 79
4.7 ランク落ちと擬似逆行列 . . . 79
4.7.1 零空間と解の集合 . . . 79
4.7.2 どれを選ぶか：最小ノルム解 . . . 81
4.7.3 フルランクのときは何が起こるか . . . 82
4.7.4 数値例 . . . 82
4.7.5 なぜ最小ノルムを選ぶのか . . . 83
4.8 数値計算上の注意 . . . 83
4.8.1 条件数が二乗される . . . 83
4.8.2 実際に使われる方法 . . . 83
4.8.3 多重共線性との関係 . . . 84
4.9 まとめ . . . 84
4.10 演習問題 . . . 85

5 勾配降下法 86
5.1 なぜ反復計算が必要か . . . 86
5.1.1 閉じた式の限界 . . . 86
5.1.2 反復計算という発想 . . . 87
5.1.3 本章で学ぶ「勾配降下法」と実際に使われる手法 . . . 87
5.2 勾配降下法 . . . 87
5.2.1 1 変数の場合 . . . 87
5.2.2 多変数への拡張 . . . 88
5.2.3 なぜ勾配と逆向きに進むのか . . . 89
5.2.4 最小二乗法への適用 . . . 89
5.2.5 数値例 . . . 90
5.2.6 学習率の役割 . . . 91
5.2.7 終了条件 . . . 92
5.3 収束の直感 . . . 92
5.3.1 固有ベクトルの向きごとに 1 変数問題に分かれる . . . 92
5.3.2 条件数と収束の速さ . . . 94
5.3.3 ジグザグの正体 . . . 95
5.3.4 特徴のスケーリング . . . 95

5.4 凸関数 . . . 97
5.4.1 定義 . . . 97
5.4.2 微分可能な場合の判定 . . . 98
5.4.3 凸関数の最小値 . . . 99
5.4.4 最小二乗法と正則化は凸である . . . 100
5.4.5 凸でないとき . . . 100
5.5 確率的勾配降下法 . . . 100
5.5.1 バッチ勾配降下法の問題 . . . 100
5.5.2 ミニバッチ . . . 100
5.5.3 エポック . . . 101
5.5.4 学習率の減衰 . . . 102
5.6 勾配降下法の改良：モメンタムと Adam . . . 102
5.6.1 モメンタム . . . 102
5.6.2 座標ごとに歩幅を変える . . . 104
5.6.3 Adam . . . 104
5.6.4 どれを使うか . . . 105
5.7 正規方程式と勾配降下法の比較 . . . 105
5.8 まとめ . . . 106
5.9 演習問題 . . . 107

6 正則化と汎化 109
6.1 なぜ正則化が必要か . . . 109
6.1.1 経験損失を最小にすると何が起きるか . . . 109
6.1.2 もう一つの症状：解が定まらない . . . 110
6.1.3 重みが大きいことの害 . . . 110
6.1.4 正則化の考え方 . . . 111
6.2 L2 正則化：リッジ回帰 . . . 111
6.2.1 定義 . . . 111
6.2.2 解の導出 . . . 112
6.2.3 数値例 . . . 112
6.2.4 多重共線性への効果 . . . 113
6.2.5 固有値で見るリッジ回帰 . . . 115
6.2.6 自由度 . . . 116
6.2.7 勾配降下法で見る：重み減衰 . . . 118
6.3 正則化係数の選び方 . . . 119
6.3.1 ハイパーパラメータ . . . 119
6.3.2 検証データ . . . 119
6.3.3 交差検証 . . . 120
6.3.4 特徴の標準化と切片の扱い . . . 121
6.4 バイアスとバリアンス . . . 122

6.4.1 思考実験：データを取り直す . . . 122
6.4.2 バイアス–バリアンス分解 . . . 123
6.4.3 1 変数モデルで計算する . . . 124
6.4.4 多次元での見方 . . . 125
6.5 制約付き最適化の導入 . . . 125
6.5.1 罰則から制約へ . . . 125
6.5.2 幾何学：等高線と制約領域の接点 . . . 126
6.5.3 接点の条件とラグランジュ乗数 . . . 126
6.5.4 ノルムの形と解の形：L1 正則化 . . . 127
6.6 正則化の広がり . . . 128
6.7 まとめ . . . 129
6.8 演習問題 . . . 130

7 確率とベイズの定理 132
7.1 なぜ確率が必要か . . . 132
7.1.1 機械学習に現れる不確かさ . . . 132
7.1.2 確率の 2 つの解釈 . . . 132
7.2 確率の基本 . . . 133
7.2.1 標本空間と事象 . . . 133
7.2.2 確率の公理 . . . 133
7.2.3 同時確率と周辺確率 . . . 135
7.3 条件付き確率と独立性 . . . 135
7.3.1 条件付き確率 . . . 135
7.3.2 乗法定理 . . . 137
7.3.3 全確率の定理 . . . 138
7.3.4 独立性 . . . 139
7.4 ベイズの定理 . . . 140
7.4.1 定理の導出 . . . 140
7.4.2 数値例：検査の陽性は何を意味するか . . . 141
7.4.3 事前確率・尤度・事後確率 . . . 142
7.4.4 逐次的な更新 . . . 144
7.5 確率変数と確率分布 . . . 145
7.5.1 離散確率変数 . . . 145
7.5.2 連続確率変数 . . . 146
7.5.3 同時分布・周辺分布・条件付き分布 . . . 146
7.5.4 正規分布 . . . 147
7.6 期待値と分散 . . . 148
7.6.1 期待値 . . . 148
7.6.2 期待値の線形性 . . . 149
7.6.3 分散 . . . 150

7.6.4 共分散と独立な和の分散 . . . 151
7.6.5 共分散行列 . . . 152
7.7 パラメータを確率で表す：ベイズ推定の入口 . . . 153
7.7.1 コインの偏りを推定する . . . 153
7.7.2 事後分布から一つの値を選ぶ . . . 156
7.7.3 最小二乗法を確率の言葉で読む（予告） . . . 157
7.8 まとめ . . . 157
7.9 演習問題 . . . 158

付録 A 勾配降下法の収束解析 161
A.1 誤差の漸化式と固有値分解 . . . 161
A.1.1 定理（式 (5.14)）の証明 . . . 161
A.2 最適な学習率と減衰率 . . . 161
A.2.1 必要な反復回数 . . . 162
A.3 相関と白色化 . . . 162

0　本講義の概要

0.1　科目概要

本講義は、AI 時代における機械学習の数理的基盤を確立することを目的とする。単なるアルゴリズムの紹介ではなく、「モデルとは何か」「学習とは何か」を数学的に理解することを重視する。具体的には、線形代数的基礎、最適化理論、正則化と汎化、ベイズ推論の基本構造、サポートベクターマシン、ニューラルネットワーク基礎、そして現代 AI の概念紹介を統合的に扱う。

本講義は以下を柱とする：

- AI をブラックボックスにしない
- 数学を道具として使う
- モデルを仮説空間として理解する
- 頻度論とベイズの両視点を示す
- 現代 AI へ接続する基礎体力を育成する

0.2　到達目標

本講義を修了した学生は、以下を説明できるようになる：

1. モデルをベクトル・行列で表現できる
2. 最小二乗法の幾何学的意味を説明できる
3. 勾配降下法の原理を理解できる
4. 正則化の数学的意味を説明できる
5. ベイズの定理と MAP 推定を説明できる
6. 制約付き最適化とラグランジュ未定乗数法を理解する
7. ニューラルネットワークを「線形変換＋非線形」として理解する

0.3　授業計画

全 13 回の構成を表 0.1 に示す。各回は「機械学習の概念」と、それを支える「数学ツール」の二層で構成される。第 1 回から第 6 回までは頻度論的な枠組み（損失最小化）を、第 7 回から第 9 回ではベイズ的な枠組みを扱い、両者の関係を明らかにする。第 10 回以降は、これらの基盤の上に SVM・ニューラルネットワーク・現代 AI を位置づける。

表 0.1　授業計画（全 13 回）

回	テーマ	内容	数学ツール
1	機械学習とは何か	仮説空間、損失関数、汎化誤差	関数最小化の基本概念
2	ベクトルと内積	ノルム、内積と類似度、幾何学的解釈	内積の性質の証明
3	行列と線形変換	線形写像、ランク、固有値（概念）	行列微分の基礎
4	最小二乗法（幾何学）	射影としての回帰、正規方程式	勾配の導出
5	勾配降下法	反復による最小化、学習率と収束、凸関数の概念、SGD と Adam	凸関数の定義
6	正則化と汎化	リッジ回帰、正則化係数の選び方（交差検証）、バイアス–バリアンス、制約付き最適化の導入、L1 正則化	ノルムと制約の幾何学
7	確率とベイズの定理	条件付き確率、ベイズの定理、事前・尤度・事後、期待値と分散	確率の基本公式の導出
8	ナイーブベイズと生成モデル	独立仮定、生成モデル vs 判別モデル、MAP 推定	対数尤度最大化
9	正則化とベイズの関係	リッジ回帰とガウス事前分布、頻度論 vs ベイズ	MAP 推定の導出
10	サポートベクターマシン	マージン最大化、制約付き最適化	ラグランジュ未定乗数法
11	SVM 双対問題とカーネル	双対問題の直感、カーネルトリック	KKT 条件（概念）
12	ニューラルネットワーク基礎	パーセプトロン、線形変換＋非線形、連鎖律、パラメータの初期値	連鎖律の導出
13	現代 AI への接続	CNN・RNN の概念、Attention の直感、Transformer 紹介、モデルとは何かの総括	—

0.4　評価方法

- 小テスト（数理確認）
- レポート（モデル比較）
- 最終試験（理論理解）

1　機械学習とは何か

本章では、機械学習の基本的な枠組みを導入する。機械学習とは、データから規則性を抽出し、未知のデータに対する予測や判断を行う手法の総称である。本章では特に、仮説空間・損失関数・汎化誤差という 3 つの基本概念を数学的に定義し、「学習とは何か」を明確にする。

1.1　学習問題の定式化

機械学習では、入力と出力の間の未知の関係を、データから推定することを目標とする。

入力空間を $\mathcal{X}$、出力空間を $\mathcal{Y}$ とする。ここで $\mathbb{R}^d$ は d 個の実数の組全体の集合であり、d を**次元**（dimension）と呼ぶ。記号 $\mathcal{X} \subseteq \mathbb{R}^d$ は、$\mathcal{X}$ が $\mathbb{R}^d$ の**部分集合**（subset）であることを意味する。すなわち、$\mathcal{X}$ の任意の要素は $\mathbb{R}^d$ の要素でもある。入力空間として $\mathbb{R}^d$ 全体を取る場合もあれば、その一部（例えば非負の実数のみなど）に制限する場合もあるため、一般に $\subseteq$ を用いて表記する。

ここで、記号 $\in$ と $\subseteq$ の違いに注意する。$\in$ は「要素である」ことを表し、$\subseteq$ は「部分集合である」ことを表す。例えば、$\boldsymbol{x} \in \mathbb{R}^d$ は「$\boldsymbol{x}$ は $\mathbb{R}^d$ の一つの要素（ベクトル）である」ことを意味し、$\mathcal{X} \subseteq \mathbb{R}^d$ は「$\mathcal{X}$ は $\mathbb{R}^d$ の部分集合（集合同士の関係）である」ことを意味する。回帰問題では $\mathcal{Y} = \mathbb{R}$、2 値分類問題では $\mathcal{Y} = \{0, 1\}$ とする。

我々が観測できるのは、入出力の組からなる**訓練データ**（training data）

$$D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_N, y_N)\} \tag{1.1}$$

のみである。ここで各 $\boldsymbol{x}_i \in \mathcal{X} \subseteq \mathbb{R}^d$ は d 次元の入力ベクトル、$y_i \in \mathcal{Y}$ は対応する出力である。N はデータの個数（サンプルサイズ）を表す。

学習の目標は、訓練データ D をもとに、未知のデータに対しても良い予測を行う関数 h を見つけることである。ここで、$h : \mathcal{X} \to \mathcal{Y}$ という記法は、h が集合 $\mathcal{X}$ の要素を受け取り、集合 $\mathcal{Y}$ の要素を返す関数であることを表す。$\mathcal{X}$ を**定義域**（domain）、$\mathcal{Y}$ を**値域**（codomain）と呼ぶ。例えば $h : \mathbb{R}^d \to \mathbb{R}$ は、d 次元ベクトルを入力として受け取り、実数値を一つ出力する関数を意味する。

以下に、関数 h の具体例を 3 つ示す。

1.1.1　例 1：1 変数の線形関数

ある都市において、部屋の広さ x（m^2）から家賃 y（万円）を予測したいとする。このとき、$h : \mathbb{R} \to \mathbb{R}$ を

$$h(x) = 0.5x + 2 \tag{1.2}$$

と定めれば、広さ 20 m^2 の部屋に対して $h(20) = 0.5 \times 20 + 2 = 12$（万円）と予測する。これは 1 次関数（直線）による最も単純な予測モデルである。

1.1.2　例 2：多変数の線形関数

家賃の予測に、広さ x_1（m^2）だけでなく駅からの距離 x_2（分）も考慮したいとする。入力を $\boldsymbol{x} = (x_1, x_2)^\top \in \mathbb{R}^2$ とし、$h : \mathbb{R}^2 \to \mathbb{R}$ を

$$h(\boldsymbol{x}) = 0.5x_1 - 0.3x_2 + 3 \tag{1.3}$$

と定める。広さ 25 m^2、駅から 10 分の部屋に対しては $h(\boldsymbol{x}) = 0.5 \times 25 - 0.3 \times 10 + 3 = 12.5$（万円）と予測する。入力の次元が $d = 2$ に増えたが、各変数に対して線形である点は同じである。

1.1.3 例 3：非線形関数

データが曲線的な関係を持つ場合、線形関数では捉えきれない。例えば $h : \mathbb{R} \to \mathbb{R}$ を

$$h(x) = 0.01x^2 + 0.2x + 1 \tag{1.4}$$

と定めれば、2 次関数（放物線）で予測を行う。$h(20) = 0.01 \times 400 + 0.2 \times 20 + 1 = 9$（万円）となる。このように、どのような形の関数 h を候補とするかは、学習者（モデル設計者）が決める重要な選択であり、次節で導入する**仮説空間**の概念に直結する。

1.2 仮説空間

入力 $\boldsymbol{x} \in \mathbb{R}^d$ から出力 y を予測する関数を**仮説**（hypothesis）と呼ぶ。学習に際して、すべての関数 $h : \mathcal{X} \to \mathcal{Y}$ を候補とすることは現実的でない。そこで、候補となる関数の集合をあらかじめ定める。

1.2.1 関数の集合という考え方

これまで「集合」といえば、数の集合（例：$\{1, 2, 3\}$）やベクトルの集合（例：$\mathbb{R}^d$）を扱ってきた。ここでは、**関数そのものを要素とする集合**を考える。

前節の例を振り返ろう。例 1 で定義した $h_1(x) = 0.5x + 2$ と、別の直線 $h_2(x) = 0.8x + 1$ はどちらも $\mathbb{R} \to \mathbb{R}$ の関数である。これらを要素として集めると、関数の集合が作れる：

$$\{h_1, h_2\} = \{0.5x + 2,\ 0.8x + 1\} \tag{1.5}$$

これは要素が 2 つの関数の集合である。さらに、パラメータ w_0, w_1 を自由に動かせば、すべての直線を集めた集合が得られる：

$$\{h(x) = w_0 + w_1 x \mid w_0 \in \mathbb{R},\ w_1 \in \mathbb{R}\} \tag{1.6}$$

この記法は「w_0 と w_1 がそれぞれ任意の実数を取るとき、$h(x) = w_0 + w_1 x$ という形の関数をすべて集めた集合」と読む。一般に $\{\cdots \mid \cdots\}$ は、縦棒「$\mid$」を「ただし」と読み、**左側に集める要素の形、右側にその要素を作り出す変数の動く範囲**（または要素が満たすべき条件）を書く記法である。ここでは左側が $h(x) = w_0 + w_1 x$ という関数の形、右側が w_0, w_1 の動く範囲である。すなわち、この集合の各要素は一つの直線（関数）であり、集合全体は「あり得るすべての直線」を表している。

このように、候補となる関数をすべて集めた集合を**仮説空間**と呼ぶ。

1.2.2 仮説空間の定義

一般に、仮説空間を次のように定義する。

定義：仮説空間

入力空間 $\mathcal{X} \subseteq \mathbb{R}^d$ から出力空間 $\mathcal{Y}$ への関数の集合

$$\mathcal{H} = \{h : \mathcal{X} \to \mathcal{Y}\} \tag{1.7}$$

を**仮説空間**（hypothesis space）と呼ぶ。ここで $\{h : \mathcal{X} \to \mathcal{Y}\}$ は「$\mathcal{X}$ から $\mathcal{Y}$ への関数 h を集めた集合」と読む。学習とは、仮説空間 $\mathcal{H}$ の中から、データ D に基づいて最適な仮説 $h^* \in \mathcal{H}$ を選ぶことである。ここで上付きの $*$ は「最適なもの」を表す記号であり、本書では一貫してこの意味で用いる。

仮説空間は、パラメータ $\boldsymbol{w} \in \mathbb{R}^p$ によって特徴づけられることが多い。ここで p はパラメータの**次元**であり、モデルの自由度を表す。このとき仮説空間は次のように書ける：

$$\mathcal{H} = \{h(\cdot\,; \boldsymbol{w}) \mid \boldsymbol{w} \in \mathbb{R}^p\} \tag{1.8}$$

この記法について補足する。$h(\boldsymbol{x}; \boldsymbol{w})$ のセミコロン「;」は、その前後で引数の役割が異なることを示す慣習的な記法である。セミコロンの前の $\boldsymbol{x}$ は関数への**入力**（データとして与えられるもの）、セミコロンの後の $\boldsymbol{w}$ は関数の振る舞いを決める**パラメータ**（学習によって調整するもの）である。例えば、前節の例 1 の直線 $h(x) = 0.5x + 2$ をこの記法で書けば $h(x; w_0, w_1) = w_1 x + w_0$ となり、$w_0 = 2$, $w_1 = 0.5$ というパラメータの値が決まって初めて一つの具体的な関数が定まる。

また、$h(\cdot\,; \boldsymbol{w})$ の「$\cdot$」は入力の場所を空けていることを表す記号であり、「パラメータ $\boldsymbol{w}$ を固定したとき、入力を受け取る関数」という意味になる。すなわち $h(\cdot\,; \boldsymbol{w})$ と $h(\boldsymbol{x}; \boldsymbol{w})$ は同じ関数を指すが、前者は「入力をまだ指定していない関数そのもの」、後者は「入力 $\boldsymbol{x}$ を具体的に与えた値」を強調する書き方である。

1.2.3 例：線形仮説空間

入力 $\boldsymbol{x} \in \mathbb{R}^d$ に対して、線形モデル

$$h(\boldsymbol{x}; \boldsymbol{w}) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_d x_d = w_0 + \boldsymbol{w}_{1:d}^\top \boldsymbol{x} \tag{1.9}$$

を考える。$w_0 \in \mathbb{R}$ を**バイアス項**（bias term、切片）と呼ぶ。パラメータ全体は $\boldsymbol{w} = (w_0, w_1, \ldots, w_d)^\top \in \mathbb{R}^{d+1}$ であり、パラメータ次元は $p = d + 1$ である。

ここで、右辺に現れた $\boldsymbol{w}_{1:d}$ の記法を説明する。ベクトルの添字にコロンを用いた $\boldsymbol{w}_{a:b}$ は、**$\boldsymbol{w}$ の第 a 成分から第 b 成分までを順に取り出して作ったベクトル**を表す：

$$\boldsymbol{w}_{a:b} = (w_a, w_{a+1}, \ldots, w_b)^\top \in \mathbb{R}^{b-a+1} \tag{1.10}$$

「ダブリュー、a から b」と読む。この記法は**スライス記法**（slice notation）と呼ばれ、Python や MATLAB など多くのプログラミング言語でも同様の表記が用いられる。

本書で最もよく使うのは $a = 1$、$b = d$ の場合である：

$$\boldsymbol{w}_{1:d} = (w_1, w_2, \ldots, w_d)^\top \in \mathbb{R}^d \tag{1.11}$$

これは、パラメータ $\boldsymbol{w} \in \mathbb{R}^{d+1}$ からバイアス項 w_0 を除いた d 個の成分だけを取り出したベクトルである。w_0 は入力 $\boldsymbol{x}$ と掛け合わされない（どの特徴にも対応しない）ため、内積をとる際には除いておく必要がある。このように書くことで、d 個の項の和 $w_1 x_1 + \cdots + w_d x_d$ を $\boldsymbol{w}_{1:d}^\top \boldsymbol{x}$ と簡潔に表せる。なお、この $\boldsymbol{w}_{1:d}^\top \boldsymbol{x}$ という演算は**内積**と呼ばれ、第 2 回で詳しく扱う。

第 2 回では、入力側に定数 1 を付け加えて $\tilde{\boldsymbol{x}} = (1, x_1, \ldots, x_d)^\top \in \mathbb{R}^{d+1}$ とすることで、バイアス項も含めて $h(\boldsymbol{x}; \boldsymbol{w}) = \boldsymbol{w}^\top \tilde{\boldsymbol{x}}$ と一つの内積にまとめる方法を学ぶ。

$d = 1$ のとき、仮説空間は平面上のすべての直線の集合である：

$$\mathcal{H}_1 = \{h(x; w_0, w_1) = w_0 + w_1 x \mid w_0, w_1 \in \mathbb{R}\} \tag{1.12}$$

1.2.4 例：多項式仮説空間

入力 $x \in \mathbb{R}$ に対して、M 次多項式モデル

$$h(x; \boldsymbol{w}) = w_0 + w_1 x + w_2 x^2 + \cdots + w_M x^M = \sum_{j=0}^{M} w_j x^j \tag{1.13}$$

を考える。パラメータは $\boldsymbol{w} = (w_0, w_1, \ldots, w_M)^\top \in \mathbb{R}^{M+1}$ であり、パラメータ次元は $p = M + 1$ である。

M を大きくするほど仮説空間は広がり、表現力が増す。すなわち $\mathcal{H}_1 \subset \mathcal{H}_2 \subset \cdots$ である。ここで $A \subset B$ は「A は B の**真部分集合**である」と読み、$A \subseteq B$ かつ $A \neq B$、すなわち A のすべての要素が B に属し、かつ B には A に属さない要素があることを表す（直線はすべて 2 次式でもあるが、x^2 のように直線でない 2 次式が存在する）。しかし、仮説空間を広げすぎると後述する**過学習**が生じる。

1.3 損失関数

仮説 $h \in \mathcal{H}$ の予測がどれだけ「悪いか」を測るために、**損失関数**（loss function）を導入する。

定義に入る前に、ここで使う記法を説明する。$\mathcal{Y} \times \mathcal{Y}$ は集合 $\mathcal{Y}$ と $\mathcal{Y}$ の**直積**（direct product）であり、2 つの要素の組（ペア）全体の集合を表す：

$$\mathcal{Y} \times \mathcal{Y} = \{(a, b) \mid a \in \mathcal{Y},\ b \in \mathcal{Y}\} \tag{1.14}$$

例えば $\mathcal{Y} = \mathbb{R}$ のとき、$\mathbb{R} \times \mathbb{R}$ は実数の組 (a, b) 全体の集合であり、これは $\mathbb{R}^2$ と同じものである。

また、$\mathbb{R}_{\geq 0}$ は 0 以上の実数全体の集合を表す：

$$\mathbb{R}_{\geq 0} = \{r \in \mathbb{R} \mid r \geq 0\} \tag{1.15}$$

したがって、$L : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}_{\geq 0}$ は「$\mathcal{Y}$ の要素 2 つの組を受け取り、0 以上の実数を返す関数」と読む。損失関数では、この 2 つの要素がそれぞれ真の値 y と予測値 $h(\boldsymbol{x})$ に対応する。

定義：損失関数

損失関数 $L : \mathcal{Y} \times \mathcal{Y} \to \mathbb{R}_{\geq 0}$ は、真の値 $y \in \mathcal{Y}$ と予測値 $h(\boldsymbol{x}) \in \mathcal{Y}$ の組を受け取り、両者の間の誤差を 0 以上の実数値で返す関数である。損失が 0 に近いほど予測が良く、大きいほど予測が悪いことを意味する。

代表的な損失関数を以下に示す。

1.3.1 二乗損失（回帰問題）

$$L(y, h(\boldsymbol{x})) = (y - h(\boldsymbol{x}))^2 \tag{1.16}$$

予測値と真の値の差の 2 乗を損失とする。微分可能であり、最適化が容易なため広く用いられる。

1.3.2 0-1 損失（分類問題）

$$L(y, h(\boldsymbol{x})) = \begin{cases} 0 & (y = h(\boldsymbol{x})) \\ 1 & (y \neq h(\boldsymbol{x})) \end{cases} \tag{1.17}$$

正しく分類できれば 0、誤分類なら 1 とする。直感的だが、微分不可能なため最適化が難しい。

1.4 経験損失と汎化誤差

1.4.1 経験損失

訓練データ D に対する仮説 h の平均的な損失を**経験損失**（empirical loss）または**訓練誤差**（training error）と呼ぶ：

$$L_D(h) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, h(\boldsymbol{x}_i)) \tag{1.18}$$

二乗損失の場合、経験損失は**平均二乗誤差**（Mean Squared Error; MSE）となる：

$$L_D(h) = \frac{1}{N} \sum_{i=1}^{N} (y_i - h(\boldsymbol{x}_i))^2 \tag{1.19}$$

1.4.2 汎化誤差

学習の真の目標は、訓練データだけでなく、未知のデータに対しても良い予測を行うことである。入力と出力の組 $(\boldsymbol{x}, y)$ が同時分布 $P(\boldsymbol{x}, y)$ に従うとき、**汎化誤差**（generalization error）を次のように定義する：

定義：汎化誤差

$$L_{\text{gen}}(h) = \mathbb{E}_{(\boldsymbol{x},y)\sim P}\left[L(y, h(\boldsymbol{x}))\right] \tag{1.20}$$

ここで $(\boldsymbol{x}, y) \sim P$ は「$(\boldsymbol{x}, y)$ が分布 P に従って生成される」ことを表し、$\mathbb{E}_{(\boldsymbol{x},y)\sim P}[\cdot]$ はその分布に関する期待値、すなわち P から無限にデータを取り出したときの損失の平均値を意味する。

確率分布と期待値の厳密な扱いは第 7 回（第 7.5 節、第 7.6 節）で学ぶが、ここでは「未知のデータ全体にわたる損失の平均」という直感で十分である。

汎化誤差は未知の分布 P に依存するため直接計算できない。そこで実際には、訓練データとは別に用意した**テストデータ** $D_{\text{test}} = \{(\boldsymbol{x}'_1, y'_1), \ldots, (\boldsymbol{x}'_{N'}, y'_{N'})\}$ を用いて汎化誤差を近似する：

$$L_{\text{test}}(h) = \frac{1}{N'} \sum_{i=1}^{N'} L(y'_i, h(\boldsymbol{x}'_i)) \tag{1.21}$$

1.5 過学習と未学習

仮説空間の選択は、学習の成否を左右する重要な決定である。

未学習（underfitting） 仮説空間 $\mathcal{H}$ が小さすぎて、データの構造を捉えられない状態。訓練誤差も汎化誤差も大きい。

過学習（overfitting）　仮説空間 $\mathcal{H}$ が大きすぎて、訓練データのノイズまで学習してしまう状態。訓練誤差は小さいが、汎化誤差が大きい。

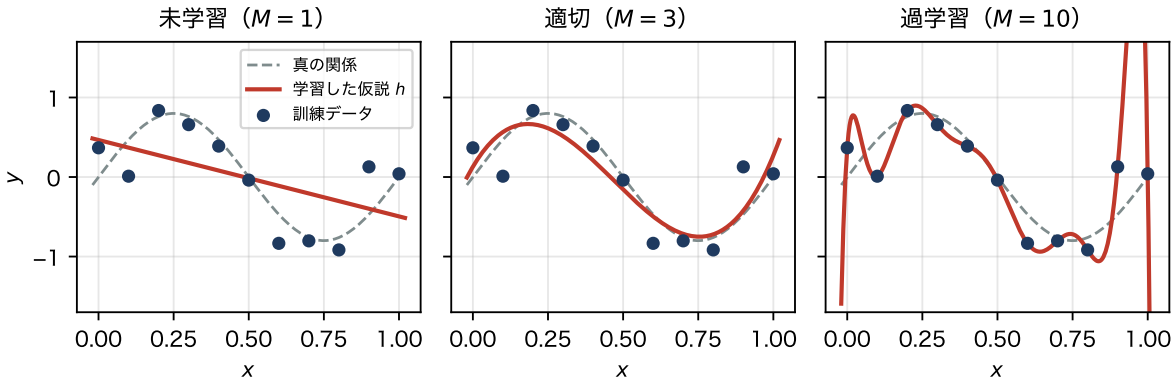


図 1.1　同じ訓練データに対する 3 つの仮説。仮説空間が小さすぎると構造を捉えられず（左）、大きすぎるとノイズまで再現してしまう（右）。

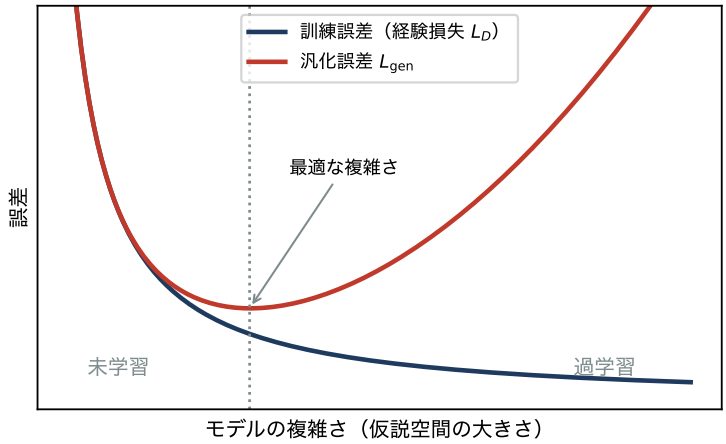


図 1.2　モデルの複雑さと 2 つの誤差。訓練誤差は単調に減少するが、汎化誤差はある点を境に増加に転じる。

適切な仮説空間の選択、すなわちモデルの複雑さの制御は、機械学習における中心的な課題であり、第 6 回で扱う**正則化**によって対処する。

1.6　学習アルゴリズムの概要

以上をまとめると、機械学習の基本的な枠組みは次の 3 ステップからなる：

1. **仮説空間の設定**: モデルの形（線形、多項式、ニューラルネットワークなど）を決める。
2. **損失関数の選択**: 予測の良さの評価基準を定める。

3. **最適化**: 訓練データに対する経験損失を最小化する仮説 h^* を求める：

$$h^* = \arg\min_{h \in \mathcal{H}} L_D(h) \tag{1.22}$$

右辺の $\arg\min_{h\in\mathcal{H}} L_D(h)$ は「$\mathcal{H}$ に属する h のうち $L_D(h)$ を最小にするもの」を表す。$\min_h L_D(h)$ が最小値（損失の値そのもの）を指すのに対し、$\arg\min_h L_D(h)$ はその最小値を達成する h（引数）を指す点に注意する。上付きの $*$ は、この最小化問題の解、すなわち最適解であることを示す。パラメトリックモデルでは、これはパラメータの最適化に帰着する：

$$\boldsymbol{w}^* = \arg\min_{\boldsymbol{w}\in\mathbb{R}^p} \frac{1}{N}\sum_{i=1}^{N} L(y_i, h(\boldsymbol{x}_i;\boldsymbol{w})) \tag{1.23}$$

$\boldsymbol{w}^*$ は経験損失を最小にする最適なパラメータであり、$h^* = h(\cdot;\boldsymbol{w}^*)$ という関係にある。

第 4 回・第 5 回では、この最適化問題を具体的に解く方法（正規方程式と勾配降下法）を学ぶ。

なお、本章では学習を「経験損失の最小化」として定式化した。この枠組みは明快であるが、過学習の問題に対して本質的な解決を与えない。第 7 回以降では、確率論とベイズの定理に基づく別の視点から学習を捉え直し、正則化がなぜ有効なのかを数理的に明らかにする。

1.7 演習問題

1. **記法の確認**　次の各主張が正しいか否かを判定し、その理由を述べよ。
   (a) $\boldsymbol{x} \in \mathbb{R}^3$ かつ $\mathcal{X} \subseteq \mathbb{R}^3$ であれば、常に $\boldsymbol{x} \in \mathcal{X}$ が成り立つ。
   (b) $h : \mathbb{R}^2 \to \{0, 1\}$ は、2 次元入力に対する 2 値分類の仮説を表す。
   (c) $\mathcal{Y} = \{0, 1\}$ のとき、直積 $\mathcal{Y} \times \mathcal{Y}$ の要素の個数は 4 である。
   (d) $h(\cdot\,;\boldsymbol{w})$ と $h(\boldsymbol{x};\boldsymbol{w})$ は、どちらも関数そのものを指す記法である。
2. **パラメータ次元**　次の各仮説空間のパラメータ次元 p を求めよ。
   (a) 入力 $\boldsymbol{x} \in \mathbb{R}^5$ に対する線形モデル $h(\boldsymbol{x};\boldsymbol{w}) = w_0 + \boldsymbol{w}_{1:5}^\top \boldsymbol{x}$
   (b) 入力 $x \in \mathbb{R}$ に対する 3 次多項式モデル
   (c) 入力 $\boldsymbol{x} = (x_1, x_2)^\top \in \mathbb{R}^2$ に対して、2 次以下のすべての単項式 $1, x_1, x_2, x_1^2, x_1x_2, x_2^2$ の線形結合で表されるモデル
3. **仮説空間の包含関係**　$\mathcal{H}_M$ を M 次多項式仮説空間とする。$\mathcal{H}_1 \subset \mathcal{H}_2$（$\mathcal{H}_1$ は $\mathcal{H}_2$ の真部分集合）であることを、次の 2 点を示すことで証明せよ。
   (a) 任意の $h \in \mathcal{H}_1$ は $\mathcal{H}_2$ の要素でもある。
   (b) $\mathcal{H}_2$ の要素であって $\mathcal{H}_1$ の要素ではない関数が存在する。
4. **経験損失の計算**　訓練データ $D = \{(1, 3),\ (2, 5),\ (3, 6)\}$ が与えられている（各組は (x_i, y_i) を表す）。2 つの仮説

$$h_a(x) = 2x + 1, \qquad h_b(x) = 1.5x + 1.5$$

について、二乗損失に基づく経験損失 $L_D(h_a)$, $L_D(h_b)$ をそれぞれ計算し、どちらの仮説が訓練データに対して良いかを判定せよ。
5. **0-1 損失**　5 個の訓練データに対する真のラベルと仮説 h の予測が次のように与えられている。

i	1	2	3	4	5
y_i	1	0	1	1	0
$h(\boldsymbol{x}_i)$	1	0	0	1	1

0-1 損失に基づく経験損失 $L_D(h)$ を求めよ。また、この値が一般に何と呼ばれる量に一致するかを述べよ。

6. **min と arg min**　問 4 の設定で、仮説空間を $\mathcal{H} = \{h_a, h_b\}$ の 2 要素からなる集合とする。このとき

$$\min_{h \in \mathcal{H}} L_D(h), \qquad h^* = \arg\min_{h \in \mathcal{H}} L_D(h)$$

をそれぞれ求めよ。両者の違いを一言で説明せよ。

7. **経験損失と汎化誤差**　平面上の 3 点 $(x_1, y_1), (x_2, y_2), (x_3, y_3)$（$x_i$ は互いに異なる）が与えられたとき、これらをすべて通る 2 次多項式 $h \in \mathcal{H}_2$ がただ一つ存在する。
   (a) この h の二乗損失に基づく経験損失 $L_D(h)$ を求めよ。
   (b) この h の汎化誤差 $L_{\mathrm{gen}}(h)$ も 0 であると言えるか。理由とともに述べよ。
   (c) 一般に N 個のデータ点（x_i は互いに異なる）が与えられたとき、経験損失を 0 にできる多項式の次数 M の最小値はいくらか。この事実と過学習の関係を説明せよ。

2　ベクトルと内積

第 1 回では、入力を $\boldsymbol{x} \in \mathbb{R}^d$ というベクトルで表し、線形モデルを $h(\boldsymbol{x}; \boldsymbol{w}) = w_0 + \boldsymbol{w}_{1:d}^\top \boldsymbol{x}$ と書いた。本章では、この $\boldsymbol{w}_{1:d}^\top \boldsymbol{x}$ という演算、すなわち**内積**の意味を明らかにする。内積は単なる計算規則ではなく、「長さ」と「角度」という幾何学的な情報を担っており、機械学習において**類似度**を測る基本的な道具となる。本章の最後では、現代 AI の 2 つの柱である Transformer の Attention 機構とニューラルネットワークが、いずれも内積によって構成されていることを見る。

2.1　ベクトルとは何か

2.1.1　データの表現としてのベクトル

d 個の実数を順番に並べたものを d 次元**ベクトル**（vector）と呼び、本書では太字の小文字で表す：

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_d)^\top \in \mathbb{R}^d \tag{2.1}$$

ここで x_i を第 i **成分**（component）と呼ぶ。右肩の $\top$ は**転置**（transpose）を表す記号であり、横に並べた表記を縦に並べ替えることを意味する：

$$(x_1, x_2, \ldots, x_d)^\top = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_d \end{pmatrix} \tag{2.2}$$

本書ではベクトルを**列ベクトル**（縦に並べたもの）として扱う。文章中では紙面の都合で横に書き、転置の記号を付けて列ベクトルであることを示す。

第 1 回の例 2 では、部屋の広さ x_1 と駅からの距離 x_2 を $\boldsymbol{x} = (x_1, x_2)^\top \in \mathbb{R}^2$ と表した。このように、機械学習ではデータの複数の属性（特徴量）を並べてベクトルとする。d 次元のベクトルは、d 個の特徴で記述されたデータ 1 件に対応する。

2.1.2　ベクトルの演算

2 つのベクトル $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ と実数 $c \in \mathbb{R}$ に対して、**和**と**スカラー倍**を成分ごとに定める：

$$\boldsymbol{x} + \boldsymbol{y} = (x_1 + y_1,\ x_2 + y_2,\ \ldots,\ x_d + y_d)^\top \tag{2.3}$$

$$c\boldsymbol{x} = (cx_1,\ cx_2,\ \ldots,\ cx_d)^\top \tag{2.4}$$

ここで c のような 1 個の実数を、ベクトルと区別して**スカラー**（scalar）と呼ぶ。

幾何学的には、ベクトルは原点から点 $(x_1, \ldots, x_d)$ に向かう矢印と見なせる。和は矢印をつなげた結果（平行四辺形の対角線）であり、スカラー倍は矢印を c 倍に伸縮する操作である（$c < 0$ なら向きが反転する）。

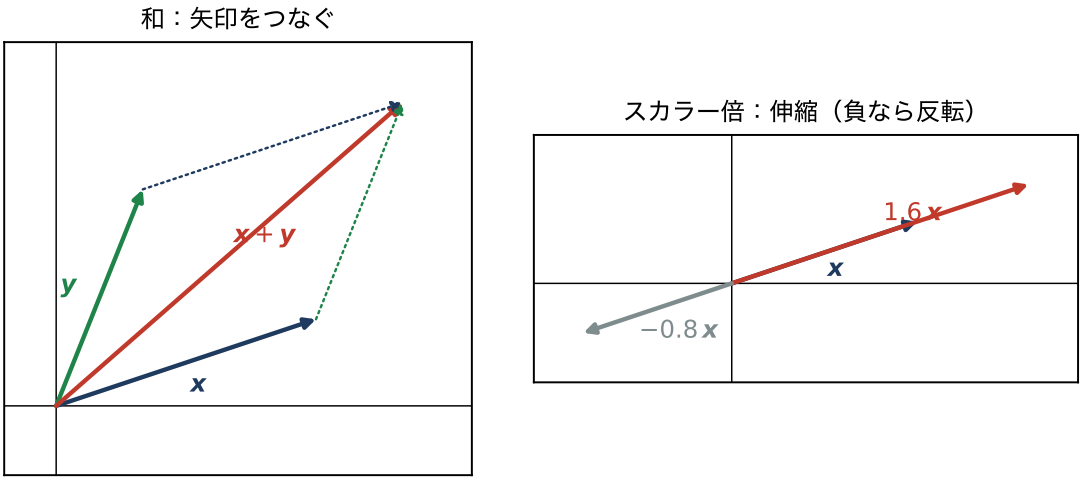


図 2.1　ベクトルの和とスカラー倍の幾何学的な意味。

なお、成分がすべて 0 のベクトルを**零ベクトル**（zero vector）と呼び、$\mathbf{0}$ と書く。

2.2　ノルム

2.2.1　ベクトルの長さ

ベクトルの「長さ」を測る量を**ノルム**（norm）と呼ぶ。2 次元の場合、$\boldsymbol{x} = (x_1, x_2)^\top$ の長さは三平方の定理より $\sqrt{x_1^2 + x_2^2}$ である。これを一般の次元に拡張する。

定義：ユークリッドノルム

ベクトル $\boldsymbol{x} = (x_1, \ldots, x_d)^\top \in \mathbb{R}^d$ に対して、

$$\|\boldsymbol{x}\| = \sqrt{x_1^2 + x_2^2 + \cdots + x_d^2} = \sqrt{\sum_{i=1}^{d} x_i^2} \tag{2.5}$$

を $\boldsymbol{x}$ の**ユークリッドノルム**（Euclidean norm）または L^2 ノルムと呼ぶ。記号 $\|\boldsymbol{x}\|$ は「$\boldsymbol{x}$ のノルム」と読む。

絶対値の記号 $|x|$ が実数の大きさを表すのに対し、二重線の記号 $\|\boldsymbol{x}\|$ はベクトルの大きさを表す。$d = 1$ のとき $\|\boldsymbol{x}\| = \sqrt{x_1^2} = |x_1|$ となり、絶対値と一致する。

例えば $\boldsymbol{x} = (3, 4)^\top$ のとき

$$\|\boldsymbol{x}\| = \sqrt{3^2 + 4^2} = \sqrt{25} = 5$$

である。

2.2.2　ノルムの性質

ノルムは次の 3 つの性質をもつ。これらは「長さ」という概念が満たすべき自然な要請である。

定理：ノルムの基本性質

任意の $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$、$c \in \mathbb{R}$ に対して、

$$\|\boldsymbol{x}\| \geq 0, \quad \text{かつ} \quad \|\boldsymbol{x}\| = 0 \iff \boldsymbol{x} = \boldsymbol{0} \qquad \text{（非負性）} \tag{2.6}$$

$$\|c\boldsymbol{x}\| = |c|\,\|\boldsymbol{x}\| \qquad \text{（斉次性）} \tag{2.7}$$

$$\|\boldsymbol{x} + \boldsymbol{y}\| \leq \|\boldsymbol{x}\| + \|\boldsymbol{y}\| \qquad \text{（三角不等式）} \tag{2.8}$$

記号 $\iff$ は「必要十分条件である」「同値である」と読む。また、3 つの性質の名称の読みと意味は次のとおりである。

名称	読み	英語	意味
非負性	ひふせい	nonnegativity	長さは負にならない。長さが 0 なのは零ベクトルだけ
斉次性	せいじせい	homogeneity	ベクトルを c 倍すると長さも $\lvert c\rvert$ 倍になる（比例する）
三角不等式	さんかくふとうしき	triangle inequality	遠回りは近道より長い

斉次（homogeneous、せいじ）とは「等しく揃っている」という意味の語で、数学では「入力を定数倍すると、出力もそれに応じて一定の規則で定数倍される」性質を指す。ノルムの場合、$\|c\boldsymbol{x}\| = |c|\,\|\boldsymbol{x}\|$ は「矢印を 2 倍に伸ばせば長さも 2 倍、3 倍に伸ばせば長さも 3 倍になる」ことを述べている。絶対値が付くのは、c が負のときは向きが反転するだけで長さは正のまま（$c = -2$ なら長さは 2 倍）だからである。この性質があるおかげで、第 2.2.3 項で述べる**正規化** $\boldsymbol{u} = \boldsymbol{x}/\|\boldsymbol{x}\|$ が $\|\boldsymbol{u}\| = 1$ を与えることが保証される。実際、

$$\left\| \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|} \right\| = \left\| \frac{1}{\|\boldsymbol{x}\|} \boldsymbol{x} \right\| = \frac{1}{\|\boldsymbol{x}\|} \|\boldsymbol{x}\| = 1 \tag{2.9}$$

であり、ここで斉次性を用いている。

非負性と斉次性は定義から直ちに従う。実際、斉次性は

$$\|c\boldsymbol{x}\| = \sqrt{\sum_{i=1}^{d} (cx_i)^2} = \sqrt{c^2 \sum_{i=1}^{d} x_i^2} = |c| \sqrt{\sum_{i=1}^{d} x_i^2} = |c|\,\|\boldsymbol{x}\| \tag{2.10}$$

と示される。ここで $\sqrt{c^2} = |c|$ であり、c そのものではないことに注意する。三角不等式は「遠回りは近道より長い」という主張である。$\boldsymbol{x}$ だけ進んでから $\boldsymbol{y}$ だけ進む道のり $\|\boldsymbol{x}\| + \|\boldsymbol{y}\|$ は、直接 $\boldsymbol{x} + \boldsymbol{y}$ だけ進む道のり $\|\boldsymbol{x} + \boldsymbol{y}\|$ 以上である、ということを述べている。これは第 2.4.1 項で述べるコーシー・シュワルツの不等式から導かれる。証明の方針は、両辺が非負であることに注意して**両辺を二乗して比較する**ことである。左辺の二乗を内積の性質で展開し、現れた項にコーシー・シュワルツの不等式を適用すればよい。実際の証明は演習問題 4 で扱う。

2.2.3 距離と単位ベクトル

2 つのベクトルの「離れ具合」は、差のノルムで測る：

$$\mathrm{dist}(\boldsymbol{x}, \boldsymbol{y}) = \|\boldsymbol{x} - \boldsymbol{y}\| = \sqrt{\sum_{i=1}^{d} (x_i - y_i)^2} \tag{2.11}$$

これを**ユークリッド距離**（Euclidean distance）と呼ぶ。

第 1 回で導入した二乗損失 $L(y, h(\boldsymbol{x})) = (y - h(\boldsymbol{x}))^2$ を N 個のデータについて足し合わせたものは、真の値を並べたベクトル $\boldsymbol{y} = (y_1, \ldots, y_N)^\top$ と予測を並べたベクトル $\hat{\boldsymbol{y}} = (h(\boldsymbol{x}_1), \ldots, h(\boldsymbol{x}_N))^\top$ を用いて

$$\sum_{i=1}^{N} (y_i - h(\boldsymbol{x}_i))^2 = \|\boldsymbol{y} - \hat{\boldsymbol{y}}\|^2 \tag{2.12}$$

と書ける。すなわち**経験損失の最小化とは、距離の最小化である**。この見方は第 4 回で最小二乗法を「射影」として理解する際の出発点となる。

また、ノルムが 1 のベクトルを**単位ベクトル**（unit vector）と呼ぶ。$\boldsymbol{x} \neq \boldsymbol{0}$ に対して

$$\boldsymbol{u} = \frac{\boldsymbol{x}}{\|\boldsymbol{x}\|} \tag{2.13}$$

とすれば $\|\boldsymbol{u}\| = 1$ となる。この操作を**正規化**（normalization）と呼び、「長さの情報を捨てて向きだけを取り出す」ことに対応する。

2.3 内積

2.3.1 内積の定義

定義：内積

2 つのベクトル $\boldsymbol{x} = (x_1, \ldots, x_d)^\top$、$\boldsymbol{y} = (y_1, \ldots, y_d)^\top \in \mathbb{R}^d$ に対して、

$$\boldsymbol{x}^\top \boldsymbol{y} = x_1 y_1 + x_2 y_2 + \cdots + x_d y_d = \sum_{i=1}^{d} x_i y_i \tag{2.14}$$

を $\boldsymbol{x}$ と $\boldsymbol{y}$ の**内積**（inner product）と呼ぶ。内積の値は**スカラー**（1 個の実数）である。

内積は $\langle \boldsymbol{x}, \boldsymbol{y} \rangle$ や $\boldsymbol{x} \cdot \boldsymbol{y}$ とも書かれるが、本書では行列との統一のため $\boldsymbol{x}^\top \boldsymbol{y}$ という記法を用いる。「エックスの転置 ワイ」と読む。

例えば $\boldsymbol{x} = (1, 2, 3)^\top$、$\boldsymbol{y} = (4, 5, 6)^\top$ のとき

$$\boldsymbol{x}^\top \boldsymbol{y} = 1 \times 4 + 2 \times 5 + 3 \times 6 = 4 + 10 + 18 = 32$$

である。

ノルムと内積の間には、定義から直ちに次の関係が成り立つ：

$$\boldsymbol{x}^\top \boldsymbol{x} = \sum_{i=1}^{d} x_i^2 = \|\boldsymbol{x}\|^2, \qquad \text{すなわち} \quad \|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^\top \boldsymbol{x}} \tag{2.15}$$

つまり、ノルムは内積から定まる量である。

2.3.2 内積の性質

定理：内積の基本性質

任意の $\boldsymbol{x}, \boldsymbol{y}, \boldsymbol{z} \in \mathbb{R}^d$、$c \in \mathbb{R}$ に対して、

$$\boldsymbol{x}^\top \boldsymbol{y} = \boldsymbol{y}^\top \boldsymbol{x} \qquad \text{（対称性）} \tag{2.16}$$

$$(\boldsymbol{x} + \boldsymbol{y})^\top \boldsymbol{z} = \boldsymbol{x}^\top \boldsymbol{z} + \boldsymbol{y}^\top \boldsymbol{z} \qquad \text{（加法性）} \tag{2.17}$$

$$(c\boldsymbol{x})^\top \boldsymbol{y} = c\,(\boldsymbol{x}^\top \boldsymbol{y}) \qquad \text{（斉次性）} \tag{2.18}$$

$$\boldsymbol{x}^\top \boldsymbol{x} \geq 0, \quad \text{かつ} \quad \boldsymbol{x}^\top \boldsymbol{x} = 0 \iff \boldsymbol{x} = \boldsymbol{0} \qquad \text{（正定値性）} \tag{2.19}$$

加法性と斉次性をあわせて**線形性**（linearity）と呼ぶ。

4 つの性質の読みと意味は次のとおりである。

名称	読み	英語	意味
対称性	たいしょうせい	symmetry	掛ける順序を入れ替えても値が変わらない
加法性	かほうせい	additivity	和の内積は、内積の和に分解できる
斉次性	せいじせい	homogeneity	片方を c 倍すると、内積も c 倍になる
正定値性	せいていちせい	positive definiteness	自分自身との内積は負にならず、0 になるのは零ベクトルのときだけ

ノルムの斉次性では絶対値 $|c|$ が付いたのに対し、内積の斉次性では c がそのまま出てくる点に注意する。長さは常に正であるのに対し、内積は負の値も取りうるからである。

加法性と斉次性をあわせた**線形性**は、「$\boldsymbol{x}$ を動かしたときに $\boldsymbol{x}^\top \boldsymbol{y}$ がどう変わるか」を表している。2 つを一つの式にまとめると、任意の $a, b \in \mathbb{R}$ に対して

$$(a\boldsymbol{x} + b\boldsymbol{y})^\top \boldsymbol{z} = a\,(\boldsymbol{x}^\top \boldsymbol{z}) + b\,(\boldsymbol{y}^\top \boldsymbol{z}) \tag{2.20}$$

すなわち**線形結合の内積は、内積の線形結合になる**。この性質は本書で繰り返し用いられる。例えば後述するコーシー・シュワルツの不等式の証明では、$\|\boldsymbol{x} - t\boldsymbol{y}\|^2$ を展開する際にこの線形性を使っている。

正定値性（positive definiteness）は、ノルムの非負性に対応する性質である。$\boldsymbol{x}^\top \boldsymbol{x} = \|\boldsymbol{x}\|^2$ であったから、「自分自身との内積が 0 になるのは零ベクトルだけ」という主張は「長さが 0 のベクトルは零ベクトルだけ」と同じことを述べている。

なお、**正定値性は内積に限られた概念ではない**。一般に「ある量が常に 0 以上であり、0 になるのは自明な場合だけである」という形の性質を、広く**正定値**（positive definite）と呼ぶ。本講義で登場するものを挙げておく。

対象	正定値の条件	登場する回
内積	$\boldsymbol{x}^\top \boldsymbol{x} > 0$ $(\boldsymbol{x} \neq \boldsymbol{0})$	第 2 回（本章）
行列 $\boldsymbol{A}$	$\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} > 0$ $(\boldsymbol{x} \neq \boldsymbol{0})$	第 3 回、第 5 回
カーネル k	$\sum_{i,j} c_i c_j\, k(\boldsymbol{x}_i, \boldsymbol{x}_j) > 0$	第 11 回

内積の正定値性は、$\boldsymbol{A}$ を単位行列とした場合の特別な場合にあたる。

ここで、よく似た用語である**半正定値**（positive semi-definite）との違いに注意する。等号が成り立つ場合を許すかどうかが両者を分ける。

$$\text{正定値：}\quad \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} > 0 \quad (\text{すべての } \boldsymbol{x} \neq \boldsymbol{0}) \tag{2.21}$$

$$\text{半正定値：}\quad \boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} \geq 0 \quad (\text{すべての } \boldsymbol{x}) \tag{2.22}$$

半正定値では、$\boldsymbol{x} \neq \boldsymbol{0}$ でありながら $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x} = 0$ となる「つぶれた方向」が存在しうる。この違いは後の回で本質的な意味をもつ。例えば第 3 回で扱う計画行列 $\boldsymbol{X}$ に対して $\boldsymbol{X}^\top \boldsymbol{X}$ は常に半正定値であるが、正定値になるのは $\boldsymbol{X}$ がフルランクのとき、すなわち多重共線性がないときに限る。つぶれた方向の存在が、最適なパラメータが一意に定まらないことに対応している。

また、第 5 回で扱う**凸関数**の判定でもこの語が現れる。関数の曲がり具合を表す行列（ヘッセ行列）が半正定値であれば凸、正定値であれば狭義凸（最小値を与える点がただ一つ）となる。これも「つぶれた方向があるかどうか」の違いである。

以下、これらの性質を証明する。なお本書では、証明の終わりを記号 ■ で示す。これは「証明終わり」を意味する慣習的な記号であり、**墓石記号**（tombstone）またはハルモス記号（Halmos symbol）と呼ばれる。ラテン語の *quod erat demonstrandum*（「これが示すべきことであった」）を略した **Q.E.D.** が同じ意味で用いられることもある。

証明　対称性は、実数の積が可換（$x_i y_i = y_i x_i$）であることから

$$\boldsymbol{x}^\top \boldsymbol{y} = \sum_{i=1}^{d} x_i y_i = \sum_{i=1}^{d} y_i x_i = \boldsymbol{y}^\top \boldsymbol{x} \tag{2.23}$$

加法性は、和の定義と総和の分配より

$$(\boldsymbol{x} + \boldsymbol{y})^\top \boldsymbol{z} = \sum_{i=1}^{d} (x_i + y_i) z_i = \sum_{i=1}^{d} x_i z_i + \sum_{i=1}^{d} y_i z_i = \boldsymbol{x}^\top \boldsymbol{z} + \boldsymbol{y}^\top \boldsymbol{z} \tag{2.24}$$

斉次性も同様に

$$(c\boldsymbol{x})^\top \boldsymbol{y} = \sum_{i=1}^{d} (c x_i) y_i = c \sum_{i=1}^{d} x_i y_i = c\,(\boldsymbol{x}^\top \boldsymbol{y}) \tag{2.25}$$

正定値性は $\boldsymbol{x}^\top \boldsymbol{x} = \sum_i x_i^2$ が二乗和であることから従う。二乗和が 0 になるのは、すべての項が 0 のとき、すなわち $\boldsymbol{x} = \boldsymbol{0}$ のときに限る。 ■

2.3.3　線形モデルの再解釈

内積の記法を用いると、第 1 回の線形モデルは

$$h(\boldsymbol{x}; \boldsymbol{w}) = w_0 + \boldsymbol{w}_{1:d}^\top \boldsymbol{x} \tag{2.26}$$

と書けた。さらに、入力に定数 1 を付け加えて $\tilde{\boldsymbol{x}} = (1, x_1, \ldots, x_d)^\top \in \mathbb{R}^{d+1}$ とすれば、

$$h(\boldsymbol{x}; \boldsymbol{w}) = \boldsymbol{w}^\top \tilde{\boldsymbol{x}}, \qquad \boldsymbol{w} = (w_0, w_1, \ldots, w_d)^\top \tag{2.27}$$

と、バイアス項も含めて一つの内積で表せる。この 1 を加える操作を**バイアス項の吸収**と呼び、以降の式変形を簡潔にする。

すなわち**線形モデルとは、入力ベクトルとパラメータベクトルの内積である**。第 4 回以降で扱う最小二乗法、第 10 回のサポートベクターマシン、第 12 回のニューラルネットワークは、いずれもこの内積を基本要素として構成される。

2.4 内積の幾何学的解釈

2.4.1 コーシー・シュワルツの不等式

内積が「角度」を表すことを見るために、まず次の不等式を示す。

定理：コーシー・シュワルツの不等式

任意の $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ に対して、

$$|\boldsymbol{x}^\top \boldsymbol{y}| \leq \|\boldsymbol{x}\| \, \|\boldsymbol{y}\| \tag{2.28}$$

等号が成立するのは、$\boldsymbol{x}$ と $\boldsymbol{y}$ が平行なとき、すなわち一方が他方のスカラー倍であるときに限る。

証明　まず $\boldsymbol{y} = \boldsymbol{0}$ の場合を除いておく。このとき左辺は $|\boldsymbol{x}^\top \boldsymbol{0}| = 0$、右辺は $\|\boldsymbol{x}\| \cdot 0 = 0$ であり、等号が成立する。以下 $\boldsymbol{y} \neq \boldsymbol{0}$ とする。

任意の実数 t に対して次の関数を考える：

$$f(t) = \|\boldsymbol{x} - t\boldsymbol{y}\|^2 \tag{2.29}$$

ノルムの二乗は非負なので、**すべての t に対して** $f(t) \geq 0$ である。一方、内積の性質を用いて $f(t)$ を展開すると

$$\begin{aligned} f(t) &= (\boldsymbol{x} - t\boldsymbol{y})^\top (\boldsymbol{x} - t\boldsymbol{y}) \\ &= \boldsymbol{x}^\top \boldsymbol{x} - t\,\boldsymbol{x}^\top \boldsymbol{y} - t\,\boldsymbol{y}^\top \boldsymbol{x} + t^2 \boldsymbol{y}^\top \boldsymbol{y} \\ &= \|\boldsymbol{y}\|^2 t^2 - 2(\boldsymbol{x}^\top \boldsymbol{y})t + \|\boldsymbol{x}\|^2 \end{aligned} \tag{2.30}$$

となる（対称性 $\boldsymbol{x}^\top \boldsymbol{y} = \boldsymbol{y}^\top \boldsymbol{x}$ を用いた）。これは t についての 2 次関数であり、$\boldsymbol{y} \neq \boldsymbol{0}$ より 2 次の係数 $\|\boldsymbol{y}\|^2$ は正である。

■2.4.1.1 不等式の証明

2 次関数 $f(t) = at^2 + bt + c$（$a > 0$）について、

$$\text{すべての } t \text{ で } f(t) \geq 0 \quad \Longleftrightarrow \quad \text{判別式 } D = b^2 - 4ac \leq 0 \tag{2.31}$$

が成り立つ。実際、平方完成すると

$$f(t) = a\left(t + \frac{b}{2a}\right)^2 - \frac{D}{4a} \tag{2.32}$$

であり、$t = -b/(2a)$ のとき最小値 $-D/(4a)$ をとる。$a > 0$ であるから、この最小値が 0 以上であることと $D \leq 0$ は同値である。

式 (2.30) に適用すると $a = \|\boldsymbol{y}\|^2$、$b = -2(\boldsymbol{x}^\top \boldsymbol{y})$、$c = \|\boldsymbol{x}\|^2$ なので、

$$\frac{D}{4} = (\boldsymbol{x}^\top \boldsymbol{y})^2 - \|\boldsymbol{y}\|^2 \|\boldsymbol{x}\|^2 \leq 0 \tag{2.33}$$

すなわち $(\boldsymbol{x}^\top \boldsymbol{y})^2 \leq \|\boldsymbol{x}\|^2 \|\boldsymbol{y}\|^2$ を得る。両辺は非負なので平方根をとってよく、$|\boldsymbol{x}^\top \boldsymbol{y}| \leq \|\boldsymbol{x}\| \, \|\boldsymbol{y}\|$ が示された。

■2.4.1.2　**等号成立条件の証明**　「$\boldsymbol{x}$ と $\boldsymbol{y}$ が平行」を「一方が他方のスカラー倍である」の意味で用いる。必要性と十分性を順に示す。

(i) 等号が成立するならば平行である。　等号 $|\boldsymbol{x}^\top \boldsymbol{y}| = \|\boldsymbol{x}\|\|\boldsymbol{y}\|$ が成り立つとする。両辺は非負なので、二乗しても同値であり

$$(\boldsymbol{x}^\top \boldsymbol{y})^2 = \|\boldsymbol{x}\|^2 \|\boldsymbol{y}\|^2 \tag{2.34}$$

が成り立つ。

ここで、f が最小値をとる t の値を t_0 とおく。平方完成の式 $f(t) = a(t + \frac{b}{2a})^2 - \frac{D}{4a}$ より $t_0 = -b/(2a)$ であり、$a = \|\boldsymbol{y}\|^2$、$b = -2(\boldsymbol{x}^\top \boldsymbol{y})$ を代入すると

$$t_0 = -\frac{b}{2a} = -\frac{-2(\boldsymbol{x}^\top \boldsymbol{y})}{2\|\boldsymbol{y}\|^2} = \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{y}\|^2} \tag{2.35}$$

となる。この t_0 における f の値を、式 (2.30) に代入して直接計算する：

$$\begin{aligned} f(t_0) &= \|\boldsymbol{y}\|^2 t_0^2 - 2(\boldsymbol{x}^\top \boldsymbol{y})\, t_0 + \|\boldsymbol{x}\|^2 \\ &= \|\boldsymbol{y}\|^2 \cdot \frac{(\boldsymbol{x}^\top \boldsymbol{y})^2}{\|\boldsymbol{y}\|^4} - 2(\boldsymbol{x}^\top \boldsymbol{y}) \cdot \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{y}\|^2} + \|\boldsymbol{x}\|^2 \\ &= \frac{(\boldsymbol{x}^\top \boldsymbol{y})^2}{\|\boldsymbol{y}\|^2} - \frac{2(\boldsymbol{x}^\top \boldsymbol{y})^2}{\|\boldsymbol{y}\|^2} + \|\boldsymbol{x}\|^2 \\ &= \|\boldsymbol{x}\|^2 - \frac{(\boldsymbol{x}^\top \boldsymbol{y})^2}{\|\boldsymbol{y}\|^2} = \frac{\|\boldsymbol{x}\|^2\|\boldsymbol{y}\|^2 - (\boldsymbol{x}^\top \boldsymbol{y})^2}{\|\boldsymbol{y}\|^2} \end{aligned} \tag{2.36}$$

ここで、仮定した等式 (2.34) より最後の分子は 0 である。よって

$$f(t_0) = 0 \tag{2.37}$$

が得られる。

一方、f はそもそも $f(t) = \|\boldsymbol{x} - t\boldsymbol{y}\|^2$ と定義したものであったから、$t = t_0$ を代入して

$$f(t_0) = \|\boldsymbol{x} - t_0 \boldsymbol{y}\|^2 \tag{2.38}$$

でもある。式 (2.37) と式 (2.38) を見比べると

$$\|\boldsymbol{x} - t_0 \boldsymbol{y}\|^2 = 0 \tag{2.39}$$

を得る。ノルムの非負性より $\|\boldsymbol{v}\| = 0 \iff \boldsymbol{v} = \boldsymbol{0}$ であったから、$\boldsymbol{x} - t_0 \boldsymbol{y} = \boldsymbol{0}$、すなわち

$$\boldsymbol{x} = t_0 \boldsymbol{y} = \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{y}\|^2}\, \boldsymbol{y} \tag{2.40}$$

となり、$\boldsymbol{x}$ は $\boldsymbol{y}$ のスカラー倍、すなわち両者は平行である。

(ii) 平行ならば等号が成立する。　逆に $\boldsymbol{x} = c\,\boldsymbol{y}$（$c \in \mathbb{R}$）と書けるとする。内積とノルムの斉次性を用いると

$$|\boldsymbol{x}^\top \boldsymbol{y}| = |(c\boldsymbol{y})^\top \boldsymbol{y}| = |c|\, \|\boldsymbol{y}\|^2, \qquad \|\boldsymbol{x}\|\, \|\boldsymbol{y}\| = \|c\boldsymbol{y}\|\, \|\boldsymbol{y}\| = |c|\, \|\boldsymbol{y}\|^2 \tag{2.41}$$

となり、両者は一致する。よって等号が成立する。

(i) と (ii) より、等号が成立することと $\boldsymbol{x}, \boldsymbol{y}$ が平行であることは同値である。なお、最初に除いた $\boldsymbol{y} = \boldsymbol{0}$ の場合も、$\boldsymbol{y} = 0 \cdot \boldsymbol{x}$ と書けるので「平行かつ等号成立」であり、この主張に含まれる。　■

2.4.2 内積と角度

前項で証明したコーシー・シュワルツの不等式 $|\boldsymbol{x}^\top \boldsymbol{y}| \le \|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$ から、次のことがわかる。

$\boldsymbol{x}, \boldsymbol{y} \neq \boldsymbol{0}$ とすると、ノルムの非負性より $\|\boldsymbol{x}\| > 0$、$\|\boldsymbol{y}\| > 0$ であり、その積 $\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|$ は正である。正の数で不等式の両辺を割っても向きは変わらないので、

$$\frac{|\boldsymbol{x}^\top \boldsymbol{y}|}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} \le 1 \tag{2.42}$$

を得る。ここで $|a|/b = |a/b|$（$b > 0$）であるから、左辺は $\left| \dfrac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} \right|$ と書ける。一般に実数 u について $|u| \le 1$ と $-1 \le u \le 1$ は同値であるから、

$$-1 \le \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} \le 1 \tag{2.43}$$

が成り立つ。

この値の範囲 $[-1, 1]$ は、余弦関数 cos の値域と一致する。すなわち、式 (2.43) の中央の量に対して、それを $\cos\theta$ とするような角 θ が必ず存在する（$0 \le \theta \le \pi$ の範囲では cos は単調減少で、値域が $[-1, 1]$ であるから、そのような θ はただ一つに定まる）。そこで次のように定義する。

定義：なす角

$\boldsymbol{x}, \boldsymbol{y} \neq \boldsymbol{0}$ に対して、

$$\cos\theta = \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|}, \qquad 0 \le \theta \le \pi \tag{2.44}$$

を満たす θ を、$\boldsymbol{x}$ と $\boldsymbol{y}$ の**なす角**と呼ぶ。変形すれば、内積は次のように表される：

$$\boldsymbol{x}^\top \boldsymbol{y} = \|\boldsymbol{x}\|\,\|\boldsymbol{y}\| \cos\theta \tag{2.45}$$

この式が本章の中心である。内積は**「2 つのベクトルの長さの積」×「向きの一致度」**という構造をもつ。

- $\theta = 0$（同じ向き）のとき $\cos\theta = 1$ で、内積は最大値 $\|\boldsymbol{x}\|\|\boldsymbol{y}\|$
- $\theta = \pi/2$（直交）のとき $\cos\theta = 0$ で、内積は 0
- $\theta = \pi$（逆向き）のとき $\cos\theta = -1$ で、内積は最小値 $-\|\boldsymbol{x}\|\|\boldsymbol{y}\|$

特に、内積が 0 であることと 2 つのベクトルが直交することは同値である：

$$\boldsymbol{x}^\top \boldsymbol{y} = 0 \iff \boldsymbol{x} \perp \boldsymbol{y} \tag{2.46}$$

この**直交性**（orthogonality）は、第 4 回で最小二乗法を扱う際の鍵となる。「誤差ベクトルがモデルの張る空間と直交する」という条件から正規方程式が導かれる。

2.4.3 正射影

$\boldsymbol{y} \neq \boldsymbol{0}$ とし、$\boldsymbol{x}$ を $\boldsymbol{y}$ の方向へ「影として落とす」ことを考える。$\boldsymbol{y}$ 方向の単位ベクトルは $\boldsymbol{u} = \boldsymbol{y}/\|\boldsymbol{y}\|$ であり、影の長さ（符号つき）は

$$\|\boldsymbol{x}\| \cos\theta = \frac{\boldsymbol{x}^\top \boldsymbol{y}}{\|\boldsymbol{y}\|} = \boldsymbol{x}^\top \boldsymbol{u} \tag{2.47}$$

となる。これを $\boldsymbol{y}$ 方向への**正射影**（orthogonal projection）の長さと呼ぶ。

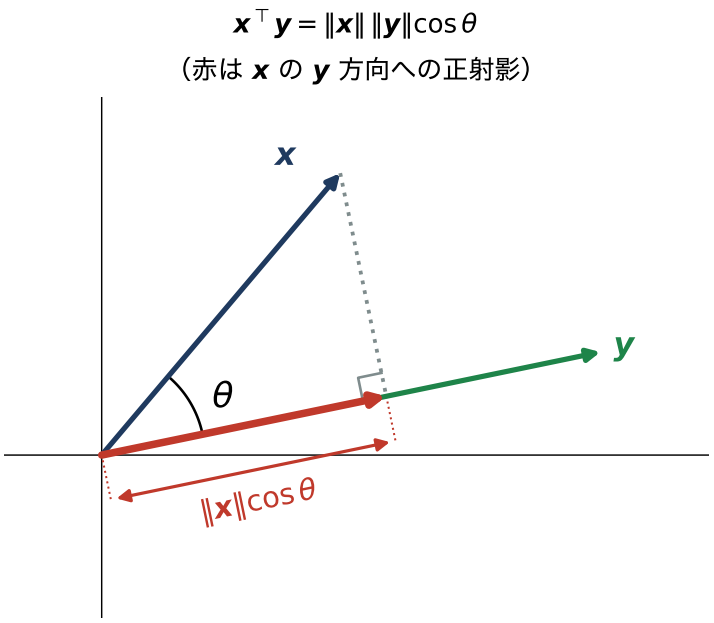


図 2.2　内積の幾何学的意味。$\boldsymbol{x}$ を $\boldsymbol{y}$ の方向に射影した長さ $\|\boldsymbol{x}\|\cos\theta$ に、$\|\boldsymbol{y}\|$ を掛けたものが内積である。

すなわち**内積とは、一方を他方の方向へ射影した長さに、その方向の長さを掛けたもの**である。$\|\boldsymbol{y}\| = 1$ のときは内積そのものが射影の長さになる。この見方は、第 4 回で「回帰とは射影である」という幾何学的理解につながる。

2.5　内積と類似度

2.5.1　コサイン類似度

内積 $\boldsymbol{x}^\top\boldsymbol{y} = \|\boldsymbol{x}\|\|\boldsymbol{y}\|\cos\theta$ は、ベクトルの長さに依存してしまう。例えば $\boldsymbol{x}$ を 2 倍すれば内積も 2 倍になるが、向きは変わっていない。「向きの近さ」だけを測りたい場合は、長さで割って正規化する。

定義：コサイン類似度

$\boldsymbol{x}, \boldsymbol{y} \neq \boldsymbol{0}$ に対して、

$$\mathrm{cossim}(\boldsymbol{x}, \boldsymbol{y}) = \frac{\boldsymbol{x}^\top\boldsymbol{y}}{\|\boldsymbol{x}\|\,\|\boldsymbol{y}\|} = \cos\theta \ \in\ [-1, 1] \tag{2.48}$$

を**コサイン類似度**（cosine similarity）と呼ぶ。1 に近いほど 2 つのベクトルは同じ向き（似ている）、0 なら無関係（直交）、-1 に近いほど逆向きであることを意味する。

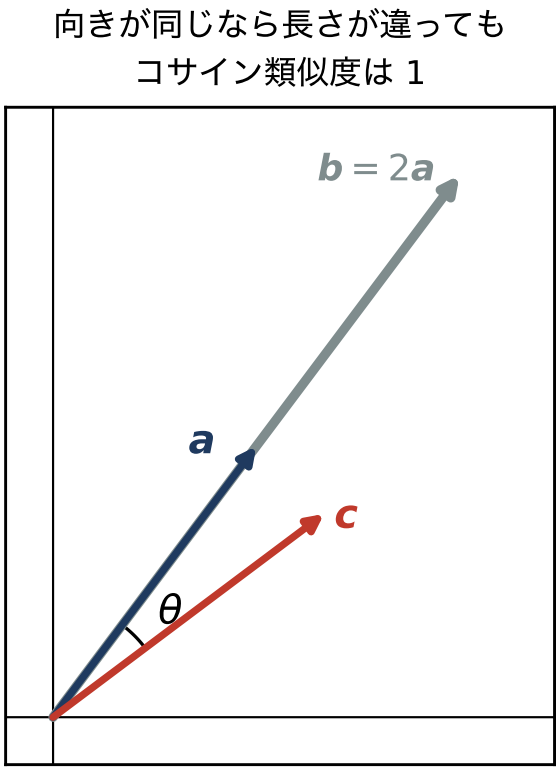


図 2.3　長さと向きの違い。$\boldsymbol{b} = 2\boldsymbol{a}$ は $\boldsymbol{a}$ より長いが向きは同じなので $\mathrm{cossim}(\boldsymbol{a}, \boldsymbol{b}) = 1$ である。

コサイン類似度は、$\boldsymbol{x}$ と $\boldsymbol{y}$ をそれぞれ正規化してから内積をとったものに等しい：

$$\mathrm{cossim}(\boldsymbol{x}, \boldsymbol{y}) = \left(\frac{\boldsymbol{x}}{\|\boldsymbol{x}\|}\right)^{\top} \left(\frac{\boldsymbol{y}}{\|\boldsymbol{y}\|}\right) \tag{2.49}$$

したがって、あらかじめ正規化されたベクトル同士であれば、内積そのものがコサイン類似度となる。

2.5.2　例：文書の類似度

3 つの文書があり、単語「学習」「行列」「料理」の出現回数を数えて 3 次元ベクトルで表したとする：

$$\boldsymbol{a} = (10, 8, 0)^{\top}, \qquad \boldsymbol{b} = (5, 4, 0)^{\top}, \qquad \boldsymbol{c} = (0, 1, 9)^{\top}$$

文書 $\boldsymbol{a}$ と $\boldsymbol{b}$ はどちらも機械学習の文書、$\boldsymbol{c}$ は料理の文書だとする。

ノルムは $\|\boldsymbol{a}\| = \sqrt{164} \approx 12.81$、$\|\boldsymbol{b}\| = \sqrt{41} \approx 6.40$、$\|\boldsymbol{c}\| = \sqrt{82} \approx 9.06$ である。内積とコサイン類似度を計算すると

$$\boldsymbol{a}^{\top}\boldsymbol{b} = 50 + 32 + 0 = 82, \qquad \mathrm{cossim}(\boldsymbol{a}, \boldsymbol{b}) = \frac{82}{12.81 \times 6.40} \approx 1.00$$

$$\boldsymbol{a}^{\top}\boldsymbol{c} = 0 + 8 + 0 = 8, \qquad \mathrm{cossim}(\boldsymbol{a}, \boldsymbol{c}) = \frac{8}{12.81 \times 9.06} \approx 0.07$$

となる。$\boldsymbol{a}$ と $\boldsymbol{b}$ は長さが約 2 倍違うにもかかわらず、向きがほぼ同じなのでコサイン類似度は 1 に近い。一方 $\boldsymbol{a}$ と $\boldsymbol{c}$ はほぼ直交しており、無関係であることが読み取れる。

このように、**内積は「関連の強さ」を 1 つの数値に要約する**。次節で見る Attention 機構は、この性質を直接利用している。

2.6 発展：内積と Attention

本節では、現代 AI の中核である **Transformer**[*1] の **Attention**（注意機構）が、本章で学んだ内積によって構成されていることを見る。Attention の全体像は第 13 回で改めて扱うため、本節では「内積が何をしているか」に焦点を当てる。本節の内容は、この時点ですべてを理解することを求めるものではない。まずは**なぜ内積を学ぶのか**を実感し、第 13 回で再びこの節に戻ってきてほしい。

2.6.1 単語をベクトルで表す

自然言語処理では、各単語を d 次元のベクトルで表現する。これを**分散表現**（distributed representation）あるいは**埋め込み**（embedding）と呼ぶ。ここでは、その作り方を具体的に定める。

まず、扱う単語の全体を**語彙**（vocabulary）と呼び、$\mathcal{V} = \{w_1, w_2, \ldots, w_V\}$ とする（V は語彙数、通常数万程度）。i 番目の単語 w_i を、第 i 成分だけが 1 で他が 0 である V 次元ベクトルで表す：

$$\boldsymbol{o}_i = (0, \ldots, 0, \underset{\substack{\uparrow \\ \text{第 } i \text{ 成分}}}{1}, 0, \ldots, 0)^\top \in \mathbb{R}^V \tag{2.50}$$

これを**ワンホットベクトル**（one-hot vector）と呼ぶ。この表現では、異なる単語のベクトルは互いに直交し（$i \neq j$ のとき $\boldsymbol{o}_i^\top \boldsymbol{o}_j = 0$）、どの 2 語も同じだけ「無関係」になってしまう。つまり**ワンホット表現では意味の近さを内積で測れない**。

そこで、各単語に d 次元（$d \ll V$、例えば $d = 512$）の実ベクトルを割り当てる。

定義：埋め込み

埋め込み行列 $\boldsymbol{E} \in \mathbb{R}^{V \times d}$ の第 i 行を単語 w_i の**埋め込みベクトル** $\boldsymbol{x}_i \in \mathbb{R}^d$ と定める：

$$\boldsymbol{x}_i = \boldsymbol{E}^\top \boldsymbol{o}_i \tag{2.51}$$

$\boldsymbol{E}$ の成分は、あらかじめ決めるのではなく**学習によって決定される**パラメータである。

この式が「第 i 行を取り出す」操作になっていることは、成分で確かめられる。$\boldsymbol{E}$ の (k, j) 成分を E_{kj} と書くと、$\boldsymbol{E}^\top$ の第 j 行は $(E_{1j}, E_{2j}, \ldots, E_{Vj})$ であるから、これと $\boldsymbol{o}_i$ の内積は

$$(\boldsymbol{x}_i)_j = \sum_{k=1}^{V} E_{kj} (\boldsymbol{o}_i)_k = E_{ij} \tag{2.52}$$

となる（$\boldsymbol{o}_i$ は第 i 成分のみ 1 なので、和のうち $k = i$ の項だけが残る）。すなわち $\boldsymbol{x}_i = (E_{i1}, \ldots, E_{id})^\top$ であり、確かに $\boldsymbol{E}$ の第 i 行である。このような操作を**埋め込みの参照**（embedding lookup）と呼ぶ。

[*1] A. Vaswani et al., “Attention Is All You Need,” NeurIPS 2017.

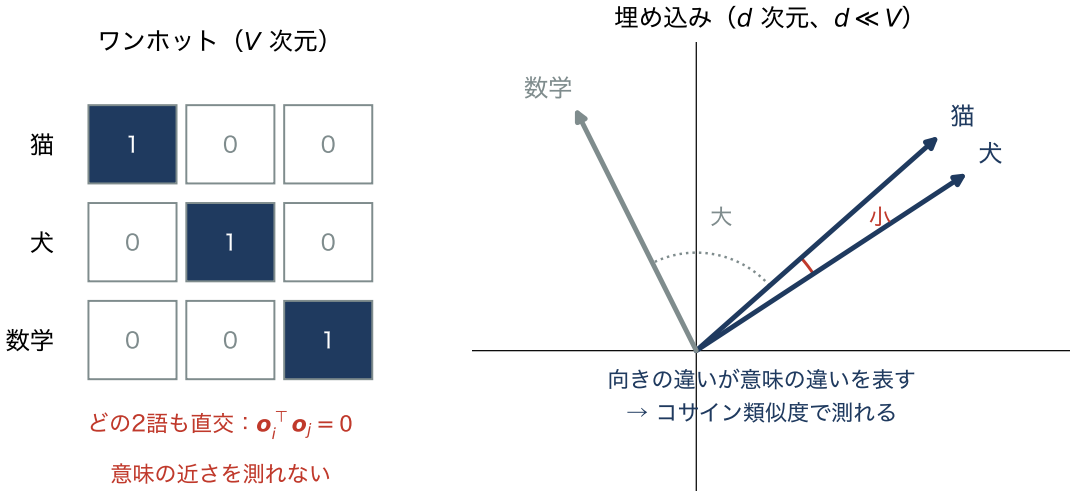


図 2.4　ワンホット表現と埋め込み。ワンホットではどの 2 語も直交するため意味の近さを測れないが、埋め込みでは向きの違いが意味の違いを表す。

学習は「文脈が似ている単語は似たベクトルになる」ように行われる。その結果、前節のコサイン類似度で意味的な近さが測れるようになる。例えば学習後には

$$\mathrm{cossim}(\boldsymbol{x}_{\text{猫}}, \boldsymbol{x}_{\text{犬}}) \gg \mathrm{cossim}(\boldsymbol{x}_{\text{猫}}, \boldsymbol{x}_{\text{数学}})$$

となることが期待される。V 次元で互いに直交していたワンホット表現が、d 次元の「意味の空間」に埋め込まれ、向きの違いとして意味の違いが表現されるようになる、というのが埋め込みの要点である。

なお、記号 $\gg$ は「はるかに大きい」と読む。

2.6.2　Query, Key, Value

「その猫は魚を食べた」という文において、「食べた」という語を理解するには「猫」（誰が）と「魚」（何を）に注目する必要がある。この「どの語に注目すべきか」を内積で決めるのが Attention である。

ここで、単語ベクトル $\boldsymbol{x}$ をそのまま使って内積を計算するのではなく、役割の異なる 3 つのベクトルに変換してから用いる。

定義：Query, Key, Value

学習されるパラメータ行列 $\boldsymbol{W}_Q, \boldsymbol{W}_K \in \mathbb{R}^{d \times d_k}$、$\boldsymbol{W}_V \in \mathbb{R}^{d \times d_v}$ を用いて、単語ベクトル $\boldsymbol{x} \in \mathbb{R}^d$ から次の 3 つを作る：

$$\boldsymbol{q} = \boldsymbol{W}_Q^\top \boldsymbol{x} \in \mathbb{R}^{d_k} \qquad \textbf{Query}\ (\text{クエリ}) \tag{2.53}$$

$$\boldsymbol{k} = \boldsymbol{W}_K^\top \boldsymbol{x} \in \mathbb{R}^{d_k} \qquad \textbf{Key}\ (\text{キー}) \tag{2.54}$$

$$\boldsymbol{v} = \boldsymbol{W}_V^\top \boldsymbol{x} \in \mathbb{R}^{d_v} \qquad \textbf{Value}\ (\text{バリュー}) \tag{2.55}$$

この変換もまた内積の集まりである。例えば $\boldsymbol{W}_Q$ の第 j 列を $\boldsymbol{u}_j \in \mathbb{R}^d$ とすると、

$$q_j = \boldsymbol{u}_j^\top \boldsymbol{x} \qquad (j = 1, \ldots, d_k) \tag{2.56}$$

であり、Query の各成分は単語ベクトルと学習された重みベクトルの内積である。これは前節のニューロンの線形部分と同じ構造であり、d_k 個の内積を並べたもの、すなわち第 3 回で学ぶ行列とベクトルの積にほかならない。

3 つのベクトルが表す役割は次のとおりである。

- **Query $\boldsymbol{q}$**：「私は何を探しているか」という問い合わせ
- **Key $\boldsymbol{k}$**：「私は何を提供できるか」という見出し
- **Value $\boldsymbol{v}$**：「実際に渡す情報」という中身

図書館に例えれば、Query は検索語、Key は各本の背表紙、Value は本の中身である。検索語と背表紙を照合して、合致した本の中身を取り出す、という仕組みである。

■2.6.2.1　**なぜ 3 つに分けるのか**　同じ単語でも、**探す側**に回るときと**探される側**に回るときでは、必要な情報が異なる。「食べた」という語は、動作の主体を探すときには「主語を探している」という Query として働き、別の語から参照されるときには「動詞である」という Key として働く。$\boldsymbol{W}_Q$ と $\boldsymbol{W}_K$ を別々に学習することで、この非対称な役割を表現できる。

実際、もし $\boldsymbol{q}$ と $\boldsymbol{k}$ を同じベクトル（$\boldsymbol{x}$ そのもの）にしてしまうと、スコアが $\boldsymbol{x}_i^\top \boldsymbol{x}_j = \boldsymbol{x}_j^\top \boldsymbol{x}_i$ と対称になり、「i が j に注目する度合い」と「j が i に注目する度合い」が常に等しくなってしまう。内積は対称性をもつが、$\boldsymbol{W}_Q \neq \boldsymbol{W}_K$ とすることで

$$\boldsymbol{q}_i^\top \boldsymbol{k}_j = (\boldsymbol{W}_Q^\top \boldsymbol{x}_i)^\top (\boldsymbol{W}_K^\top \boldsymbol{x}_j) \neq \boldsymbol{q}_j^\top \boldsymbol{k}_i \quad \text{（一般に）} \tag{2.57}$$

となり、非対称な注目関係を表せるようになる。

また Value を分けるのは、**照合に使う情報**と**受け渡す情報**を独立に設計できるようにするためである。そのため $\boldsymbol{v}$ の次元 d_v は d_k と異なってよい。

■2.6.2.2　**自己注意と次元**　入力文の n 個の単語すべてから Query, Key, Value を作り、同じ文の中で照合を行う場合を**自己注意**（self-attention）と呼ぶ。Transformer の基本構成要素はこれである。代表的な設定では $d = 512$、$d_k = d_v = 64$ である。

2.6.3　注目度を内積で測る

Query $\boldsymbol{q}$ と各 Key $\boldsymbol{k}_i$ の**関連の強さ**を、内積で測る：

$$\mathrm{score}(\boldsymbol{q}, \boldsymbol{k}_i) = \boldsymbol{q}^\top \boldsymbol{k}_i = \|\boldsymbol{q}\| \, \|\boldsymbol{k}_i\| \cos\theta_i \tag{2.58}$$

前節で見たとおり、この値は $\boldsymbol{q}$ と $\boldsymbol{k}_i$ の向きが一致するほど大きくなる。すなわち**「探しているもの」と「提供できるもの」が合致する単語のスコアが高くなる**。

2.6.4　スコアを重みに変換する

スコアは正にも負にもなり、合計も 1 にならないため、そのままでは「重み」として使えない。そこで**ソフトマックス関数**（softmax）で正規化する：

$$\alpha_i = \frac{\exp(\mathrm{score}_i)}{\sum_{j=1}^{n} \exp(\mathrm{score}_j)} \tag{2.59}$$

指数関数 exp は常に正であり、分母で全体の和を割っているので、

$$\alpha_i > 0, \qquad \sum_{i=1}^{n} \alpha_i = 1 \tag{2.60}$$

が成り立つ。すなわち α_i は「単語 i にどれだけ注目するか」の割合を表す。

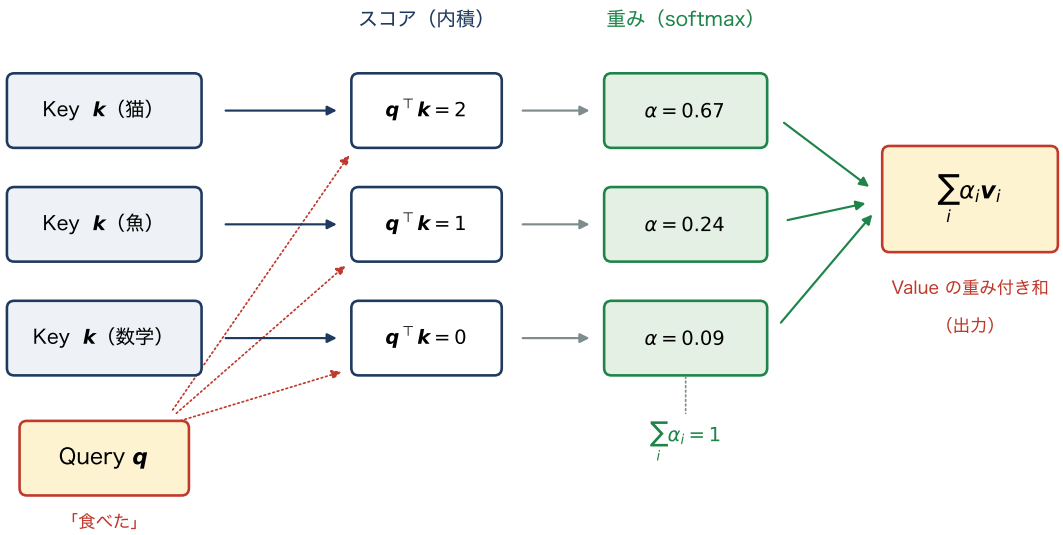


図 2.5　Attention のデータフロー。Query と各 Key の内積でスコアを計算し、ソフトマックスで重みに変換して、Value を混ぜ合わせる。

最終的な出力は、Value の重み付き和である：

$$\mathrm{Attention}(\boldsymbol{q}, K, V) = \sum_{i=1}^{n} \alpha_i \boldsymbol{v}_i \tag{2.61}$$

注目度が高い単語の情報ほど、強く混ぜ合わされることになる。

2.6.5　数値例

「食べた」という Query に対し、「猫」「魚」「数学」の 3 つの Key があるとする。簡単のため $d_k = 2$ とし、

$$\boldsymbol{q} = (1,1)^\top, \qquad \boldsymbol{k}_1 = (1,1)^\top, \quad \boldsymbol{k}_2 = (1,0)^\top, \quad \boldsymbol{k}_3 = (-1,1)^\top$$

とする（$\boldsymbol{k}_1$：猫、$\boldsymbol{k}_2$：魚、$\boldsymbol{k}_3$：数学）。内積を計算すると

$$\boldsymbol{q}^\top \boldsymbol{k}_1 = 1+1 = 2, \qquad \boldsymbol{q}^\top \boldsymbol{k}_2 = 1+0 = 1, \qquad \boldsymbol{q}^\top \boldsymbol{k}_3 = -1+1 = 0$$

となる。ソフトマックスを適用すると、$\exp(2) \approx 7.39$、$\exp(1) \approx 2.72$、$\exp(0) = 1$ より、分母は $7.39 + 2.72 + 1 = 11.11$ で

$$\alpha_1 \approx 0.67, \qquad \alpha_2 \approx 0.24, \qquad \alpha_3 \approx 0.09$$

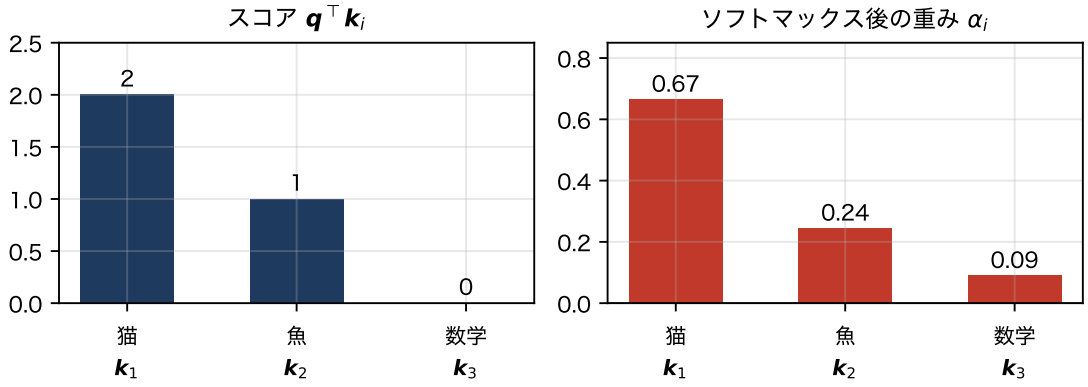


図 2.6　内積で計算したスコアと、ソフトマックスによる重み。スコアの差が指数関数で強調され、合計が 1 になる。

を得る。「猫」に約 67%、「魚」に約 24%、「数学」に約 9% の注目が向けられる。出力は $0.67\boldsymbol{v}_1 + 0.24\boldsymbol{v}_2 + 0.09\boldsymbol{v}_3$ となり、「猫」の情報を中心に混ぜ合わせた表現が得られる。

2.6.6　行列表記と $\sqrt{d_k}$

実際には、多数の Query を同時に処理する。n 個の Query を縦に並べた Q、m 個の Key を並べた K、Value を並べた V を用いると、すべての Query と Key の内積は一つの積 $QK^\top$ にまとまる。この**行列**という概念は次回（第 3 回）で扱う。結果として、Attention は次の一つの式で表される：

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V \tag{2.62}$$

ここで $\sqrt{d_k}$ で割る理由を、本章のノルムの言葉で説明する。$\boldsymbol{q}$ と $\boldsymbol{k}$ の各成分が独立に平均 0、分散 1 程度であるとすると、内積 $\boldsymbol{q}^\top \boldsymbol{k} = \sum_{i=1}^{d_k} q_i k_i$ は d_k 個の項の和であり、その大きさはおよそ $\sqrt{d_k}$ に比例して増大する。次元 d_k が大きい（実際のモデルでは 64 程度）とスコアの絶対値が大きくなり、ソフトマックスの指数関数によって最大値のみが 1、他がほぼ 0 という極端な分布になってしまう。これを防ぐため、$\sqrt{d_k}$ で割ってスコアの尺度を揃えている。これは**次元が上がるとノルムが大きくなる**という、本章で扱った性質に基づく調整である。

2.6.7　まとめ

Attention の本質は次の一文に要約される：

「関連の強さを内積で測り、その重みで情報を混ぜ合わせる」

本章で学んだ内積が、現代 AI の中核をなす仕組みを直接支えている。Transformer 全体の構造、multi-head attention、位置符号化などは第 13 回で扱う。

2.7　発展：内積とニューラルネットワーク

前節では、内積が Transformer の Attention を支えていることを見た。本節では、もう一つの現代 AI の柱である**ニューラルネットワーク**（neural network）においても、内積が基本要素となっていることを見る。

前節と同様、全体像は第 12 回で改めて扱う。本節では、本章で学んだ内積とノルムだけを用いて、ニューロン 1 個が何を計算しているのかを正確に理解することを目標とする。

2.7.1 ニューロン 1 個の計算

ニューラルネットワークの最小単位を**ニューロン**（neuron）あるいはユニットと呼ぶ。1 個のニューロンが行う計算は、次の 2 段階である。

定義：ニューロンの計算

入力 $\boldsymbol{x} \in \mathbb{R}^d$、重み $\boldsymbol{w} \in \mathbb{R}^d$、バイアス $b \in \mathbb{R}$ に対して、

$$z = \boldsymbol{w}^\top \boldsymbol{x} + b \qquad \text{（線形部分：内積とバイアス）} \tag{2.63}$$

$$a = \sigma(z) \qquad \text{（非線形部分：活性化関数）} \tag{2.64}$$

を計算する。z を**重み付き和**（weighted sum）あるいは活性、a を**出力**（output）と呼び、σ を**活性化関数**（activation function）と呼ぶ。

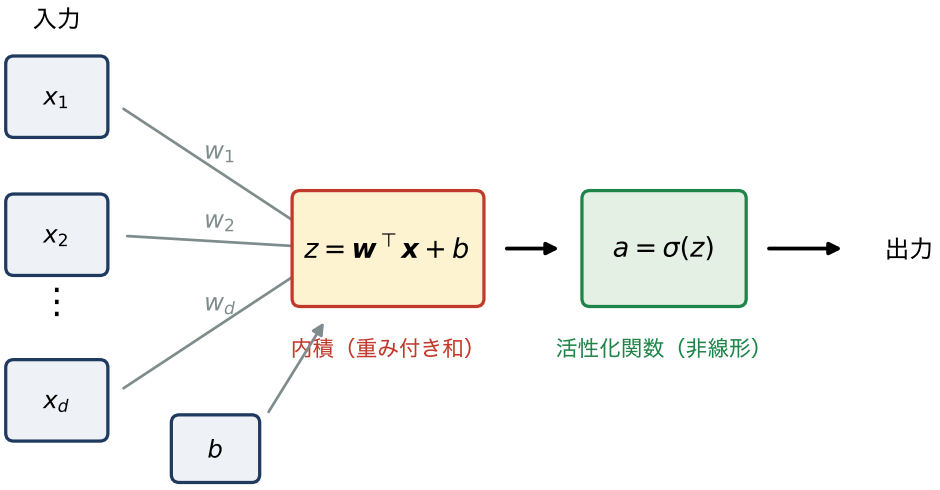


図 2.7　ニューロン 1 個の計算。入力と重みの内積にバイアスを加え（線形部分）、活性化関数を通す（非線形部分）。

第 1 段階の $\boldsymbol{w}^\top \boldsymbol{x} + b$ は、第 1 回で扱った線形モデルそのものである。すなわち**ニューロンの線形部分は内積にほかならない**。入力の各成分に重みを掛けて足し合わせる、という素朴な計算が、ベクトルの言葉では 1 つの内積として簡潔に表される。

2.7.2 ニューロンは何を検出しているのか

なぜ内積を計算するのか。その意味は、本章で導いた幾何学的解釈から明らかになる：

$$\boldsymbol{w}^\top \boldsymbol{x} = \|\boldsymbol{w}\| \, \|\boldsymbol{x}\| \cos\theta \tag{2.65}$$

すなわち z は、入力 $\boldsymbol{x}$ が重み $\boldsymbol{w}$ の向きとどれだけ一致しているかを測っている。

- $\boldsymbol{x}$ が $\boldsymbol{w}$ と同じ向き（θ が小さい）$\Rightarrow$ z が大きい $\Rightarrow$ 強く発火する
- $\boldsymbol{x}$ が $\boldsymbol{w}$ と直交（$\theta = \pi/2$）$\Rightarrow$ $z = 0$ $\Rightarrow$ 反応しない
- $\boldsymbol{x}$ が $\boldsymbol{w}$ と逆向き $\Rightarrow$ z が負 $\Rightarrow$ 抑制される

つまり**重みベクトル $\boldsymbol{w}$ は、そのニューロンが検出したい「特徴の向き」を表している**。学習とは、検出すべき向きを見つけることにほかならない。前節の Attention が「Query と Key の一致度」を内積で測っていたのと、同じ構造である。

2.7.3 決定境界と法線ベクトル

バイアス b の役割も幾何学的に理解できる。$z = 0$ となる入力の集合

$$\{\, \boldsymbol{x} \in \mathbb{R}^d \mid \boldsymbol{w}^\top \boldsymbol{x} + b = 0 \,\} \tag{2.66}$$

は、$d = 2$ のとき直線、$d = 3$ のとき平面、一般には**超平面**（hyperplane）と呼ばれる。これを境に出力の符号が変わるため、**決定境界**（decision boundary）と呼ばれる。

この超平面上の任意の 2 点 $\boldsymbol{x}_1, \boldsymbol{x}_2$ に対して $\boldsymbol{w}^\top \boldsymbol{x}_1 + b = \boldsymbol{w}^\top \boldsymbol{x}_2 + b = 0$ であるから、差をとると

$$\boldsymbol{w}^\top (\boldsymbol{x}_1 - \boldsymbol{x}_2) = 0 \tag{2.67}$$

すなわち $\boldsymbol{w}$ は超平面に沿う任意の方向と直交する。したがって **$\boldsymbol{w}$ は決定境界の法線ベクトル**であり、b は境界を原点からどれだけずらすかを決める。この見方は、第 10 回のサポートベクターマシンでマージンを考える際の出発点となる。

2.7.4 なぜ非線形が必要か

第 2 段階の活性化関数 σ には、次のような非線形関数が用いられる。

$$\text{ReLU：}\quad \sigma(z) = \max(0, z) \tag{2.68}$$

$$\text{シグモイド：}\quad \sigma(z) = \frac{1}{1 + e^{-z}} \ \in\ (0, 1) \tag{2.69}$$

なぜ非線形関数が必要なのか。仮に σ を恒等写像 $\sigma(z) = z$（線形）としてみよう。2 段重ねたとき、

$$a_2 = \boldsymbol{w}_2^\top (\boldsymbol{w}_1^\top \boldsymbol{x} + b_1) + b_2 = (\boldsymbol{w}_2^\top \boldsymbol{w}_1^\top) \boldsymbol{x} + (\boldsymbol{w}_2^\top b_1 + b_2) \tag{2.70}$$

となり、これは結局 $\boldsymbol{x}$ についての 1 次式、すなわち **1 層の線形モデルと同じ**である。何層重ねても表現力は増えない。**非線形関数を挟むことで初めて、層を深くする意味が生まれる**。

これが第 12 回の「ニューラルネットワーク＝線形変換＋非線形」という理解の核心である。

2.7.5 数値例：AND を計算するニューロン

2 入力 $\boldsymbol{x} = (x_1, x_2)^\top$ が 0 または 1 をとるとき、論理積（AND）を計算するニューロンを作ってみよう。$\boldsymbol{w} = (1, 1)^\top$、$b = -1.5$、活性化関数をステップ関数（$z > 0$ なら 1、そうでなければ 0）とする。

x_1	x_2	$z = \boldsymbol{w}^\top \boldsymbol{x} + b$	出力 a
0	0	$0 - 1.5 = -1.5$	0
0	1	$1 - 1.5 = -0.5$	0
1	0	$1 - 1.5 = -0.5$	0
1	1	$2 - 1.5 = 0.5$	1

確かに AND が実現されている。決定境界 $x_1 + x_2 = 1.5$ は、点 $(1,1)$ とそれ以外の 3 点を分離する直線である。法線ベクトル $\boldsymbol{w} = (1,1)^\top$ は、この直線に垂直な方向を向いている。

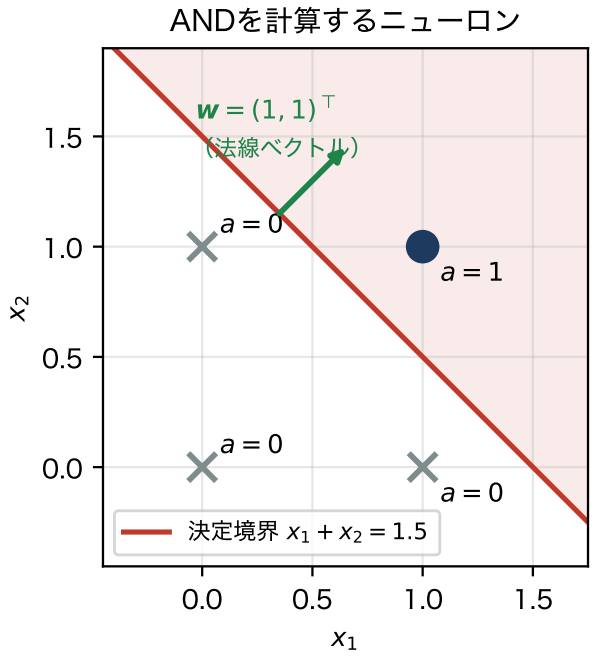


図 2.8　AND を計算するニューロン。決定境界 $x_1 + x_2 = 1.5$ が点 $(1,1)$ とそれ以外を分離し、重み $\boldsymbol{w}$ は境界の法線ベクトルになっている。

なお、排他的論理和（XOR）は 1 個のニューロンでは実現できない。1 本の直線では $(0,1),(1,0)$ と $(0,0),(1,1)$ を分離できないからである。これが**層を重ねる必要性**を示す古典的な例であり、第 12 回で改めて扱う。

2.7.6　層：内積を並べたもの

実際のニューラルネットワークでは、同じ入力に対して多数のニューロンを並列に配置する。これを**層**（layer）と呼ぶ。m 個のニューロンがそれぞれ重み $\boldsymbol{w}_1, \dots, \boldsymbol{w}_m \in \mathbb{R}^d$ を持つとき、層の出力は

$$\boldsymbol{a} = \begin{pmatrix} \sigma(\boldsymbol{w}_1^\top \boldsymbol{x} + b_1) \\ \sigma(\boldsymbol{w}_2^\top \boldsymbol{x} + b_2) \\ \vdots \\ \sigma(\boldsymbol{w}_m^\top \boldsymbol{x} + b_m) \end{pmatrix} \in \mathbb{R}^m \tag{2.71}$$

となる。すなわち**層とは、m 本の内積を並べたもの**である。

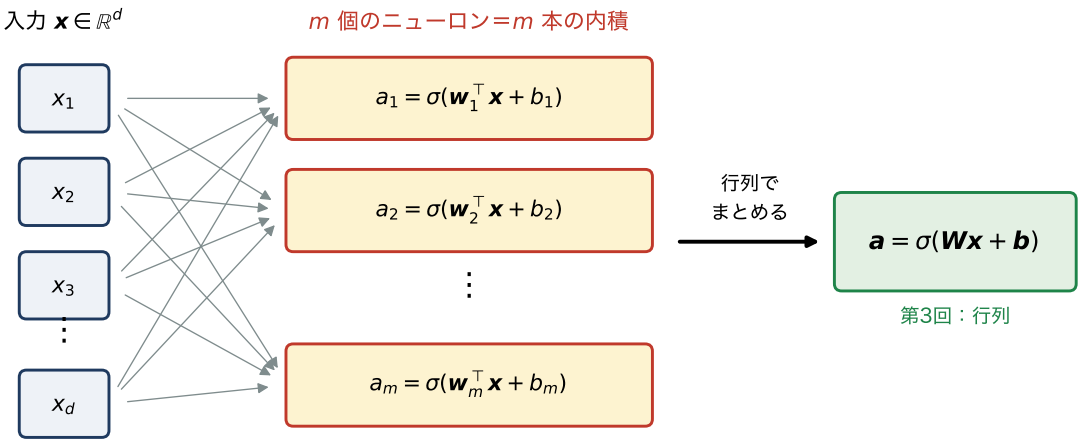


図 2.9　層は m 個のニューロンからなり、m 本の内積を並べたものである。次回学ぶ行列を用いると、これは一つの式 $\boldsymbol{a} = \sigma(\boldsymbol{W}\boldsymbol{x} + \boldsymbol{b})$ にまとまる。

それぞれのニューロンが異なる向き $\boldsymbol{w}_i$ の特徴を検出し、入力を m 個の「特徴の強さ」に変換している。式 (2.71) の m 本の内積は、次回（第 3 回）で学ぶ**行列**を用いると

$$\boldsymbol{a} = \sigma(\boldsymbol{W}\boldsymbol{x} + \boldsymbol{b}), \qquad \boldsymbol{W} \in \mathbb{R}^{m \times d} \tag{2.72}$$

という一つの式にまとまる（σ は各成分に適用する）。$\boldsymbol{W}$ の第 i 行が $\boldsymbol{w}_i^\top$ である。この計算を層ごとに繰り返して出力へ至る流れを**順伝播**（forward propagation）と呼ぶ。

「複数の内積を一度に計算する」という操作が行列の積であり、これは前節の Attention における $QK^\top$ とまったく同じ構造である。次回、行列を導入することで、Attention とニューラルネットワークの両方が同じ言葉で書けるようになる。

2.7.7　まとめ

ニューラルネットワークの 1 ニューロンは、次の一文に要約される：

「入力と重みの内積で特徴の一致度を測り、非線形関数を通す」

本章の内積が、Attention とニューラルネットワークという現代 AI の 2 つの柱を共通して支えている。誤差逆伝播法による学習、深層化の効果などは第 12 回で扱う。

2.8　まとめ

本章の内容を整理する。

- ベクトルはデータを並べたものであり、ノルム $\|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^\top \boldsymbol{x}}$ で長さを測る
- 内積 $\boldsymbol{x}^\top \boldsymbol{y} = \sum_i x_i y_i$ は対称性・線形性・正定値性をもつ
- コーシー・シュワルツの不等式から、内積は $\boldsymbol{x}^\top \boldsymbol{y} = \|\boldsymbol{x}\|\|\boldsymbol{y}\| \cos\theta$ と表され、長さと角度の情報を担う
- 内積が 0 であることと直交は同値であり、第 4 回の最小二乗法の鍵となる
- 長さで正規化したコサイン類似度は、向きの近さを $[-1, 1]$ で測る

- Transformer の Attention は、Query と Key の内積で注目度を決めている
- ニューラルネットワークの 1 ニューロンは、内積で特徴の一致度を測り非線形関数を通す。重み $\boldsymbol{w}$ は検出したい特徴の向きであり、決定境界の法線ベクトルでもある

次回（第 3 回）は、複数のベクトルをまとめて扱う**行列**を導入し、線形変換という視点から機械学習のモデルを捉え直す。本章で見た $QK^\top$ や層の計算 $\boldsymbol{W}\boldsymbol{x}$ は、いずれも「複数の内積をまとめる」操作であり、行列の積として統一的に表される。

特に、N 件のデータ $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N$ を縦に積み上げると一つの行列となり、モデルの予測全体が「行列とベクトルの積」として表される。このとき予測は行列の列ベクトルの線形結合になっており、第 1 回で導入した抽象的な仮説空間 $\mathcal{H}$ が、具体的な幾何学的対象（列空間）として姿を現す。

2.9 演習問題

1. **ノルムと内積の計算**　$\boldsymbol{x} = (2, -1, 2)^\top$、$\boldsymbol{y} = (1, 2, 2)^\top \in \mathbb{R}^3$ とする。
   (a) $\|\boldsymbol{x}\|$ と $\|\boldsymbol{y}\|$ を求めよ。
   (b) $\boldsymbol{x}^\top \boldsymbol{y}$ を求めよ。
   (c) $\boldsymbol{x}$ と $\boldsymbol{y}$ のコサイン類似度を求めよ。
   (d) $\boldsymbol{x}$ を正規化した単位ベクトル $\boldsymbol{u}$ を求め、$\|\boldsymbol{u}\| = 1$ を確認せよ。
2. **直交性**　$\boldsymbol{a} = (1, 2)^\top$ とする。
   (a) $\boldsymbol{a}$ と直交するベクトルを 1 つ求めよ。
   (b) $\boldsymbol{a}$ と直交するベクトル全体の集合を、集合の記法を用いて表せ。
   (c) $\boldsymbol{x} = (3, 1)^\top$ と $\boldsymbol{a}$ のなす角 θ について、$\cos\theta$ を求めよ。θ は鋭角か鈍角か。
3. **内積の性質の証明**　任意の $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^d$ に対して、次の等式を内積の性質を用いて証明せよ。

$$\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + 2\,\boldsymbol{x}^\top \boldsymbol{y} + \|\boldsymbol{y}\|^2$$

   また、この結果を用いて、$\boldsymbol{x} \perp \boldsymbol{y}$ のとき $\|\boldsymbol{x} + \boldsymbol{y}\|^2 = \|\boldsymbol{x}\|^2 + \|\boldsymbol{y}\|^2$（三平方の定理）が成り立つことを示せ。
4. **三角不等式**　問 3 の結果とコーシー・シュワルツの不等式を用いて、三角不等式 $\|\boldsymbol{x} + \boldsymbol{y}\| \le \|\boldsymbol{x}\| + \|\boldsymbol{y}\|$ を証明せよ。
5. **コサイン類似度と長さ**　$\boldsymbol{a} = (3, 4)^\top$、$\boldsymbol{b} = (6, 8)^\top$、$\boldsymbol{c} = (4, 3)^\top$ とする。
   (a) 内積 $\boldsymbol{a}^\top \boldsymbol{b}$ と $\boldsymbol{a}^\top \boldsymbol{c}$ をそれぞれ求めよ。
   (b) コサイン類似度 $\mathrm{cossim}(\boldsymbol{a}, \boldsymbol{b})$ と $\mathrm{cossim}(\boldsymbol{a}, \boldsymbol{c})$ をそれぞれ求めよ。
   (c) 内積で比較した場合とコサイン類似度で比較した場合で、$\boldsymbol{a}$ により「似ている」のはどちらのベクトルか。結果が異なる理由を、長さと向きの観点から説明せよ。
6. **線形モデルと内積**　第 1 回の例 2 の線形モデル $h(\boldsymbol{x}) = 0.5x_1 - 0.3x_2 + 3$ を考える。
   (a) バイアス項を吸収した記法 $h(\boldsymbol{x}) = \boldsymbol{w}^\top \tilde{\boldsymbol{x}}$ で表すとき、$\boldsymbol{w}$ と $\tilde{\boldsymbol{x}}$ をそれぞれ書け。
   (b) $\boldsymbol{x} = (25, 10)^\top$ に対する予測値を、内積の計算として求めよ。
   (c) $h(\boldsymbol{x}) = 0$ を満たす $\boldsymbol{x}$ の集合は平面上でどのような図形になるか。また、$\boldsymbol{w}_{1:2} = (0.5, -0.3)^\top$ とその図形の関係を述べよ。
7. **ニューロンと決定境界**　重み $\boldsymbol{w} = (2, -1)^\top$、バイアス $b = -1$ のニューロンを考える。活性化関数はステップ関数（$z > 0$ なら 1、そうでなければ 0）とする。

(a) 入力 $\boldsymbol{x} = (2, 1)^\top$ に対する $z = \boldsymbol{w}^\top \boldsymbol{x} + b$ と出力を求めよ。

(b) 入力 $\boldsymbol{x} = (0, 3)^\top$ に対する z と出力を求めよ。

(c) 決定境界 $\boldsymbol{w}^\top \boldsymbol{x} + b = 0$ を x_2 について解き、直線の式として書け。

(d) $\boldsymbol{w}$ がこの直線の法線ベクトルであることを、直線上の異なる 2 点を取って内積を計算することで確認せよ。

(e) 活性化関数を恒等写像 $\sigma(z) = z$ とし、このニューロンを 2 段重ねると 1 段の場合と同じ表現力しか持たないことを、式を書いて説明せよ。

8. **Attention のスコア計算**　Query $\boldsymbol{q} = (2, 0)^\top$ と、3 つの Key $\boldsymbol{k}_1 = (1, 0)^\top$、$\boldsymbol{k}_2 = (0, 2)^\top$、$\boldsymbol{k}_3 = (1, 1)^\top$ が与えられている。

(a) 各スコア $\boldsymbol{q}^\top \boldsymbol{k}_i$（$i = 1, 2, 3$）を求めよ。

(b) ソフトマックスによる重み α_i を求めよ（$\exp(2) \approx 7.39$、$\exp(0) = 1$ を用いてよい）。

(c) 最も注目される Key はどれか。その理由を内積の幾何学的意味から説明せよ。

(d) d_k が大きいとき、スコアを $\sqrt{d_k}$ で割る理由を説明せよ。

3　行列と線形変換

第 2 回では、1 件のデータをベクトル $\boldsymbol{x} \in \mathbb{R}^d$ で表し、線形モデルを内積 $\boldsymbol{w}^\top \boldsymbol{x}$ として理解した。しかし実際の学習では、N 件のデータをまとめて扱う必要がある。本章では、数を長方形に並べた**行列**を導入し、「行列とベクトルの積」という演算によってモデル全体を一つの式で表せることを見る。

さらに本章の後半では、N 件のデータを並べた**計画行列**を導入し、モデルが表現できる予測の全体が**列空間**という部分空間になることを示す。これにより、第 1 回で抽象的に定義した仮説空間 $\mathcal{H}$ が、具体的な幾何学的対象として理解できるようになる。

3.1　行列とは何か

3.1.1　行列の定義

定義：行列

実数を m 行 n 列の長方形に並べたものを $m \times n$ **行列**（matrix）と呼び、本書では太字の大文字で表す：

$$\boldsymbol{A} = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \in \mathbb{R}^{m \times n} \tag{3.1}$$

a_{ij} を第 (i, j) **成分**と呼ぶ。添字は「行が先、列が後」の順であり、a_{ij} は第 i 行・第 j 列の成分を表す。

記号 $\mathbb{R}^{m \times n}$ は「m 行 n 列の実行列全体の集合」を表す。$n = 1$ のとき $\mathbb{R}^{m \times 1}$ は列ベクトル全体、すなわち $\mathbb{R}^m$ と同一視される。つまり**ベクトルは行列の特別な場合**である。

行列 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ は、2 通りの見方ができる。いずれも、行列をベクトルの集まりとみなす見方である。

定義：行と列の取り出し

$\boldsymbol{A} \in \mathbb{R}^{m \times n}$ の第 i 行の成分を並べたベクトル、および第 j 列の成分を並べたベクトルを、それぞれ

$$\boldsymbol{r}_i = (a_{i1},\ a_{i2},\ \ldots,\ a_{in})^\top \ \in \ \mathbb{R}^n \qquad (i = 1, \ldots, m) \tag{3.2}$$

$$\boldsymbol{c}_j = (a_{1j},\ a_{2j},\ \ldots,\ a_{mj})^\top \ \in \ \mathbb{R}^m \qquad (j = 1, \ldots, n) \tag{3.3}$$

と定める。どちらも**列ベクトル**である。$\boldsymbol{A}$ の第 i 行そのものは、$\boldsymbol{r}_i$ を横に倒した $\boldsymbol{r}_i^\top$（$1 \times n$ 行列）である。これを用いると $\boldsymbol{A}$ は次の 2 通りに書ける：

$$\boldsymbol{A} = \begin{pmatrix} \boldsymbol{r}_1^\top \\ \boldsymbol{r}_2^\top \\ \vdots \\ \boldsymbol{r}_m^\top \end{pmatrix} \quad \text{（行による分解）}, \qquad \boldsymbol{A} = (\boldsymbol{c}_1 \ \ \boldsymbol{c}_2 \ \ \cdots \ \ \boldsymbol{c}_n) \quad \text{（列による分解）} \tag{3.4}$$

3.1.1.1　なぜ $\boldsymbol{r}_i$ に転置が付くのか

式 (3.2) で $\boldsymbol{r}_i$ に $\top$ が付いていることに戸惑うかもしれない。これは第 2.1.1 項の約束によるものである。本書ではベクトルをすべて**列ベクトル**として扱い、紙面では横に並べて書いて $\top$ を付けることで「これは縦

に並んだ列ベクトルである」と示す、という約束であった。したがって式 (3.2) は

$$\boldsymbol{r}_i = \begin{pmatrix} a_{i1} \\ a_{i2} \\ \vdots \\ a_{in} \end{pmatrix} \in \mathbb{R}^n \tag{3.5}$$

と書いているのと同じ意味であり、$\boldsymbol{r}_i$ は**列ベクトル**である。

一方、$\boldsymbol{A}$ の第 i 行は横に並んだ $1 \times n$ 行列であるから、$\boldsymbol{r}_i$ ではなく**その転置** $\boldsymbol{r}_i^\top$ が第 i 行に一致する。つまり $\top$ は 2 つの役割で現れており、混同しないよう注意してほしい。

- 式 (3.2) の $\top$：横書きの組が**列**ベクトルであることを示す（表記上の約束）
- $\boldsymbol{r}_i^\top$ の $\top$：列ベクトル $\boldsymbol{r}_i$ を**横に倒す**操作（第 i 行そのもの）

この約束のおかげで、第 i 行と $\boldsymbol{x} \in \mathbb{R}^n$ の内積が $\boldsymbol{r}_i^\top \boldsymbol{x}$ と自然に書ける。$\boldsymbol{r}_i, \boldsymbol{x}$ がともに列ベクトル（n 次元）なので、これは第 2 回の内積の記法 $\boldsymbol{x}^\top \boldsymbol{y}$ とまったく同じ形である。

3.1.1.2 次元の確認

次元を取り違えやすいので、しっかり確認してほしい。

- 第 i 行 $\boldsymbol{r}_i^\top$：成分は n 個（$=$ 列の本数）。行は m 本ある
- 第 j 列 $\boldsymbol{c}_j$：成分は m 個（$=$ 行の本数）。列は n 本ある

すなわち、1 本の行は横に n 個の成分が並んだものだから $\boldsymbol{r}_i \in \mathbb{R}^n$ であり、1 本の列は縦に m 個の成分が並んだものだから $\boldsymbol{c}_j \in \mathbb{R}^m$ である。行の長さと列の長さで m と n が入れ替わる点に注意する。

本章では特に**列による分解**が重要になる。

3.1.2 転置

行と列を入れ替える操作を**転置**（transpose）と呼び、$\boldsymbol{A}^\top$ と書く：

$$(\boldsymbol{A}^\top)_{ij} = a_{ji}, \qquad \boldsymbol{A} \in \mathbb{R}^{m \times n} \;\Rightarrow\; \boldsymbol{A}^\top \in \mathbb{R}^{n \times m} \tag{3.6}$$

第 2 回で用いた $\boldsymbol{x}^\top$ は、$d \times 1$ 行列（列ベクトル）を $1 \times d$ 行列（行ベクトル）に変える操作であった。

3.1.3 行列の和とスカラー倍

同じ大きさの行列同士の和、およびスカラー倍は、成分ごとに定める：

$$(\boldsymbol{A} + \boldsymbol{B})_{ij} = a_{ij} + b_{ij}, \qquad (c\boldsymbol{A})_{ij} = c\, a_{ij} \tag{3.7}$$

3.2 行列とベクトルの積

3.2.1 定義と 2 つの見方

定義：行列とベクトルの積

$\boldsymbol{A} \in \mathbb{R}^{m\times n}$ と $\boldsymbol{x} \in \mathbb{R}^n$ に対して、積 $\boldsymbol{Ax} \in \mathbb{R}^m$ を次で定める：

$$(\boldsymbol{Ax})_i = \sum_{j=1}^{n} a_{ij}x_j \qquad (i = 1, \ldots, m) \tag{3.8}$$

$\boldsymbol{A}$ の列数と $\boldsymbol{x}$ の次元が一致していなければ、積は定義されないことに注意する。

この積には、次の 2 つの見方がある。どちらも正しく、場面に応じて使い分ける。

■3.2.1.1 見方 1：行との内積

$\boldsymbol{A}$ の第 i 行を $\boldsymbol{r}_i^\top$ とすると、

$$\boldsymbol{Ax} = \begin{pmatrix} \boldsymbol{r}_1^\top \boldsymbol{x} \\ \boldsymbol{r}_2^\top \boldsymbol{x} \\ \vdots \\ \boldsymbol{r}_m^\top \boldsymbol{x} \end{pmatrix} \tag{3.9}$$

すなわち、積の第 i 成分は第 i 行と $\boldsymbol{x}$ の内積である。m 個の内積をまとめて計算しているとみなせる。

■3.2.1.2 見方 2：列の線形結合

$\boldsymbol{A}$ の第 j 列を $\boldsymbol{c}_j$ とすると、

$$\boldsymbol{Ax} = x_1\boldsymbol{c}_1 + x_2\boldsymbol{c}_2 + \cdots + x_n\boldsymbol{c}_n = \sum_{j=1}^{n} x_j\boldsymbol{c}_j \tag{3.10}$$

すなわち、積は **$\boldsymbol{A}$ の列ベクトルを、$\boldsymbol{x}$ の成分を係数として足し合わせたもの**である。このように、ベクトルにスカラーを掛けて足し合わせたものを**線形結合**（linear combination）と呼ぶ。

確認　式 (3.10) の第 i 成分を計算すると

$$\left(\sum_{j=1}^{n} x_j\boldsymbol{c}_j\right)_i = \sum_{j=1}^{n} x_j(\boldsymbol{c}_j)_i = \sum_{j=1}^{n} x_j a_{ij} \tag{3.11}$$

となり、定義と一致する（$\boldsymbol{c}_j$ の第 i 成分は a_{ij} である）。

3.2.1.3 見方 2 の幾何学的な意味

式 (3.10) は、**$\boldsymbol{Ax}$ がつねに列ベクトル $\boldsymbol{c}_1, \ldots, \boldsymbol{c}_n$ の線形結合として表される**ことを述べている。言い換えれば、$\boldsymbol{x}$ をどのように選んでも、$\boldsymbol{Ax}$ は列ベクトルたちが**張る**空間の中にしか現れない。

例えば $\boldsymbol{A} \in \mathbb{R}^{3\times 2}$ で、2 本の列 $\boldsymbol{c}_1, \boldsymbol{c}_2$ が平行でない場合を考えよう（この条件を一般化したものが、第 3.2.3 項で定義する**線形独立**である）。$\boldsymbol{x} = (x_1, x_2)^\top$ を $\mathbb{R}^2$ 全体で動かしたとき、$\boldsymbol{Ax} = x_1\boldsymbol{c}_1 + x_2\boldsymbol{c}_2$ が取りうる値の全体は、$\mathbb{R}^3$ の中の**原点を通る平面**になる（図 3.1）。$\mathbb{R}^3$ 全体（3 次元）ではなく、2 次元の平面にとどまる点が重要である。

この「列ベクトルが張る空間」が第 3.5 節で定義する**列空間**であり、線形モデルが表現できる予測の全体を表す。第 4 回で学ぶ最小二乗法は、目標のベクトルがこの空間の外にあるとき、その中で最も近い点を探す問題として定式化される。

なお、$\boldsymbol{c}_1$ と $\boldsymbol{c}_2$ が平行な場合は、どのように線形結合しても同じ直線上にしか行けないため、張られる空間は平面ではなく**直線**になる。このように「張られる空間の次元」がモデルの自由度を決めており、これを測る量が第 3.5.4 項の**ランク**である。

3.2.2 例

$$\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix} \in \mathbb{R}^{3\times 2}, \qquad \boldsymbol{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix} \in \mathbb{R}^{2}$$

のとき、見方 1（行との内積）では

$$\boldsymbol{A}\boldsymbol{x} = \begin{pmatrix} 1\cdot 2 + 2\cdot(-1) \\ 3\cdot 2 + 4\cdot(-1) \\ 5\cdot 2 + 6\cdot(-1) \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \\ 4 \end{pmatrix}$$

見方 2（列の線形結合）では

$$\boldsymbol{A}\boldsymbol{x} = 2\begin{pmatrix} 1 \\ 3 \\ 5 \end{pmatrix} - 1\begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix} = \begin{pmatrix} 2 \\ 6 \\ 10 \end{pmatrix} - \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix} = \begin{pmatrix} 0 \\ 2 \\ 4 \end{pmatrix}$$

当然ながら結果は一致する。この例を見方 2 で図示したものが図 3.1 である。$\boldsymbol{A}\boldsymbol{x}$ は $\boldsymbol{c}_1$ を 2 倍したものから $\boldsymbol{c}_2$ を引いた点であり、2 本の列が張る平面の上に位置している。

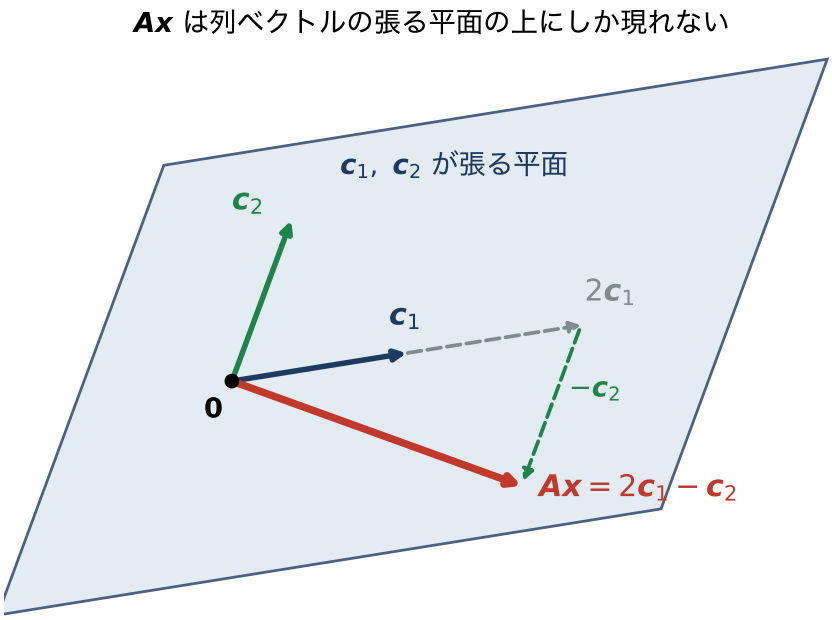


図 3.1　見方 2（列の線形結合）の幾何学的な意味（模式図）。$\boldsymbol{A}\boldsymbol{x}$ は列ベクトル $\boldsymbol{c}_1, \boldsymbol{c}_2$ の線形結合であるから、$\boldsymbol{x}$ をどう選んでも、2 本の列が張る平面の上にしか現れない。

3.2.3 線形独立と張られる空間

前項で「2 本の列が平行でない場合」という条件を置いた。この条件を一般の本数に拡張したものが**線形独立**である。

定義：線形独立・線形従属

ベクトル $\boldsymbol{c}_1, \ldots, \boldsymbol{c}_n \in \mathbb{R}^m$ が**線形独立**（linearly independent）であるとは、

$$a_1\boldsymbol{c}_1 + a_2\boldsymbol{c}_2 + \cdots + a_n\boldsymbol{c}_n = \boldsymbol{0} \implies a_1 = a_2 = \cdots = a_n = 0 \tag{3.12}$$

が成り立つことをいう。すなわち、線形結合が零ベクトルになるのは、係数がすべて 0 という自明な場合に限る、ということである。線形独立でないとき**線形従属**（linearly dependent）という。

3.2.3.1 定義の読み方

この定義は一見わかりにくいが、**「どのベクトルも、他のベクトルの線形結合では表せない」**と言い換えられる。理由を確かめよう。

線形従属、すなわち式 (3.12) が成り立たないとする。このとき、すべてが 0 ではない係数 $a_1, \ldots, a_n$ で $a_1\boldsymbol{c}_1 + \cdots + a_n\boldsymbol{c}_n = \boldsymbol{0}$ となるものが存在する。0 でない係数の一つを $a_k \neq 0$ とすると、$a_k\boldsymbol{c}_k$ を左辺に残して移項し、両辺を a_k で割れば

$$\boldsymbol{c}_k = -\frac{1}{a_k}\sum_{j \neq k} a_j \boldsymbol{c}_j \tag{3.13}$$

となる。つまり $\boldsymbol{c}_k$ が他のベクトルの線形結合で表せてしまう。逆に、あるベクトルが他の線形結合で表せるなら、移項すれば自明でない係数の組が作れるので線形従属である。したがって両者は同値である。

3.2.3.2 2 本の場合：平行かどうか

$n = 2$ のときは、幾何学的に単純な判定になる。$\boldsymbol{c}_1, \boldsymbol{c}_2$ が線形従属であるとは、$a_1\boldsymbol{c}_1 + a_2\boldsymbol{c}_2 = \boldsymbol{0}$ を満たす自明でない係数があることだから、例えば $a_2 \neq 0$ として $\boldsymbol{c}_2 = -(a_1/a_2)\boldsymbol{c}_1$、すなわち**一方が他方のスカラー倍**である。これは 2 本の矢印が**同じ直線上にある（平行である）**ことを意味する。

3.2.3.3 張られる空間の次元

線形独立かどうかは、**張られる空間の大きさ**を決める（図 3.2）。

- **線形独立**のとき：$\boldsymbol{c}_1, \boldsymbol{c}_2$ の線形結合は平面全体を覆う。張られる空間は **2 次元**である
- **線形従属**のとき：どう線形結合しても同じ直線上にしか行けない。張られる空間は **1 次元**にとどまる

本数を n 本に増やしても同じである。n 本のうち線形独立なものが r 本であれば、張られる空間の次元は n ではなく r になる。

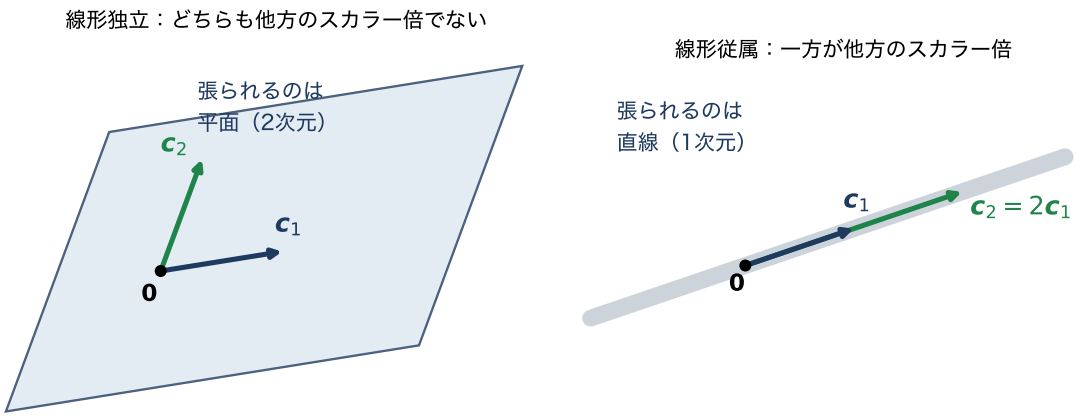


図 3.2　線形独立と線形従属（模式図）。左：2 本が平行でなければ、線形結合は平面（2 次元）を張る。右：一方が他方のスカラー倍であれば、どう線形結合しても直線（1 次元）から出られない。

この「張られる空間の次元」こそが、第 3.5.4 項で定義する**ランク**であり、モデルが実際に表現できる自由度を表す量である。線形従属な列があるということは、その列が他の列で説明できてしまい**新しい情報を加えていない**ということであり、第 3.5.5 項で扱う多重共線性の問題につながる。

3.2.4　行列の積

$\boldsymbol{A} \in \mathbb{R}^{m \times n}$、$\boldsymbol{B} \in \mathbb{R}^{n \times p}$ に対して、積 $\boldsymbol{AB} \in \mathbb{R}^{m \times p}$ を

$$(\boldsymbol{AB})_{ij} = \sum_{k=1}^{n} a_{ik} b_{kj} \tag{3.14}$$

で定める。$\boldsymbol{A}$ の第 i 行を $\boldsymbol{r}_i^{\top}$、$\boldsymbol{B}$ の第 j 列を $\boldsymbol{c}_j$ と書けば、これは**「$\boldsymbol{A}$ の第 i 行と $\boldsymbol{B}$ の第 j 列の内積」**にほかならない：

$$(\boldsymbol{AB})_{ij} = \boldsymbol{r}_i^{\top} \boldsymbol{c}_j \tag{3.15}$$

$\boldsymbol{A}$ の列数と $\boldsymbol{B}$ の行数がともに n で一致していなければ内積が定義できないため、積も定義されない。

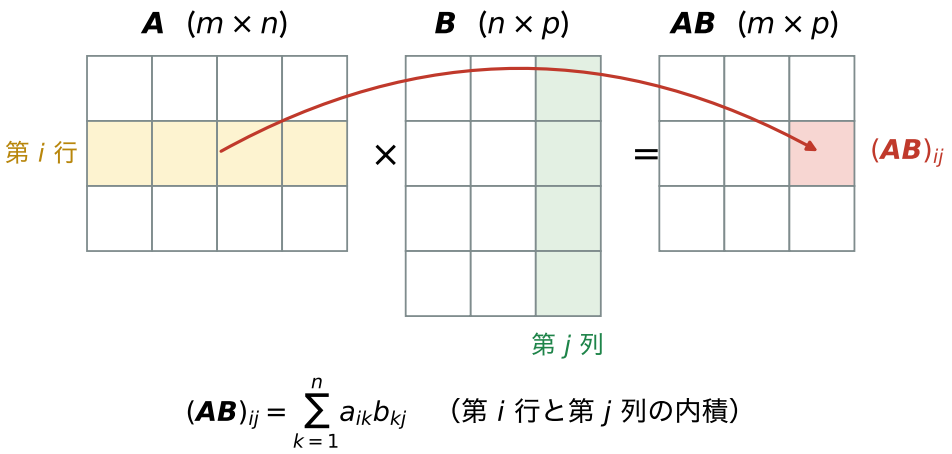


図 3.3　行列の積の意味。$\boldsymbol{AB}$ の (i,j) 成分は、$\boldsymbol{A}$ の第 i 行と $\boldsymbol{B}$ の第 j 列の内積である。$\boldsymbol{AB}$ 全体は、$\boldsymbol{A}$ の m 本の行と $\boldsymbol{B}$ の p 本の列の、すべての組合せの内積を並べた表にあたる。

図 3.3 が示すとおり、$\boldsymbol{AB}$ の 1 つの成分を得るには 1 組の内積を計算すればよく、積の行列全体は $m \times p$ **通りすべての組合せの内積を並べた表**である。すなわち行列の積とは、**多数の内積を一度にまとめて計算する操作**である。第 2 回で「複数の内積をまとめる」と述べたのは、この演算のことであった。

なお、行列とベクトルの積 $\boldsymbol{Ax}$ は、$p = 1$ の特別な場合にあたる。このとき $\boldsymbol{B}$ は 1 本の列 $\boldsymbol{x}$ だけからなり、結果は m 個の内積を縦に並べた m 次元ベクトルになる。これは第 3.2.1.1 項の見方 1 にほかならない。

なお、行列の積は一般に可換でない（$\boldsymbol{AB} \neq \boldsymbol{BA}$）ことに注意する。一方、転置については次が成り立つ：

$$(\boldsymbol{AB})^\top = \boldsymbol{B}^\top \boldsymbol{A}^\top \tag{3.16}$$

順序が入れ替わる点に注意する。

3.3　線形写像

3.3.1　行列は写像である

行列 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ を固定すると、ベクトル $\boldsymbol{x} \in \mathbb{R}^n$ に対して $\boldsymbol{Ax} \in \mathbb{R}^m$ を対応させる関数

$$f_{\boldsymbol{A}} : \mathbb{R}^n \to \mathbb{R}^m, \qquad f_{\boldsymbol{A}}(\boldsymbol{x}) = \boldsymbol{Ax} \tag{3.17}$$

が定まる。第 1 回で学んだ関数の記法である。すなわち**行列は n 次元空間から m 次元空間への写像**とみなせる。

定義：線形写像

写像 $f : \mathbb{R}^n \to \mathbb{R}^m$ が、任意の $\boldsymbol{x}, \boldsymbol{y} \in \mathbb{R}^n$、$c \in \mathbb{R}$ に対して

$$f(\boldsymbol{x} + \boldsymbol{y}) = f(\boldsymbol{x}) + f(\boldsymbol{y}) \tag{3.18}$$
$$f(c\boldsymbol{x}) = c\, f(\boldsymbol{x}) \tag{3.19}$$

を満たすとき、f を**線形写像**（linear map）と呼ぶ。

行列による写像 $f_{\boldsymbol{A}}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$ は線形写像である。実際、

$$\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{A}\boldsymbol{y}, \qquad \boldsymbol{A}(c\boldsymbol{x}) = c\,\boldsymbol{A}\boldsymbol{x} \tag{3.20}$$

が成分計算から直ちに確かめられる。逆に、任意の線形写像は行列で表せることが知られている。すなわち**線形写像と行列は同じものの 2 つの表現**である。

3.3.1.1 線形写像が何をしているか

線形写像を $n = m = 2$ の場合で図示したものが図 3.4 である。左が定義域、右がその像であり、$\boldsymbol{A}$ を掛けることで空間全体が引き伸ばされ、傾けられている。

この図から、線形写像の性質が 3 つ読み取れる。

- **等間隔の格子が、等間隔の格子に写る**。直線は直線に写り、平行な直線は平行なまま保たれる
- **原点は原点に写る**。実際 $\boldsymbol{A}\boldsymbol{0} = \boldsymbol{0}$ である
- **平行四辺形は平行四辺形に写る**。これは加法性 $\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{A}\boldsymbol{y}$ の図形的な表現である

3 つ目について補足する。左の図では、$\boldsymbol{x}$ と $\boldsymbol{y}$ を 2 辺とする平行四辺形の対角線が $\boldsymbol{x}+\boldsymbol{y}$ であった。右の図でも、$\boldsymbol{A}\boldsymbol{x}$ と $\boldsymbol{A}\boldsymbol{y}$ を 2 辺とする平行四辺形の対角線が $\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y})$ になっている。すなわち「先に足してから写す」か「先に写してから足す」かで結果が変わらない。これが加法性である。同様に、斉次性 $\boldsymbol{A}(c\boldsymbol{x}) = c\,\boldsymbol{A}\boldsymbol{x}$ は「矢印を c 倍してから写す」ことと「写してから c 倍する」ことが一致する、という性質である。

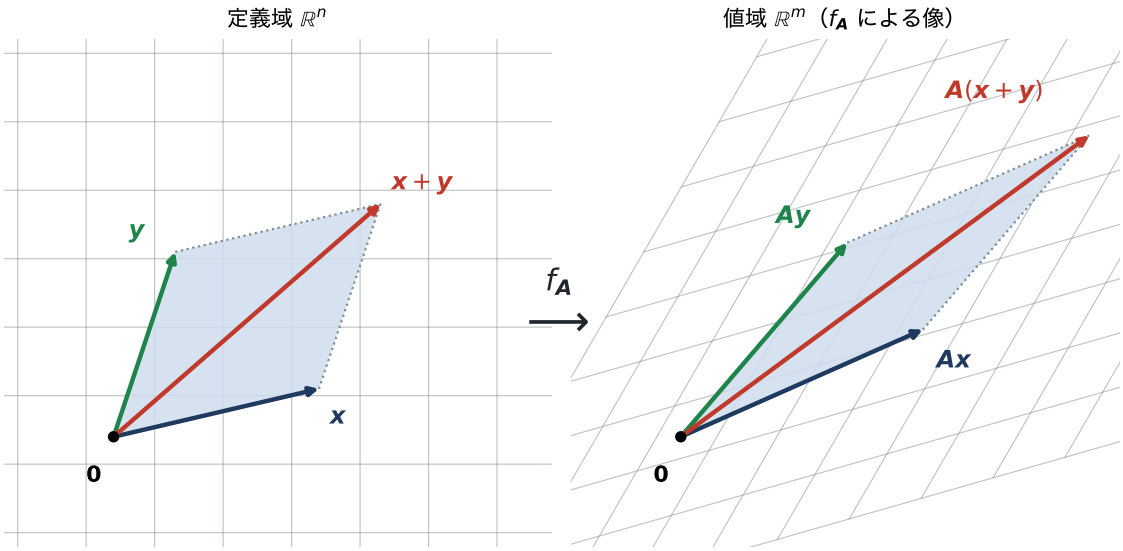


図 3.4　線形写像 $f_{\boldsymbol{A}}(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$ のはたらき（$n = m = 2$ の例）。格子は格子に、原点は原点に、平行四辺形は平行四辺形に写る。右図で $\boldsymbol{A}\boldsymbol{x}, \boldsymbol{A}\boldsymbol{y}$ の作る平行四辺形の対角線が $\boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y})$ になっていることが、加法性にあたる。

3.3.2 線形性が意味すること

線形写像は「直線を直線に、原点を原点に写す」写像である。$f(\boldsymbol{0}) = f(0\cdot\boldsymbol{0}) = 0\cdot f(\boldsymbol{0}) = \boldsymbol{0}$ より、原点は必ず原点に移る。

ここで注意すべきは、第 1 回の線形モデル

$$h(\boldsymbol{x};\boldsymbol{w}) = w_0 + \boldsymbol{w}_{1:d}^{\top}\boldsymbol{x} \tag{3.21}$$

は、$w_0 \neq 0$ のとき**線形写像ではない**。実際、線形写像ならば $f(\mathbf{0}) = \mathbf{0}$ でなければならないが、

$$h(\mathbf{0};\boldsymbol{w}) = w_0 + \boldsymbol{w}_{1:d}^{\top}\mathbf{0} = w_0 \neq 0 \tag{3.22}$$

だからである。（逆に $w_0 = 0$ のときは $h(\boldsymbol{x}) = \boldsymbol{w}_{1:d}^{\top}\boldsymbol{x}$ となり、これは線形写像である。）

このような写像は、線形写像に定数ベクトルを加えたものとして特徴づけられる。

定義：アフィン写像

写像 $g : \mathbb{R}^n \to \mathbb{R}^m$ が、ある行列 $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ とベクトル $\boldsymbol{b} \in \mathbb{R}^m$ を用いて

$$g(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b} \tag{3.23}$$

と書けるとき、g を**アフィン写像**（affine map）と呼ぶ。$\boldsymbol{b} = \mathbf{0}$ の場合が線形写像であり、**線形写像はアフィン写像の特別な場合**である。

線形写像が「原点を原点に写す」のに対し、アフィン写像は「線形写像で変換したうえで、全体を $\boldsymbol{b}$ だけ平行移動する」写像である。直線を直線に写す性質は保たれるが、原点は一般に原点に移らない。

線形性の 2 条件は、アフィン写像では次のように崩れる。$\boldsymbol{b} \neq \mathbf{0}$ のとき

$$g(\boldsymbol{x}+\boldsymbol{y}) = \boldsymbol{A}(\boldsymbol{x}+\boldsymbol{y}) + \boldsymbol{b} = g(\boldsymbol{x}) + g(\boldsymbol{y}) - \boldsymbol{b} \;\neq\; g(\boldsymbol{x}) + g(\boldsymbol{y}) \tag{3.24}$$

$$g(c\boldsymbol{x}) = c\boldsymbol{A}\boldsymbol{x} + \boldsymbol{b} = c\,g(\boldsymbol{x}) + (1-c)\boldsymbol{b} \;\neq\; c\,g(\boldsymbol{x}) \quad (c \neq 1) \tag{3.25}$$

いずれも余分な $\boldsymbol{b}$ の項が残る。

第 2 回で行った「バイアス項の吸収」、すなわち入力に定数 1 を付け加えて $\tilde{\boldsymbol{x}} = (1, x_1, \ldots, x_d)^{\top}$ とする操作は、アフィン写像を 1 次元高い空間の線形写像として扱うための技法である。実際、$h(\boldsymbol{x};\boldsymbol{w}) = \boldsymbol{w}^{\top}\tilde{\boldsymbol{x}}$ と書けば、$\tilde{\boldsymbol{x}}$ を入力とみなす限りこれは線形（$\mathbb{R}^{d+1} \to \mathbb{R}$）である。このように書き換えられるおかげで、以降の議論ではバイアス項を特別扱いせずに済む。

3.4 計画行列

3.4.1 データをまとめる

ここまでは 1 件のデータ $\boldsymbol{x}$ を扱ってきた。N 件の訓練データ $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N \in \mathbb{R}^d$ をまとめて扱うため、各データを行として縦に積み上げた行列を考える。

定義：計画行列

N 件の訓練データ $\boldsymbol{x}_i = (x_{i1}, \ldots, x_{id})^\top$ に対して、バイアス項のための定数列 1 を加えた行列

$$\boldsymbol{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1d} \\ 1 & x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_{N1} & x_{N2} & \cdots & x_{Nd} \end{pmatrix} \in \mathbb{R}^{N \times (d+1)} \tag{3.26}$$

を**計画行列**（design matrix）と呼ぶ。**データ行列**、**観測行列**とも呼ばれる。第 i 行が i 番目のデータに対応する。列については、第 0 列がバイアス項のための定数列であり、第 j 列（$j = 1, \ldots, d$）が j 番目の特徴に対応する。列を 0 から数える点に注意する。

行と列の意味が異なることを、しっかり区別してほしい。第 1 回の家賃の例（特徴が「広さ」と「駅からの距離」の 2 つ、$d = 2$）で説明する。

- **行 $\tilde{\boldsymbol{x}}_i^\top \in \mathbb{R}^{d+1}$：1 件のデータ**。すなわち 1 軒の物件について、定数 1・広さ・駅からの距離を横に並べたもの
- **列 $\boldsymbol{c}_j \in \mathbb{R}^N$：1 つの特徴を全データにわたって縦に並べたベクトル**。例えば $\boldsymbol{c}_1$ は N 軒すべての物件の広さを並べた N 次元ベクトルである

ただし第 0 列 $\boldsymbol{c}_0 = (1, 1, \ldots, 1)^\top$ だけは特徴ではなく、バイアス項のための定数列である。行の長さは特徴の個数 $d+1$、列の長さはデータの個数 N であり、通常 $N \gg d$ であるから、計画行列は縦に細長い形をしている。

3.4.2 予測の全体を一つの式で表す

3.4.2.1 線形モデルの再掲

計画行列に $\boldsymbol{w}$ を掛けることがなぜ予測になるのかを見るために、まず線形モデルを思い出そう。第 1.2.3 項で導入し、第 2.3.3 項で内積の形に書き直したとおり、入力 $\boldsymbol{x} = (x_1, \ldots, x_d)^\top$ に対する予測は

$$h(\boldsymbol{x}; \boldsymbol{w}) = w_0 + w_1 x_1 + \cdots + w_d x_d = \boldsymbol{w}^\top \tilde{\boldsymbol{x}} = \tilde{\boldsymbol{x}}^\top \boldsymbol{w} \tag{3.27}$$

であった。ここで $\tilde{\boldsymbol{x}} = (1, x_1, \ldots, x_d)^\top \in \mathbb{R}^{d+1}$ はバイアス項を吸収した拡張入力であり、最後の等号は内積の対称性による。すなわち **1 件のデータに対する予測は、拡張入力とパラメータの内積 1 つ**である。

3.4.2.2 なぜ $\boldsymbol{X}\boldsymbol{w}$ が予測になるのか

ここで計画行列 $\boldsymbol{X}$ の構造を思い出す。第 3.4.1 項で定めたとおり、$\boldsymbol{X}$ の第 i 行は i 番目のデータの拡張入力 $\tilde{\boldsymbol{x}}_i^\top$ であった。一方、第 3.2.1.1 項の**見方 1** によれば、行列とベクトルの積 $\boldsymbol{X}\boldsymbol{w}$ の第 i 成分は「$\boldsymbol{X}$ の第 i 行と $\boldsymbol{w}$ の内積」である。この 2 つを重ねると、

$$(\boldsymbol{X}\boldsymbol{w})_i = \tilde{\boldsymbol{x}}_i^\top \boldsymbol{w} = h(\boldsymbol{x}_i; \boldsymbol{w}) \tag{3.28}$$

となり、まさに式 (3.27) の予測そのものである。

つまり、$\boldsymbol{X}\boldsymbol{w}$ の各成分は各データへの予測であり、これを N 件すべてについて縦に並べたものが

$$\hat{\boldsymbol{y}} = \begin{pmatrix} h(\boldsymbol{x}_1; \boldsymbol{w}) \\ h(\boldsymbol{x}_2; \boldsymbol{w}) \\ \vdots \\ h(\boldsymbol{x}_N; \boldsymbol{w}) \end{pmatrix} = \begin{pmatrix} \tilde{\boldsymbol{x}}_1^\top \boldsymbol{w} \\ \tilde{\boldsymbol{x}}_2^\top \boldsymbol{w} \\ \vdots \\ \tilde{\boldsymbol{x}}_N^\top \boldsymbol{w} \end{pmatrix} = \boldsymbol{X}\boldsymbol{w} \in \mathbb{R}^N \tag{3.29}$$

である。N **回の内積計算が、行列とベクトルの積 1 つにまとまった**わけである。

3.4.2.3 $\hat{\boldsymbol{y}}$ は訓練データに対する予測である

ここで誤解しやすい点を確認しておく。式 (3.29) の $\hat{\boldsymbol{y}}$ は、**計画行列 $\boldsymbol{X}$ に入っている訓練データ自身に対する予測**である。手元にあって正解 $\boldsymbol{y}$ も分かっているデータに、モデルを当てはめ直した値であり、**当てはめ値**（fitted values）とも呼ばれる。これは「まだ見ていないデータを予測する」という意味での予測ではない。

学習が済んで最適なパラメータ $\boldsymbol{w}^*$ が得られた後、**新しい入力 $\boldsymbol{x}_{\text{new}}$**（訓練データには含まれないもの）に対する予測は、行列ではなく内積 1 つで計算される：

$$\hat{y}_{\text{new}} = h(\boldsymbol{x}_{\text{new}}; \boldsymbol{w}^*) = \tilde{\boldsymbol{x}}_{\text{new}}^\top \boldsymbol{w}^* \tag{3.30}$$

この区別は、第 1 回で導入した 2 つの誤差に対応している。

- **経験損失** L_D：訓練データに対する当てはめ値 $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ と正解 $\boldsymbol{y}$ のずれ。計算できる
- **汎化誤差** L_{gen}：新しいデータ $\boldsymbol{x}_{\text{new}}$ に対する予測のずれ。直接は計算できない

本章および第 4 回・第 5 回で最小化するのは、あくまで前者である。後者を小さくするために何をすべきかが、第 6 回の正則化の主題となる。

3.4.2.4 経験損失を一つの式で表す

さらに第 2 回で見たように、経験損失（二乗損失）は距離の二乗で書けた。真の値を並べたベクトルを $\boldsymbol{y} = (y_1, \ldots, y_N)^\top$ とすれば、

$$L_D(\boldsymbol{w}) = \frac{1}{N} \sum_{i=1}^{N} (y_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{w})^2 = \frac{1}{N} \|\boldsymbol{y} - \hat{\boldsymbol{y}}\|^2 = \frac{1}{N} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 \tag{3.31}$$

となる。N **個の和が、たった一つのノルムの記号にまとまった**。第 4 回・第 5 回では、この式 (3.31) を最小にする $\boldsymbol{w}$ を求めることになる。

3.5 列空間とランク

3.5.1 予測は列の線形結合である

ここで、積 $\boldsymbol{X}\boldsymbol{w}$ を**見方 2**（列の線形結合）で捉え直す。$\boldsymbol{X}$ の列を $\boldsymbol{c}_0, \boldsymbol{c}_1, \ldots, \boldsymbol{c}_d \in \mathbb{R}^N$ とすると、

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w} = w_0 \boldsymbol{c}_0 + w_1 \boldsymbol{c}_1 + \cdots + w_d \boldsymbol{c}_d \tag{3.32}$$

である。ここで $\boldsymbol{c}_0 = (1, 1, \ldots, 1)^\top$ は定数列、$\boldsymbol{c}_j$（$j \geq 1$）は特徴 j の値を全データについて並べたベクトルである。

すなわち**モデルの予測とは、特徴ベクトルたちの線形結合にほかならない**。パラメータ $\boldsymbol{w}$ を学習するとは、この線形結合の係数を選ぶことである。

このことは、学習で到達できる予測の範囲を強く制限する。$\boldsymbol{w}$ をどのように選んでも、$\hat{\boldsymbol{y}}$ は $\boldsymbol{c}_0, \boldsymbol{c}_1, \ldots, \boldsymbol{c}_d$ の線形結合の形をしており、これらが張る集合の外へは出られない。図 3.5 はこの様子を模式的に示したものである。

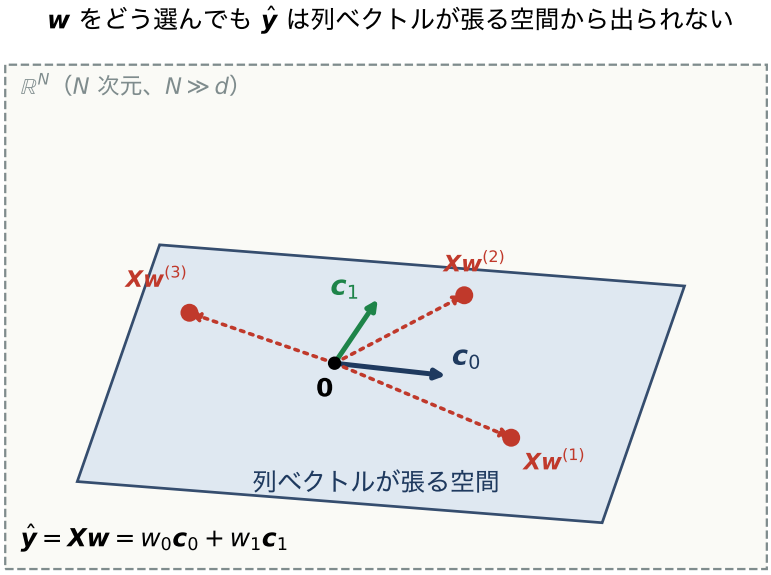


図 3.5　$\boldsymbol{w}$ を動かしたときの予測 $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ の動く範囲。$\boldsymbol{w}$ をどう選んでも $\hat{\boldsymbol{y}}$ は列ベクトルの張る部分空間から出られない。図は $\mathrm{rank}(\boldsymbol{X}) = 2$ の場合（平面）を描いた模式図である。

3.5.2　列空間

パラメータ $\boldsymbol{w}$ は $\mathbb{R}^{d+1}$ を自由に動ける。そこで、$\boldsymbol{w}$ を動かしたときに $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ が取りうる値の全体を考える。

定義：列空間

行列 $\boldsymbol{X} \in \mathbb{R}^{N\times(d+1)}$ に対して、

$$\mathrm{Col}(\boldsymbol{X}) = \{\, \boldsymbol{X}\boldsymbol{w} \mid \boldsymbol{w} \in \mathbb{R}^{d+1} \,\} \subseteq \mathbb{R}^N \tag{3.33}$$

を $\boldsymbol{X}$ の**列空間**（column space）または**値域**（range）と呼ぶ。式 (3.32) より、これは **$\boldsymbol{X}$ の列ベクトルのすべての線形結合からなる集合**である。

記法を確認しておく（第 1.2 節参照）。$\{\cdots \mid \cdots\}$ の縦棒は「ただし」と読み、左側に**集める要素の形**、右側に**その要素を作り出す変数の動く範囲**を書く。したがって式 (3.33) は「$\boldsymbol{w}$ が $\mathbb{R}^{d+1}$ 全体を動くとき、$\boldsymbol{X}\boldsymbol{w}$ という形のベクトルをすべて集めた集合」と読む。集めている要素は $\boldsymbol{w}$ ではなく $\boldsymbol{X}\boldsymbol{w} \in \mathbb{R}^N$ である点に注意する。$\boldsymbol{w}$ は $\mathbb{R}^{d+1}$ の点、$\boldsymbol{X}\boldsymbol{w}$ は $\mathbb{R}^N$ の点であり、$\mathrm{Col}(\boldsymbol{X})$ は後者の住む空間 $\mathbb{R}^N$ の部分集合である。

列空間は $\mathbb{R}^N$ の**部分空間**（subspace）である。すなわち、$\boldsymbol{0}$ を含み、和とスカラー倍について閉じている：

$\boldsymbol{X}\boldsymbol{w}_1 + \boldsymbol{X}\boldsymbol{w}_2 = \boldsymbol{X}(\boldsymbol{w}_1 + \boldsymbol{w}_2) \in \mathrm{Col}(\boldsymbol{X})$、$c\,\boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}(c\boldsymbol{w}) \in \mathrm{Col}(\boldsymbol{X})$ が成り立つからである。

3.5.3 仮説空間の正体

ここで第 1 回を思い出そう。仮説空間 $\mathcal{H}$ は「候補となる関数の集合」という抽象的な定義であった。しかし**訓練データ上での振る舞いだけ**に着目すれば、仮説 $h(\cdot\,;\boldsymbol{w})$ は N 次元ベクトル $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ と同一視できる。したがって

$$\{\,\hat{\boldsymbol{y}} \mid h(\cdot\,;\boldsymbol{w}) \in \mathcal{H}\,\} = \mathrm{Col}(\boldsymbol{X}) \tag{3.34}$$

となる。すなわち**線形モデルの仮説空間の正体は、計画行列の列空間である**。

この事実は重要な帰結をもたらす。真の値のベクトル $\boldsymbol{y} \in \mathbb{R}^N$ は、一般に列空間の**外**にある。なぜなら $\mathrm{Col}(\boldsymbol{X})$ は高々 $d+1$ 次元であるのに対し、$\boldsymbol{y}$ は N 次元空間の任意の点でありうるからである（通常 $N \gg d$）。どれほど $\boldsymbol{w}$ を調整しても、予測は列空間の中しか動けない。したがって

$$\min_{\boldsymbol{w}} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\| = (\boldsymbol{y} \text{ から列空間までの距離}) \tag{3.35}$$

であり、これを達成する $\hat{\boldsymbol{y}}$ は $\boldsymbol{y}$ **の列空間への正射影**にほかならない。

最小二乗法＝$\boldsymbol{y}$ の列空間への正射影

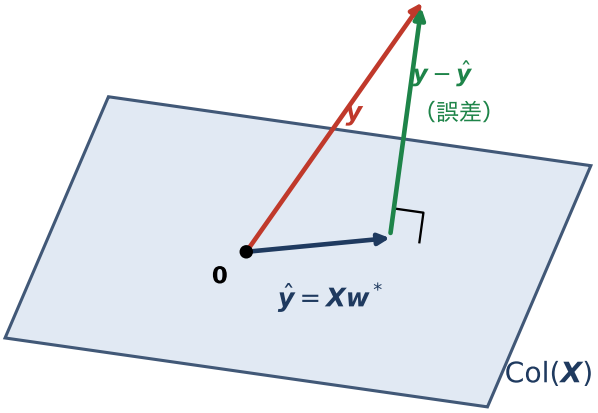


図 3.6　列空間と最小二乗法。予測 $\boldsymbol{X}\boldsymbol{w}$ は列空間の中しか動けないため、誤差を最小にするのは $\boldsymbol{y}$ を列空間へ正射影した点である。

第 2 回で学んだ正射影が、ここで再び現れる。第 4 回ではこの幾何学的描像から**正規方程式**（normal equation）を導く。これは「誤差ベクトル $\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}$ が列空間のすべての列と直交する」という条件 $\boldsymbol{X}^\top(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}) = \boldsymbol{0}$ を整理した

$$\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^\top\boldsymbol{y} \tag{3.36}$$

のことであり、最適なパラメータ $\boldsymbol{w}^*$ が**連立一次方程式を解くだけで求まる**ことを意味する。

3.5.4 ランク

列空間の「大きさ」を測る量がランクである。

定義：ランク

行列 $\boldsymbol{A}$ の列空間の次元を $\boldsymbol{A}$ の**ランク**（rank、階数）と呼び、$\mathrm{rank}(\boldsymbol{A})$ と書く。これは、$\boldsymbol{A}$ の列ベクトルのうち**線形独立**なものの最大個数に等しい。

線形独立の定義は第 3.2.3 項で与えた（式 (3.12)、すなわち**どの列も他の列の線形結合で表せない**こと）。そこで見たとおり、線形独立な列が r 本あれば張られる空間は r 次元になる。ランクとは、まさにこの r のことである。図 3.5 で平面として描いたのは $\mathrm{rank}(\boldsymbol{X}) = 2$ の場合であり、一般には $\mathrm{rank}(\boldsymbol{X})$ 次元の部分空間になる。

$\boldsymbol{X} \in \mathbb{R}^{N\times(d+1)}$ に対して、常に $\mathrm{rank}(\boldsymbol{X}) \le \min(N, d+1)$ が成り立つ。等号が成り立つとき**フルランク**（full rank）であるという。

3.5.5 ランク落ちと多重共線性

$\mathrm{rank}(\boldsymbol{X}) < d+1$ となる場合、すなわち列が線形従属な場合を考えよう。このとき、ある $\boldsymbol{v} \neq \boldsymbol{0}$ が存在して $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる。したがって任意の $\boldsymbol{w}$ に対して

$$\boldsymbol{X}(\boldsymbol{w} + \boldsymbol{v}) = \boldsymbol{X}\boldsymbol{w} + \boldsymbol{X}\boldsymbol{v} = \boldsymbol{X}\boldsymbol{w} \tag{3.37}$$

となり、**異なるパラメータが全く同じ予測を与える**。すなわち最適なパラメータ $\boldsymbol{w}^*$ が一意に定まらない。

これは実データで頻繁に起こる。例えば、物件の広さを「平方メートル」と「坪」の 2 つの列として記録した場合、$\boldsymbol{c}_{\text{坪}} = 0.3025\,\boldsymbol{c}_{\mathrm{m}^2}$ という関係があり、完全に線形従属である。より一般に、複数の特徴が強く相関している状況を**多重共線性**（multicollinearity）と呼ぶ。相関するのは**列どうし**、すなわち特徴どうしである点に注意する。行は個々のデータに対応しており、似た物件が何件あっても $\mathrm{rank}(\boldsymbol{X}) \le d+1$ という上限は変わらない。問題になるのは「$\boldsymbol{c}_i$ と $\boldsymbol{c}_j$ が似ている」という列の間の関係である。

厳密に線形従属でなくとも、ほぼ従属であればパラメータの推定は極めて不安定になり、データのわずかな変化で $\boldsymbol{w}^*$ が大きく変動する。次の例でそれを確かめよう。

3.5.5.1 例：ほぼ線形従属な 2 つの特徴

$N = 4$ 件の物件について、家賃を予測する問題を考える。

- 出力 y：**家賃**（万円）
- 特徴 1：広さ（m^2）
- 特徴 2：部屋数（室）

すなわち $d = 2$ であり、計画行列は $\boldsymbol{X} \in \mathbb{R}^{4\times 3}$ となる。その 3 本の列はそれぞれ

$$\begin{aligned}
&\boldsymbol{c}_0 = (1,\ 1,\ 1,\ 1)^\top && \text{バイアス項のための定数列}\\
&\boldsymbol{c}_1 = (22,\ 38,\ 61,\ 79)^\top && 4\text{ 件の広さ（}\mathrm{m}^2\text{）}\\
&\boldsymbol{c}_2 = (1,\ 2,\ 3,\ 4)^\top && 4\text{ 件の部屋数（室）}
\end{aligned}$$

であり、これらを並べると

$$\boldsymbol{X} = \begin{pmatrix} 1 & 22 & 1 \\ 1 & 38 & 2 \\ 1 & 61 & 3 \\ 1 & 79 & 4 \end{pmatrix}$$

となる。各行が 1 件の物件であり、例えば第 3 行は「広さ $61\,\mathrm{m}^2$、3 室」の物件を表す。

部屋数が多ければ広さも大きいので、この 2 列は強く相関する：

$$\boldsymbol{c}_1 \approx 20\,\boldsymbol{c}_2$$

実際 $20\,\boldsymbol{c}_2 = (20, 40, 60, 80)^\top$ であり、$\boldsymbol{c}_1 = (22, 38, 61, 79)^\top$ とのずれは各成分 2 以内にすぎない。ただし厳密には $\boldsymbol{c}_1 \neq 20\,\boldsymbol{c}_2$ なので $\mathrm{rank}(\boldsymbol{X}) = 3$、すなわちフルランクであり、解は数学的には一意に定まる。

それでも困ったことが起こる。次の 2 つのパラメータを比べてみよう。

$$\begin{aligned} \boldsymbol{w}^{(\mathrm{A})} &= (0,\ 0.5,\ 0)^\top & \Rightarrow \quad \hat{\boldsymbol{y}} &= (11,\ 19,\ 30.5,\ 39.5)^\top \\ \boldsymbol{w}^{(\mathrm{B})} &= (0,\ 0,\ 10)^\top & \Rightarrow \quad \hat{\boldsymbol{y}} &= (10,\ 20,\ 30,\ 40)^\top \end{aligned}$$

$\boldsymbol{w}^{(\mathrm{A})}$ は「広さ $1\,\mathrm{m}^2$ につき 0.5 万円、部屋数は家賃に無関係」、$\boldsymbol{w}^{(\mathrm{B})}$ は「部屋数 1 室につき 10 万円、広さは家賃に無関係」という、**解釈が正反対のモデル**である。にもかかわらず、予測はどのデータでも 1 万円以内しか違わない。

3.5.5.2 なぜ 2 つの差を見るのか

式 (3.37) が示していたのは「$\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ を満たす方向 $\boldsymbol{v}$ に沿って $\boldsymbol{w}$ をずらしても予測は変わらない」ということであった。つまり 2 つのパラメータが同じ予測を与えるかどうかは、**その差がそのような方向を向いているか**で決まる。そこで差を計算すると

$$\boldsymbol{w}^{(\mathrm{B})} - \boldsymbol{w}^{(\mathrm{A})} = (0,\ -0.5,\ 10)^\top = -0.5\,\boldsymbol{v}, \qquad \boldsymbol{v} = (0,\ 1,\ -20)^\top$$

となる。この $\boldsymbol{v}$ は、まさに $\boldsymbol{c}_1 \approx 20\,\boldsymbol{c}_2$ という列どうしの関係を係数の形で書いたものである。実際

$$\boldsymbol{X}\boldsymbol{v} = 0 \cdot \boldsymbol{c}_0 + 1 \cdot \boldsymbol{c}_1 - 20 \cdot \boldsymbol{c}_2 = \begin{pmatrix} 22 \\ 38 \\ 61 \\ 79 \end{pmatrix} - \begin{pmatrix} 20 \\ 40 \\ 60 \\ 80 \end{pmatrix} = \begin{pmatrix} 2 \\ -2 \\ 1 \\ -1 \end{pmatrix}$$

であり、2 つの列がほぼ打ち消し合っている。

3.5.5.3 なぜ $\boldsymbol{X}\boldsymbol{v}$ が「0 に近い」といえるのか

まず、$\boldsymbol{0}$ に近いといっているのが**どのベクトルか**を確認する。近いのは $\boldsymbol{v}$ ではなく、その像 $\boldsymbol{X}\boldsymbol{v}$ の方である。実際 $\boldsymbol{v} = (0,\ 1,\ -20)^\top$ 自身は $\|\boldsymbol{v}\| = \sqrt{401} \approx 20.0$ であり、決して小さなベクトルではない。

- $\boldsymbol{v} \in \mathbb{R}^3$：**パラメータの空間**の点。$\boldsymbol{w}$ をずらす向きを表す
- $\boldsymbol{X}\boldsymbol{v} \in \mathbb{R}^4$：**予測の空間**の点。そのずらしによって予測 $\hat{\boldsymbol{y}}$ がどれだけ変わるかを表す

「予測がほとんど変わらない」と言いたいのだから、小ささを問題にすべきは後者、すなわち $\boldsymbol{X}\boldsymbol{v}$ である。

その上で、ベクトルが「小さい」かどうかは、**何と比べるか**を決めなければ意味をもたない。そこで、$\boldsymbol{w}$ を**同じ長さだけ**動かしたときの予測の変化量を比べる。$\|\boldsymbol{v}\| = \sqrt{1+400} \approx 20.0$ なので、同じ長さをもつ別の方向として $\boldsymbol{u} = (0,\ 20,\ 0)^\top$（$\|\boldsymbol{u}\| = 20$）をとると

$$\boldsymbol{X}\boldsymbol{u} = 20\,\boldsymbol{c}_1 = (440,\ 760,\ 1220,\ 1580)^\top, \qquad \|\boldsymbol{X}\boldsymbol{u}\| \approx 2181$$
$$\boldsymbol{X}\boldsymbol{v} = (2,\ -2,\ 1,\ -1)^\top, \qquad \|\boldsymbol{X}\boldsymbol{v}\| = \sqrt{10} \approx 3.2$$

となる。すなわち、$\boldsymbol{w}$ を同じ距離だけ動かしても、$\boldsymbol{v}$ の向きに動かしたときの予測の変化は他の向きの約 700 分の 1 でしかない。この意味で $\boldsymbol{X}\boldsymbol{v}$ は $\boldsymbol{0}$ に近い。

3.5.5.4　損失関数の形で見る：ほぼ平らな谷

ここが多重共線性のいちばん重要な点なので、経験損失の形として見ておこう。

完全に線形従属なら $\boldsymbol{X}\boldsymbol{v}$ はちょうど $\boldsymbol{0}$ になり、この方向に $\boldsymbol{w}$ を動かしても予測は**まったく**変わらない（式 (3.37)）。ほぼ従属な今の場合は、まったくではないがほとんど変わらない。予測が変わらなければ経験損失 $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ も変わらない。すなわち L_D は $\boldsymbol{v}$ の方向に**ほぼ平らな谷**になっている（図 3.7 左）。解釈が正反対の $\boldsymbol{w}^{(\mathrm{A})}$ と $\boldsymbol{w}^{(\mathrm{B})}$ が同程度に良い解に見えたのは、2 点がこの谷の底に並んでいたからである。

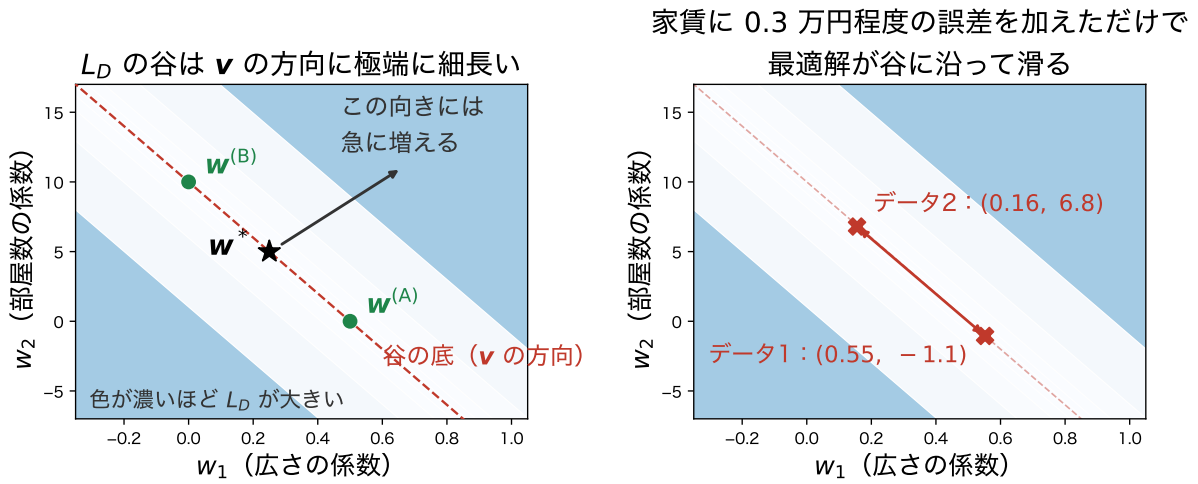


図 3.7　ほぼ平らな谷。左：経験損失 L_D の等高線。$\boldsymbol{v} = (0, 1, -20)^\top$ の方向にはほとんど増えず、それと交わる向きには急に増える。右：家賃に 0.3 万円程度の誤差を加えた 2 通りのデータについて最適解を求めたもの。谷に沿って大きく離れ、「広さ中心のモデル」と「部屋数中心のモデル」のどちらにもなりうる。なお縦軸と横軸で目盛りの刻みが異なるため、谷の細さは実際よりも緩やかに見えている。

谷が平らであることの帰結は深刻である。手元のデータがわずかに違えば、谷の底のどこで最小値を取るかは簡単に入れ替わる。図 3.7 右は、家賃に 0.3 万円程度の誤差を加えた 2 通りのデータについて最適解を求めたものである。得られる $\boldsymbol{w}^*$ は谷に沿って大きく滑り、「広さが効いている」とも「部屋数が効いている」とも結論できてしまう。これが**推定が不安定になる**ということの正体である。

なお、谷の**向き**と**細さ**は計画行列 $\boldsymbol{X}$ だけで決まる。図を描くには家賃の実測値 $\boldsymbol{y}$ が必要だが、$\boldsymbol{y}$ を変えても谷の**底の位置**が動くだけで、谷の細長さそのものは変わらない。多重共線性は $\boldsymbol{X}$ の性質であり、出力がどのような値であっても同じ不安定さが生じる。

解の一意性を回復し、推定を安定させることが、第 6 回で学ぶ**正則化**の重要な役割の一つである。第 1 回で見た「仮説空間が大きすぎると過学習する」という問題と、ここで見た「列が従属だと解が定まらない」という問題は、いずれも**モデルの自由度が過剰である**ことに由来しており、正則化はその両方に効く処方箋となる。

3.5.6 数値例

3 件のデータについて、特徴を「広さ（m^2）」と「広さ（坪）」とした場合の計画行列

$$\boldsymbol{X} = \begin{pmatrix} 1 & 20 & 6 \\ 1 & 40 & 12 \\ 1 & 60 & 18 \end{pmatrix}$$

を考える。第 3 列は第 2 列の 0.3 倍であり、線形従属である。実際、$\boldsymbol{v} = (0, 0.3, -1)^\top$ とすると

$$\boldsymbol{X}\boldsymbol{v} = 0 \cdot \boldsymbol{c}_0 + 0.3\,\boldsymbol{c}_1 - 1 \cdot \boldsymbol{c}_2 = \begin{pmatrix} 6 \\ 12 \\ 18 \end{pmatrix} - \begin{pmatrix} 6 \\ 12 \\ 18 \end{pmatrix} = \boldsymbol{0}$$

となる。よって $\mathrm{rank}(\boldsymbol{X}) = 2 < 3$ であり、$\boldsymbol{w}^*$ に $\boldsymbol{v}$ の任意の定数倍を加えても予測は変わらない。この場合、列空間は $\mathbb{R}^3$ の中の 2 次元平面であり、3 次元空間全体を張ることはできない。

3.6 行列のノルム

第 2 回では、ベクトルの「大きさ」をノルム $\|\boldsymbol{x}\| = \sqrt{\boldsymbol{x}^\top \boldsymbol{x}}$ で測った。行列に対しても同様に大きさを測りたい場面がある。最も基本的なものが**フロベニウスノルム**である。

3.6.1 定義

定義：フロベニウスノルム

行列 $\boldsymbol{A} \in \mathbb{R}^{m \times n}$ に対して、

$$\|\boldsymbol{A}\|_F = \sqrt{\sum_{i=1}^{m} \sum_{j=1}^{n} a_{ij}^2} \tag{3.38}$$

を $\boldsymbol{A}$ の**フロベニウスノルム**（Frobenius norm）と呼ぶ。添字の F は Frobenius の頭文字である。

定義を見ればわかるとおり、これは**行列の全成分を 1 本のベクトルとみなしたときのユークリッドノルム**にほかならない。実際、$m \times n$ 行列の成分を順に並べて mn 次元ベクトルを作れば、そのノルムが $\|\boldsymbol{A}\|_F$ である。したがって、第 2 回で示したノルムの 3 性質（非負性・斉次性・三角不等式）はそのまま成り立つ。

例えば

$$\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ -2 & 4 \end{pmatrix} \quad \Longrightarrow \quad \|\boldsymbol{A}\|_F = \sqrt{1^2 + 2^2 + (-2)^2 + 4^2} = \sqrt{25} = 5$$

である。

3.6.2 列ベクトルとの関係

$\boldsymbol{A}$ の列を $\boldsymbol{c}_1, \ldots, \boldsymbol{c}_n$ とすると、二重和を列ごとにまとめることで

$$\|\boldsymbol{A}\|_F^2 = \sum_{j=1}^{n} \sum_{i=1}^{m} a_{ij}^2 = \sum_{j=1}^{n} \|\boldsymbol{c}_j\|^2 \tag{3.39}$$

が得られる。すなわち**フロベニウスノルムの二乗は、各列ベクトルのノルムの二乗和**である。行についても同様である。

また、トレース（正方行列の対角成分の和）$\mathrm{tr}(\boldsymbol{B}) = \sum_i b_{ii}$ を用いると

$$\|\boldsymbol{A}\|_F^2 = \mathrm{tr}(\boldsymbol{A}^\top \boldsymbol{A}) \tag{3.40}$$

と書ける。実際、$(\boldsymbol{A}^\top \boldsymbol{A})_{jj} = \sum_i a_{ij}^2 = \|\boldsymbol{c}_j\|^2$ であり、その和をとれば前式に一致する。この表現は、第 4 回以降で行列の微分を扱う際に有用である。

3.6.3 どのような場面で使うか

フロベニウスノルムは、機械学習において主に次の 3 つの場面で用いられる。

■3.6.3.1 (1) 正則化：モデルの複雑さを測る 第 1 回で見たように、仮説空間が大きすぎると過学習が生じる。第 6 回で学ぶ **L2 正則化**は、パラメータの大きさを罰則として加えることでこれを抑制する。線形モデルでは経験損失に $\lambda\|\boldsymbol{w}\|^2$ を加えるが、ニューラルネットワークのようにパラメータが行列 $\boldsymbol{W}$ である場合は、

$$\min_{\boldsymbol{W}} \left\{ L_D(\boldsymbol{W}) + \lambda \|\boldsymbol{W}\|_F^2 \right\} \tag{3.41}$$

とフロベニウスノルムを用いる。これは**重み減衰**（weight decay）と呼ばれ、深層学習で標準的に使われる手法である。「重みを不必要に大きくしない」という要請を、行列の大きさとして数式化したものである。

■3.6.3.2 (2) 行列の近さを測る：低ランク近似 2 つの行列がどれだけ近いかは、差のフロベニウスノルム $\|\boldsymbol{A} - \boldsymbol{B}\|_F$ で測る。第 2 回でベクトルの距離を $\|\boldsymbol{x} - \boldsymbol{y}\|$ で測ったのと同じ考え方である。

特に重要なのが**低ランク近似**である。前節で見たように、ランクは列空間の次元、すなわちデータの「実質的な自由度」を表す。そこで、与えられた行列 $\boldsymbol{A}$ を、ランクが r 以下の行列 $\boldsymbol{B}$ で近似する問題

$$\min_{\mathrm{rank}(\boldsymbol{B}) \le r} \|\boldsymbol{A} - \boldsymbol{B}\|_F \tag{3.42}$$

を考える。この解は特異値分解によって与えられることが知られている。主成分分析による次元削減、推薦システムにおける行列分解、大規模言語モデルの効率的な微調整手法である LoRA などは、いずれもこの考え方に基づいている。

■3.6.3.3 (3) 収束判定と勾配の大きさ 第 5 回で学ぶ勾配降下法のような反復計算では、更新の前後でパラメータがほとんど変化しなくなった時点で計算を止める。このとき $\|\boldsymbol{W}^{(t+1)} - \boldsymbol{W}^{(t)}\|_F < \varepsilon$ を判定条件に用いる。また、深層学習では勾配が発散することを防ぐため、勾配のノルムが一定値を超えたら縮小する**勾配クリッピング**（gradient clipping）という手法が用いられるが、ここでもフロベニウスノルムが使われる。

3.6.4 他の行列ノルムとの違い

行列のノルムはフロベニウスノルムだけではない。代表的なものに**スペクトルノルム**（作用素ノルム）

$$\|\boldsymbol{A}\|_2 = \max_{\boldsymbol{x} \neq \boldsymbol{0}} \frac{\|\boldsymbol{A}\boldsymbol{x}\|}{\|\boldsymbol{x}\|} \tag{3.43}$$

がある。これは「行列がベクトルを最大何倍に引き伸ばすか」を表す量であり、線形写像としての性質を測る。両者の間には $\|\boldsymbol{A}\|_2 \le \|\boldsymbol{A}\|_F$ という関係がある。

目的に応じた使い分けを簡単にまとめる。

- **フロベニウスノルム**：成分の大きさの総量を測りたいとき（正則化、近似誤差）。計算が容易で微分しやすい
- **スペクトルノルム**：変換としての増幅率を抑えたいとき（安定性の解析、GAN の Spectral Normalization など）

本講義で扱うのは主にフロベニウスノルムである。

3.7 固有値と固有ベクトル（概念）

最後に、行列のもう一つの重要な見方に触れる。本節は概念の紹介にとどめ、詳細は第 6 回以降で必要に応じて扱う。

定義：固有値と固有ベクトル

正方行列 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$ に対して、

$$\boldsymbol{A}\boldsymbol{v} = \lambda \boldsymbol{v}, \qquad \boldsymbol{v} \neq \boldsymbol{0} \tag{3.44}$$

を満たす実数 λ を**固有値**（eigenvalue）、$\boldsymbol{v}$ を対応する**固有ベクトル**（eigenvector）と呼ぶ。

3.7.1 幾何学的な意味

行列は一般にベクトルの向きと長さの両方を変える（第 3.3 節）。しかし固有ベクトルだけは**向きが変わらず、長さだけが λ 倍される**。すなわち固有ベクトルは、その線形変換の「軸」を表す（図 3.8 左）。$\lambda < 0$ のときは向きが逆になるが、同じ直線上にとどまる点は変わらない。

図 3.8 右のように、単位円を $\boldsymbol{A}$ で写すと楕円になる。このとき**楕円の軸の向きが固有ベクトル、軸の長さが固有値**に対応する。ただしこの描像が成り立つのは $\boldsymbol{A}$ が**対称行列**（$\boldsymbol{A}^\top = \boldsymbol{A}$）の場合である。幸い、機械学習で固有値を考える相手は $\boldsymbol{X}^\top\boldsymbol{X}$、共分散行列、ヘッセ行列のようにいずれも対称行列なので、この「楕円の軸」という描像をそのまま使える。

3.7.2 特性方程式

固有値を実際に求める方法を見ておく。$\boldsymbol{I}_n$ を**単位行列**（identity matrix）、すなわち対角成分がすべて 1、それ以外が 0 の $n \times n$ 行列とする。任意の $\boldsymbol{x}$ に対して $\boldsymbol{I}_n\boldsymbol{x} = \boldsymbol{x}$ が成り立つ。これを使うと定義式は

$$\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v} \iff (\boldsymbol{A} - \lambda\boldsymbol{I}_n)\,\boldsymbol{v} = \boldsymbol{0} \tag{3.45}$$

と書き直せる。

ここで第 3.5 節の議論がそのまま効く。式 (3.45) が $\boldsymbol{v} \neq \boldsymbol{0}$ の解をもつということは、**行列 $\boldsymbol{A} - \lambda\boldsymbol{I}_n$ の列が線形従属**だということである（ランク落ちしている、ということに他ならない）。

2×2 の場合、この条件は簡単に書ける。$\boldsymbol{M} = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ の 2 本の列 $(a,c)^\top$ と $(b,d)^\top$ が平行であることと

$$\det \boldsymbol{M} = ad - bc = 0 \tag{3.46}$$

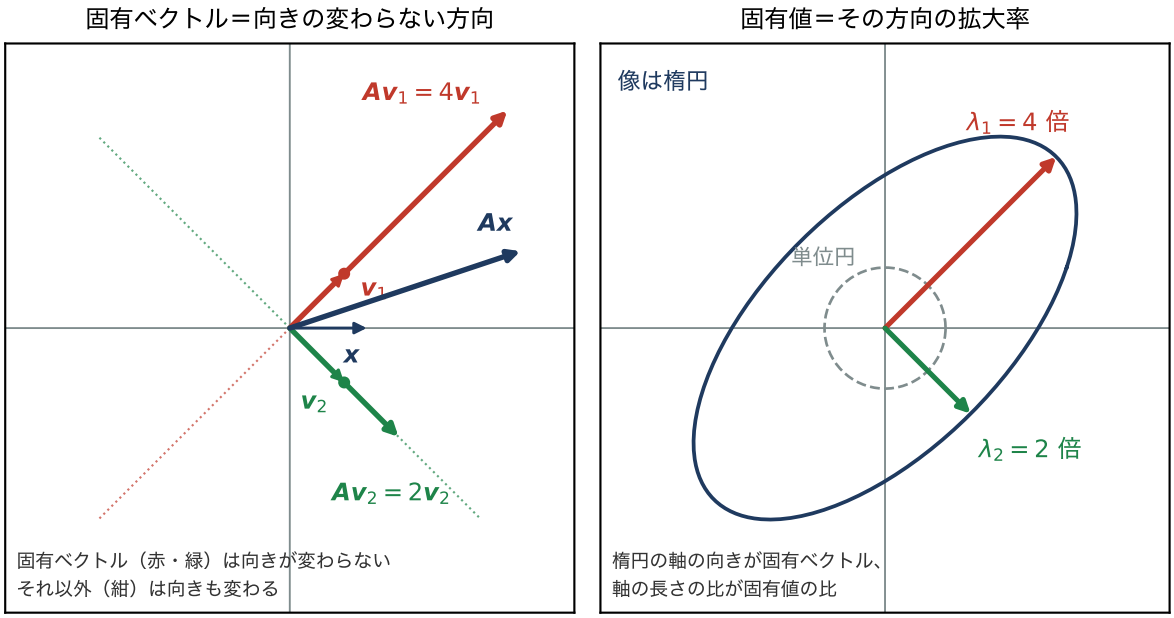


図 3.8　$\boldsymbol{A} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ による変換。左：固有ベクトル $\boldsymbol{v}_1, \boldsymbol{v}_2$ は向きが変わらず、長さだけがそれぞれ 4 倍、2 倍になる。固有ベクトルでない $\boldsymbol{x}$ は向きまで変わる。右：単位円の像は楕円になり、楕円の軸の向きが固有ベクトル、軸の長さが固有値に対応する。

は同値である。この量 $\det \boldsymbol{M}$ を**行列式**（determinant）と呼ぶ。したがって固有値は

$$\det(\boldsymbol{A} - \lambda \boldsymbol{I}_n) = 0 \tag{3.47}$$

を満たす λ として求まる。これを**特性方程式**（characteristic equation）と呼ぶ。

3.7.2.1　例

$\boldsymbol{A} = \begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ の固有値と固有ベクトルを求めよう。特性方程式は

$$\det \begin{pmatrix} 3-\lambda & 1 \\ 1 & 3-\lambda \end{pmatrix} = (3-\lambda)^2 - 1 = \lambda^2 - 6\lambda + 8 = (\lambda - 2)(\lambda - 4) = 0$$

であるから、固有値は $\lambda_1 = 4$, $\lambda_2 = 2$ である。それぞれに対して式 (3.45) を解くと

$$\lambda_1 = 4: \quad \begin{pmatrix} -1 & 1 \\ 1 & -1 \end{pmatrix} \boldsymbol{v} = \boldsymbol{0} \;\Rightarrow\; \boldsymbol{v}_1 = (1,\ 1)^\top \text{（の定数倍）}$$

$$\lambda_2 = 2: \quad \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix} \boldsymbol{v} = \boldsymbol{0} \;\Rightarrow\; \boldsymbol{v}_2 = (1,\ -1)^\top \text{（の定数倍）}$$

を得る。実際に確かめると $\boldsymbol{A}\boldsymbol{v}_1 = (4, 4)^\top = 4\,\boldsymbol{v}_1$、$\boldsymbol{A}\boldsymbol{v}_2 = (2, -2)^\top = 2\,\boldsymbol{v}_2$ であり、どちらも向きが変わらず長さだけが λ 倍になっている。これが図 3.8 で描いた状況である。なお固有ベクトルは定数倍の自由度をもつので、長さを 1 に揃えて $\boldsymbol{v}_1 = (1,1)^\top/\sqrt{2}$ と書くことも多い。

3.7.3 機械学習での現れ方

機械学習では次のような場面で現れる（図 3.9）。

- **主成分分析**：データの分散が最大となる方向が、共分散行列の最大固有値に対応する固有ベクトルである
- **最適化の収束**：第 5 回で扱う勾配降下法の収束の速さは、損失関数の曲がり具合（ヘッセ行列）の固有値の比で決まる
- **数値的安定性**：$\boldsymbol{X}^\top \boldsymbol{X}$ の最小固有値が 0 に近いとき、多重共線性が生じており推定が不安定になる

3 つはいずれも**「どの向きにどれだけ伸びているか」**を固有値と固有ベクトルで読んでいる点で共通している。

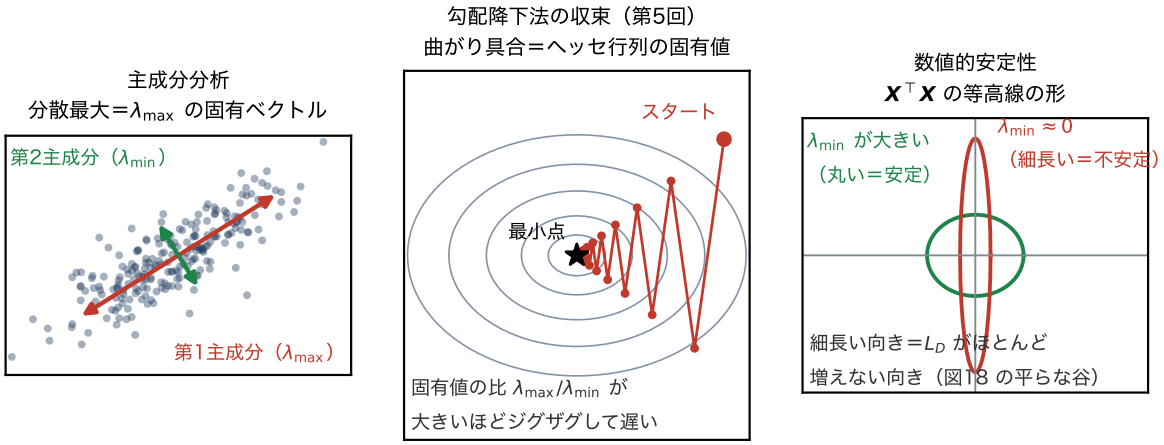


図 3.9　固有値が現れる 3 つの場面（概念図）。左：主成分分析。データが最も散らばる方向が共分散行列の最大固有値の固有ベクトルである。中：勾配降下法。等高線が細長い（固有値の比が大きい）ほど経路がジグザグし、収束が遅くなる。右：数値的安定性。$\boldsymbol{X}^\top \boldsymbol{X}$ の最小固有値が 0 に近いほど等高線が細長くなり、その向きには L_D がほとんど増えない。これが図 3.7 で見た「平らな谷」である。

3.7.4 ランクとの関係

上の 3 番目の項目は、前節のランクの議論と直接つながっている。実際、$\boldsymbol{X}^\top \boldsymbol{X}$ について次の 3 つは同値である：

1. $\mathrm{rank}(\boldsymbol{X}) < d + 1$（列が線形従属、多重共線性がある）
2. $\boldsymbol{X}^\top \boldsymbol{X}$ が固有値 0 をもつ
3. $\boldsymbol{X}^\top \boldsymbol{X}$ が半正定値だが正定値ではない

第 2 回で述べたように、$\boldsymbol{X}^\top \boldsymbol{X}$ は常に半正定値である（任意の $\boldsymbol{v}$ に対し $\boldsymbol{v}^\top \boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{v} = \|\boldsymbol{X}\boldsymbol{v}\|^2 \geq 0$）。正定値でない、すなわち $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる $\boldsymbol{v} \neq \boldsymbol{0}$ が存在することが、前節で見た「解が一意に定まらない」状況にほかならない。

3.8 まとめ

- 行列は数を長方形に並べたものであり、線形写像と同一視できる
- 積 $\boldsymbol{A}\boldsymbol{x}$ には「行との内積」と「列の線形結合」の 2 つの見方がある
- N 件のデータを積み上げた計画行列 $\boldsymbol{X}$ により、予測全体が $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$、経験損失が $\frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ と書ける
- 予測 $\boldsymbol{X}\boldsymbol{w}$ は $\boldsymbol{X}$ の列の線形結合であり、その全体である列空間 $\mathrm{Col}(\boldsymbol{X})$ が線形モデルの仮説空間の正体である
- $\boldsymbol{y}$ は一般に列空間の外にあり、最小二乗法は $\boldsymbol{y}$ の列空間への正射影を求める問題である
- ランクは列空間の次元であり、ランクが落ちると（多重共線性）解が一意に定まらない
- フロベニウスノルム $\|\boldsymbol{A}\|_F$ は行列の大きさを測る。正則化（重み減衰）、行列の近さ（低ランク近似）、収束判定に用いられる

次回（第 4 回）は、本章で得た $\min_{\boldsymbol{w}} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ という定式化を出発点に、最小二乗法を射影の幾何学として解き、正規方程式を導く。

3.9 演習問題

1. **行列とベクトルの積**

$$\boldsymbol{A} = \begin{pmatrix} 2 & 0 & 1 \\ -1 & 3 & 2 \end{pmatrix}, \qquad \boldsymbol{x} = \begin{pmatrix} 1 \\ 2 \\ -1 \end{pmatrix}$$

とする。

(a) $\boldsymbol{A}$ は何行何列の行列か。$\boldsymbol{A}\boldsymbol{x}$ は何次元のベクトルか。

(b) $\boldsymbol{A}\boldsymbol{x}$ を「行との内積」として計算せよ。

(c) $\boldsymbol{A}\boldsymbol{x}$ を「列の線形結合」として計算し、(b) と一致することを確認せよ。

(d) $\boldsymbol{A}^\top$ を書け。また $\boldsymbol{A}^\top$ は何行何列か。

2. **線形写像**

(a) $f(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x}$ が線形写像であること、すなわち $f(\boldsymbol{x}+\boldsymbol{y}) = f(\boldsymbol{x}) + f(\boldsymbol{y})$ と $f(c\boldsymbol{x}) = cf(\boldsymbol{x})$ を、行列とベクトルの積の定義から証明せよ。

(b) $g(\boldsymbol{x}) = \boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}$（$\boldsymbol{b} \neq \boldsymbol{0}$）は線形写像でないことを、$g(\boldsymbol{0})$ を計算して示せ。このような写像を何と呼ぶか。

3. **計画行列**　3 軒の物件について、広さ（m^2）と駅からの距離（分）が $(20, 5)$、$(35, 10)$、$(50, 3)$ であり、家賃（万円）が $12, 15, 20$ であるとする。

(a) バイアス項を含む計画行列 $\boldsymbol{X}$ と、目的変数のベクトル $\boldsymbol{y}$ を書け。

(b) $\boldsymbol{X}$ は何行何列か。また、行と列はそれぞれ何を表すか。

(c) $\boldsymbol{w} = (3, 0.5, -0.3)^\top$ のとき、予測ベクトル $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ を求めよ。

(d) この $\boldsymbol{w}$ に対する経験損失 $\frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を求めよ。

4. **列空間**

$$\boldsymbol{X} = \begin{pmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 6 \end{pmatrix}$$

とする。

(a) $\mathrm{Col}(\boldsymbol{X})$ の要素を、$\boldsymbol{w} = (w_0, w_1)^\top$ を用いて具体的に書き下せ。

(b) $\mathrm{Col}(\boldsymbol{X})$ は $\mathbb{R}^3$ の中でどのような図形か。その次元はいくつか。

(c) $\boldsymbol{y} = (1, 2, 4)^\top$ は $\mathrm{Col}(\boldsymbol{X})$ に属するか。属さない場合、それは何を意味するか。

5. **ランクと多重共線性**

$$\boldsymbol{X} = \begin{pmatrix} 1 & 2 & 4 \\ 1 & 3 & 6 \\ 1 & 5 & 10 \end{pmatrix}$$

とする。

(a) 第 3 列と第 2 列の関係を述べよ。

(b) $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ を満たす $\boldsymbol{v} \neq \boldsymbol{0}$ を 1 つ求めよ。

(c) $\mathrm{rank}(\boldsymbol{X})$ を求めよ。

(d) $\boldsymbol{w}^* = (1, 2, 1)^\top$ が経験損失を最小にするとき、同じ予測を与える別のパラメータを 1 つ挙げよ。この事実は、最適なパラメータの一意性について何を意味するか。

6. **仮説空間と列空間**　N 件のデータに対する線形モデルを考える。

(a) $N = 100$、$d = 3$（バイアス項を含めて 4 列）のとき、$\mathrm{Col}(\boldsymbol{X})$ は $\mathbb{R}^{100}$ の中の高々何次元の部分空間か。

(b) 真の値のベクトル $\boldsymbol{y} \in \mathbb{R}^{100}$ が $\mathrm{Col}(\boldsymbol{X})$ に属さないとき、経験損失を 0 にできるか。理由とともに述べよ。

(c) 第 1 回の問 7 では「N 個のデータ点に対し $M = N - 1$ 次の多項式なら経験損失を 0 にできる」ことを見た。この事実を、列空間の次元という観点から説明せよ。

7. **フロベニウスノルム**

$$\boldsymbol{A} = \begin{pmatrix} 3 & 0 \\ 4 & 12 \end{pmatrix}, \qquad \boldsymbol{B} = \begin{pmatrix} 3 & 1 \\ 4 & 12 \end{pmatrix}$$

とする。

(a) $\|\boldsymbol{A}\|_F$ を求めよ。

(b) $\boldsymbol{A}$ の各列のノルム $\|\boldsymbol{c}_1\|, \|\boldsymbol{c}_2\|$ を求め、$\|\boldsymbol{A}\|_F^2 = \|\boldsymbol{c}_1\|^2 + \|\boldsymbol{c}_2\|^2$ が成り立つことを確認せよ。

(c) $\|\boldsymbol{A} - \boldsymbol{B}\|_F$ を求めよ。この値は何を意味するか。

(d) $\mathrm{tr}(\boldsymbol{A}^\top \boldsymbol{A})$ を計算し、$\|\boldsymbol{A}\|_F^2$ と一致することを確認せよ。

(e) ニューラルネットワークの学習において $L_D(\boldsymbol{W}) + \lambda \|\boldsymbol{W}\|_F^2$ を最小化することの意味を、λ を大きくした場合に $\boldsymbol{W}$ がどうなるかとあわせて説明せよ。

8. **行列の積と内積**

$$\boldsymbol{A} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{2\times 2}, \qquad \boldsymbol{B} = \begin{pmatrix} 1 & 2 & 0 \\ 1 & 0 & 3 \end{pmatrix} \in \mathbb{R}^{2\times 3}$$

とする。

(a) 積 $\boldsymbol{A}\boldsymbol{B}$ は何行何列の行列か。また、積 $\boldsymbol{B}\boldsymbol{A}$ は定義されるか。

(b) $\boldsymbol{A}$ の第 i 行を $\boldsymbol{r}_i^\top$、$\boldsymbol{B}$ の第 j 列を $\boldsymbol{c}_j$ とするとき、$(\boldsymbol{A}\boldsymbol{B})_{ij} = \boldsymbol{r}_i^\top \boldsymbol{c}_j$ が成り立つことを、行列の積の定義 $(\boldsymbol{A}\boldsymbol{B})_{ij} = \sum_k a_{ik} b_{kj}$ から示せ。

(c) $\boldsymbol{A}\boldsymbol{B}$ を計算せよ。6 個の成分がそれぞれどの行とどの列の内積か明記すること。

(d) $\boldsymbol{B}^\top \boldsymbol{A}^\top$ を計算し、$(\boldsymbol{A}\boldsymbol{B})^\top$ と一致することを確認せよ。

9. **固有値と固有ベクトル**

$$\boldsymbol{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \boldsymbol{B} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

とする。

(a) $\boldsymbol{A}$ の特性方程式 $\det(\boldsymbol{A} - \lambda \boldsymbol{I}_2) = 0$ を書き下し、固有値 $\lambda_1 > \lambda_2$ を求めよ。

(b) 各固有値に対応する固有ベクトルを 1 つずつ求めよ。

(c) (b) で求めた固有ベクトル $\boldsymbol{v}$ について $\boldsymbol{A}\boldsymbol{v}$ を実際に計算し、向きが変わらず長さが λ 倍になっていることを確認せよ。

(d) $\boldsymbol{B}$ の固有値を求めよ。固有値 0 をもつことを確認し、それが $\mathrm{rank}(\boldsymbol{B})$ および $\boldsymbol{B}$ の列の線形従属性とどう対応しているかを説明せよ。

(e) (d) の固有値 0 に対応する固有ベクトル $\boldsymbol{v}$ を求め、$\boldsymbol{B}\boldsymbol{v} = \boldsymbol{0}$ を確認せよ。第 3.5.5 項の議論に照らして、この $\boldsymbol{v}$ が何を意味するかを述べよ。

4 最小二乗法（幾何学）

第 3 回では、N 件のデータに対する予測が $\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ と書けること、そして経験損失が $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ という一つの式にまとまることを見た。また、予測が計画行列の**列空間**の中しか動けないこと、したがって最良の予測は $\boldsymbol{y}$ をその列空間へ**正射影**した点であることも確認した。

本章では、この描像から出発して、最適なパラメータ $\boldsymbol{w}^*$ を実際に求める。導出は **2 通り**行う。一つは幾何学（射影）による導出、もう一つは微分による導出である。この 2 つはまったく違う見た目をしているが、同じ式にたどり着く。その式が**正規方程式**である。

さらに本章では、解が一意に定まる条件、一意に定まらないときにどう扱うか（**擬似逆行列**）、そして実際に計算機で解くときの注意までを扱う。

4.1 問題の確認

4.1.1 これまでの到達点

第 3 回の結論を再掲する。N 件のデータに対する予測と経験損失は

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w} \in \mathbb{R}^N, \qquad L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 \tag{4.1}$$

であった（式 (3.31)）。ここで $\boldsymbol{X} \in \mathbb{R}^{N \times (d+1)}$ は計画行列、$\boldsymbol{y} \in \mathbb{R}^N$ は真の値を並べたベクトル、$\boldsymbol{w} \in \mathbb{R}^{d+1}$ はパラメータである。

我々が求めたいのは、この経験損失を最小にするパラメータ

$$\boldsymbol{w}^* = \operatorname*{arg\,min}_{\boldsymbol{w} \in \mathbb{R}^{d+1}} L_D(\boldsymbol{w}) \tag{4.2}$$

である。第 1 回で述べたとおり、min が**最小値**そのものを指すのに対し、arg min は**それを達成する $\boldsymbol{w}$** を指す。ここで欲しいのは後者である。

なお、$\frac{1}{N}$ は $\boldsymbol{w}$ に依存しない定数なので、最小化する $\boldsymbol{w}$ を求めるうえでは $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を最小にすればよい。以下ではこの事実を断りなく使う。

4.1.2 本章の進め方

式 (4.2) を解く道筋は 2 つある。

- **幾何学による導出**（第 4.2 節）：「列空間の中で $\boldsymbol{y}$ に最も近い点を探す」という問題だと読み替え、その点では誤差が列空間と直交することを示す。
- **微分による導出**（第 4.3 節）：L_D を $\boldsymbol{w}$ の関数として展開し、微分して $\boldsymbol{0}$ とおく。

どちらも同じ**正規方程式**に到達する。両方を知っておく価値は大きい。幾何学は「なぜその式になるのか」を教えてくれ、微分は損失関数を変えたときにも機械的に使える道具を与えてくれるからである。

4.2 幾何学による導出

4.2.1 最小化問題の言い換え

$\boldsymbol{w}$ が $\mathbb{R}^{d+1}$ 全体を動くとき、$\boldsymbol{X}\boldsymbol{w}$ は列空間 $\mathrm{Col}(\boldsymbol{X})$ 全体を動く（第 3.5.2 項）。したがって、最小化問題は次のように読み替えられる。

$$\min_{\boldsymbol{w}\in\mathbb{R}^{d+1}} \|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}\| \;=\; \min_{\boldsymbol{v}\in\mathrm{Col}(\boldsymbol{X})} \|\boldsymbol{y}-\boldsymbol{v}\| \tag{4.3}$$

左辺は「パラメータをどう選ぶか」という問題、右辺は「列空間という平面の上で、$\boldsymbol{y}$ に最も近い点はどこか」という**純粋に幾何学的な問題**である。パラメータの話が、距離の話になった。

この対応を図 4.1 に示す。図の $\boldsymbol{w}^{(1)}, \boldsymbol{w}^{(2)}, \boldsymbol{w}^{(3)}$ は、パラメータの選び方を 3 通り例示したものである。特別な値ではなく、$\mathbb{R}^{d+1}$ のどこにとってもよい。

$\boldsymbol{w}$ を一つ選ぶことは、左の図で点を一つ選ぶことである。その $\boldsymbol{w}$ に $\boldsymbol{X}$ を掛けると、右の図の列空間 $\mathrm{Col}(\boldsymbol{X})$ の上に点 $\boldsymbol{X}\boldsymbol{w}$ が一つ定まる。$\boldsymbol{w}$ を動かせば右の点も動くが、どう動かしても $\mathrm{Col}(\boldsymbol{X})$ の外には出られない。したがって問題は「$\mathrm{Col}(\boldsymbol{X})$ 上のどの点が $\boldsymbol{y}$ に最も近いか」に帰着する。

4.2.2 直交性の原理

幾何学的な直感を述べよう。平面の外にある点から平面へ最短距離で行くには、**真下に垂直に降りればよい**。斜めに降りれば遠回りになる。これを一般の部分空間に対して述べたものが次の定理である。

定理：直交性の原理

$\boldsymbol{v}^* \in \mathrm{Col}(\boldsymbol{X})$ が $\|\boldsymbol{y}-\boldsymbol{v}\|$ を $\boldsymbol{v}\in\mathrm{Col}(\boldsymbol{X})$ の範囲で最小にするための必要十分条件は、誤差 $\boldsymbol{y}-\boldsymbol{v}^*$ が列空間のすべてのベクトルと直交することである：

$$\boldsymbol{u}^\top(\boldsymbol{y}-\boldsymbol{v}^*)=0 \qquad (\text{すべての } \boldsymbol{u}\in\mathrm{Col}(\boldsymbol{X}) \text{ に対して}) \tag{4.4}$$

このとき $\boldsymbol{v}^*$ を $\boldsymbol{y}$ の $\mathrm{Col}(\boldsymbol{X})$ への**正射影**と呼ぶ。

4.2.3 証明：三平方の定理が効く

■4.2.3.1 **十分性** $\boldsymbol{y}-\boldsymbol{v}^*$ が列空間と直交していると仮定する。$\boldsymbol{v}\in\mathrm{Col}(\boldsymbol{X})$ を任意にとる。列空間は部分空間なので（第 3.5.2 項）、差 $\boldsymbol{v}^*-\boldsymbol{v}$ もまた列空間に属する。したがって仮定より

$$(\boldsymbol{v}^*-\boldsymbol{v})^\top(\boldsymbol{y}-\boldsymbol{v}^*)=0$$

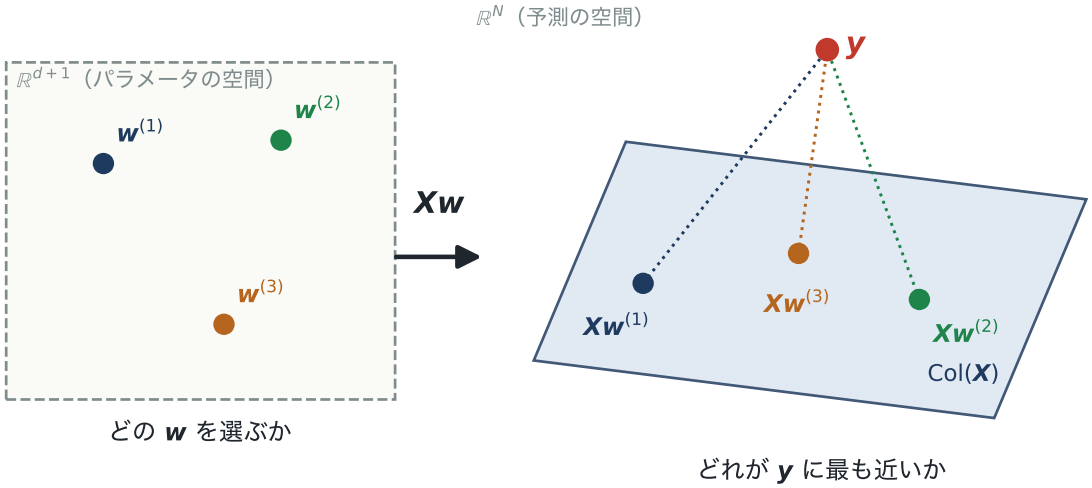


図 4.1　式 (4.3) の読み替え。左はパラメータの空間、右は予測の空間であり、$\boldsymbol{X}$ を掛ける操作が両者を結んでいる。$\boldsymbol{w}^{(1)}, \boldsymbol{w}^{(2)}, \boldsymbol{w}^{(3)}$ はパラメータの選び方の例であり、それぞれが右の $\mathrm{Col}(\boldsymbol{X})$ 上の 1 点に対応する。パラメータをどう選ぶかという問いが、$\mathrm{Col}(\boldsymbol{X})$ 上のどの点が $\boldsymbol{y}$ に近いかという距離の問いに置き換わる。

である。ここで誤差を 2 つに分ける。

$$\boldsymbol{y} - \boldsymbol{v} = (\boldsymbol{y} - \boldsymbol{v}^*) + (\boldsymbol{v}^* - \boldsymbol{v})$$

この 2 つの項は直交しているので、第 2 回で示した三平方の定理（$\boldsymbol{a} \perp \boldsymbol{b}$ のとき $\|\boldsymbol{a}+\boldsymbol{b}\|^2 = \|\boldsymbol{a}\|^2 + \|\boldsymbol{b}\|^2$）が使えて

$$\|\boldsymbol{y} - \boldsymbol{v}\|^2 = \|\boldsymbol{y} - \boldsymbol{v}^*\|^2 + \|\boldsymbol{v}^* - \boldsymbol{v}\|^2 \;\geq\; \|\boldsymbol{y} - \boldsymbol{v}^*\|^2 \tag{4.5}$$

を得る。

最後の不等号は、第 2 項 $\|\boldsymbol{v}^* - \boldsymbol{v}\|^2$ が**つねに 0 以上**であることから従う（ノルムの非負性、第 2.2.2 項）。右辺の第 1 項 $\|\boldsymbol{y} - \boldsymbol{v}^*\|^2$ は $\boldsymbol{v}$ に依存しない定数なので、$\boldsymbol{v}$ をどう選んでも $\|\boldsymbol{y} - \boldsymbol{v}\|^2$ はこの定数より小さくなれない。

等号が成り立つのは第 2 項が 0 になるとき、すなわち $\|\boldsymbol{v}^* - \boldsymbol{v}\| = 0$、言い換えれば $\boldsymbol{v} = \boldsymbol{v}^*$ のときだけである（ノルムが 0 になるのは零ベクトルのときに限る、という非負性の後半を使った）。よって $\boldsymbol{v}^*$ が唯一の最小点である。

■4.2.3.2　必要性

示したい主張を記号で置く。

$$P : \text{誤差 } \boldsymbol{y} - \boldsymbol{v}^* \text{ が } \mathrm{Col}(\boldsymbol{X}) \text{ のすべてのベクトルと直交する}$$
$$Q : \boldsymbol{v}^* \text{ が } \|\boldsymbol{y} - \boldsymbol{v}\| \text{ を最小にする}$$

必要性とは $Q \Rightarrow P$ のことである。これを直接示すのは難しいので、**対偶** $\neg P \Rightarrow \neg Q$、すなわち

「直交しないベクトルが一つでもあれば、$\boldsymbol{v}^*$ より近い点が作れる」

を示す。対偶が真であれば元の主張も真である。

そこで、ある $\boldsymbol{u} \in \mathrm{Col}(\boldsymbol{X})$ に対して

$$\boldsymbol{u}^\top(\boldsymbol{y} - \boldsymbol{v}^*) = c \neq 0$$

であったとする（$\neg P$ の仮定）。このとき $\boldsymbol{u} \neq \boldsymbol{0}$ である。$\boldsymbol{u} = \boldsymbol{0}$ なら内積は 0 になり、$c \neq 0$ に反するからである。

列空間は部分空間なので、任意の実数 t に対して $\boldsymbol{v}_t = \boldsymbol{v}^* + t\boldsymbol{u}$ もまた $\mathrm{Col}(\boldsymbol{X})$ に属する。$\boldsymbol{u}$ の方向に $\boldsymbol{v}^*$ をずらした点である。この点での誤差を、第 2 回で示した展開 $\|\boldsymbol{a} - \boldsymbol{b}\|^2 = \|\boldsymbol{a}\|^2 - 2\boldsymbol{a}^\top\boldsymbol{b} + \|\boldsymbol{b}\|^2$ を使って計算すると

$$\begin{aligned} \|\boldsymbol{y} - \boldsymbol{v}_t\|^2 &= \|(\boldsymbol{y} - \boldsymbol{v}^*) - t\boldsymbol{u}\|^2 \\ &= \|\boldsymbol{y} - \boldsymbol{v}^*\|^2 - 2t\,\boldsymbol{u}^\top(\boldsymbol{y} - \boldsymbol{v}^*) + t^2\|\boldsymbol{u}\|^2 \\ &= \|\boldsymbol{y} - \boldsymbol{v}^*\|^2 + g(t), \qquad g(t) = t^2\|\boldsymbol{u}\|^2 - 2ct \end{aligned} \tag{4.6}$$

となる。$\boldsymbol{v}^*$ より誤差を小さくできるかは、$g(t)$ **を負にできるか**だけで決まる。

g は t の下に凸な 2 次関数であり、$g(0) = 0$ である。$g'(t) = 2t\|\boldsymbol{u}\|^2 - 2c = 0$ より $t = c/\|\boldsymbol{u}\|^2$ で最小になる。この値を代入すると

$$g\left(\frac{c}{\|\boldsymbol{u}\|^2}\right) = \frac{c^2}{\|\boldsymbol{u}\|^2} - \frac{2c^2}{\|\boldsymbol{u}\|^2} = -\frac{c^2}{\|\boldsymbol{u}\|^2} \;<\; 0 \tag{4.7}$$

である。$c \neq 0$ より分子は正、$\boldsymbol{u} \neq \boldsymbol{0}$ より分母は正だからである。したがって、この t に対して

$$\|\boldsymbol{y} - \boldsymbol{v}_t\|^2 = \|\boldsymbol{y} - \boldsymbol{v}^*\|^2 - \frac{c^2}{\|\boldsymbol{u}\|^2} \;<\; \|\boldsymbol{y} - \boldsymbol{v}^*\|^2$$

となる。$\boldsymbol{v}^*$ より $\boldsymbol{y}$ に近い点が $\mathrm{Col}(\boldsymbol{X})$ の中に実際に見つかったので、$\boldsymbol{v}^*$ は最小点ではない。すなわち $\neg Q$ である。

これで $\neg P \Rightarrow \neg Q$ が示された。対偶をとると

$$Q \Rightarrow P\colon \quad \boldsymbol{v}^* \text{ が最小点ならば、誤差は } \mathrm{Col}(\boldsymbol{X}) \text{ のすべてのベクトルと直交する}$$

となり、これが示したかった必要性である。 ■

なお、最適な $t = c/\|\boldsymbol{u}\|^2$ には意味がある。これは

$$t\boldsymbol{u} = \frac{\boldsymbol{u}^\top(\boldsymbol{y} - \boldsymbol{v}^*)}{\|\boldsymbol{u}\|^2}\,\boldsymbol{u}$$

と書けるので、**誤差 $\boldsymbol{y} - \boldsymbol{v}^*$ を $\boldsymbol{u}$ の方向へ正射影したベクトル**そのものである（第 2.4.3 項）。直交していない分だけ $\boldsymbol{u}$ 方向に動けば、その分だけ誤差が縮む。ここでも正射影が顔を出している。

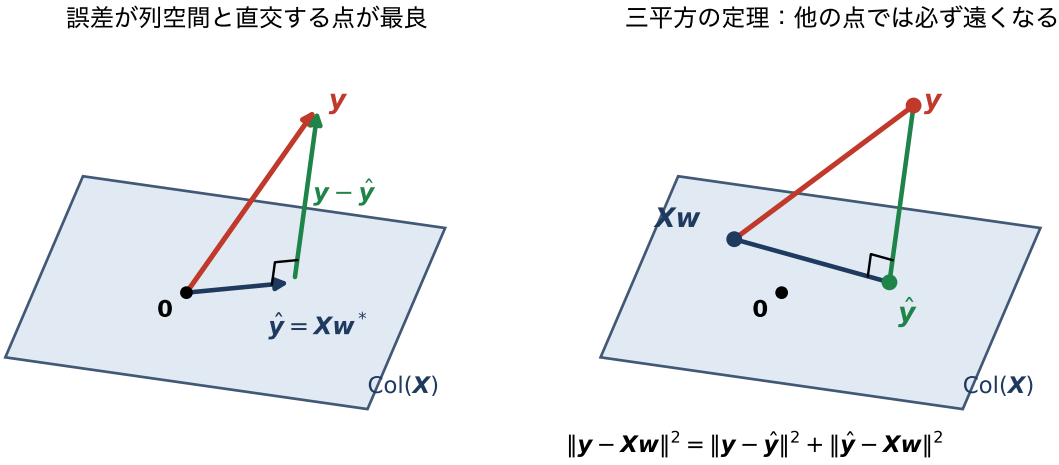


図 4.2　最小二乗法の幾何学。左：誤差 $\boldsymbol{y} - \hat{\boldsymbol{y}}$ が列空間と直交する点が最良の予測である。右：列空間上の他の点 $\boldsymbol{X}\boldsymbol{w}$ をとると、三平方の定理により $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 = \|\boldsymbol{y} - \hat{\boldsymbol{y}}\|^2 + \|\hat{\boldsymbol{y}} - \boldsymbol{X}\boldsymbol{w}\|^2$ となり、必ず遠くなる。

4.2.4　直交条件を行列の式に直す

あとは式 (4.4) を計算できる形に書き直すだけである。

列空間のすべてのベクトルと直交することは、$\boldsymbol{X}$ **のすべての列と直交すること**と同じである。なぜなら列空間の任意の元は列の線形結合であり、各列と直交していればその線形結合とも直交するからである。

$\boldsymbol{X}$ の列を $\boldsymbol{c}_0, \ldots, \boldsymbol{c}_d$、$\boldsymbol{v}^* = \boldsymbol{X}\boldsymbol{w}$ と書くと、条件は

$$\boldsymbol{c}_j^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}) = 0 \qquad (j = 0, 1, \ldots, d)$$

である。この $d+1$ 本の式は、第 3.2.1 項の**見方 1**（行との内積）を使えば一つの行列の式にまとまる。$\boldsymbol{X}^\top$ の第 j 行は $\boldsymbol{X}$ の第 j 列 $\boldsymbol{c}_j$ にほかならないので、

$$\boldsymbol{X}^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}) = \boldsymbol{0} \tag{4.8}$$

と書ける。$\boldsymbol{X}^\top$ を左から掛けるという操作が、「すべての列との内積を一度に取る」という操作に対応しているわけである。

これを整理すれば目的の式が得られる。

定義：正規方程式

経験損失 $\frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を最小にする $\boldsymbol{w}$ は、

$$\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^\top \boldsymbol{y} \tag{4.9}$$

を満たす。この連立一次方程式を**正規方程式**（normal equation）と呼ぶ。

$\boldsymbol{X}^\top \boldsymbol{X}$ は $(d+1) \times (d+1)$ の正方行列、$\boldsymbol{X}^\top \boldsymbol{y}$ は $d+1$ 次元のベクトルである。元の問題は N 件（数万件かもしれない）のデータに関する最小化問題だったが、それが $d+1$ 本の連立一次方程式に縮んだ。これが正規方程式のありがたみである。

なお「正規」は normal の訳で、ここでは**直交**（normal ＝法線）の意味である。誤差が列空間の法線方向を向いている、という条件から出てきた式だからこう呼ばれる。

4.3 微分による導出

同じ式を、今度は解析的に導く。こちらは幾何学的な洞察を必要としない代わりに、機械的に計算できる。

4.3.1 1 変数の場合の復習

まず 1 変数で感覚を取り戻しておこう。$a > 0$ として

$$f(w) = aw^2 - 2bw + c$$

という下に凸な 2 次関数を考える。最小点は微分して 0 とおけば求まる：

$$f'(w) = 2aw - 2b = 0 \quad \Longrightarrow \quad w = \frac{b}{a}$$

これから見るように、$L_D(\boldsymbol{w})$ はこの式の多変数版であり、a にあたるのが $\boldsymbol{X}^\top \boldsymbol{X}$、$b$ にあたるのが $\boldsymbol{X}^\top \boldsymbol{y}$ である。

4.3.2 勾配

多変数の場合、「微分して 0」は各変数についての偏微分をすべて 0 にすることである。これをベクトルにまとめたものを勾配と呼ぶ。

定義：偏微分と勾配

$f : \mathbb{R}^p \to \mathbb{R}$ に対して、第 i 変数だけを動かし他を固定して微分したものを**偏微分**（partial derivative）と呼び $\dfrac{\partial f}{\partial w_i}$ と書く。これらを縦に並べたベクトル

$$\nabla f(\boldsymbol{w}) = \left(\frac{\partial f}{\partial w_1},\ \frac{\partial f}{\partial w_2},\ \ldots,\ \frac{\partial f}{\partial w_p} \right)^\top \in \mathbb{R}^p \tag{4.10}$$

を f の**勾配**（gradient）と呼ぶ。記号 ∇ は「ナブラ」と読む。

勾配には明確な幾何学的意味がある。$\nabla f(\boldsymbol{w})$ は、その点で f **が最も急に増える向き**を指し、その大きさ $\|\nabla f(\boldsymbol{w})\|$ は増え方の急さを表す。したがって $-\nabla f(\boldsymbol{w})$ は最も急に減る向きであり、これが第 5 回で学ぶ**勾配降下法**の原理になる。

図 4.3 で具体例を見ておこう。$f(w_1, w_2) = w_1^2 + 2w_2^2$ の偏微分は $\partial f/\partial w_1 = 2w_1$、$\partial f/\partial w_2 = 4w_2$ であり、左図のように、それぞれ曲面を w_1 軸・w_2 軸に平行に切った断面曲線の傾きである。点 $\boldsymbol{w} = (1, 0.5)^\top$ ではどちらも 2 なので $\nabla f(\boldsymbol{w}) = (2, 2)^\top$ となる。右図はこれを等高線の上に描いたもので、2 つの偏微分がそのまま矢印の成分になっている。勾配はつねに等高線と直交し、等高線が密な（＝急な）場所ほど長い。w_2 方向の係数が大きいため等高線は横長の楕円になり、同じ距離だけ動いても w_2 方向の方が f は速く増える。

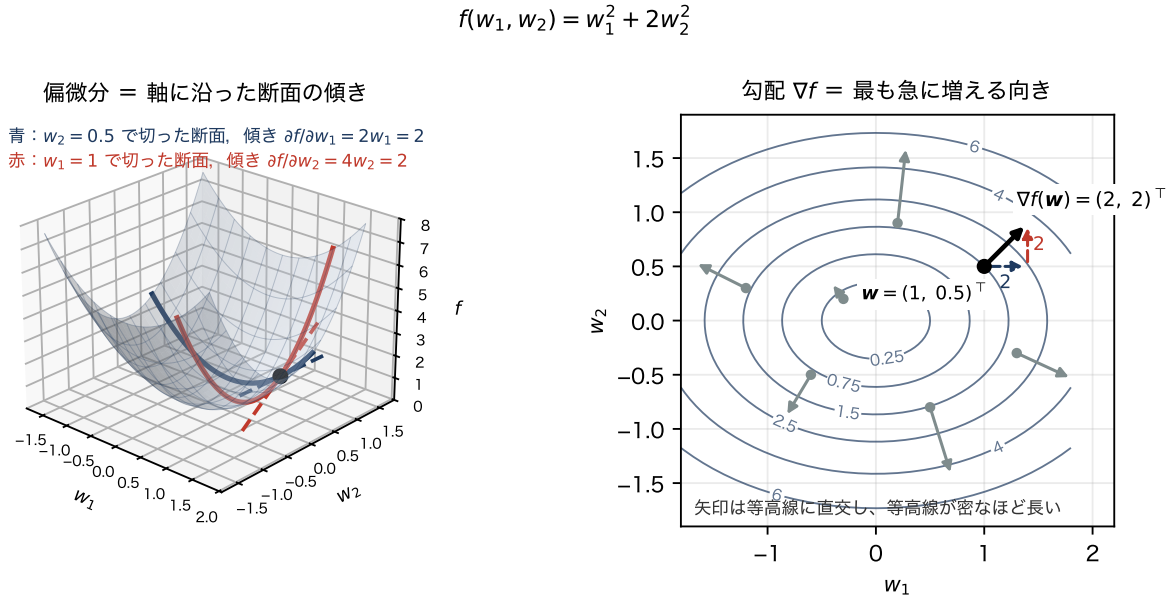


図 4.3　$f(w_1, w_2) = w_1^2 + 2w_2^2$ における偏微分と勾配。左：偏微分は曲面を各軸に平行に切った断面（青・赤の曲線）の傾き（破線）である。右：同じ関数の等高線と勾配ベクトル。点 $(1, 0.5)^\top$ での勾配 $(2, 2)^\top$ は 2 つの偏微分を成分に持ち、灰色の矢印も含めすべて等高線に直交する。

関数が滑らかで下に凸なとき、最小点では $\nabla f(\boldsymbol{w}) = \boldsymbol{0}$ となる。どの向きに動いても増えも減りもしない、という状態である。

4.3.3　必要な 2 つの公式

L_D を微分するために、行列・ベクトルの微分公式を 2 つだけ用意する。

公式：ベクトルによる微分

$\boldsymbol{a} \in \mathbb{R}^p$ を定ベクトル、$\boldsymbol{A} \in \mathbb{R}^{p \times p}$ を**対称**な定行列とする。

$$\nabla_{\boldsymbol{w}} \left(\boldsymbol{a}^\top \boldsymbol{w} \right) = \boldsymbol{a} \tag{4.11}$$

$$\nabla_{\boldsymbol{w}} \left(\boldsymbol{w}^\top \boldsymbol{A} \boldsymbol{w} \right) = 2\boldsymbol{A}\boldsymbol{w} \tag{4.12}$$

■4.3.3.1　1 次の項の公式の証明　$\boldsymbol{a}^\top \boldsymbol{w} = \sum_j a_j w_j$ であるから、w_i について偏微分すると w_i を含む項は $a_i w_i$ だけで、

$$\frac{\partial}{\partial w_i} \sum_j a_j w_j = a_i$$

これを並べると $\boldsymbol{a}$ になる。 ■

■4.3.3.2　**2 次の項の公式の証明**　$\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w} = \sum_j \sum_k a_{jk} w_j w_k$ である。w_i を含むのは、$j = i$ の項、$k = i$ の項、および $j = k = i$ の項である。積の微分に注意して

$$\begin{aligned}\frac{\partial}{\partial w_i} \sum_j \sum_k a_{jk} w_j w_k &= \sum_k a_{ik} w_k + \sum_j a_{ji} w_j \\ &= (\boldsymbol{A}\boldsymbol{w})_i + (\boldsymbol{A}^\top \boldsymbol{w})_i\end{aligned}$$

$\boldsymbol{A}$ が対称なら $\boldsymbol{A}^\top = \boldsymbol{A}$ なので、これは $2(\boldsymbol{A}\boldsymbol{w})_i$ に等しい。並べれば $2\boldsymbol{A}\boldsymbol{w}$ である。 ■

対称性の仮定は本質的である。我々が扱う $\boldsymbol{A} = \boldsymbol{X}^\top \boldsymbol{X}$ はつねに対称なので（第 4.5.1 項）、この公式がそのまま使える。

4.3.4　経験損失を展開して微分する

$L_D(\boldsymbol{w}) = \frac{1}{N} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$（式 (4.1)）を展開する。ここで N はデータ件数である。係数 $\frac{1}{N}$ を毎回書くのは煩わしいので、両辺を N 倍した $N \cdot L_D(\boldsymbol{w})$ を扱う。定数倍しても最小点は変わらないので（第 4.1.1 項）、勾配を $\boldsymbol{0}$ とおく議論には影響しない。$\|\boldsymbol{z}\|^2 = \boldsymbol{z}^\top \boldsymbol{z}$ を使うと

$$\begin{aligned}N \cdot L_D(\boldsymbol{w}) &= (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w})^\top (\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}) \\ &= \boldsymbol{y}^\top \boldsymbol{y} - \boldsymbol{y}^\top \boldsymbol{X}\boldsymbol{w} - (\boldsymbol{X}\boldsymbol{w})^\top \boldsymbol{y} + (\boldsymbol{X}\boldsymbol{w})^\top \boldsymbol{X}\boldsymbol{w} \\ &= \boldsymbol{y}^\top \boldsymbol{y} - 2\,(\boldsymbol{X}^\top \boldsymbol{y})^\top \boldsymbol{w} + \boldsymbol{w}^\top (\boldsymbol{X}^\top \boldsymbol{X}) \boldsymbol{w}\end{aligned} \tag{4.13}$$

2 行目から 3 行目では、$(\boldsymbol{X}\boldsymbol{w})^\top \boldsymbol{y} = \boldsymbol{w}^\top \boldsymbol{X}^\top \boldsymbol{y}$ がスカラーであり、スカラーは転置しても変わらないことから $\boldsymbol{y}^\top \boldsymbol{X}\boldsymbol{w} = \boldsymbol{w}^\top \boldsymbol{X}^\top \boldsymbol{y} = (\boldsymbol{X}^\top \boldsymbol{y})^\top \boldsymbol{w}$ となることを用いた。また $(\boldsymbol{X}\boldsymbol{w})^\top \boldsymbol{X}\boldsymbol{w} = \boldsymbol{w}^\top \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w}$ である（転置すると積の順序が逆になる、第 3.2.4 項）。

式 (4.13) は、1 変数のときの $aw^2 - 2bw + c$ とまったく同じ形をしている。あとは公式を当てはめるだけである。第 1 項は $\boldsymbol{w}$ を含まないので消え、第 2 項に式 (4.11)、第 3 項に式 (4.12) を使って

$$\nabla_{\boldsymbol{w}} \big(N \cdot L_D(\boldsymbol{w}) \big) = -2\,\boldsymbol{X}^\top \boldsymbol{y} + 2\,\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} \tag{4.14}$$

を得る。これを $\boldsymbol{0}$ とおくと

$$\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^\top \boldsymbol{y}$$

となり、幾何学から導いた式 (4.9) と**完全に一致する**。

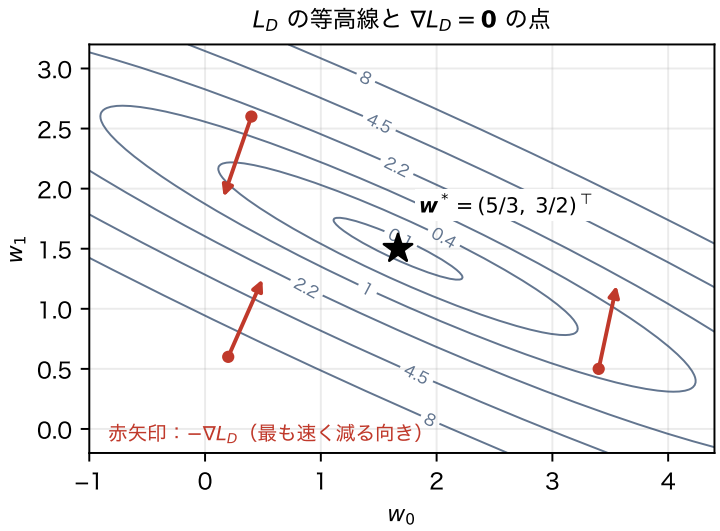


図 4.4　後述の数値例（$D = \{(1,3),(2,5),(3,6)\}$）における経験損失の等高線。赤い矢印は $-\nabla L_D$、すなわち損失が最も速く減る向きである。中央の $\boldsymbol{w}^*$ では勾配が $\mathbf{0}$ になり、どの向きに動いても損失は増える。

4.3.5　停留点が最小値である理由

$\nabla L_D = \mathbf{0}$ は、厳密には「接平面が水平な点」（**停留点**）の条件であって、それだけでは最小・最大・鞍点のどれかは分からない。ここで最小だと言い切れるのは、L_D が下に凸だからである。

1 変数の $f(w) = aw^2 - 2bw + c$ では、2 階微分 $f''(w) = 2a$ の符号がすべてを決めていた。$a > 0$ なら下に凸で停留点はただ一つの最小点、$a = 0$ なら曲がっておらず（直線）停留点は最小点とは限らず、$a < 0$ なら上に凸で停留点は最大点である。

多変数で f'' の役割を果たすのが、2 階偏微分を並べた次の行列である。

定義：ヘッセ行列

$f : \mathbb{R}^p \to \mathbb{R}$ が 2 回微分可能なとき、すべての 2 階偏微分を $p \times p$ に並べた行列

$$\nabla^2 f(\boldsymbol{w}) = \begin{pmatrix} \dfrac{\partial^2 f}{\partial w_1^2} & \dfrac{\partial^2 f}{\partial w_1 \partial w_2} & \cdots & \dfrac{\partial^2 f}{\partial w_1 \partial w_p} \\ \dfrac{\partial^2 f}{\partial w_2 \partial w_1} & \dfrac{\partial^2 f}{\partial w_2^2} & \cdots & \dfrac{\partial^2 f}{\partial w_2 \partial w_p} \\ \vdots & \vdots & \ddots & \vdots \\ \dfrac{\partial^2 f}{\partial w_p \partial w_1} & \dfrac{\partial^2 f}{\partial w_p \partial w_2} & \cdots & \dfrac{\partial^2 f}{\partial w_p^2} \end{pmatrix} \in \mathbb{R}^{p \times p} \tag{4.15}$$

を f の**ヘッセ行列**（Hessian matrix）と呼ぶ。(i,j) 成分は $\partial^2 f / \partial w_i \partial w_j$、すなわち「$w_j$ で偏微分してから w_i で偏微分したもの」である。f が滑らかなら偏微分の順序は交換できる（$\partial^2 f / \partial w_i \partial w_j = \partial^2 f / \partial w_j \partial w_i$）ので、ヘッセ行列は**対称行列**である。勾配 ∇f が「1 階微分を並べたベクトル」であったのに対し、ヘッセ行列は「2 階微分を並べた行列」であり、∇^2 はその意味の記号である。

$p=1$ のときヘッセ行列は 1×1 行列 (f'') にほかならない。ただし多変数では「曲がり方」が方向ごとに異なりうる。点 $\boldsymbol{w}$ から向き $\boldsymbol{v}\in\mathbb{R}^p$ に沿って進んだときの f の曲がり方、すなわち $g(t)=f(\boldsymbol{w}+t\boldsymbol{v})$ の 2 階微分は

$$g''(0)=\boldsymbol{v}^\top\big(\nabla^2 f(\boldsymbol{w})\big)\boldsymbol{v} \tag{4.16}$$

で与えられる。つまり「ヘッセ行列に $\boldsymbol{v}$ を挟んだもの」は**向き $\boldsymbol{v}$ での 2 階微分**である。これが、第 2.3.2 項で定義した正定値・半正定値がここで登場する理由である。

定義（再掲）：正定値と半正定値

対称行列 $\boldsymbol{A}\in\mathbb{R}^{p\times p}$ について

$$\text{正定値（positive definite）：}\quad \boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}>0\quad(\text{すべての }\boldsymbol{v}\neq\boldsymbol{0})$$
$$\text{半正定値（positive semi-definite）：}\quad \boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}\geq 0\quad(\text{すべての }\boldsymbol{v})$$

等号 $\boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}=0$ を $\boldsymbol{v}\neq\boldsymbol{0}$ に対して許すかどうかが両者を分ける。

■4.3.5.1　**直感的な意味**　ヘッセ行列に限らず、正定値・半正定値は次の 3 通りに捉えるとよい。図 4.5 に、正定値な $\boldsymbol{A}$ と半正定値止まりの $\boldsymbol{B}$ を並べて 3 つの見方を示した。

「正の数」の行列版。1 変数で $a>0$ は「$av^2>0$ がすべての $v\neq 0$ で成り立つ」と言い換えられる。$\boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}=\sum_i\sum_j a_{ij}v_iv_j$ は av^2 の多変数版（2 次形式）であり、これがつねに正になる $\boldsymbol{A}$ が正定値、つねに非負になる $\boldsymbol{A}$ が半正定値である。つまり正定値は「正の数」、半正定値は「非負の数」の行列への拡張であり、$a>0$ と $a\geq 0$ の違いがそのまま両者の違いにあたる。例えば

$$\boldsymbol{A}=\begin{pmatrix}1&0\\0&2\end{pmatrix}\implies \boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}=v_1^2+2v_2^2,\qquad \boldsymbol{B}=\begin{pmatrix}1&0\\0&0\end{pmatrix}\implies \boldsymbol{v}^\top\boldsymbol{B}\boldsymbol{v}=v_1^2$$

で、$\boldsymbol{A}$ は正定値（図 4.3 左のお椀の形がまさに $\boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}$ のグラフである）、$\boldsymbol{B}$ は半正定値だが正定値ではない。$\boldsymbol{B}$ では $\boldsymbol{v}=(0,1)^\top$ のように v_2 方向へ動いても値が変わらず、グラフはお椀ではなく、v_2 方向に平らな**樋（とい）の形**になる。この「値が変わらない向き」が、第 2.3.2 項で述べた「つぶれた方向」である。

向きをほぼ保つ変換。$\boldsymbol{v}^\top\boldsymbol{A}\boldsymbol{v}=\boldsymbol{v}^\top(\boldsymbol{A}\boldsymbol{v})$ は、$\boldsymbol{v}$ と、それを $\boldsymbol{A}$ で変換した $\boldsymbol{A}\boldsymbol{v}$ との内積である。第 2 回の内積の意味から、これが正であることは $\boldsymbol{v}$ と $\boldsymbol{A}\boldsymbol{v}$ のなす角が 90° 未満であることを意味する。すなわち正定値な $\boldsymbol{A}$ は、どのベクトルも 90° 以上は回さない（おおまかに向きを保つ）変換である。半正定値では、ちょうど 90° 回す場合や、$\boldsymbol{A}\boldsymbol{v}=\boldsymbol{0}$ につぶす場合までが許される。

固有値で見る。対称行列 $\boldsymbol{A}$ については、正定値であることは固有値がすべて正であること、半正定値であることは固有値がすべて非負であることと同値である（第 3.7 節）。固有値 0 に対応する固有ベクトルの向きが、上で述べた「つぶれた方向」にほかならない。上の例では $\boldsymbol{A}$ の固有値は $1,2$、$\boldsymbol{B}$ の固有値は $1,0$ である。

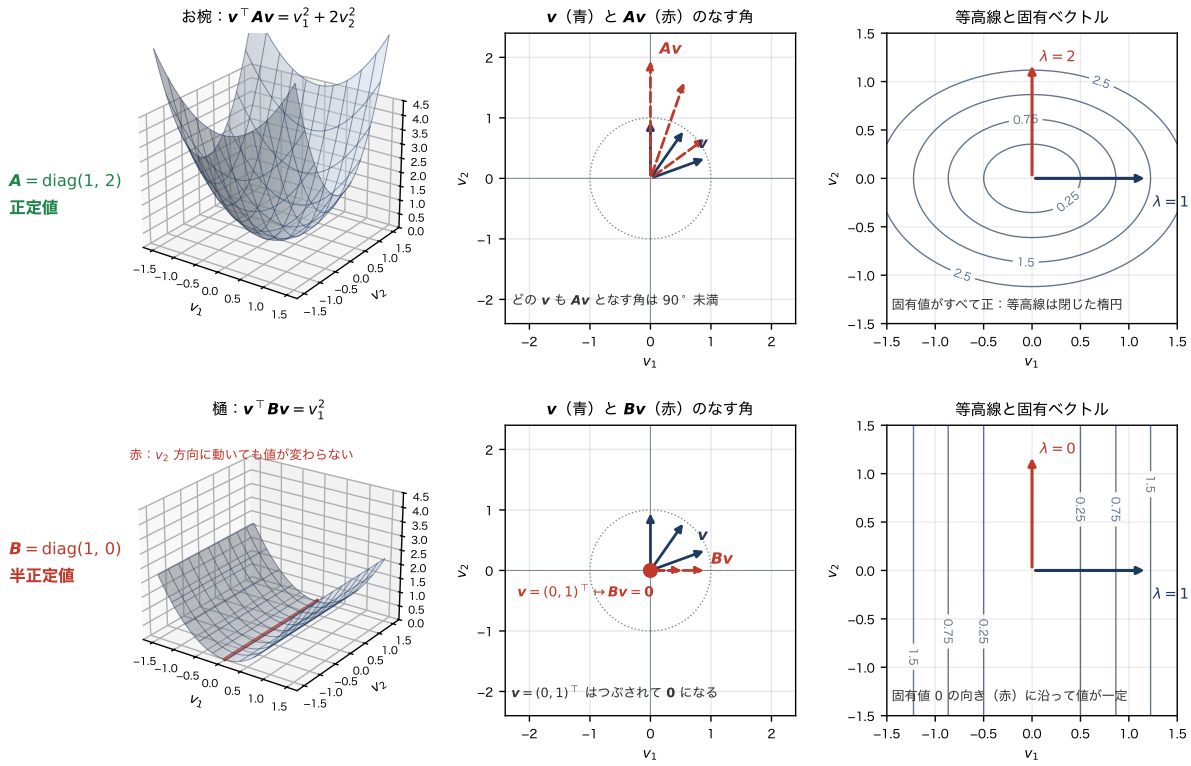


図 4.5　正定値（上段：$\boldsymbol{A} = \mathrm{diag}(1, 2)$）と半正定値（下段：$\boldsymbol{B} = \mathrm{diag}(1, 0)$）の 3 つの見方。左：2 次形式 $\boldsymbol{v}^\top \boldsymbol{A}\boldsymbol{v}$ のグラフはお椀、$\boldsymbol{v}^\top \boldsymbol{B}\boldsymbol{v}$ は v_2 方向に平らな樋になる。中：$\boldsymbol{v}$（青）と $\boldsymbol{A}\boldsymbol{v}$（赤）のなす角はつねに 90° 未満だが、$\boldsymbol{B}$ は $\boldsymbol{v} = (0, 1)^\top$ を $\boldsymbol{0}$ につぶす。右：$\boldsymbol{A}$ の等高線は閉じた楕円で固有値はすべて正、$\boldsymbol{B}$ は固有値 0 の固有ベクトルの向きに沿って値が一定で、等高線が閉じない。

■4.3.5.2　ヘッセ行列の場合　$\boldsymbol{A}$ がヘッセ行列のとき、式 (4.16) より $\boldsymbol{v}^\top \boldsymbol{A}\boldsymbol{v}$ は向き $\boldsymbol{v}$ での曲がり方なので、上の直感は次のように翻訳される。

- **正定値**：どの向きに進んでも f は上に曲がる（お椀の形）。停留点は**ただ一つの**最小点である。
- **半正定値**：どの向きにも下には曲がらないが、$\boldsymbol{v}^\top \boldsymbol{A}\boldsymbol{v} = 0$ となる「平らな向き」があってよい（樋の形）。停留点は最小点ではあるが、平らな向きに沿って最小点が**無数に**連なりうる。

L_D の場合を見よう。式 (4.13) をもう一度微分すると

$$\nabla^2 L_D(\boldsymbol{w}) = \frac{2}{N} \boldsymbol{X}^\top \boldsymbol{X} \tag{4.17}$$

であり、これは $\boldsymbol{w}$ によらない定行列である。そして任意の $\boldsymbol{v} \in \mathbb{R}^{d+1}$ に対して

$$\boldsymbol{v}^\top (\boldsymbol{X}^\top \boldsymbol{X})\boldsymbol{v} = (\boldsymbol{X}\boldsymbol{v})^\top (\boldsymbol{X}\boldsymbol{v}) = \|\boldsymbol{X}\boldsymbol{v}\|^2 \geq 0 \tag{4.18}$$

であるから、$\boldsymbol{X}^\top \boldsymbol{X}$ は少なくとも**半正定値**である。よって L_D はどの向きにも下に曲がらず（下に凸）、停留点は**大域的な最小点**である。これで「勾配が $\boldsymbol{0}$ の点が最小点だ」と言い切ってよい理由が確かめられた。

さらに式 (4.18) を見ると、等号 $\|\boldsymbol{X}\boldsymbol{v}\|^2 = 0$ が成り立つのは $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ のときだけである。したがって $\boldsymbol{X}^\top\boldsymbol{X}$ が正定値か半正定値にとどまるかは、$\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる $\boldsymbol{v} \neq \boldsymbol{0}$ が存在するかどうか、すなわち $\boldsymbol{X}$ がフルランクかどうかで決まる。

- $\boldsymbol{X}$ がフルランク：$\boldsymbol{X}^\top\boldsymbol{X}$ は**正定値**。最小点は一意に定まる（第 4.5.3 項）。
- $\boldsymbol{X}$ がランク落ち：$\boldsymbol{X}^\top\boldsymbol{X}$ は**半正定値だが正定値ではない**。$\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ の向きには L_D が平らで、最小点がその向きに沿って無数に並ぶ（第 3 回の図 3.7、第 4.7 節）。

式 (4.18) は本章で何度も使う。覚えておく価値がある。「$\boldsymbol{X}^\top\boldsymbol{X}$ に $\boldsymbol{v}$ を挟んだものは $\boldsymbol{X}\boldsymbol{v}$ の長さの二乗」という事実である。凸関数の一般論は第 5 回で扱う。

4.4 2 つの導出の対応

同じ式に 2 通りで到達した。両者の関係を整理しておく。

	幾何学（射影）	微分
出発点	列空間の中で $\boldsymbol{y}$ に最も近い点を探す	$L_D(\boldsymbol{w})$ を $\boldsymbol{w}$ の関数とみて微分する
鍵となる事実	誤差が列空間と直交する	勾配が $\boldsymbol{0}$ になる
使う道具	三平方の定理、内積	偏微分、行列の展開
分かること	**なぜ**その式なのか。$\hat{\boldsymbol{y}}$ が射影であること	損失を変えても**同じ手順**で解けること

この 2 つは実は同じことを言っている。式 (4.8) の左辺 $\boldsymbol{X}^\top(\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w})$ は、符号と定数倍を除いてそのまま勾配 ∇L_D である。つまり**「勾配が 0」と「誤差が列空間と直交」は同じ条件**なのである。

どちらを使うべきか。目的によって使い分けるのがよい。たとえば第 6 回で扱うリッジ回帰では、損失に $\lambda\|\boldsymbol{w}\|^2$ という項が加わる。このとき微分による導出は、公式 (4.12) をもう一度使うだけで済む。一方、正則化が解をどう変えるかを図で理解したいときには、幾何学的な描像のほうが役に立つ。

4.5 正規方程式を解く

正規方程式 $\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^\top\boldsymbol{y}$ が得られた。これを $\boldsymbol{w}$ について解きたい。

4.5.1 $\boldsymbol{X}^\top\boldsymbol{X}$ の性質

まず相手を知っておく。$\boldsymbol{X} \in \mathbb{R}^{N\times(d+1)}$ に対して $\boldsymbol{X}^\top\boldsymbol{X}$ は次の性質をもつ。

- **正方行列**である。$(d+1)\times N$ と $N\times(d+1)$ の積なので $(d+1)\times(d+1)$ になる。データ件数 N がいくら大きくてもサイズは変わらない。
- **対称**である。$(\boldsymbol{X}^\top\boldsymbol{X})^\top = \boldsymbol{X}^\top(\boldsymbol{X}^\top)^\top = \boldsymbol{X}^\top\boldsymbol{X}$。
- **半正定値**である。式 (4.18) で示したとおり。
- 第 (i,j) 成分は $\boldsymbol{c}_i^\top\boldsymbol{c}_j$、すなわち**列どうしの内積**である。対角成分は $\|\boldsymbol{c}_i\|^2$ になる。

最後の項目は見逃せない。$\boldsymbol{X}^\top\boldsymbol{X}$ は**特徴どうしの関係をまとめた表**なのである。第 3.5.5 項で見た多重共線

性、すなわち特徴どうしが似ている状況は、この行列の性質としてはっきり現れる。

4.5.2 逆行列

連立一次方程式 $\boldsymbol{A}\boldsymbol{w} = \boldsymbol{b}$ を解くとは、1 変数の $aw = b$ を $w = b/a$ と解くことの行列版である。「a で割る」にあたる操作を与えるのが逆行列である。

定義：逆行列

正方行列 $\boldsymbol{A} \in \mathbb{R}^{n \times n}$ に対して

$$\boldsymbol{A}\boldsymbol{B} = \boldsymbol{B}\boldsymbol{A} = \boldsymbol{I}_n \tag{4.19}$$

を満たす $\boldsymbol{B}$ が存在するとき、$\boldsymbol{A}$ は**正則**（regular, invertible）であるといい、$\boldsymbol{B}$ を $\boldsymbol{A}$ の**逆行列**（inverse matrix）と呼んで $\boldsymbol{A}^{-1}$ と書く。逆行列は存在すればただ一つである。

一意性は次のように確かめられる。$\boldsymbol{B}, \boldsymbol{C}$ がともに逆行列だとすると

$$\boldsymbol{B} = \boldsymbol{B}\boldsymbol{I}_n = \boldsymbol{B}(\boldsymbol{A}\boldsymbol{C}) = (\boldsymbol{B}\boldsymbol{A})\boldsymbol{C} = \boldsymbol{I}_n\boldsymbol{C} = \boldsymbol{C}$$

となる。

2×2 の場合は具体的に書ける。$\det \boldsymbol{A} = ad - bc \neq 0$ のとき

$$\boldsymbol{A} = \begin{pmatrix} a & b \\ c & d \end{pmatrix} \quad \Longrightarrow \quad \boldsymbol{A}^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix} \tag{4.20}$$

逆に $\det \boldsymbol{A} = 0$、すなわち列が線形従属なときは逆行列が存在しない。第 3.7.2 項で見たとおり、$\det \boldsymbol{A} = 0$ は「列がつぶれている」ことの印であった。つぶれた変換は元に戻せない、と考えると納得しやすい。

4.5.3 解が一意に定まる条件

いつ $\boldsymbol{X}^\top \boldsymbol{X}$ は正則になるのか。答えは第 3 回のランクで決まる。

定理：正規方程式の一意可解性

$\boldsymbol{X} \in \mathbb{R}^{N \times (d+1)}$ について、次の 3 つは同値である。

1. $\boldsymbol{X}$ の列が線形独立である（$\operatorname{rank}(\boldsymbol{X}) = d + 1$、フルランク）
2. $\boldsymbol{X}^\top \boldsymbol{X}$ が正定値である
3. $\boldsymbol{X}^\top \boldsymbol{X}$ が正則である

このとき正規方程式の解は一意に定まり、

$$\boldsymbol{w}^* = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y} \tag{4.21}$$

である。

■4.5.3.1 証明の要点 (1) ⇒ (2)：$\boldsymbol{v} \neq \boldsymbol{0}$ とすると、列が線形独立なので $\boldsymbol{X}\boldsymbol{v} \neq \boldsymbol{0}$ である。よって式 (4.18) より $\boldsymbol{v}^\top \boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{v} = \|\boldsymbol{X}\boldsymbol{v}\|^2 > 0$ となり、正定値。

(2) ⇒ (3)：正定値なら固有値はすべて正なので 0 を固有値にもたない。第 3.7.4 項より、固有値 0 をもたないことはランク落ちしていないことと同値であり、正則である。

(3) $\Rightarrow$ (1)：対偶を示す。列が線形従属なら $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる $\boldsymbol{v} \neq \boldsymbol{0}$ が存在し（第 3.5.5 項）、このとき $\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる。正則な行列は $\boldsymbol{0}$ でないベクトルを $\boldsymbol{0}$ に写さないので、$\boldsymbol{X}^\top \boldsymbol{X}$ は正則でない。 ■

フルランクであるためには、少なくとも $N \geq d+1$ が必要である（$\mathrm{rank}(\boldsymbol{X}) \leq \min(N, d+1)$ だから）。**データ件数が特徴数より少なければ、この方法では解が定まらない**。現代の機械学習ではこの状況がごく普通に起こる。その場合の扱いが第 4.7 節の主題である。

4.5.4 数値例

第 1 回の演習問題で扱ったデータを使う。$D = \{(1,3),\ (2,5),\ (3,6)\}$ に、バイアス項つきの直線 $h(x) = w_0 + w_1 x$ を当てはめる。

計画行列と目的変数は

$$\boldsymbol{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 3 \\ 5 \\ 6 \end{pmatrix}$$

である。まず正規方程式の両辺を作る。

$$\boldsymbol{X}^\top \boldsymbol{X} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix}$$

$$\boldsymbol{X}^\top \boldsymbol{y} = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{pmatrix} \begin{pmatrix} 3 \\ 5 \\ 6 \end{pmatrix} = \begin{pmatrix} 14 \\ 31 \end{pmatrix}$$

成分の意味を確認しておくとよい。$\boldsymbol{X}^\top \boldsymbol{X}$ の $(1,1)$ 成分 3 はデータ件数 N、$(1,2)$ 成分 6 は $\sum_i x_i$、$(2,2)$ 成分 14 は $\sum_i x_i^2$ である。$\boldsymbol{X}^\top \boldsymbol{y}$ は $\sum_i y_i = 14$ と $\sum_i x_i y_i = 31$ である。

$\det(\boldsymbol{X}^\top \boldsymbol{X}) = 3 \cdot 14 - 6 \cdot 6 = 6 \neq 0$ なのでフルランクであり、式 (4.20) を使って

$$\boldsymbol{w}^* = \frac{1}{6} \begin{pmatrix} 14 & -6 \\ -6 & 3 \end{pmatrix} \begin{pmatrix} 14 \\ 31 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 196 - 186 \\ -84 + 93 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 10 \\ 9 \end{pmatrix} = \begin{pmatrix} 5/3 \\ 3/2 \end{pmatrix}$$

を得る。求める直線は $h(x) = \frac{5}{3} + \frac{3}{2} x$ である。

4.5.5 解いた後の確認

得られた解が本当に正しいかは、**誤差が列空間と直交しているか**を見れば確かめられる。予測は

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}^* = \left(\tfrac{5}{3} + \tfrac{3}{2},\ \tfrac{5}{3} + 3,\ \tfrac{5}{3} + \tfrac{9}{2}\right)^\top = \left(\tfrac{19}{6},\ \tfrac{28}{6},\ \tfrac{37}{6}\right)^\top$$

であり、残差は

$$\boldsymbol{r} = \boldsymbol{y} - \hat{\boldsymbol{y}} = \left(-\tfrac{1}{6},\ \tfrac{2}{6},\ -\tfrac{1}{6}\right)^\top$$

である。これが 2 本の列と直交することを確かめる。

$$\boldsymbol{c}_0^\top \boldsymbol{r} = -\tfrac{1}{6} + \tfrac{2}{6} - \tfrac{1}{6} = 0$$
$$\boldsymbol{c}_1^\top \boldsymbol{r} = 1 \cdot \left(-\tfrac{1}{6}\right) + 2 \cdot \tfrac{2}{6} + 3 \cdot \left(-\tfrac{1}{6}\right) = \tfrac{-1+4-3}{6} = 0$$

どちらも 0 になった。

$\boldsymbol{c}_0^\top \boldsymbol{r} = 0$ は $\sum_i r_i = 0$、すなわち**残差の和がゼロ**という意味である。バイアス項を入れておくと自動的にこうなる。これはバイアス項の役割の一つである。

最後に経験損失は

$$L_D(\boldsymbol{w}^*) = \frac{1}{3}\|\boldsymbol{r}\|^2 = \frac{1}{3}\left(\frac{1}{36} + \frac{4}{36} + \frac{1}{36}\right) = \frac{1}{3}\cdot\frac{1}{6} = \frac{1}{18} \approx 0.056$$

である。第 1 回の演習問題で試した 2 つの直線 $h_a(x) = 2x + 1$（$L_D = 1/3$）や $h_b(x) = 1.5x + 1.5$（$L_D = 1/12$）よりも小さい。これは当然である。$\boldsymbol{w}^*$ はすべての直線の中で経験損失を最小にするものであり、しかも $\boldsymbol{X}$ がフルランクなので最小点は $\boldsymbol{w}^*$ ただ一つである（第 4.5.3 項）。したがって $\boldsymbol{w}^*$ と異なる直線 h_a, h_b の経験損失は、必ず $L_D(\boldsymbol{w}^*)$ より大きい。第 1 回では h_a と h_b の 2 つを比べて h_b を選んだが、それは「与えられた候補の中での最良」であって、直線全体の中での最良ではなかったわけである。

4.6 ハット行列（射影行列）

4.6.1 定義と意味

式 (4.21) を予測の式に代入すると

$$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}^* = \underbrace{\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top}_{\boldsymbol{H}}\,\boldsymbol{y} \tag{4.22}$$

となる。

定義：ハット行列

$\boldsymbol{X}$ がフルランクのとき、

$$\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top \in \mathbb{R}^{N\times N} \tag{4.23}$$

を**ハット行列**（hat matrix）または**射影行列**（projection matrix）と呼ぶ。$\hat{\boldsymbol{y}} = \boldsymbol{H}\boldsymbol{y}$ が成り立つ。

「ハット」という名前は、$\boldsymbol{y}$ に帽子（ハット）を乗せて $\hat{\boldsymbol{y}}$ にする行列だから、という洒落である。$\boldsymbol{H}$ は $\boldsymbol{y}$ だけに依存せず、**計画行列だけで決まる**点が重要である。どんな目的変数が来ようと、射影の仕方は $\boldsymbol{X}$ が決めている。

4.6.2 射影行列の 2 つの性質

$\boldsymbol{H}$ は射影としてふさわしい性質をもつ。

■4.6.2.1 (1) **対称性：$\boldsymbol{H}^\top = \boldsymbol{H}$** $\boldsymbol{X}^\top\boldsymbol{X}$ が対称なのでその逆行列も対称であり、

$$\boldsymbol{H}^\top = \left(\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\right)^\top = \boldsymbol{X}\left((\boldsymbol{X}^\top\boldsymbol{X})^{-1}\right)^\top\boldsymbol{X}^\top = \boldsymbol{H}$$

■4.6.2.2 (2) **冪等性：$\boldsymbol{H}^2 = \boldsymbol{H}$** 「冪等」は「べきとう」と読む（idempotent）。「冪」は累乗（べき乗）の意味で、何乗しても等しい、すなわち $\boldsymbol{H}^2 = \boldsymbol{H}^3 = \cdots = \boldsymbol{H}$ となる性質を指す。

$$\boldsymbol{H}^2 = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\underbrace{\boldsymbol{X}^\top\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}}_{\boldsymbol{I}}\boldsymbol{X}^\top = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top = \boldsymbol{H}$$

冪等性には分かりやすい意味がある。**一度影を落としたものに、もう一度影を落としても何も変わらない。** $\hat{\boldsymbol{y}}$ はすでに列空間の中にあるのだから、射影しても動かないのである。

4.6.3 トレースと自由度

$\boldsymbol{H}$ のトレース（第 3.6 節）を計算してみよう。$\mathrm{tr}(\boldsymbol{AB}) = \mathrm{tr}(\boldsymbol{BA})$ という性質を使うと

$$\mathrm{tr}(\boldsymbol{H}) = \mathrm{tr}\left(\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\right) = \mathrm{tr}\left((\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{X}\right) = \mathrm{tr}(\boldsymbol{I}_{d+1}) = d+1 \tag{4.24}$$

となる。$N \times N$ の大きな行列なのに、トレースはパラメータの個数 $d+1$ に等しい。

この $d+1$ は、モデルが使っている**自由度**（degrees of freedom）と呼ばれる量である。直感的には「データに合わせるために何個のつまみを回せるか」を表している。第 6 回で学ぶ正則化は、この自由度を実質的に $d+1$ より小さくする操作であり、そこでも $\mathrm{tr}(\boldsymbol{H})$ に相当する量が顔を出す。

先の数値例では $N=3$, $d+1=2$ であり、実際に計算すると

$$\boldsymbol{H} = \frac{1}{6}\begin{pmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{pmatrix}, \qquad \mathrm{tr}(\boldsymbol{H}) = \frac{5+2+5}{6} = 2 = d+1$$

となる。$\boldsymbol{H}^2 = \boldsymbol{H}$ も成り立っていることは手で確かめられる。

4.7 ランク落ちと擬似逆行列

ここまでは $\boldsymbol{X}$ がフルランクであることを前提にしてきた。しかし第 3.5.5 項で見たとおり、実データでは列が線形従属になることがある。また $N < d+1$、すなわち**データより特徴のほうが多い**場合もフルランクにはなりえない。このとき何が起こり、どう対処するのか。

4.7.1 零空間と解の集合

まず、予測を変えない方向に名前を付けておく。

定義：零空間

行列 $\boldsymbol{X} \in \mathbb{R}^{N\times(d+1)}$ に対して

$$\mathrm{Null}(\boldsymbol{X}) = \{\, \boldsymbol{v} \in \mathbb{R}^{d+1} \mid \boldsymbol{X}\boldsymbol{v} = \boldsymbol{0} \,\} \tag{4.25}$$

を $\boldsymbol{X}$ の**零空間**（null space）または**核**（kernel）と呼ぶ。これは $\mathbb{R}^{d+1}$ の部分空間である。

記法を確認しておく（第 1.2.1 項）。$\{\cdots \mid \cdots\}$ は集合を表す書き方で、縦棒「$\mid$」を「ただし」と読み、**左側に集める要素の形、右側にその要素が満たすべき条件**を書く。式 (4.25) は「$\mathbb{R}^{d+1}$ のベクトル $\boldsymbol{v}$ のうち、$\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ を満たすものをすべて集めた集合」と読む。つまり $\mathrm{Null}(\boldsymbol{X})$ は一つのベクトルでも数でもなく、**条件 $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ に合格するベクトルの集まり**である。$\boldsymbol{v} = \boldsymbol{0}$ はつねに条件を満たすので、零空間は少なくとも $\boldsymbol{0}$ を含む。また $\boldsymbol{v}_1, \boldsymbol{v}_2$ が条件を満たせば $\boldsymbol{X}(a\boldsymbol{v}_1 + b\boldsymbol{v}_2) = a\boldsymbol{X}\boldsymbol{v}_1 + b\boldsymbol{X}\boldsymbol{v}_2 = \boldsymbol{0}$ なので、その線形結合も条件を満たす。これが「部分空間である」の意味であり、第 3.5.2 項で列空間について確かめたのと同じ議論である。

具体例を一つ挙げる。$\boldsymbol{X}$ の 2 つの列が $\boldsymbol{c}_1$ と $\boldsymbol{c}_2 = 2\boldsymbol{c}_1$ のように比例していれば、$\boldsymbol{v} = (2, -1)^\top$ に対して $\boldsymbol{X}\boldsymbol{v} = 2\boldsymbol{c}_1 - \boldsymbol{c}_2 = \boldsymbol{0}$ となる。その定数倍もすべて条件を満たすので

$$\mathrm{Null}(\boldsymbol{X}) = \{\, t\,(2,-1)^\top \mid t \in \mathbb{R} \,\}$$

という直線（1 次元の部分空間）になる。右側の「$t \in \mathbb{R}$」は、t を実数全体にわたって動かしたときの $t\,(2,-1)^\top$ をすべて集める、という意味である。

$\boldsymbol{X}$ がフルランクなら $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ を満たす $\boldsymbol{v}$ は $\boldsymbol{0}$ だけなので $\mathrm{Null}(\boldsymbol{X})=\{\boldsymbol{0}\}$（$\boldsymbol{0}$ ただ一つからなる集合）であり、ランクが落ちていれば上の例のように $\boldsymbol{0}$ でない元を含む。

正規方程式 $\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w}=\boldsymbol{X}^\top\boldsymbol{y}$ の解がどれだけあるかを、零空間を使って正確に述べる。$\boldsymbol{w}^*$ を解の一つとする（解が少なくとも一つ存在することは第 4.2 節で示した。$\boldsymbol{y}$ の列空間への正射影は必ず存在するからである）。示したいのは、「解の全体」と「$\boldsymbol{w}^*$ に零空間の元を足したものの全体」が集合として一致することである。集合が一致することを示すには、**両方の向きの包含**を示せばよい。

■4.7.1.1　**向き 1：$\boldsymbol{w}^*+\boldsymbol{v}$ はすべて解である**　任意の $\boldsymbol{v}\in\mathrm{Null}(\boldsymbol{X})$、すなわち $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ を満たす $\boldsymbol{v}$ をとると

$$\boldsymbol{X}^\top\boldsymbol{X}(\boldsymbol{w}^*+\boldsymbol{v})=\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w}^*+\boldsymbol{X}^\top(\boldsymbol{X}\boldsymbol{v})=\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w}^*+\boldsymbol{0}=\boldsymbol{X}^\top\boldsymbol{y}$$

となる。最後の等号は $\boldsymbol{w}^*$ が解であることによる。よって $\boldsymbol{w}^*+\boldsymbol{v}$ も正規方程式を満たす。つまり $\boldsymbol{w}^*$ に零空間の元を足したものは、すべて解である。

■4.7.1.2　**向き 2：解はすべて $\boldsymbol{w}^*+\boldsymbol{v}$ の形をしている**　逆に、$\boldsymbol{w}'$ を任意の解とし、$\boldsymbol{v}=\boldsymbol{w}'-\boldsymbol{w}^*$ とおく。示したいのは $\boldsymbol{v}\in\mathrm{Null}(\boldsymbol{X})$、すなわち $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ である。$\boldsymbol{w}'$ も $\boldsymbol{w}^*$ も解なので、両辺を引き算すると

$$\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w}'-\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{w}^*=\boldsymbol{X}^\top\boldsymbol{y}-\boldsymbol{X}^\top\boldsymbol{y}\quad\Longrightarrow\quad\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$$

を得る。ただしここで分かるのは $\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ であって、欲しい $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ そのものではない。両者をつなぐのが式 (4.18) である。$\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ の両辺に左から $\boldsymbol{v}^\top$ を掛けると

$$0=\boldsymbol{v}^\top\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}=\|\boldsymbol{X}\boldsymbol{v}\|^2$$

となり、ノルムが 0 のベクトルは $\boldsymbol{0}$ だけなので $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$、すなわち $\boldsymbol{v}\in\mathrm{Null}(\boldsymbol{X})$ である。よって任意の解 $\boldsymbol{w}'$ は $\boldsymbol{w}'=\boldsymbol{w}^*+\boldsymbol{v}$（$\boldsymbol{v}\in\mathrm{Null}(\boldsymbol{X})$）の形に書ける。

■4.7.1.3　**結論**　向き 1 より「$\boldsymbol{w}^*+\boldsymbol{v}$ の形のものはすべて解」、向き 2 より「解はすべて $\boldsymbol{w}^*+\boldsymbol{v}$ の形」なので、両者は一致し、解の全体は

$$\{\,\boldsymbol{w}^*+\boldsymbol{v}\mid\boldsymbol{v}\in\mathrm{Null}(\boldsymbol{X})\,\}\tag{4.26}$$

という集合になる。なお向き 2 の計算は、$\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ と $\boldsymbol{X}\boldsymbol{v}=\boldsymbol{0}$ が同値であること、すなわち $\mathrm{Null}(\boldsymbol{X}^\top\boldsymbol{X})=\mathrm{Null}(\boldsymbol{X})$ を示している。第 4.5.3 項で「$\boldsymbol{X}$ がフルランク $\Leftrightarrow$ $\boldsymbol{X}^\top\boldsymbol{X}$ が正則」と述べたのも、この事実の言い換えである。これも同じ記法で、「$\boldsymbol{v}$ を零空間の中で動かしたときの $\boldsymbol{w}^*+\boldsymbol{v}$ をすべて集めたもの」と読む。一つの解 $\boldsymbol{w}^*$ を起点に、零空間の向きへ平行移動した点がすべて解だ、ということである。零空間が 1 次元なら解は直線状に、2 次元なら平面状に無数に存在する。

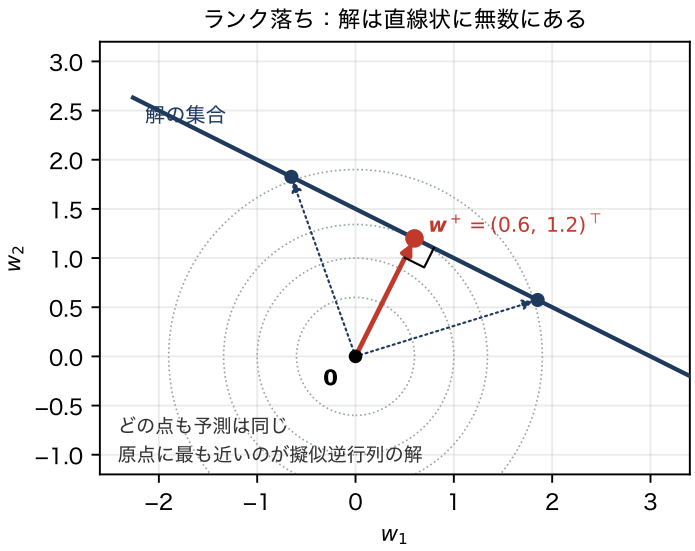


図 4.6　ランクが落ちた場合の解。直線上のどの点も同じ予測を与え、経験損失も等しい。擬似逆行列が選ぶのは、このうち原点に最も近い点（最小ノルム解）である。

4.7.2　どれを選ぶか：最小ノルム解

解が無数にあるとき、「正しい答え」は原理的に決まらない。どれを選んでも訓練データへの当てはまりは同じだからである。そこで**追加の基準**を持ち込む。最も標準的なのが「解の中で、**パラメータベクトル $\boldsymbol{w}$ のノルム $\|\boldsymbol{w}\|$ が最小のもの**を選ぶ」という基準である。ここでのノルムは誤差 $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|$ のことではない。誤差はどの解でも同じ最小値なので、それでは選べない。比べるのは解そのもの、すなわち係数を並べたベクトル $\boldsymbol{w} = (w_0, w_1, \ldots, w_d)^\top$ の長さであり、「係数の値が全体として小さい解を選ぶ」という意味である。この「$\|\boldsymbol{w}\|$ を小さく保つ」という発想は、第 6 回のリッジ回帰（正則化）と同じものである。両者の関係は第 4.7.5 項で述べる。

定義：ムーア・ペンローズ擬似逆行列

任意の行列 $\boldsymbol{X} \in \mathbb{R}^{N \times (d+1)}$ に対して、次の性質をもつ行列 $\boldsymbol{X}^+ \in \mathbb{R}^{(d+1) \times N}$ がただ一つ存在する。

$$\boldsymbol{w}^+ = \boldsymbol{X}^+ \boldsymbol{y} \tag{4.27}$$

は、$\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|$ を最小にする $\boldsymbol{w}$ のうちで $\|\boldsymbol{w}\|$ が最小のものである。この $\boldsymbol{X}^+$ を**ムーア・ペンローズ擬似逆行列**（Moore–Penrose pseudo-inverse）と呼ぶ。

「最小ノルム」という条件には幾何学的な意味がある。解の集合 (4.26) は、零空間を $\boldsymbol{w}^*$ だけ平行移動した集合である。そのうち原点に最も近い点は、**零空間と直交する**点にほかならない（図 4.6）。ここでも直交性が最適性を特徴づけている。本章で 3 度目である。

なお $\boldsymbol{X}^+$ は、次の 4 条件（ペンローズ条件）を満たす唯一の行列として定義することもある。

$$\boldsymbol{X}\boldsymbol{X}^+\boldsymbol{X} = \boldsymbol{X}, \quad \boldsymbol{X}^+\boldsymbol{X}\boldsymbol{X}^+ = \boldsymbol{X}^+, \quad (\boldsymbol{X}\boldsymbol{X}^+)^\top = \boldsymbol{X}\boldsymbol{X}^+, \quad (\boldsymbol{X}^+\boldsymbol{X})^\top = \boldsymbol{X}^+\boldsymbol{X}$$

第 1 式と第 2 式は逆行列の性質 $\boldsymbol{A}\boldsymbol{A}^{-1}\boldsymbol{A} = \boldsymbol{A}$ の緩和版であり、第 3 式と第 4 式は $\boldsymbol{X}\boldsymbol{X}^+$ と $\boldsymbol{X}^+\boldsymbol{X}$ が射影

行列であることを要求している。

4.7.3 フルランクのときは何が起こるか

$\boldsymbol{X}$ がフルランクなら零空間は $\{\boldsymbol{0}\}$ なので解は一つしかなく、「最小ノルムのものを選ぶ」という条件は何も制限しない。このとき擬似逆行列は具体的に書き下せる：

$$\boldsymbol{X}^{+} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top} \tag{4.28}$$

式 (4.28) は、擬似逆行列の定義（式 (4.27)）から次のように導かれる。定義により $\boldsymbol{X}^{+}\boldsymbol{y} = \boldsymbol{w}^{+}$ であり、$\boldsymbol{w}^{+}$ とは「$\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|$ を最小にする $\boldsymbol{w}$ のうち $\|\boldsymbol{w}\|$ が最小のもの」であった。$\boldsymbol{X}$ がフルランクのとき、$\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|$ を最小にする $\boldsymbol{w}$ は式 (4.21) の $\boldsymbol{w}^{*} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}\boldsymbol{y}$ ただ一つである（第 4.5.3 項）。候補が一つしかないのだから、その中でノルム最小のものも $\boldsymbol{w}^{*}$ 自身、すなわち $\boldsymbol{w}^{+} = \boldsymbol{w}^{*}$ である。したがって

$$\boldsymbol{X}^{+}\boldsymbol{y} = \boldsymbol{w}^{+} = \boldsymbol{w}^{*} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}\boldsymbol{y}$$

がどんな $\boldsymbol{y}$ に対しても成り立つ（1 つ目の等号は定義 (4.27)、2 つ目はフルランクによる一意性、3 つ目は式 (4.21)）。$\boldsymbol{y}$ は任意なので、これは行列として $\boldsymbol{X}^{+} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}$ ということである。

ペンローズ条件の側から確かめることもできる。$\boldsymbol{P} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}$ とおくと $\boldsymbol{P}\boldsymbol{X} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}\boldsymbol{X} = \boldsymbol{I}$ なので、第 1 式 $\boldsymbol{X}\boldsymbol{P}\boldsymbol{X} = \boldsymbol{X}\boldsymbol{I} = \boldsymbol{X}$、第 2 式 $\boldsymbol{P}\boldsymbol{X}\boldsymbol{P} = \boldsymbol{I}\boldsymbol{P} = \boldsymbol{P}$、第 4 式 $(\boldsymbol{P}\boldsymbol{X})^{\top} = \boldsymbol{I}^{\top} = \boldsymbol{I} = \boldsymbol{P}\boldsymbol{X}$ が成り立つ。第 3 式は $\boldsymbol{X}\boldsymbol{P} = \boldsymbol{X}(\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top} = \boldsymbol{H}$ がハット行列であり、その対称性は第 4.6.2 項で示した。4 条件を満たす行列は唯一なので、やはり $\boldsymbol{X}^{+} = \boldsymbol{P}$ である。

いずれにせよ式 (4.28) は式 (4.21) と一致する。つまり擬似逆行列は、**これまでの話を特別な場合として含む一般化**である。

さらに $\boldsymbol{X}$ が正方かつ正則なら $\boldsymbol{X}^{+} = \boldsymbol{X}^{-1}$ となる。記号 $\boldsymbol{X}^{+}$ は $\boldsymbol{X}^{-1}$ の拡張だと思ってよい。

4.7.4 数値例

第 3 回の演習問題 9 で扱った行列を使う。

$$\boldsymbol{X} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 3 \\ 6 \end{pmatrix}$$

ここでは説明のためバイアス項を省き、2 つの特徴だけを考えている。第 2 列は第 1 列の 2 倍なので $\operatorname{rank}(\boldsymbol{X}) = 1$ であり、ランクが落ちている。

$\boldsymbol{y} = 3\,\boldsymbol{c}_1$ なので $\boldsymbol{y} \in \operatorname{Col}(\boldsymbol{X})$ であり、誤差を 0 にできる。条件は

$$w_1 + 2w_2 = 3$$

という 1 本の式だけで、これを満たす (w_1, w_2) は直線上に無数にある。

零空間は $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ すなわち $v_1 + 2v_2 = 0$ の解で、$\boldsymbol{v} = (-2, 1)^{\top}$ の定数倍である。

最小ノルム解を求めよう。$w_1 = 3 - 2w_2$ を代入して

$$\|\boldsymbol{w}\|^2 = (3 - 2w_2)^2 + w_2^2 = 5w_2^2 - 12w_2 + 9$$

これを w_2 で微分して 0 とおくと $10w_2 - 12 = 0$、すなわち $w_2 = 1.2$、$w_1 = 0.6$。

$$\boldsymbol{w}^{+} = \boldsymbol{X}^{+}\boldsymbol{y} = (0.6,\ 1.2)^{\top}, \qquad \|\boldsymbol{w}^{+}\| = \sqrt{1.8} \approx 1.342$$

これが零空間と直交することも確かめられる：$\boldsymbol{w}^{+\top}\boldsymbol{v} = 0.6\cdot(-2) + 1.2\cdot 1 = 0$。

比べてみよう。$t=1$ として $\boldsymbol{w}^{+}+\boldsymbol{v} = (-1.4,\ 2.2)^{\top}$ も解だが、そのノルムは $\sqrt{1.96+4.84}\approx 2.608$ で、$\boldsymbol{w}^{+}$ より大きい。予測はどちらも $\boldsymbol{X}\boldsymbol{w} = (3,6)^{\top}$ で完全に同じである。

4.7.5 なぜ最小ノルムを選ぶのか

「どれも同じなら、なぜ小さいものを選ぶのか」という問いには、第 6 回の正則化が答えを与える。

結論だけ先取りする。リッジ回帰は、経験損失に罰則 $\lambda\|\boldsymbol{w}\|^2$（$\lambda>0$）を加えた

$$\|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}\|^2 + \lambda\|\boldsymbol{w}\|^2$$

を最小にする。罰則の中身は、まさに本節で比べていた $\|\boldsymbol{w}\|$ である。第 4.3 節と同じ手順で勾配を $\boldsymbol{0}$ とおくと（公式 (4.12) を $\lambda\boldsymbol{w}^{\top}\boldsymbol{I}\boldsymbol{w}$ にも使う）、解は

$$\boldsymbol{w}_{\lambda} = (\boldsymbol{X}^{\top}\boldsymbol{X} + \lambda\boldsymbol{I})^{-1}\boldsymbol{X}^{\top}\boldsymbol{y}$$

となる。ここで $\boldsymbol{X}^{\top}\boldsymbol{X}+\lambda\boldsymbol{I}$ は、$\boldsymbol{X}$ がランク落ちしていても**つねに正則**である。任意の $\boldsymbol{v}\neq\boldsymbol{0}$ に対して $\boldsymbol{v}^{\top}(\boldsymbol{X}^{\top}\boldsymbol{X}+\lambda\boldsymbol{I})\boldsymbol{v} = \|\boldsymbol{X}\boldsymbol{v}\|^2+\lambda\|\boldsymbol{v}\|^2 > 0$ となり、正定値だからである（第 4.5.3 項）。つまり罰則を加えた瞬間に「解が無数にある」という問題は消え、解はつねに一意に定まる。そして λ を 0 に近づけていくと、$\boldsymbol{w}_{\lambda}$ は**最小ノルム解 $\boldsymbol{w}^{+}$ に収束する**。最小ノルム解は「ごくわずかに正則化した解」の極限なのである。

第 3.6 節で述べたとおり、重みが大きいと入力のわずかな違いが出力の大きな違いに増幅され、ノイズを拾いやすくなる。同じ当てはまりなら重みは小さいほうがよい、というのは汎化の観点から理にかなった選択なのである。

4.8 数値計算上の注意

理論的には $\boldsymbol{w}^{*} = (\boldsymbol{X}^{\top}\boldsymbol{X})^{-1}\boldsymbol{X}^{\top}\boldsymbol{y}$ で解ける。しかし計算機でこの式をそのまま実装するのは**推奨されない**。

4.8.1 条件数が二乗される

行列の「解きにくさ」を測る量に**条件数**（condition number）がある。対称かつ正定値な行列については、最大固有値と最小固有値の比

$$\kappa(\boldsymbol{A}) = \frac{\lambda_{\max}(\boldsymbol{A})}{\lambda_{\min}(\boldsymbol{A})} \tag{4.29}$$

で定義される。条件数が大きいほど、入力のわずかな誤差が解の大きな誤差に増幅される。第 3.7.3 項で見た「細長い谷」は、まさに条件数が大きい状況であった。

ここで問題になるのは、$\boldsymbol{X}^{\top}\boldsymbol{X}$ を作った時点で

$$\kappa(\boldsymbol{X}^{\top}\boldsymbol{X}) = \kappa(\boldsymbol{X})^2 \tag{4.30}$$

となり、条件数が**二乗されてしまう**ことである。$\boldsymbol{X}$ の条件数が 10^4 程度でも、$\boldsymbol{X}^{\top}\boldsymbol{X}$ では 10^8 になる。倍精度計算の有効桁数がおよそ 16 桁であることを考えると、無視できない劣化である。

4.8.2 実際に使われる方法

そこで数値計算では、$\boldsymbol{X}^{\top}\boldsymbol{X}$ を明示的に作らずに解く方法が用いられる。詳細は本講義の範囲を超えるが、考え方だけ述べておく。

- **QR 分解**：$\boldsymbol{X} = \boldsymbol{Q}\boldsymbol{R}$（$\boldsymbol{Q}$ は列が直交、$\boldsymbol{R}$ は上三角）と分解し、$\boldsymbol{R}\boldsymbol{w} = \boldsymbol{Q}^\top \boldsymbol{y}$ を解く。条件数が二乗されない。
- **特異値分解（SVD）**：$\boldsymbol{X}$ を 3 つの行列の積に分解する方法で、ランクが落ちていても扱える。擬似逆行列はこの分解を用いて計算される。

実装上は、自分で逆行列を書くのではなくライブラリの最小二乗ソルバを使うのが鉄則である。Python では `numpy.linalg.lstsq` がこれにあたり、内部では SVD が使われる。擬似逆行列そのものは `numpy.linalg.pinv` で得られる。

4.8.3 多重共線性との関係

第 3.5.5 項で見た多重共線性は、ここでは条件数の問題として現れる。特徴どうしが強く相関していると $\boldsymbol{X}$ の条件数が大きくなり、$\boldsymbol{X}^\top \boldsymbol{X}$ の最小固有値が 0 に近づく。形式的には正則でも、数値的にはほとんど特異であり、解は信用できない。

対処は 3 つある。

1. 相関の強い特徴を削る（特徴選択）
2. 正則化を入れて $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I}$ とする（第 6 回）
3. 擬似逆行列を使い、最小ノルム解を取る

2 番目が実務で最もよく使われる。$\lambda \boldsymbol{I}$ を足すと最小固有値が λ だけ持ち上がり、条件数が改善するからである。この見方は第 6 回で詳しく扱う。

4.9 まとめ

- 最小二乗法は「列空間の中で $\boldsymbol{y}$ に最も近い点を探す」問題であり、その答えは $\boldsymbol{y}$ の**正射影**である
- 最適性の条件は**誤差が列空間と直交すること**であり、これを式にしたものが**正規方程式** $\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} = \boldsymbol{X}^\top \boldsymbol{y}$ である
- 同じ式は L_D を微分して $\nabla L_D = \boldsymbol{0}$ とおいても得られる。「勾配が $\boldsymbol{0}$」と「誤差が直交」は同じ条件である
- $\boldsymbol{X}^\top \boldsymbol{X}$ はつねに対称かつ半正定値。$\boldsymbol{X}$ がフルランクのときに限り正定値（＝正則）となり、解は $\boldsymbol{w}^* = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}$ と一意に定まる
- 予測は $\hat{\boldsymbol{y}} = \boldsymbol{H}\boldsymbol{y}$ と書け、ハット行列 $\boldsymbol{H}$ は対称・冪等であり $\mathrm{tr}(\boldsymbol{H}) = d + 1$（モデルの自由度）である
- ランクが落ちると解は無数に存在する。**擬似逆行列** $\boldsymbol{X}^+$ はそのうち**ノルム最小**のものを選ぶ
- 計算機では $\boldsymbol{X}^\top \boldsymbol{X}$ を作らず、QR 分解や SVD で解く。条件数が二乗されるのを避けるためである

本章では解を**閉じた式**で求めた。閉じた式（closed-form expression）とは、$\boldsymbol{w}^* = (\boldsymbol{X}^\top \boldsymbol{X})^{-1} \boldsymbol{X}^\top \boldsymbol{y}$ のように、答えそのものを有限回の四則演算・行列演算で直接書き下した式のことである。しかしこの方法は、d が非常に大きいとき（$\boldsymbol{X}^\top \boldsymbol{X}$ が巨大になる）や、モデルが線形でないときには使えない。次回（第 5 回）は、同じ最小化問題を**反復計算**で解く方法、すなわち勾配降下法を扱う。本章で定義した勾配 ∇L_D が、そこで主役になる。

4.10 演習問題

1. **直交性の確認** $\boldsymbol{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$、$\boldsymbol{y} = (1, 2, 2)^\top$ とする。
   (a) $\boldsymbol{X}^\top \boldsymbol{X}$ と $\boldsymbol{X}^\top \boldsymbol{y}$ を求めよ。
   (b) 正規方程式を解いて $\boldsymbol{w}^*$ を求めよ。
   (c) 残差 $\boldsymbol{r} = \boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}^*$ を求め、$\boldsymbol{X}^\top \boldsymbol{r} = \boldsymbol{0}$ を確認せよ。
   (d) 経験損失 $L_D(\boldsymbol{w}^*)$ を求めよ。
2. **三平方の定理による最適性** 問 1 の設定で、$\boldsymbol{w} = (1, 1)^\top$ としたときの予測を $\boldsymbol{X}\boldsymbol{w}$ とする。
   (a) $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を計算せよ。
   (b) $\|\boldsymbol{y} - \hat{\boldsymbol{y}}\|^2 + \|\hat{\boldsymbol{y}} - \boldsymbol{X}\boldsymbol{w}\|^2$ を計算し、(a) と一致することを確認せよ（式 (4.5)）。
   (c) この等式が成り立つのはなぜか。どのベクトルとどのベクトルが直交していることを使っているか明記して説明せよ。
3. **微分による導出** $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ について答えよ。
   (a) $N \cdot L_D(\boldsymbol{w})$ を展開し、式 (4.13) の形に書け。途中で使った「スカラーの転置は変わらない」という事実がどこで効いたか示せ。
   (b) 公式 (4.11) と (4.12) を用いて ∇L_D を求めよ。
   (c) $\nabla L_D = \boldsymbol{0}$ から正規方程式を導け。
4. **行列微分の公式** $\boldsymbol{A} \in \mathbb{R}^{p \times p}$ を**対称とは限らない**定行列とする。
   (a) $\nabla_{\boldsymbol{w}}(\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}) = (\boldsymbol{A} + \boldsymbol{A}^\top)\boldsymbol{w}$ を成分計算で示せ。
   (b) $\boldsymbol{A}$ が対称のとき、これが $2\boldsymbol{A}\boldsymbol{w}$ になることを確認せよ。
   (c) $\boldsymbol{A} = \begin{pmatrix} 1 & 2 \\ 0 & 3 \end{pmatrix}$、$\boldsymbol{w} = (w_1, w_2)^\top$ のとき、$\boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$ を w_1, w_2 の式として書き下し、偏微分して (a) の結果と一致することを確かめよ。
5. **ハット行列** 問 1 の $\boldsymbol{X}$ について答えよ。
   (a) $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^\top \boldsymbol{X})^{-1}\boldsymbol{X}^\top$ を計算せよ。
   (b) $\boldsymbol{H}^\top = \boldsymbol{H}$ と $\boldsymbol{H}^2 = \boldsymbol{H}$ を確認せよ。
   (c) $\mathrm{tr}(\boldsymbol{H})$ を求め、$d + 1$ に一致することを確認せよ。
   (d) $\boldsymbol{H}$ の固有値は 0 か 1 のいずれかであることを、$\boldsymbol{H}^2 = \boldsymbol{H}$ から示せ。固有値 1 の個数は何個か。
6. **一意可解性**
   (a) 任意の $\boldsymbol{v}$ に対して $\boldsymbol{v}^\top \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{v} = \|\boldsymbol{X}\boldsymbol{v}\|^2$ が成り立つことを示せ。
   (b) これを用いて、$\boldsymbol{X}$ の列が線形独立ならば $\boldsymbol{X}^\top \boldsymbol{X}$ が正定値であることを示せ。
   (c) 逆に、$\boldsymbol{X}$ の列が線形従属ならば $\boldsymbol{X}^\top \boldsymbol{X}$ は正則でないことを示せ。
   (d) $N = 5$, $d = 10$（特徴が 10 個）のとき、$\boldsymbol{X}^\top \boldsymbol{X}$ は正則になりうるか。理由とともに述べよ。
7. **擬似逆行列** $\boldsymbol{X} = \begin{pmatrix} 1 & 3 \\ 2 & 6 \end{pmatrix}$、$\boldsymbol{y} = (2, 4)^\top$ とする。
   (a) $\mathrm{rank}(\boldsymbol{X})$ を求めよ。
   (b) $\mathrm{Null}(\boldsymbol{X})$ を求めよ。
   (c) $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|$ を最小にする $\boldsymbol{w}$ の集合を書き下せ。

（d）そのうちノルム最小のもの $\boldsymbol{w}^+$ を求めよ。

（e）$\boldsymbol{w}^+$ が $\mathrm{Null}(\boldsymbol{X})$ と直交することを確認せよ。

8. **条件数**　$\boldsymbol{X}^\top\boldsymbol{X} = \begin{pmatrix} 1 & 0 \\ 0 & \varepsilon \end{pmatrix}$（$\varepsilon > 0$ は小さい数）という状況を考える。

（a）固有値と条件数 $\kappa(\boldsymbol{X}^\top\boldsymbol{X})$ を求めよ。

（b）$\boldsymbol{X}^\top\boldsymbol{y} = (1, \varepsilon)^\top$ のとき $\boldsymbol{w}^*$ を求めよ。

（c）$\boldsymbol{X}^\top\boldsymbol{y}$ の第 2 成分が ε から 2ε に変化したとき、$\boldsymbol{w}^*$ はどれだけ変化するか。ε が小さいほど何が問題になるか説明せよ。

（d）$\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I}_2$（$\lambda > 0$）としたとき、条件数はどうなるか。$\lambda$ を大きくすると条件数はどう変わるか。

5　勾配降下法

第 4 回では、経験損失 $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を最小にするパラメータを、正規方程式を解くことで**閉じた式** $\boldsymbol{w}^* = (\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{y}$ として求めた。閉じた式とは、答えそのものを直接書き下した式のことであり、この式に $\boldsymbol{X}, \boldsymbol{y}$ を代入すれば一度の計算で答えが出る。きわめて強力な方法である。

しかし、この方法が使える場面は限られている。本章では、同じ最小化問題を**反復計算**で解く方法、すなわち**勾配降下法**を学ぶ。第 4 回で定義した勾配 ∇L_D が、ここで主役になる。勾配降下法の考え方は最小二乗法に限らず、ニューラルネットワークを含むほぼすべての機械学習モデルの学習の土台になっており、本講義の後半を通じて何度も登場する。ただし、実際の深層学習で使われているのは、本章の前半で学ぶ最も基本的な形そのものではなく、その確率的な変種（確率的勾配降下法）と改良版（Adam など）である。この点は第 5.1 節の最後で整理する。

後半では、「勾配降下法はいつ、どれくらいの速さで答えにたどり着くのか」を考える。その鍵が**凸関数**という概念である。第 2 回・第 4 回で触れた正定値・半正定値が、ここで本来の役割を果たす。最後に、データが巨大なときの**確率的勾配降下法**（ミニバッチ、エポック）と、深層学習で標準的に使われる改良版（**モメンタム**、**Adam**）を紹介する。

5.1　なぜ反復計算が必要か

5.1.1　閉じた式の限界

正規方程式による解法には、3 つの限界がある。

■5.1.1.1　(1) **特徴の数が大きいとき**　$\boldsymbol{X}^\top\boldsymbol{X}$ は $(d+1) \times (d+1)$ の行列であり、その逆行列を求める計算量はおよそ $(d+1)^3$ に比例する。$d = 10^3$ なら 10^9 回程度の演算で済むが、$d = 10^6$（画像の画素数や語彙数の規模）になると 10^{18} 回となり、現実的でない。行列を保持するメモリも $(d+1)^2$ に比例して増える。

■5.1.1.2　(2) **モデルが線形でないとき**　正規方程式が出てきたのは、L_D が $\boldsymbol{w}$ の **2 次関数**だったからである（第 4.3.4 項）。2 次関数の勾配は $\boldsymbol{w}$ の 1 次式になるので、勾配 $= \boldsymbol{0}$ が連立**一次**方程式になり、逆行列で解けた。ニューラルネットワークのように、パラメータに対して非線形なモデルでは、勾配 $= \boldsymbol{0}$ は非線形の方程式になり、一般に閉じた式では解けない。

■5.1.1.3 (3) **データが逐次的に届くとき** データが一度にすべて手に入るとは限らない。新しいデータが来るたびに $\boldsymbol{X}^\top \boldsymbol{X}$ を作り直して逆行列を計算するのは無駄が多い。

これらの状況では、「一度の計算で答えを出す」ことをあきらめ、「少しずつ答えに近づいていく」方法に切り替える必要がある。

5.1.2 反復計算という発想

反復計算の考え方は単純である。適当な初期値 $\boldsymbol{w}^{(0)}$ から出発し、

$$\boldsymbol{w}^{(0)} \;\to\; \boldsymbol{w}^{(1)} \;\to\; \boldsymbol{w}^{(2)} \;\to\; \cdots \tag{5.1}$$

と、各ステップで経験損失が**減る向き**に少し動かす。これを十分な回数くり返せば、最小点の近くにたどり着くだろう、という発想である。上付きの (t) は t 回目の反復で得られた値を表す。

霧の中で山を下る状況を想像するとよい。谷底（最小点）がどこにあるかは見えないが、足元の傾きは分かる。傾きが最も急に下がる向きへ一歩進み、また足元の傾きを調べて一歩進む。これをくり返せば、やがて谷底に着く。「足元の傾き」にあたるのが勾配であり、第 4.3.2 項で見たとおり、$-\nabla L_D(\boldsymbol{w})$ が損失の最も速く減る向きであった。

5.1.3 本章で学ぶ「勾配降下法」と実際に使われる手法

はじめに用語を整理しておく。第 5.2〜5.4 節で扱うのは、毎回の更新で**全データ**の勾配 $\nabla L_D(\boldsymbol{w})$ を計算して一歩進む、最も基本的な形の勾配降下法である（区別が必要なときは**バッチ勾配降下法**と呼ぶ）。仕組みと収束の性質を最も見通しよく理解できるので、まずこれを学ぶ。

一方、現在の深層学習で実際に使われているのは、この基本形そのものではない。データの一部（ミニバッチ）だけで勾配を近似する**確率的勾配降下法**（SGD、第 5.5 節）と、過去の勾配を使って歩幅や向きを調整する改良版（**モメンタム**、**Adam**、第 5.6 節）である。「AI は勾配降下法で学習している」という言い方は、正確にはこれらの変種を指している。ただし、「勾配と逆向きに少しずつ進む」という原理、学習率の役割、収束を左右する条件数の考え方は、どの変種にも共通である。本章では、以下で単に「勾配降下法」と言うときは基本形を指し、変種は名前を付けて区別する。

5.2 勾配降下法

5.2.1 1 変数の場合

まず 1 変数で仕組みを確かめる。第 4.3.1 項と同じ下に凸な 2 次関数

$$f(w) = aw^2 - 2bw + c \qquad (a > 0)$$

を考える。最小点は $w^* = b/a$ であった。これを「微分して 0 とおく」のではなく、反復で求めてみる。

点 $w^{(t)}$ での傾きは $f'(w^{(t)}) = 2aw^{(t)} - 2b$ である。傾きが正なら右上がりなので左へ、負なら右へ動けば f は減る。すなわち「傾きと逆の向きに動く」のが正しい。動く量を傾きに比例させて

$$w^{(t+1)} = w^{(t)} - \eta\, f'(w^{(t)}) \tag{5.2}$$

と定める。$\eta > 0$ は 1 歩の大きさを調節する定数で、**学習率**（learning rate）と呼ぶ。記号 η は「イータ」と読む。

この更新を実際に追ってみよう。$f'(w) = 2a(w - w^*)$ と書き直せるので

$$w^{(t+1)} - w^* = (w^{(t)} - w^*) - 2a\eta\,(w^{(t)} - w^*) = (1 - 2a\eta)\,(w^{(t)} - w^*) \tag{5.3}$$

となる。最小点との差が、1 回の更新ごとに $(1 - 2a\eta)$ 倍される。したがって

$$w^{(t)} - w^* = (1 - 2a\eta)^t\,(w^{(0)} - w^*) \tag{5.4}$$

であり、$|1 - 2a\eta| < 1$、すなわち

$$0 < \eta < \frac{1}{a} \tag{5.5}$$

のときに限って $w^{(t)} \to w^*$ と収束する。η が小さいほど $(1 - 2a\eta)$ は 1 に近く、収束は遅い。η が $1/(2a)$ を超えると $(1 - 2a\eta)$ は負になり、最小点を**行き過ぎて**反対側に出る（振動しながら近づく）。さらに $\eta > 1/a$ では差が毎回拡大し、**発散**する。図 5.1 にこの 3 つの様子を示す。

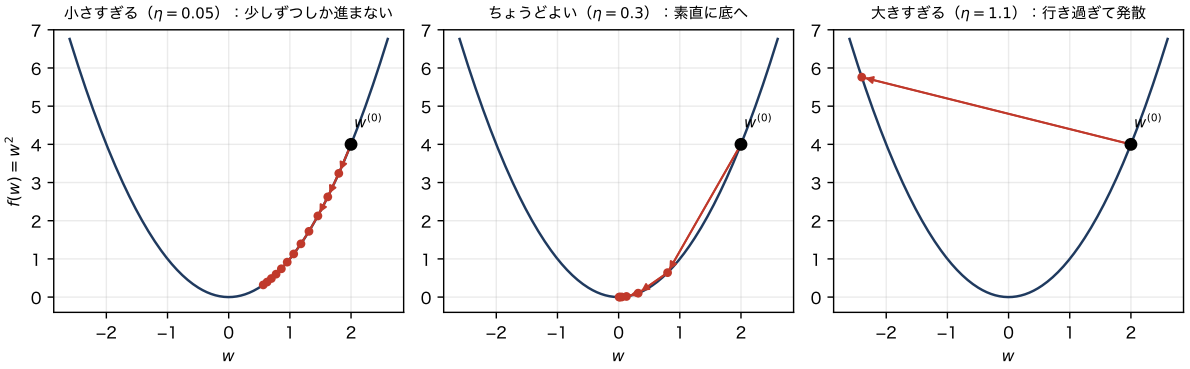


図 5.1　$f(w) = w^2$（$a = 1$）に対する勾配降下法。$w^{(0)} = 2$ から出発。学習率が小さいと進みが遅く、適切なら素直に底へ向かい、$1/a = 1$ を超えると行き過ぎを繰り返して発散する。

1 変数のうちに、重要な観察を 2 つしておく。第一に、収束の速さは a、すなわち $f'' = 2a$ という**曲がり具合**で決まる。第二に、安全な学習率の上限 $1/a$ もまた曲がり具合で決まる。多変数ではこの「曲がり具合」が向きによって異なり、それが収束の難しさを生む。

5.2.2　多変数への拡張

多変数では、傾き f' の役割を勾配 ∇f が担う。

定義：勾配降下法

微分可能な関数 $f : \mathbb{R}^p \to \mathbb{R}$ を最小化するために、初期値 $\boldsymbol{w}^{(0)} \in \mathbb{R}^p$ と学習率 $\eta > 0$ を定め、

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\,\nabla f(\boldsymbol{w}^{(t)}) \qquad (t = 0, 1, 2, \ldots) \tag{5.6}$$

を反復する方法を**勾配降下法**（gradient descent）と呼ぶ。

式 (5.6) は、p 本の式

$$w_i^{(t+1)} = w_i^{(t)} - \eta\,\frac{\partial f}{\partial w_i}(\boldsymbol{w}^{(t)}) \qquad (i = 1, \ldots, p)$$

をベクトルにまとめたものである。各座標について、1 変数のときとまったく同じ更新をしていることになる。

5.2.3 なぜ勾配と逆向きに進むのか

第 4.3.2 項では「∇f は最も急に増える向き」と述べた。ここでその理由を確かめておく。点 $\boldsymbol{w}$ から微小なベクトル $\boldsymbol{\delta}$ だけ動いたときの f の変化は、1 変数のときの $f(w+\delta) \approx f(w) + f'(w)\,\delta$ と同様に

$$f(\boldsymbol{w}+\boldsymbol{\delta}) \;\approx\; f(\boldsymbol{w}) + \nabla f(\boldsymbol{w})^{\top}\boldsymbol{\delta} \tag{5.7}$$

と近似できる（各座標について 1 変数の近似を適用し、足し合わせたものである）。f の変化量は、勾配と移動方向の**内積** $\nabla f(\boldsymbol{w})^{\top}\boldsymbol{\delta}$ で決まる。

ここで第 2 回のコーシー・シュワルツの不等式を思い出そう。$\|\boldsymbol{\delta}\|$ を一定にしたとき、内積 $\nabla f^{\top}\boldsymbol{\delta}$ が最大になるのは $\boldsymbol{\delta}$ が ∇f と同じ向きのとき、最小（最も負）になるのは $\boldsymbol{\delta}$ が $-\nabla f$ の向きのときである。したがって、同じ歩幅なら $-\nabla f$ の向きに進むのが f を最も大きく減らす。式 (5.6) の $\boldsymbol{\delta} = -\eta\nabla f(\boldsymbol{w})$ を式 (5.7) に代入すると

$$f(\boldsymbol{w}^{(t+1)}) \;\approx\; f(\boldsymbol{w}^{(t)}) - \eta\,\|\nabla f(\boldsymbol{w}^{(t)})\|^2 \;\le\; f(\boldsymbol{w}^{(t)}) \tag{5.8}$$

となり、η が十分小さければ各ステップで f は減少する。勾配が $\boldsymbol{0}$ でない限り、必ず減る。これが勾配降下法の根拠である。

5.2.4 最小二乗法への適用

経験損失に適用しよう。第 4.3.4 項より

$$\nabla L_D(\boldsymbol{w}) = \frac{2}{N}\,\boldsymbol{X}^{\top}(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y}) \tag{5.9}$$

であるから、更新式は

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \frac{2\eta}{N}\,\boldsymbol{X}^{\top}\bigl(\boldsymbol{X}\boldsymbol{w}^{(t)} - \boldsymbol{y}\bigr) \tag{5.10}$$

となる。括弧の中 $\boldsymbol{X}\boldsymbol{w}^{(t)} - \boldsymbol{y}$ は現在の予測と真の値の差、すなわち**残差**（の符号を変えたもの）である。以下これを $\boldsymbol{r} = \boldsymbol{X}\boldsymbol{w} - \boldsymbol{y} \in \mathbb{R}^N$ と書く。第 i 成分 $r_i = \hat{y}_i - y_i$ が観測 i の残差であり、$\boldsymbol{r}$ は観測の数 N だけ成分を持つ。残差に $\boldsymbol{X}^{\top}$ を掛けるのは、第 4.2.4 項で見たとおり「各列（各特徴）との内積を取る」操作であった。図 5.2 左のように、$\boldsymbol{X}^{\top}$ の第 j 行は $\boldsymbol{X}$ の第 j 列 $\boldsymbol{c}_j$（特徴 j の値を並べたもの）なので、$\boldsymbol{X}^{\top}\boldsymbol{r}$ の第 j 成分は $\boldsymbol{c}_j^{\top}\boldsymbol{r} = \sum_i x_{ij} r_i$、すなわち「特徴 j と残差の内積」である。つまり式 (5.10) は、成分ごとに見れば「特徴 j と残差の相関が正なら w_j を減らし、負なら増やす」という、きわめて自然な更新である。図 5.2 右は数値例（第 4 回と同じ $D = \{(1,3),(2,5),(3,6)\}$）での 1 回分の更新である。現在の直線が左側で高すぎ、右側で低すぎるとき、残差 $r_i = \hat{y}_i - y_i$ は左で正、右で負になる。x の大きい右側の残差が重く効くので $\boldsymbol{c}_1^{\top}\boldsymbol{r} < 0$ となり、傾き w_1 は増える。一方、残差の単純和 $\boldsymbol{c}_0^{\top}\boldsymbol{r}$ は正なので、切片 w_0 は減る。勾配降下法は、この「どの特徴が残差とどう相関しているか」を見て、パラメータを一斉に修正しているのである。

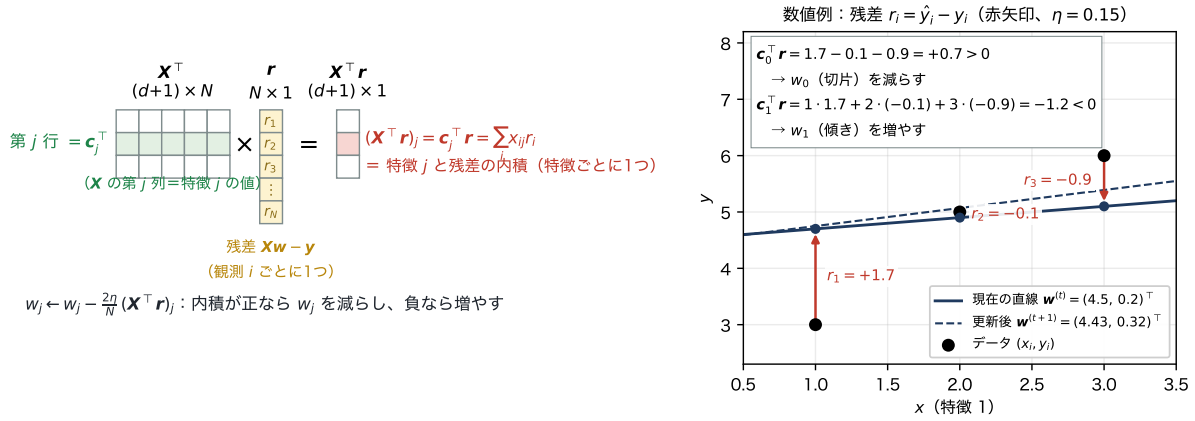


図 5.2　最小二乗法の勾配 $\boldsymbol{X}^\top \boldsymbol{r}$ の意味。左：残差 $\boldsymbol{r} = \boldsymbol{X}\boldsymbol{w} - \boldsymbol{y} \in \mathbb{R}^N$ は観測ごとに 1 成分を持つ。$\boldsymbol{X}^\top$ の第 j 行は $\boldsymbol{X}$ の第 j 列 $\boldsymbol{c}_j$ なので、$\boldsymbol{X}^\top \boldsymbol{r}$ の第 j 成分は「特徴 j と残差 $\boldsymbol{r}$ の内積」である。右：数値例で $\boldsymbol{w}^{(t)} = (4.5, 0.2)^\top$ からの 1 回の更新。残差（赤矢印）と各特徴との内積の符号が、各 w_j を増やすか減らすかを決める。

1 回の更新に必要な計算は、$\boldsymbol{X}\boldsymbol{w}$（$N(d+1)$ 回の掛け算）と $\boldsymbol{X}^\top(\cdot)$（同じく $N(d+1)$ 回）だけであり、逆行列は一切出てこない。d が大きくても、計算量は d に比例して増えるにすぎない。これが反復計算の利点である。

5.2.5　数値例

第 4 回と同じデータ $D = \{(1,3),(2,5),(3,6)\}$ で実際に計算する。計画行列と目的変数は

$$\boldsymbol{X} = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 3 \\ 5 \\ 6 \end{pmatrix}$$

であり、正規方程式の解は $\boldsymbol{w}^* = (5/3,\ 3/2)^\top$ であった。勾配を計算しやすいように

$$\boldsymbol{A} = \frac{2}{N}\boldsymbol{X}^\top \boldsymbol{X} = \frac{2}{3}\begin{pmatrix} 3 & 6 \\ 6 & 14 \end{pmatrix} = \begin{pmatrix} 2 & 4 \\ 4 & 28/3 \end{pmatrix}, \qquad \boldsymbol{b} = \frac{2}{N}\boldsymbol{X}^\top \boldsymbol{y} = \frac{2}{3}\begin{pmatrix} 14 \\ 31 \end{pmatrix} = \begin{pmatrix} 28/3 \\ 62/3 \end{pmatrix} \tag{5.11}$$

とおくと $\nabla L_D(\boldsymbol{w}) = \boldsymbol{A}\boldsymbol{w} - \boldsymbol{b}$ であり、更新式は $\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta(\boldsymbol{A}\boldsymbol{w}^{(t)} - \boldsymbol{b})$ となる。

初期値 $\boldsymbol{w}^{(0)} = (0,0)^\top$、学習率 $\eta = 0.1$ とする。最初の更新は $\boldsymbol{A}\boldsymbol{w}^{(0)} = \boldsymbol{0}$ なので

$$\boldsymbol{w}^{(1)} = \boldsymbol{0} - 0.1\,(\boldsymbol{0} - \boldsymbol{b}) = 0.1\,\boldsymbol{b} = \begin{pmatrix} 14/15 \\ 31/15 \end{pmatrix} \approx \begin{pmatrix} 0.933 \\ 2.067 \end{pmatrix}$$

2 回目は

$$\boldsymbol{A}\boldsymbol{w}^{(1)} - \boldsymbol{b} = \begin{pmatrix} 2\cdot 0.933 + 4\cdot 2.067 \\ 4\cdot 0.933 + 9.333\cdot 2.067 \end{pmatrix} - \begin{pmatrix} 9.333 \\ 20.667 \end{pmatrix} = \begin{pmatrix} 10.133 - 9.333 \\ 23.022 - 20.667 \end{pmatrix} = \begin{pmatrix} 0.800 \\ 2.356 \end{pmatrix}$$

$$\boldsymbol{w}^{(2)} = \begin{pmatrix} 0.933 \\ 2.067 \end{pmatrix} - 0.1\begin{pmatrix} 0.800 \\ 2.356 \end{pmatrix} = \begin{pmatrix} 0.853 \\ 1.831 \end{pmatrix}$$

である。以降の推移を表 5.1 にまとめる。

表 5.1　数値例に対する勾配降下法の推移（$\eta = 0.1$、$\boldsymbol{w}^{(0)} = \mathbf{0}$）。最適値は $\boldsymbol{w}^{*} = (1.667,\ 1.500)^{\top}$、$L_D(\boldsymbol{w}^{*}) = 1/18 \approx 0.0556$。

t	$w_0^{(t)}$	$w_1^{(t)}$	$L_D(\boldsymbol{w}^{(t)})$	$\partial L_D/\partial w_0$	$\partial L_D/\partial w_1$
0	0.000	0.000	23.333	-9.333	-20.667
1	0.933	2.067	0.430	0.800	2.356
2	0.853	1.831	0.152	-0.302	-0.163
3	0.884	1.847	0.144	-0.177	0.110
5	0.920	1.829	0.136	-0.179	0.079
10	1.005	1.791	0.118	-0.159	0.070
20	1.148	1.728	0.094	-0.125	0.055
50	1.417	1.610	0.065	-0.060	0.026
100	1.593	1.533	0.056	-0.018	0.008

表から 2 つのことが読み取れる。第一に、損失は最初の数回で急激に下がる（$23.3 \to 0.43 \to 0.15$）。第二に、そこから先は**非常に遅い**。$t = 100$ でもまだ $w_0 = 1.593$ であり、最適値 1.667 との差が残っている。損失の値は 0.056 でほぼ最適だが、パラメータの収束は遅い。この「最初は速く、あとが遅い」という振る舞いの理由を、第 5.3 節で明らかにする。

5.2.6　学習率の役割

同じ問題を、学習率を変えて解いた経路を図 5.3 に示す。

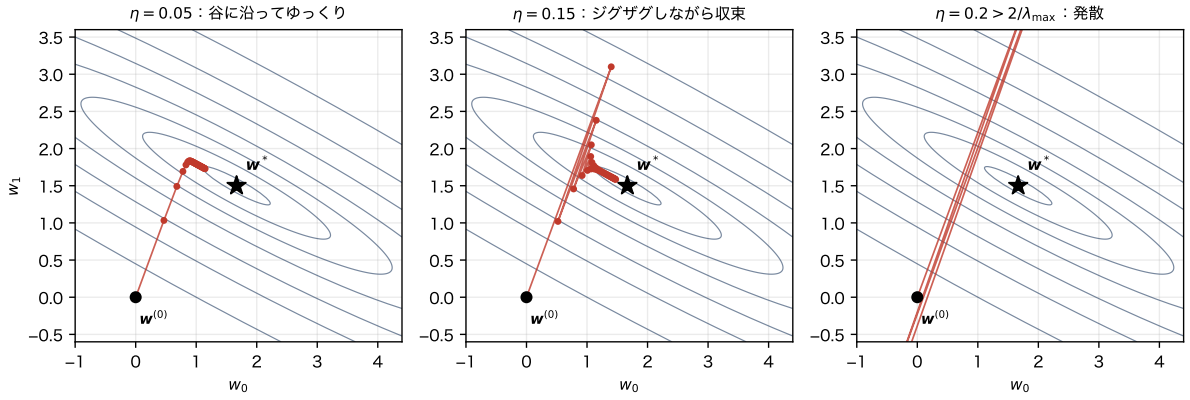


図 5.3　数値例の経験損失の等高線と、勾配降下法の経路（$\boldsymbol{w}^{(0)} = \mathbf{0}$）。左：$\eta = 0.05$ では谷に沿ってゆっくり進む。中：$\eta = 0.15$ では谷を横切る向きに行き過ぎてジグザグするが、収束する。右：$\eta = 0.2$ では 1 歩ごとに振れ幅が拡大し、発散する。

1 変数のときと同じ 3 つの振る舞いが見える。ただし多変数では、ジグザグの様子に注目してほしい。$\eta = 0.15$ の経路は、等高線の**短い軸の方向**には行き過ぎて往復しているのに、**長い軸の方向**（谷底に沿う向き）にはなかなか進まない。谷が細長いほど、この問題は深刻になる。

学習率の選び方は、実務では次のように行う。

- いくつかの値（$0.001, 0.01, 0.1, \ldots$）を試し、損失が発散せず最も速く下がるものを選ぶ
- 最初は大きめにとり、反復が進むにつれて小さくする（**学習率の減衰**）
- 勾配の履歴を使って方向ごとに歩幅を自動調整する（Adam などの適応的手法。深層学習で標準的）

しばらくは最も基本的な、一定の学習率を使う形で考える。学習率の減衰は第 5.5.4 項、Adam は第 5.6 節で扱う。

5.2.7 終了条件

反復は無限には続けられないので、どこかで止める必要がある。よく使われる判定は次の 3 つである。

1. **勾配が小さい**：$\|\nabla f(\boldsymbol{w}^{(t)})\| < \varepsilon$。最小点では勾配が $\boldsymbol{0}$ なので、その近くに来た印である。
2. **パラメータが動かない**：$\|\boldsymbol{w}^{(t+1)} - \boldsymbol{w}^{(t)}\| < \varepsilon$。式 (5.6) より、これは 1 と同じ条件を η 倍したものである（第 3.6 節で触れたとおり）。
3. **損失が減らない**：$f(\boldsymbol{w}^{(t)}) - f(\boldsymbol{w}^{(t+1)}) < \varepsilon$。

あるいは単純に、反復回数の上限を決めておく。表 5.1 の例では、$\|\nabla L_D\| < 0.01$ を条件にすると $t \approx 160$ で止まる。

5.3 収束の直感

勾配降下法はいつ収束し、どれくらいの速さで収束するのか。最小二乗法では L_D が 2 次関数なので、1 変数のとき（式 (5.4)、(5.5)）と同じように厳密に答えられる。本節ではその**結果と直感**を述べ、式の導出は付録 A にまとめる。結論は 3 つである：収束の条件は「最も急な向き」で決まる、収束の速さは「条件数」で決まる、だから特徴の標準化が効く。

5.3.1 固有ベクトルの向きごとに 1 変数問題に分かれる

式 (5.11) と同じく $\boldsymbol{A} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{X}$、$\boldsymbol{b} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{y}$ とおく。$\boldsymbol{A}$ は L_D のヘッセ行列であり（第 4.3.5 項）、最適解は $\boldsymbol{A}\boldsymbol{w}^* = \boldsymbol{b}$ を満たす（正規方程式の両辺を $2/N$ 倍したもの）。更新式 $\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta(\boldsymbol{A}\boldsymbol{w}^{(t)} - \boldsymbol{b})$ に $\boldsymbol{b} = \boldsymbol{A}\boldsymbol{w}^*$ を代入すると、誤差 $\boldsymbol{e}^{(t)} = \boldsymbol{w}^{(t)} - \boldsymbol{w}^*$ について

$$\boldsymbol{e}^{(t+1)} = (\boldsymbol{I} - \eta\boldsymbol{A})\,\boldsymbol{e}^{(t)} \tag{5.12}$$

を得る。式 (5.3) の $(1 - 2a\eta)$ が、行列 $(\boldsymbol{I} - \eta\boldsymbol{A})$ に置き換わった形である。1 変数では「毎回同じ数を掛ける」だけだったが、多変数では「毎回同じ行列を掛ける」ことになる。これを見通しよく扱う道具が固有値である（第 3.7 節）。

コラム：固有値・固有ベクトルを思い出す

第 3.7 節の内容を、本章で使う形に絞ってまとめ直しておく。

定義：正方行列 $\boldsymbol{A}$ に対して $\boldsymbol{A}\boldsymbol{v} = \lambda\boldsymbol{v}$（$\boldsymbol{v} \neq \boldsymbol{0}$）を満たす λ が固有値、$\boldsymbol{v}$ が固有ベクトルである。行列を掛けると、ほとんどのベクトルは向きも長さも変わる。ところが固有ベクトルだけは**向きが変わらず、長さが λ 倍されるだけ**である。固有ベクトルは、その行列にとっての「特別な向き」、いわば**変換の軸**である。

対称行列なら軸が直交する：$\boldsymbol{A}$ が対称（$\boldsymbol{A}^\top = \boldsymbol{A}$）なら、固有値はすべて実数で、固有ベクトルは**互いに直交する** p **本**がとれる。長さを 1 にそろえた固有ベクトルを列に並べた直交行列 $\boldsymbol{Q} = (\boldsymbol{v}_1 \cdots \boldsymbol{v}_p)$ と、固有値を対角に並べた

$\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_p)$ を使って

$$\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$$

と書ける（**固有値分解**）。本章で固有値を考える相手（$\boldsymbol{X}^\top\boldsymbol{X}$、ヘッセ行列、共分散行列）はすべて対称行列なので、以下はこの場合だけを考える。

なぜ便利か：行列の作用が「軸ごとの掛け算」になる：直交する p 本の固有ベクトルは空間全体を張るので、どんなベクトルも $\boldsymbol{e} = c_1\boldsymbol{v}_1 + \cdots + c_p\boldsymbol{v}_p$ と分解できる（$c_i = \boldsymbol{v}_i^\top\boldsymbol{e}$）。この形にしておくと $\boldsymbol{A}\boldsymbol{e} = c_1\lambda_1\boldsymbol{v}_1 + \cdots + c_p\lambda_p\boldsymbol{v}_p$ であり、$\boldsymbol{A}$ を t 回掛けても $\boldsymbol{A}^t\boldsymbol{e} = c_1\lambda_1^t\boldsymbol{v}_1 + \cdots + c_p\lambda_p^t\boldsymbol{v}_p$ と、「軸ごとに λ_i^t 倍」という 1 変数の計算 p 個に分かれる。$\boldsymbol{I} - \eta\boldsymbol{A}$ も固有ベクトルは同じで、固有値が $1 - \eta\lambda_i$ になる。本節の解析はこの性質だけを使う。

等高線との関係：固有値は軸ごとの曲がり具合：対称行列 $\boldsymbol{A}$ がヘッセ行列であるような 2 次関数 $f(\boldsymbol{w}) = \frac{1}{2}\boldsymbol{w}^\top\boldsymbol{A}\boldsymbol{w}$ を、固有ベクトルの座標 $u_i = \boldsymbol{v}_i^\top\boldsymbol{w}$ で書き直すと

$$f = \frac{1}{2}\left(\lambda_1 u_1^2 + \cdots + \lambda_p u_p^2\right)$$

となり、交差項が消える。したがって**等高線は固有ベクトルを軸とする楕円**で、固有値 λ_i は「$\boldsymbol{v}_i$ の向きに進んだときの曲がり具合」（式 (4.16)）であり、λ_i が大きい軸ほど楕円はその向きに短い（軸の長さは $1/\sqrt{\lambda_i}$ に比例）。すべての $\lambda_i > 0$ ならお椀（正定値）、$\lambda_i = 0$ の向きがあればその向きに平らな樋（とい）、というのが第 4.3.5 項の図 4.5 の正体である。最大と最小の固有値の比 $\kappa = \lambda_{\max}/\lambda_{\min}$（条件数）は、楕円の細長さの指標である。

数値例：$\boldsymbol{A} = \frac{2}{3}\boldsymbol{X}^\top\boldsymbol{X} = \begin{pmatrix} 2 & 4 \\ 4 & 28/3 \end{pmatrix}$ の特性方程式 $\det(\boldsymbol{A} - \lambda\boldsymbol{I}) = \lambda^2 - \frac{34}{3}\lambda + \frac{8}{3} = 0$ を解くと $\lambda_1 \approx 11.09$、$\lambda_2 \approx 0.240$、対応する固有ベクトルは $\boldsymbol{v}_1 \approx (0.40,\ 0.92)^\top$、$\boldsymbol{v}_2 \approx (0.92,\ -0.40)^\top$ である（互いに直交している）。図 5.4 左のとおり、$\boldsymbol{v}_1$ は等高線の短軸（急な向き）、$\boldsymbol{v}_2$ は長軸（緩やかな谷底の向き）を指す。右は同じ勾配降下法の経路を固有ベクトルの座標 (u_1, u_2) で描き直したもので、u_1 は符号を変えながら急速に 0 に近づき、u_2 はじりじりとしか減らない。

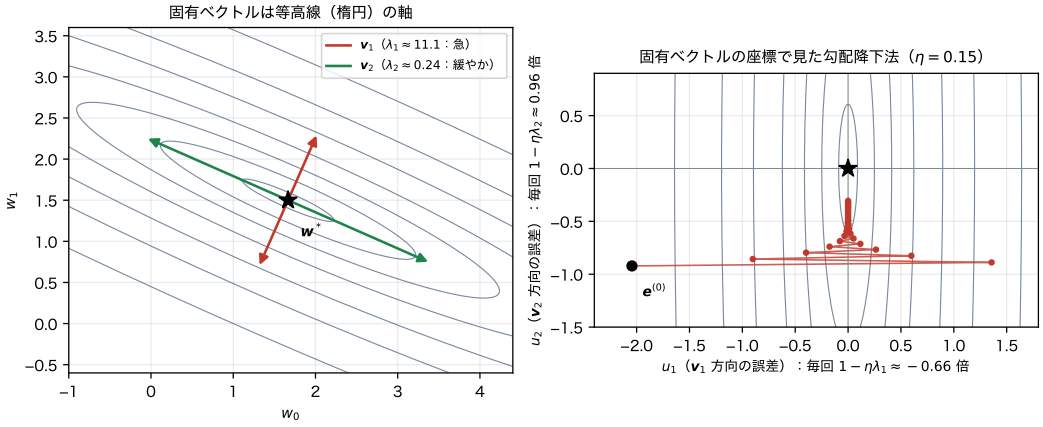


図 5.4　固有ベクトルと勾配降下法。左：数値例の等高線と、$\boldsymbol{w}^*$ を通る 2 本の固有ベクトル。固有値の大きい $\boldsymbol{v}_1$ の向きには等高線が詰まっており（急）、小さい $\boldsymbol{v}_2$ の向きには広い（緩やか）。右：誤差 $\boldsymbol{e} = \boldsymbol{w} - \boldsymbol{w}^*$ を固有ベクトルの座標 $u_i = \boldsymbol{v}_i^\top\boldsymbol{e}$ で表すと、等高線は軸に平行な楕円になり、勾配降下法は各軸で独立に $1 - \eta\lambda_i$ 倍の縮小を繰り返す。

$\boldsymbol{A}$ は対称かつ半正定値なので、固有値 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_p \geq 0$ と、互いに直交する固有ベクトル $\boldsymbol{v}_1, \ldots, \boldsymbol{v}_p$ をもつ。互いに直交する p 本の固有ベクトルは線形独立で $\mathbb{R}^p$ の基底をなすから（第 3.2.3 項）、初期誤差はこれらの一次結合として**一通りに** $\boldsymbol{e}^{(0)} = c_1\boldsymbol{v}_1 + \cdots + c_p\boldsymbol{v}_p$ と書ける。固有ベクトルの定義 $\boldsymbol{A}\boldsymbol{v}_i = \lambda_i\boldsymbol{v}_i$ より

$(\boldsymbol{I}-\eta\boldsymbol{A})\boldsymbol{v}_i = \boldsymbol{v}_i - \eta\lambda_i\boldsymbol{v}_i = (1-\eta\lambda_i)\boldsymbol{v}_i$ である。式 (5.12) を 1 回適用すると、行列の積は和に分配できるので

$$\boldsymbol{e}^{(1)} = (\boldsymbol{I}-\eta\boldsymbol{A})\boldsymbol{e}^{(0)} = \sum_{i=1}^{p} c_i\,(\boldsymbol{I}-\eta\boldsymbol{A})\boldsymbol{v}_i = \sum_{i=1}^{p} c_i\,(1-\eta\lambda_i)\,\boldsymbol{v}_i$$

となる。右辺もまた固有ベクトルの一次結合であり、基底による表し方は一通りなので、この式は「$\boldsymbol{v}_i$ の向きの係数が c_i から $c_i(1-\eta\lambda_i)$ に変わった」と読める。向きどうしが混ざらないのは、固有ベクトルが線形独立だからである。同じことを t 回くり返せば係数は $(1-\eta\lambda_i)^t$ 倍になるから

$$\boldsymbol{e}^{(t)} = \sum_{i=1}^{p} c_i\,(1-\eta\lambda_i)^t\,\boldsymbol{v}_i \tag{5.13}$$

である（固有値分解 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$ を使った同じ計算を付録 A に示す）。**各固有ベクトルの向きごとに、1 変数の式 (5.4) がそのまま成り立っている**（1 変数の $2a$ が λ_i に対応する）。向き $\boldsymbol{v}_i$ での「曲がり具合」が λ_i であり（式 (4.16)）、その向きの誤差は $(1-\eta\lambda_i)^t$ で減る。多変数の勾配降下法は、固有ベクトルの向きごとに独立に走る p 個の 1 変数の勾配降下法にほかならない。

定理：2 次関数に対する勾配降下法の収束

$\boldsymbol{A}$ が正定値（固有値がすべて正）のとき、勾配降下法が任意の初期値から $\boldsymbol{w}^*$ に収束するための必要十分条件は、すべての i について $|1-\eta\lambda_i| < 1$、すなわち

$$0 < \eta < \frac{2}{\lambda_{\max}} \tag{5.14}$$

である。ここで $\lambda_{\max} = \lambda_1$ は $\boldsymbol{A}$ の最大固有値である。

条件が**最大**固有値で決まる点に注意する。最も曲がりの急な向きで行き過ぎないように、学習率の上限が決まるのである。数値例では $\boldsymbol{A}$ の固有値は $\lambda_1 \approx 11.09$、$\lambda_2 \approx 0.240$ であり、$2/\lambda_{\max} \approx 0.180$ となる。図 5.3 で $\eta = 0.15$ が収束し $\eta = 0.2$ が発散したのは、このためである。

5.3.2 条件数と収束の速さ

収束するとして、その速さはどうか。式 (5.13) より、最も遅く減るのは $|1-\eta\lambda_i|$ が最も 1 に近い成分である。学習率を上限 $2/\lambda_{\max}$ の近くにとると、$\lambda_{\max}$ の向きはすぐ収束するが、$\lambda_{\min}$ の向きは $(1-\eta\lambda_{\min})$ が 1 に近いままで、いつまでも残る。逆に学習率を小さくすると、今度はすべての向きが遅くなる。学習率をどう選んでも、両方の向きを同時に速く減らすことはできない。

最もよい学習率は、両端の減衰率をそろえる $\eta = 2/(\lambda_{\max}+\lambda_{\min})$ であり、このとき誤差は毎回

$$\rho = \frac{\lambda_{\max}-\lambda_{\min}}{\lambda_{\max}+\lambda_{\min}} = \frac{\kappa-1}{\kappa+1}, \qquad \kappa = \frac{\lambda_{\max}}{\lambda_{\min}} \tag{5.15}$$

倍される（導出は付録 A.2）。κ は第 4.8.1 項で導入した**条件数**である。誤差を ε 倍まで縮めるのに必要な反復回数はおよそ $\log(1/\varepsilon)/\log(1/\rho)$ であり、κ が大きいときこれは κ に比例する。

収束の速さと条件数

2 次関数に対する勾配降下法の収束に必要な反復回数は、ヘッセ行列の**条件数** $\kappa = \lambda_{\max}/\lambda_{\min}$ にほぼ比例する。$\kappa = 1$（等高線が円）なら 1 回で収束し、κ が大きい（等高線が細長い楕円）ほど収束は遅い。

数値例では $\kappa \approx 11.09/0.240 \approx 46$ であり、$\rho \approx 0.958$ となる。誤差を $1/100$ にするには $\log 100/\log(1/0.958) \approx 107$ 回の反復が必要で、表 5.1 で $t = 100$ でもまだ差が残っていたのはこのためである。これが第 3.7.3 項で予告した「収束の速さはヘッセ行列の固有値の比で決まる」の正確な意味である。

5.3.3 ジグザグの正体

図 5.3 中央のジグザグも、同じ式から説明できる。$\lambda_{\max}$ の向きでは $(1-\eta\lambda_{\max})$ が負なので、誤差の符号が毎回反転する。すなわち谷を横切る向きに行ったり来たりする。一方 $\lambda_{\min}$ の向きでは $(1-\eta\lambda_{\min})$ が 1 に近い正の数なので、谷底に沿ってじりじりとしか進まない。この 2 つが重なって、細長い谷の中をジグザグに進む経路になる。

勾配は等高線に直交する（第 4.3.2 項）。等高線が細長い楕円のとき、谷底から少し外れた点での勾配は、谷底の向きではなく**谷の壁の向き**をほぼ指す。だから勾配の逆向きに進んでも、谷底に沿って進むことにはならないのである。第 3.7.3 項の「ほぼ平らな谷」は、正規方程式では解の不安定さとして、勾配降下法では収束の遅さとして現れる。同じ条件数の問題である。

5.3.4 特徴のスケーリング

条件数が収束を支配するなら、**条件数を小さくしてから**勾配降下法を適用すればよい。最も簡単で効果の大きい方法が、特徴の**標準化**（standardization）である。各特徴 x_j について、平均 $\bar{x}_j$ を引き、標準偏差 s_j で割る：

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \tag{5.16}$$

こうすると各特徴は平均 0・分散 1 にそろい、$\boldsymbol{X}^\top\boldsymbol{X}$ の対角成分が均等になる。

数値例でやってみよう。$x = 1, 2, 3$ の平均は 2、標準偏差は $\sqrt{2/3}$ なので $z = (-\sqrt{3/2},\ 0,\ \sqrt{3/2})^\top \approx (-1.225,\ 0,\ 1.225)^\top$ である。標準化した計画行列 $\boldsymbol{Z} = (\mathbf{1}\ \ \boldsymbol{z})$ について

$$\boldsymbol{Z}^\top\boldsymbol{Z} = \begin{pmatrix} 3 & \sum z_i \\ \sum z_i & \sum z_i^2 \end{pmatrix} = \begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix}$$

となる。平均を引いたので $\sum z_i = 0$、分散を 1 にしたので $\sum z_i^2 = 3 = N$ である。

標準化後のモデル $\hat{y} = w_0 + w_1 z$ の経験損失は $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{Z}\boldsymbol{w}\|^2$ であり、計画行列が $\boldsymbol{X}$ から $\boldsymbol{Z}$ に替わっただけで形は同じである。したがってそのヘッセ行列は、第 5.3.1 項の $\boldsymbol{A} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{X}$ の $\boldsymbol{X}$ を $\boldsymbol{Z}$ に置き換えた

$$\boldsymbol{A}_{\boldsymbol{Z}} = \frac{2}{N}\boldsymbol{Z}^\top\boldsymbol{Z} = \frac{2}{3}\begin{pmatrix} 3 & 0 \\ 0 & 3 \end{pmatrix} = 2\boldsymbol{I}$$

になる。対角行列の固有値は対角成分そのものなので、固有値は両方 2、条件数は $\kappa = 1$。等高線は真円になり、$\eta = 1/2$ とすれば $\boldsymbol{I} - \eta\boldsymbol{A}_{\boldsymbol{Z}} = \mathbf{0}$ なので、式 (5.12) より誤差は **1 回の更新で 0** になる（図 5.5）。なお、$\boldsymbol{w}$ は標準化後のモデルのパラメータなので、その最適解は元のモデルの $\boldsymbol{w}^*$ とは値が異なる。

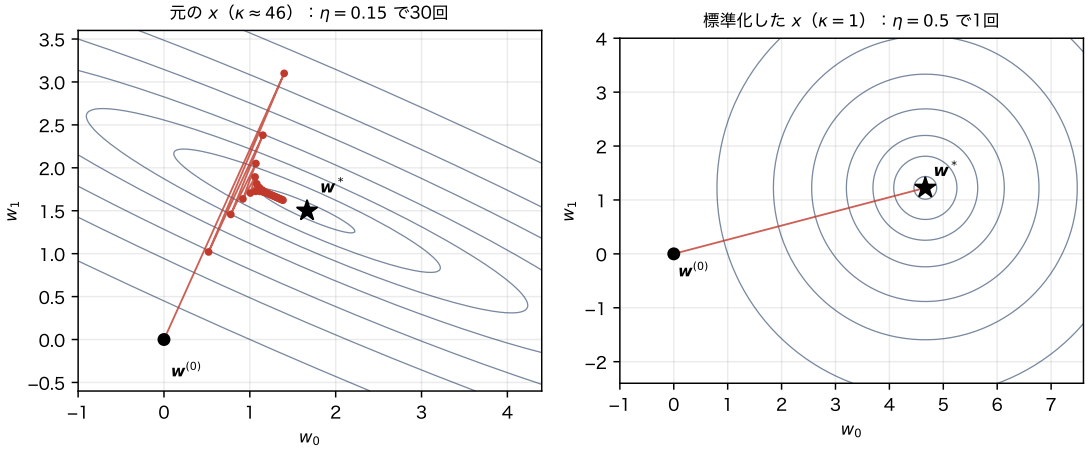


図 5.5　特徴の標準化の効果。左：元の x では等高線が細長く（$\kappa \approx 46$）、$\eta = 0.15$ で 30 回反復してもまだ届かない。右：x を標準化すると等高線が円になり（$\kappa = 1$）、$\eta = 0.5$ で 1 回の更新で最適解に着く。横軸・縦軸はそれぞれのモデルでのパラメータ w_0, w_1 であり、最適解の値は元のモデルとは異なる。

もちろん一般のデータで条件数がちょうど 1 になることはないが、特徴ごとの単位の違い（面積は m^2、距離は分、など）に由来する条件数の悪化は、標準化でほぼ解消できる。勾配降下法を使う前に特徴を標準化するのは、機械学習の実務における基本的な作法である。

ただし、標準化がそろえるのは $\boldsymbol{X}^\top \boldsymbol{X}$ の**対角成分**だけである。2 つの特徴が強く相関していると（第 3.5.5 項の多重共線性）、標準化しても非対角成分が残る。標準化済みの 2 つの特徴 z_1, z_2 の相関係数を r とすると、

$$\frac{1}{N}\boldsymbol{Z}^\top \boldsymbol{Z} = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}, \qquad \text{固有値は } 1 + r \ (\boldsymbol{v}_1 \propto (1,1)^\top), \quad 1 - r \ (\boldsymbol{v}_2 \propto (1,-1)^\top)$$

であり、条件数は $\kappa = (1+r)/(1-r)$ となる。$r = 0.8$ で $\kappa = 9$、$r = 0.95$ で $\kappa = 39$、$r = 0.99$ では $\kappa = 199$ に達する。図 5.6 のように、等高線は $(1,1)$ の向きにつぶれた斜めの楕円になる。2 つの特徴がほぼ同じ情報を持つので、「w_1 を増やして w_2 を減らす」向き（$\boldsymbol{v}_2$）には損失がほとんど変わらず、谷底がその向きに長く伸びるのである。相関（非対角成分）まで消す変換を**白色化**（whitening）といい、付録 A.3 で触れる。

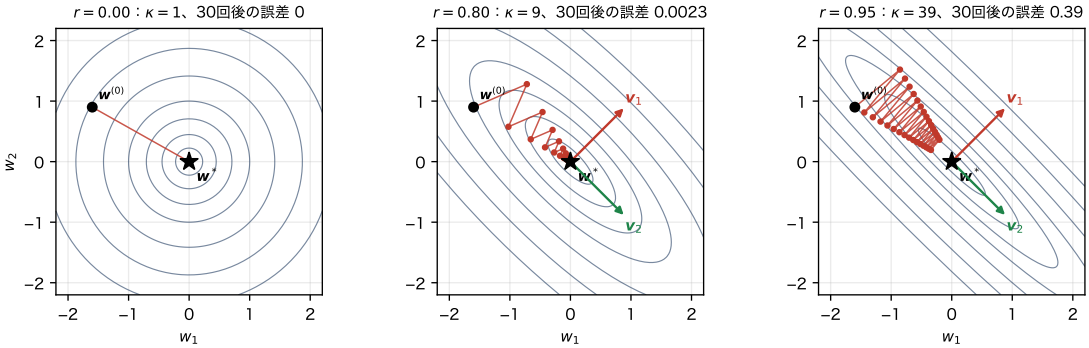


図 5.6　標準化済みの 2 特徴に相関 r があるときの等高線と勾配降下法の経路（$\boldsymbol{w}^* = \boldsymbol{0}$、最適な一定の学習率、30 回反復）。$r$ が大きいほど等高線は $\boldsymbol{v}_1 \propto (1,1)^\top$ の向きにつぶれ、$\boldsymbol{v}_2$ の向きの谷底に沿った収束が遅い（誤差は毎回 r 倍）。

5.4 凸関数

ここまで扱ってきた経験損失 $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ は $\boldsymbol{w}$ の 2 次関数であった。これは 2 つの前提の産物である。モデルが $\boldsymbol{w}$ について**線形**（$\hat{\boldsymbol{y}} = \boldsymbol{X}\boldsymbol{w}$ は $\boldsymbol{w}$ の 1 次式）であることと、損失が**二乗誤差**であることである（第 4.3.4 項）。1 次式を 2 乗するから 2 次式になるのであって、どちらか一方が崩れれば 2 次関数ではなくなる。二乗誤差でもニューラルネットワークのように $\hat{\boldsymbol{y}}$ が $\boldsymbol{w}$ の非線形関数なら 2 次にならないし、線形モデルでも絶対値誤差や、分類で使う損失（第 8 回の対数尤度、第 10 回のヒンジ損失）なら 2 次ではない。

2 次関数（ヘッセ行列が正定値のもの）では停留点がただ一つの最小点であり、勾配降下法はそこに向かって進んだ。しかし一般の関数では、勾配が $\boldsymbol{0}$ になる点が複数あったり、$\boldsymbol{0}$ になっても最小点でなかったりする。「勾配降下法で見つけた点は本当に最小点か」を保証する概念が凸性である。

5.4.1 定義

定義：凸集合

集合 $C \subseteq \mathbb{R}^p$ が**凸集合**（convex set）であるとは、C の任意の 2 点 $\boldsymbol{x}, \boldsymbol{y}$ と任意の $\theta \in [0, 1]$ に対して

$$\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y} \in C \tag{5.17}$$

が成り立つことをいう。すなわち、2 点を結ぶ線分が丸ごと C に含まれる。

記号を確認しておく。$\mathbb{R}^p$ は p 次元ベクトル全体の集合であり、本章では p はパラメータの数（$\boldsymbol{w} \in \mathbb{R}^p$ の次元）である。$C \subseteq \mathbb{R}^p$ は「C は $\mathbb{R}^p$ の部分集合」、$\boldsymbol{x} \in C$ は「点 $\boldsymbol{x}$ は C に属する」を表す。$\boldsymbol{x}, \boldsymbol{y}$ は C に属する 2 つの p 次元ベクトル（たとえば 2 通りのパラメータ）である。$\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y}$ は、$\theta = 1$ で $\boldsymbol{x}$、$\theta = 0$ で $\boldsymbol{y}$ に一致し、θ を 1 から 0 まで動かすと $\boldsymbol{x}$ から $\boldsymbol{y}$ へ線分上を動く（例えば $\theta = 1/2$ なら中点 $(\boldsymbol{x} + \boldsymbol{y})/2$）。したがって定義は「$C$ のどの 2 点を選んでも、その 2 点を結ぶ線分が C からはみ出さない」と言っている。

図 5.7 に $p = 2$ の例を示す。円板、半平面、三角形は、どの 2 点を結ぶ線分も中に収まるので凸集合である。三日月形やドーナツ形は、2 点の選び方によっては線分が集合の外（くぼみや穴）を通るので凸集合でない。$\mathbb{R}^p$ 全体、球、半空間、部分空間（原点を通る平面など）はすべて凸集合である。

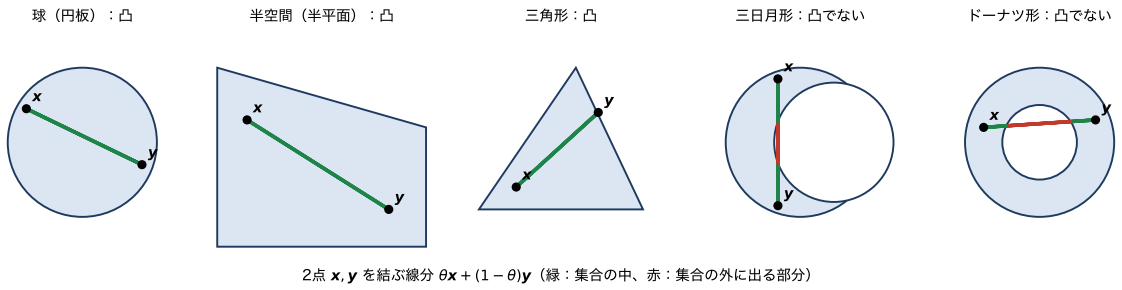


図 5.7 $\mathbb{R}^2$ の凸集合と凸でない集合。左の 3 つは、どの 2 点 $\boldsymbol{x}, \boldsymbol{y}$ を結ぶ線分も集合の中に収まる。右の 2 つは、線分が集合の外（赤い部分）に出る 2 点が存在するので凸集合でない。

なぜ凸集合から始めるのかというと、凸関数の定義（次の定義）で「2 点の間の点 $\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y}$ での関数

の値」を考えるので、その点が f の定義域に入っている必要があるからである。本章では f の定義域はつねに $\mathbb{R}^p$ 全体とする（パラメータはどんな値でもとれる）ので、凸集合の条件は自動的に満たされる。定義域を制限する場合（第 6 回の制約付き最適化）に、この条件が効いてくる。

定義：凸関数

凸集合 C 上の関数 $f : C \to \mathbb{R}$ が**凸関数**（convex function）であるとは、任意の $\boldsymbol{x}, \boldsymbol{y} \in C$ と任意の $\theta \in [0,1]$ に対して

$$f\big(\theta \boldsymbol{x} + (1-\theta)\boldsymbol{y}\big) \;\le\; \theta f(\boldsymbol{x}) + (1-\theta) f(\boldsymbol{y}) \tag{5.18}$$

が成り立つことをいう。$\boldsymbol{x} \neq \boldsymbol{y}$、$\theta \in (0,1)$ のとき不等号がつねに厳密（$<$）に成り立つなら、**狭義凸**（strictly convex）であるという。

式 (5.18) の意味を図 5.8 左で確認する。ここで用語を一つ定める。関数 f のグラフ上の 2 点 $(\boldsymbol{x}, f(\boldsymbol{x}))$ と $(\boldsymbol{y}, f(\boldsymbol{y}))$ を結ぶ線分を、その 2 点の間の**弦**（chord）と呼ぶ（円の弦と同じ言葉である）。弦上の点は、横の位置が $\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y}$ のとき高さが $\theta f(\boldsymbol{x}) + (1-\theta) f(\boldsymbol{y})$ である（両端の高さを同じ比率 $\theta : 1-\theta$ で混ぜたもの）。

式 (5.18) の左辺は、$\boldsymbol{x}$ と $\boldsymbol{y}$ の間の点 $\theta\boldsymbol{x} + (1-\theta)\boldsymbol{y}$ における**関数の値**（グラフの高さ）、右辺は同じ横の位置における**弦の高さ**である。したがって凸関数とは、**どの 2 点をとっても、弦がグラフの上（または上に接して）にある**関数である。「下に凸」とも呼ばれ、お椀を上向きに置いた形をしている。

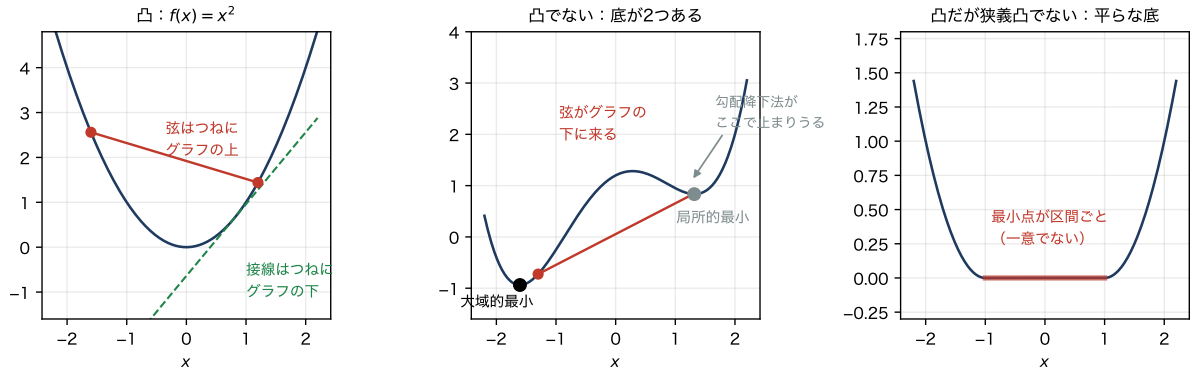


図 5.8　凸関数と凸でない関数。左：$f(x) = x^2$ は凸。任意の弦がグラフの上にあり、任意の接線がグラフの下にある。中：底が 2 つある関数は凸でない。弦がグラフの下に来る区間があり、勾配降下法は局所的最小点で止まりうる。右：底が平らな関数は凸だが狭義凸ではなく、最小点が区間ごと存在する。

1 変数の例を挙げる。x^2、$|x|$、e^x、$x \log x$（$x > 0$）はいずれも凸関数である。x^3 は凸でない（$x < 0$ で上に凸になる）。$\sin x$ も凸でない。多変数では、ノルム $\|\boldsymbol{x}\|$、2 次形式 $\boldsymbol{x}^\top \boldsymbol{A}\boldsymbol{x}$（$\boldsymbol{A}$ が半正定値のとき）が凸である。また、凸関数の和、凸関数の正の定数倍、凸関数の最大値はいずれも凸関数である（演習問題で確かめる）。

5.4.2　微分可能な場合の判定

定義 (5.18) を直接確かめるのは手間がかかる。微分可能な関数については、次の 2 つの判定法が使える。

定理：凸性の 1 次条件

微分可能な $f : \mathbb{R}^p \to \mathbb{R}$ が凸であることは、任意の $\boldsymbol{x}, \boldsymbol{y}$ に対して

$$f(\boldsymbol{y}) \ \geq \ f(\boldsymbol{x}) + \nabla f(\boldsymbol{x})^\top (\boldsymbol{y} - \boldsymbol{x}) \tag{5.19}$$

が成り立つことと同値である。

右辺は、点 $\boldsymbol{x}$ での f の**接平面**（1 変数なら接線）の高さである（式 (5.7) の近似を等式にしたもの）。したがって 1 次条件は、**どの点での接平面も、グラフの下にある**ことを言っている（図 5.8 左）。弦が上、接線が下。この 2 つは同じ性質の表と裏である。

定理：凸性の 2 次条件

2 回微分可能な $f : \mathbb{R}^p \to \mathbb{R}$ について、

- f が凸 $\iff$ すべての $\boldsymbol{x}$ でヘッセ行列 $\nabla^2 f(\boldsymbol{x})$ が**半正定値**
- すべての $\boldsymbol{x}$ でヘッセ行列が**正定値** $\implies$ f は狭義凸

1 変数なら「$f'' \geq 0$ なら凸、$f'' > 0$ なら狭義凸」である。多変数では、第 4.3.5 項で見たとおり $\boldsymbol{v}^\top (\nabla^2 f)\boldsymbol{v}$ が向き $\boldsymbol{v}$ での 2 階微分なので、「どの向きに切っても $f'' \geq 0$」が半正定値、「どの向きでも $f'' > 0$」が正定値に対応する。第 2.3.2 項で「半正定値なら凸、正定値なら狭義凸」と予告した言葉の意味がこれである。なお 2 つ目の矢印は逆向きには成り立たない。$f(x) = x^4$ は狭義凸だが $f''(0) = 0$ である。

5.4.3 凸関数の最小値

凸関数が重要な理由は、次の性質にある。

定理：凸関数の停留点は大域的最小点

微分可能な凸関数 f について、$\nabla f(\boldsymbol{w}^*) = \boldsymbol{0}$ ならば、$\boldsymbol{w}^*$ は f の**大域的最小点**（global minimum）である。すなわち、すべての $\boldsymbol{w}$ に対して $f(\boldsymbol{w}) \geq f(\boldsymbol{w}^*)$ が成り立つ。さらに f が狭義凸なら、最小点は $\boldsymbol{w}^*$ ただ一つである。

■5.4.3.1 **証明** 1 次条件 (5.19) で $\boldsymbol{x} = \boldsymbol{w}^*$ とおくと、任意の $\boldsymbol{w}$ に対して

$$f(\boldsymbol{w}) \ \geq \ f(\boldsymbol{w}^*) + \underbrace{\nabla f(\boldsymbol{w}^*)^\top}_{\boldsymbol{0}^\top} (\boldsymbol{w} - \boldsymbol{w}^*) = f(\boldsymbol{w}^*)$$

となる。これが大域的最小の定義そのものである。狭義凸のときは、$\boldsymbol{w} \neq \boldsymbol{w}^*$ に対して不等号が厳密になるので、$f(\boldsymbol{w}) > f(\boldsymbol{w}^*)$ であり、$\boldsymbol{w}^*$ 以外に最小点はない。 ■

この定理の意味を整理する。一般の関数では、勾配が $\boldsymbol{0}$ の点は「最小点か、最大点か、鞍点か、局所的な最小点にすぎないか」のいずれかであり、区別には追加の情報が要る（第 4.3.5 項）。しかし凸関数では、**勾配が $\boldsymbol{0}$ の点を見つけさえすれば、それが答え**である。局所的最小点と大域的最小点の区別がない。第 4 回で「$\nabla L_D = \boldsymbol{0}$ とおいて正規方程式を導く」ことが許された理由は、最小二乗法の L_D が凸だから、と一言で言える。

勾配降下法との関係も明らかになる。式 (5.8) により勾配降下法は損失を減らし続け、勾配が $\boldsymbol{0}$ の点に近づく。凸関数なら、その点が大域的最小点である。したがって**凸関数に対しては、勾配降下法は（学習率が適切**

なら）必ず最小点に収束する。凸でない関数では、図 5.8 中央のように、初期値によっては局所的最小点で止まる。

5.4.4 最小二乗法と正則化は凸である

経験損失 $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ のヘッセ行列は $\frac{2}{N}\boldsymbol{X}^\top\boldsymbol{X}$ であり、式 (4.18) よりつねに半正定値である。よって L_D は**凸関数**であり、停留点は大域的最小点である。$\boldsymbol{X}$ がフルランクならヘッセ行列は正定値で L_D は狭義凸、最小点はただ一つ。ランクが落ちていれば凸だが狭義凸でなく、図 5.8 右のように最小点が平らな谷に沿って無数に並ぶ。これは第 4.7 節の零空間の話の、凸関数の言葉による言い換えである。

第 6 回で扱うリッジ回帰 $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \lambda\|\boldsymbol{w}\|^2$（$\lambda > 0$）のヘッセ行列は $2(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I})$ である。第 4.7.5 項で見たとおり $\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I}$ はランクによらず正則であり、固有値は $\boldsymbol{X}^\top\boldsymbol{X}$ の固有値（≥ 0）に $\lambda > 0$ を足したものなので、正定値でもある。したがってリッジ回帰の損失は**つねに狭義凸**で、最小点はつねに一意に定まる。正則化の恩恵の一つが、ここにも現れている。

5.4.5 凸でないとき

ニューラルネットワーク（第 12 回）の損失関数は、パラメータについて凸でない。勾配降下法は局所的最小点や鞍点で止まりうるし、どこで止まるかは初期値に依存する。それでも深層学習が機能している理由は、本講義の範囲を超えるが、「高次元では悪い局所的最小点がまれである」「鞍点は勾配降下法の揺らぎで抜けられる」といったことが経験的・理論的に分かってきている。いずれにせよ、凸関数の理論は「何が保証され、何が保証されないか」を測る基準として、凸でない問題を考えるときにも不可欠である。

初期値についても一言触れておく。凸関数なら初期値はどこでもよく（本章の数値例では $\boldsymbol{w}^{(0)} = \boldsymbol{0}$ とした）、変わるのは反復回数だけである。一方ニューラルネットワークでは、すべてのパラメータを 0 にしてはいけない理由や、乱数の大きさを層の入力数に合わせて選ぶ方法（LeCun の初期化）など、初期値の設計が学習の成否を左右する。これは第 12 回で扱う。

5.5 確率的勾配降下法

5.5.1 バッチ勾配降下法の問題

式 (5.10) の 1 回の更新には、N 件すべてのデータを使った勾配の計算が必要である。全データ（**バッチ**、batch）を毎回使うので、これを**バッチ勾配降下法**と呼ぶ。N が数百万件になると、1 歩進むだけで大きな計算になり、しかも第 5.3 節で見たとおり、その 1 歩で進める距離は学習率で制限されている。

5.5.2 ミニバッチ

経験損失は各データの損失の平均 $L_D(\boldsymbol{w}) = \frac{1}{N}\sum_{i=1}^{N}\ell_i(\boldsymbol{w})$（$\ell_i(\boldsymbol{w}) = (y_i - \tilde{\boldsymbol{x}}_i^\top\boldsymbol{w})^2$）であるから、勾配も平均 $\nabla L_D = \frac{1}{N}\sum_i \nabla\ell_i$ である。そこで、全データの平均をとる代わりに、**ランダムに選んだ一部のデータ** $B \subset \{1, \ldots, N\}$ だけで勾配を近似する：

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\,\frac{1}{|B|}\sum_{i\in B}\nabla\ell_i(\boldsymbol{w}^{(t)}) \tag{5.20}$$

この部分集合 B を**ミニバッチ**（mini-batch）、その件数 $|B|$ を**バッチサイズ**と呼び、式 (5.20) を**確率的勾配降下法**（stochastic gradient descent, SGD）と呼ぶ。$|B|$ は 32 や 256 といった小さな数にとることが多い。用語の整理をしておく。

バッチ・ミニバッチ・確率的

- **バッチ勾配降下法**：$|B| = N$。毎回全データで勾配を計算する。式 (5.10)
- **ミニバッチ勾配降下法**：$1 < |B| < N$。実務で「SGD」と言えば通常これを指す
- **（狭義の）確率的勾配降下法**：$|B| = 1$。データ 1 件ごとに更新する

ミニバッチの勾配は本当の勾配 ∇L_D とは異なるが、B を一様ランダムに選べば平均的には一致する（**不偏**である）：B の選び方についての期待値をとると $\mathbb{E}\big[\frac{1}{|B|}\sum_{i\in B}\nabla\ell_i\big] = \frac{1}{N}\sum_{i=1}^{N}\nabla\ell_i = \nabla L_D$ となる（証明は第 7.6.2 項で与える）。図 5.9 左は、ある 1 点 $\boldsymbol{w}$ でミニバッチを引き直して勾配を計算することを 60 回くり返したものである。ミニバッチの勾配は真の勾配（赤矢印）のまわりに散らばるが、その中心は真の勾配に一致し、$|B|$ が大きいほど散らばりは小さい。1 歩あたりの計算量は N から $|B|$ に減り、同じ計算時間で $N/|B|$ 倍の更新ができる。その代わり、勾配の誤差のために経路は揺らぎ、最小点のまわりをふらつく（図 5.9 中央）。

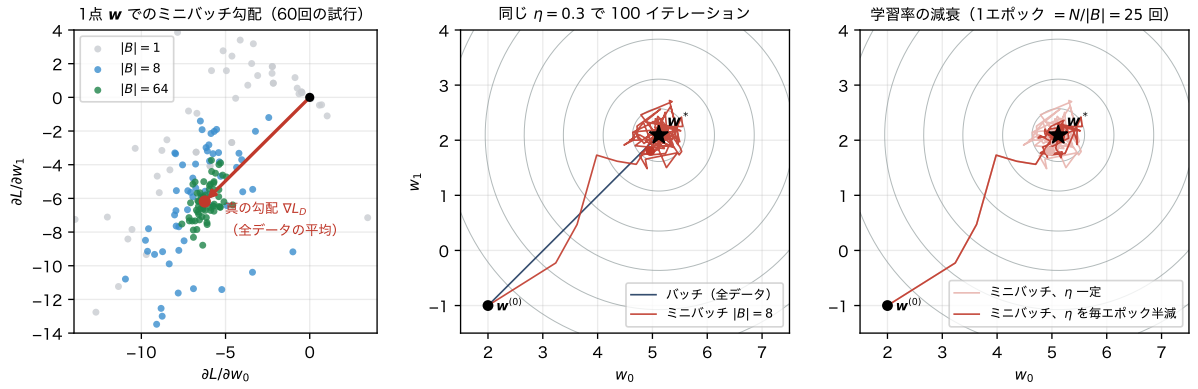


図 5.9　ミニバッチ勾配降下法（$N = 200$ 件の 1 特徴回帰、特徴は標準化済み）。左：1 点 $\boldsymbol{w}$ におけるミニバッチ勾配の散らばり。平均は真の勾配 ∇L_D に一致し、$|B|$ が大きいほど散らばりは小さい。中：同じ学習率でのバッチ勾配降下法（紺）とミニバッチ法（$|B| = 8$、赤）の経路。ミニバッチ法は揺らぎながら進み、最小点のまわりをふらつく。右：エポックごとに学習率を半減すると、ふらつきが収まり最小点に近づく（第 5.5.4 項）。

5.5.3　エポック

実際には、毎回 N 件から無作為に $|B|$ 件を選び直すのではなく、データ全体を**シャッフル**して先頭から $|B|$ 件ずつ切り出していく。こうすると、$N/|B|$ 回の更新で全データをちょうど 1 回ずつ使い終わる。この「全データを一巡する」単位を**エポック**（epoch）と呼ぶ。1 回の更新を**イテレーション**（iteration）または**ステップ**と呼び、

$$1\ \text{エポックのイテレーション数} = \frac{N}{|B|}$$

である。例えば $N = 60000$、$|B| = 100$ なら 1 エポックは 600 イテレーションになる。エポックが終わるたびにデータを再びシャッフルし、次のエポックに入る（図 5.10）。

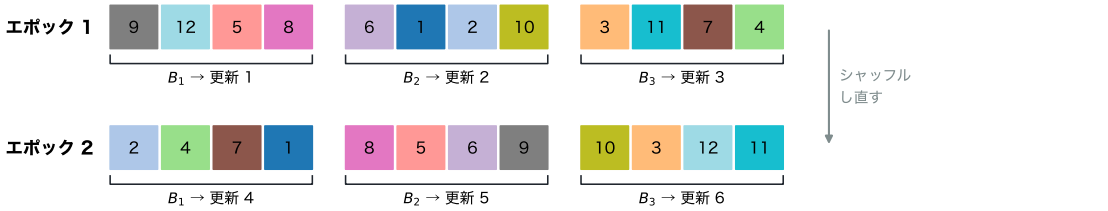


図 5.10　エポックとイテレーション。$N = 12$ 件を $|B| = 4$ 件ずつのミニバッチに切り分けると、1 エポック（全データを一巡）は $N/|B| = 3$ 回の更新からなる。エポックごとに順序をシャッフルし直す。

学習の長さは「何エポック回すか」で指定するのが普通である。ここで、式 (5.20) の更新はミニバッチを 1 つ取り出すたびに 1 回行うので、1 エポックの間に $N/|B|$ 回適用される（図 5.10 のエポック 1 なら B_1, B_2, B_3 に対して更新 1、2、3）。一方、バッチ勾配降下法の式 (5.10) は全 N 件で勾配を計算して 1 回動くので、その 1 回の更新がちょうど 1 エポック（全データを 1 回使う）に相当する。したがって同じエポック数で比べると、ミニバッチ法は $N/|B|$ 倍の更新を行っていることになる。第 5.3 節の「必要な反復回数」はイテレーション数についての話であり、エポック数に直せば $|B|/N$ 倍になる。これが、N が大きいときにミニバッチ法が圧倒的に有利な理由である。

5.5.4　学習率の減衰

ミニバッチの勾配には誤差があるので、学習率 η を固定したままでは最小点のまわりを η に比例する幅でふらつき続け、ぴたりとは収束しない。そこで、エポックが進むにつれて学習率を徐々に小さくする（**学習率の減衰**、learning rate decay）。例えば一定エポックごとに η を $1/10$ にする、あるいは $\eta_t = \eta_0/\sqrt{t}$ のように減らす。初めは大きな歩幅で大まかな位置を探し、後半は小さな歩幅で細かく詰める、という考え方である。図 5.9 右では、エポックごとに η を半減させることで、一定の η では残っていたふらつきが収まっている。深層学習の学習はほぼすべてこの方法（とその改良）で行われている。

5.6　勾配降下法の改良：モメンタムと Adam

第 5.3 節で見たとおり、勾配降下法の弱点は条件数が大きいときのジグザグと遅さである。最小二乗法なら標準化や白色化で条件数を整えられるが、ニューラルネットワークでは損失関数の形がパラメータの場所ごと・層ごとに異なり、前もって条件数を整えることができない。そこで、**更新式そのもの**を工夫して谷に沿って速く進む方法が数多く提案されてきた。ここでは最も基本的な**モメンタム**と、深層学習で標準的に使われる **Adam** を紹介する。以下では t 回目の勾配を $\boldsymbol{g}^{(t)} = \nabla f(\boldsymbol{w}^{(t)})$ と略記する。確率的勾配降下法ではミニバッチ勾配に置き換えればよい。

5.6.1　モメンタム

第 5.3.3 項のジグザグを思い出そう。谷の壁の向きの成分は符号が毎回反転し、谷底の向きの成分はいつも同じ向きを指していた。ならば、**過去の勾配を足し合わせて**進めばよい。反転する成分は打ち消し合い、同じ向きの成分は積み上がる。これが**モメンタム**（momentum、運動量）法である：

$$\boldsymbol{v}^{(t+1)} = \beta\,\boldsymbol{v}^{(t)} - \eta\,\boldsymbol{g}^{(t)}, \qquad \boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} + \boldsymbol{v}^{(t+1)} \tag{5.21}$$

$\boldsymbol{v}$ は**速度**、$\beta \in [0, 1)$ は**モメンタム係数**で、0.9 がよく使われる。$\boldsymbol{v}^{(0)} = \boldsymbol{0}$ から始め、$\beta = 0$ とすれば通常の勾配降下法に戻る。坂を転がるボールを思い浮かべるとよい。勾配 $\boldsymbol{g} = \nabla f$ は「最も急に**上る**向き」を指すので、ボールに働く力は**下り**向きの $-\boldsymbol{g}$ である。式 (5.21) の $-\eta \boldsymbol{g}^{(t)}$ はこの力による速度の変化（加速）であり、符号は通常の勾配降下法 $\boldsymbol{w} \leftarrow \boldsymbol{w} - \eta \nabla f$ と同じである（$+\eta \boldsymbol{g}$ にするとボールは坂を登ってしまう）。ボールはこの力で加速されるが、それまでの速度を β 倍だけ保ち続ける（慣性）。谷の壁に当たって跳ね返る動きは慣性で均され、谷底に沿った動きは加速していく。

式 (5.21) を $\boldsymbol{v}^{(0)} = \boldsymbol{0}$ から展開すると

$$\boldsymbol{v}^{(t+1)} = -\eta \sum_{k=0}^{t} \beta^{\,t-k}\, \boldsymbol{g}^{(k)} \tag{5.22}$$

となる。速度とは、過去の勾配を古いものほど β 倍ずつ軽くして足した**指数的な重み付き和**である。もし勾配がずっと同じ $\boldsymbol{g}$ なら、$\boldsymbol{v}$ は $-\eta \boldsymbol{g}(1 + \beta + \beta^2 + \cdots) = -\eta \boldsymbol{g}/(1 - \beta)$ に近づく。すなわち、同じ向きが続く成分では実効的な学習率が $1/(1 - \beta)$ 倍（$\beta = 0.9$ なら 10 倍）になる。逆に $\boldsymbol{g}, -\boldsymbol{g}, \boldsymbol{g}, -\boldsymbol{g}, \ldots$ と反転を繰り返す成分では $\boldsymbol{v}$ は $-\eta \boldsymbol{g}/(1 + \beta)$ 程度に抑えられる（演習問題 9）。谷底方向は加速し、壁方向は減速する、という狙いどおりの振る舞いである。

2 次関数に対しては、付録 A と同じ固有値解析ができ、η と β を最適に選んだときの減衰率は

$$\rho_{\mathrm{mom}} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \tag{5.23}$$

になることが知られている（Polyak, 1964。証明は省く）。式 (5.15) の $(\kappa - 1)/(\kappa + 1)$ と比べると、必要な反復回数が κ に比例から $\sqrt{\kappa}$ に比例へと改善する。$\kappa = 10^4$ なら 100 倍の差である。数値例（$\kappa \approx 46$）では、$\|\boldsymbol{w}^{(t)} - \boldsymbol{w}^{*}\| < 0.01$ に達するまでに勾配降下法（$\eta = 0.15$）が 124 回かかるのに対し、同じ η に $\beta = 0.7$ のモメンタムを加えると 23 回で済む（図 5.11 中央）。ただし β を大きくしすぎると、ボールが谷底を行き過ぎて振動する。図の中央でも最初の数歩は大きく揺れている。

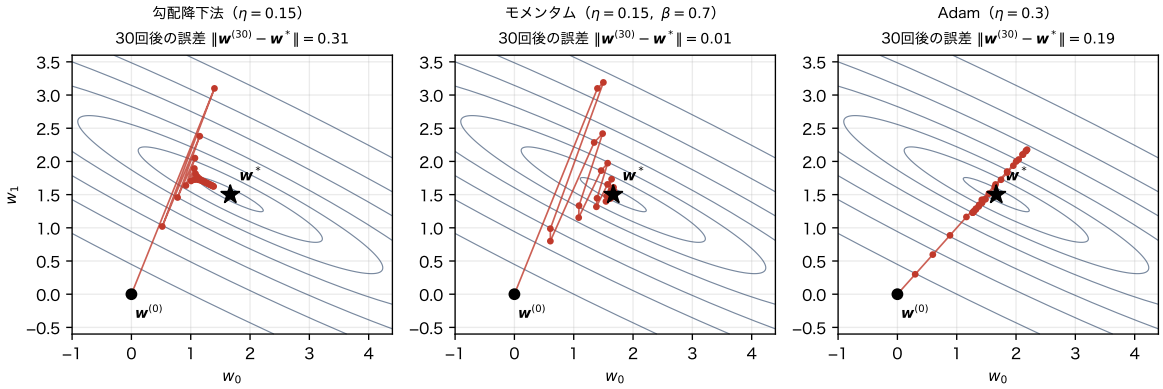


図 5.11　数値例に対する 3 つの方法の経路（それぞれ 30 回の更新）。左：勾配降下法は谷の壁をジグザグに往復しながらゆっくり谷底を進む。中央：モメンタムは最初に大きく揺れるが、往復の成分が打ち消されて速く最小点に近づく。右：Adam は各座標をほぼ一定の歩幅 η で動かすため、等高線の形によらず対角線上を進み、最小点を少し行き過ぎてから戻る。

5.6.2 座標ごとに歩幅を変える

勾配降下法のもう一つの弱点は、1 つの学習率 η をすべての成分に共通して使うことである。細長い谷では、勾配の大きな成分（壁の向き）に合わせて η を小さくせざるをえず、勾配の小さな成分（谷底の向き）はほとんど動けない。標準化と同じ発想を更新式に組み込み、**勾配の大きな成分は歩幅を小さく、小さな成分は歩幅を大きく**すればよい。そのために、勾配の 2 乗の移動平均 $\boldsymbol{s}$ を成分ごとに持ち、勾配をその平方根で割る：

$$\boldsymbol{s}^{(t+1)} = \beta_2\, \boldsymbol{s}^{(t)} + (1-\beta_2)\, \boldsymbol{g}^{(t)} \odot \boldsymbol{g}^{(t)}, \qquad \boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\, \frac{\boldsymbol{g}^{(t)}}{\sqrt{\boldsymbol{s}^{(t+1)}} + \epsilon} \tag{5.24}$$

ここで $\odot$ は成分ごとの積、平方根と割り算も成分ごとに行う。ϵ（10^{-8} 程度）は 0 で割るのを防ぐための小さな定数である。この方法は RMSProp（Hinton, 2012）と呼ばれる。$\sqrt{s_j}$ は成分 j の勾配の典型的な大きさなので、$g_j/\sqrt{s_j}$ はおよそ ± 1 の大きさになり、**どの成分も 1 回におよそ η だけ動く**。勾配の大きさ（単位）が更新量から消えるのである。

5.6.3 Adam

モメンタム（勾配の移動平均）と RMSProp（勾配の 2 乗の移動平均）を組み合わせ、さらに初期のずれを補正したものが **Adam**（adaptive moment estimation; Kingma and Ba, 2015）である。現在の深層学習で最も広く使われている更新則であり、次の 3 段階からなる。

Adam の更新則

$\boldsymbol{m}^{(0)} = \boldsymbol{v}^{(0)} = \boldsymbol{0}$ から始め、$t = 1, 2, \ldots$ について

$$\begin{aligned}
\boldsymbol{m}^{(t)} &= \beta_1\, \boldsymbol{m}^{(t-1)} + (1-\beta_1)\, \boldsymbol{g}^{(t-1)} && \text{（勾配の移動平均：1 次モーメント）} \\
\boldsymbol{v}^{(t)} &= \beta_2\, \boldsymbol{v}^{(t-1)} + (1-\beta_2)\, \boldsymbol{g}^{(t-1)} \odot \boldsymbol{g}^{(t-1)} && \text{（勾配の 2 乗の移動平均：2 次モーメント）} \\
\hat{\boldsymbol{m}}^{(t)} &= \frac{\boldsymbol{m}^{(t)}}{1-\beta_1^t}, \qquad \hat{\boldsymbol{v}}^{(t)} = \frac{\boldsymbol{v}^{(t)}}{1-\beta_2^t} && \text{（バイアス補正）} \\
\boldsymbol{w}^{(t)} &= \boldsymbol{w}^{(t-1)} - \eta\, \frac{\hat{\boldsymbol{m}}^{(t)}}{\sqrt{\hat{\boldsymbol{v}}^{(t)}} + \epsilon} && \text{（更新）}
\end{aligned} \tag{5.25}$$

既定値は $\beta_1 = 0.9$、$\beta_2 = 0.999$、$\epsilon = 10^{-8}$、$\eta = 10^{-3}$ である。

各段階の意味を確認しよう。

- **1 次モーメント $\boldsymbol{m}$**：モメンタムの速度と同じ役割だが、$(1-\beta_1)$ を掛けて正規化してあるので、$\boldsymbol{m}$ は勾配と同じスケールの「平均的な勾配」になる。符号が反転する成分は平均で小さくなり、同じ向きが続く成分は残る。
- **2 次モーメント $\boldsymbol{v}$**：RMSProp の $\boldsymbol{s}$ と同じで、各成分の勾配の典型的な大きさの 2 乗。$\beta_2 = 0.999$ は、およそ過去 1000 回分の平均をとることに相当する。
- **バイアス補正**：$\boldsymbol{m}^{(0)} = \boldsymbol{0}$ から始めるため、最初のうち $\boldsymbol{m}$ は小さすぎる。$t = 1$ では $\boldsymbol{m}^{(1)} = (1-\beta_1)\boldsymbol{g}^{(0)} = 0.1\, \boldsymbol{g}^{(0)}$ である。これを $1-\beta_1^t$ で割ると $\hat{\boldsymbol{m}}^{(1)} = \boldsymbol{g}^{(0)}$ と正しい大きさに戻る。t が大きくなると $\beta_1^t \to 0$ なので補正は効かなくなる。$\boldsymbol{v}$ についても同様で、$\beta_2 = 0.999$ では $\boldsymbol{v}$ が本来の大きさに育つまで 1000 回程度かかるため、この補正は欠かせない。
- **更新**：$\hat{\boldsymbol{m}}/\sqrt{\hat{\boldsymbol{v}}}$ は「平均的な勾配」を「典型的な大きさ」で割ったもので、各成分がおよそ ± 1 以下に

なる。したがって**各成分の 1 回の更新量は高々 η 程度**であり、勾配の大きさによらない。特に $t=1$ では $\hat{\boldsymbol{m}} = \boldsymbol{g}^{(0)}$、$\hat{\boldsymbol{v}} = \boldsymbol{g}^{(0)} \odot \boldsymbol{g}^{(0)}$ なので、更新量はちょうど $\eta \cdot \mathrm{sign}(\boldsymbol{g}^{(0)})$ である（演習問題 9）。

図 5.11 右は数値例に Adam（$\eta = 0.3$）を適用したものである。最初は両成分が毎回 0.3 ずつ、対角線に沿って進んでいる。最小点を行き過ぎると勾配の符号が変わり、$\boldsymbol{m}$ が小さくなって歩幅が縮み、引き返す。この例では収束までの回数は勾配降下法とあまり変わらず（$\|\boldsymbol{w}^{(t)} - \boldsymbol{w}^*\| < 0.01$ まで 96 回）、モメンタムの方が速い。Adam の強みは速さそのものより、**勾配のスケールに左右されない**ことにある。表 5.2 は、数値例の特徴 x の単位を 10 倍、100 倍にしたとき（$x = 10, 20, 30$ や $x = 100, 200, 300$ と測り直したとき）の反復回数である。勾配降下法は条件数の悪化がそのまま反復回数に跳ね返り、学習率も毎回選び直さなければならない。Adam は同じ η のまま、ほぼ同じ回数で収束する。

表 5.2　特徴 x の単位を変えたときの反復回数（$\|\boldsymbol{w}^{(t)} - \boldsymbol{w}^*\| < 0.01$ に達するまで）。勾配降下法は各行で最適な学習率 $\eta = 2/(\lambda_{\max} + \lambda_{\min})$ を用いた。元の $\eta = 0.15$ では 2 行目以降は発散する。Adam は $\eta = 0.3$ で固定。

特徴の値	条件数 κ	勾配降下法の η	勾配降下法	Adam
$x = 1, 2, 3$	46	0.18	125 回	96 回
$x = 10, 20, 30$	3.3×10^3	2.1×10^{-3}	8394 回	92 回
$x = 100, 200, 300$	3.3×10^5	2.1×10^{-5}	835650 回	659 回

5.6.4　どれを使うか

- 最小二乗法のように条件数を整えられる凸問題では、標準化した上での勾配降下法かモメンタムで十分であり、理論的な保証もそちらが強い。Adam は凸問題でも収束しない例が知られており（Reddi et al., 2018）、改良版が提案されている。
- ニューラルネットワークのように、層ごとに勾配のスケールが桁違いに異なり、条件数を前もって整えられない問題では、Adam（とその変種）が事実上の標準である。学習率をあまり丁寧に調整しなくても動く頑健さが、最大の利点である。
- いずれの方法でも学習率 η は調整が必要であり、第 5.5.4 項の学習率の減衰も併用する。Adam の η は「1 回に各パラメータが動く量」という意味を持つので、パラメータの典型的な大きさ（0.01 〜 1 程度）より十分小さく選ぶ、という目安が立つ。

本章で見てきた標準化・白色化・Adam は、いずれも「勾配降下法が扱う量のスケールをそろえる」という一つの考え方の現れである。勾配降下法は本来スケールに敏感な方法であり、そのままでは条件数の悪い問題に弱い。データの側（標準化・白色化）と更新則の側（Adam）でスケールをそろえることで、深層学習のような巨大な非凸問題でも実用になっている。第 12 回で扱うパラメータの初期値の設計（各層の出力の分散をそろえる）も、同じ発想の延長にある。

5.7　正規方程式と勾配降下法の比較

2 つの解法を表 5.3 に整理する。

表 5.3　正規方程式と勾配降下法の比較

	正規方程式（第 4 回）	勾配降下法（本章）
解の求め方	閉じた式で一度に	反復で少しずつ
計算量	$(d+1)^3$ に比例（逆行列）	1 回あたり $N(d+1)$ に比例。反復回数は κ に比例
d が大きいとき	困難	問題ない
N が大きいとき	$\boldsymbol{X}^\top\boldsymbol{X}$ を作れれば問題ない	SGD で対応
非線形モデル	使えない	使える（勾配さえ計算できれば）
調整すべきもの	なし	学習率、初期値、終了条件
精度	厳密解	近似解（反復を重ねれば任意の精度）
条件数の影響	解の数値誤差が増幅	収束が遅くなる

最小二乗法に限れば、d が数千程度までなら正規方程式（を QR 分解などで解いたもの）が速くて正確である。勾配降下法の真価は、d が巨大なとき、そして何よりモデルが非線形なときに発揮される。第 12 回のニューラルネットワークでは、勾配を効率よく計算する方法（誤差逆伝播法）と組み合わせて、本章の更新式 (5.6) がそのまま使われる。

5.8　まとめ

- 正規方程式は d が大きいときや非線形モデルでは使えない。代わりに**反復計算**で最小点に近づく
- **勾配降下法**：$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\nabla f(\boldsymbol{w}^{(t)})$。$-\nabla f$ は損失が最も速く減る向きであり、η が小さければ各ステップで損失は減る
- 最小二乗法では $\nabla L_D = \frac{2}{N}\boldsymbol{X}^\top(\boldsymbol{X}\boldsymbol{w} - \boldsymbol{y})$。1 回の更新は $N(d+1)$ に比例する計算で済み、逆行列は不要
- 学習率 η は小さすぎると遅く、大きすぎると発散する。2 次関数では $0 < \eta < 2/\lambda_{\max}$ が収束の条件
- 収束の速さはヘッセ行列の**条件数** $\kappa = \lambda_{\max}/\lambda_{\min}$ で決まる。細長い谷ではジグザグして遅い。特徴の**標準化**で $\boldsymbol{X}^\top\boldsymbol{X}$ の対角成分をそろえ、条件数を改善できる（相関＝非対角成分まで消す**白色化**は付録 A.3）
- **凸関数**：弦がグラフの上にある関数。微分可能なら接平面がグラフの下、2 回微分可能ならヘッセ行列が半正定値、と同値
- 凸関数では**停留点＝大域的最小点**。狭義凸なら一意。だから最小二乗法は $\nabla L_D = \boldsymbol{0}$ を解けばよく、勾配降下法は必ず最小点に収束する
- **確率的勾配降下法**：ミニバッチで勾配を近似し、N が巨大でも 1 歩を安く進む。全データを一巡する単位が**エポック**、1 回の更新が**イテレーション**。勾配の誤差によるふらつきは**学習率の減衰**で収める
- **モメンタム**は過去の勾配を蓄積してジグザグを打ち消し、反復回数を κ 比例から $\sqrt{\kappa}$ 比例へ改善する。**Adam** は勾配の移動平均を勾配の大きさで割り、各成分を歩幅 η 程度で動かす。勾配のスケールに左右されず、深層学習の標準的な方法である

本章で、「経験損失を最小にするパラメータを求める」という第 1 回以来の問題に、2 通りの解法（閉じた式

と反復計算）が揃った。しかし第 1 回で述べたとおり、経験損失を最小にすることと、未知のデータに対する誤差を小さくすることは別である。次回（第 6 回）は、訓練データへの当てはまりを少し犠牲にしてでも汎化を改善する**正則化**を扱う。本章で登場した $\lambda\|\boldsymbol{w}\|^2$ という項が、その主役になる。

5.9 演習問題

1. **1 変数の勾配降下法**　$f(w) = 3w^2 - 12w + 5$ について答えよ。
   (a) 最小点 w^* を微分して求めよ。
   (b) $w^{(0)} = 0$、$\eta = 0.1$ として $w^{(1)}, w^{(2)}, w^{(3)}$ を計算せよ。
   (c) 式 (5.4) を用いて、$w^{(t)} - w^*$ を t の式で書け。$w^{(3)}$ の値が (b) と一致することを確かめよ。
   (d) この f に対して勾配降下法が収束する学習率の範囲を求めよ。また、振動せずに収束する（$w^{(t)}$ が w^* を行き過ぎない）範囲を求めよ。
2. **最小二乗法への適用**　$\boldsymbol{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$、$\boldsymbol{y} = (1, 2, 2)^\top$（第 4 回演習問題 1 のデータ）について答えよ。
   (a) $\boldsymbol{A} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{X}$ と $\boldsymbol{b} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{y}$ を求めよ。
   (b) $\boldsymbol{w}^{(0)} = \boldsymbol{0}$、$\eta = 0.1$ として $\boldsymbol{w}^{(1)}$ と $\boldsymbol{w}^{(2)}$ を計算せよ。
   (c) $L_D(\boldsymbol{w}^{(0)})$、$L_D(\boldsymbol{w}^{(1)})$、$L_D(\boldsymbol{w}^{(2)})$ を計算し、単調に減っていることを確かめよ。
   (d) 第 4 回で求めた厳密解 $\boldsymbol{w}^* = (7/6, 1/2)^\top$ と $\boldsymbol{w}^{(2)}$ を比べ、どちらの成分がより収束しているか述べよ。
3. **収束条件**　問 2 の $\boldsymbol{A}$ について答えよ。
   (a) $\boldsymbol{A}$ の固有値 $\lambda_1 > \lambda_2$ を求めよ（特性方程式を解く）。
   (b) 条件数 κ を求めよ。
   (c) 勾配降下法が収束する学習率の上限 $2/\lambda_{\max}$ を求めよ。
   (d) 式 (5.15) の最適な学習率と、そのときの減衰率 ρ を求めよ。誤差を $1/1000$ にするのに必要な反復回数を見積もれ。
   (e) λ_1, λ_2 に対応する固有ベクトル $\boldsymbol{v}_1, \boldsymbol{v}_2$ を求め、互いに直交することを確かめよ。L_D の等高線（楕円）の長軸はどちらの固有ベクトルの向きか。理由とともに述べよ。
4. **勾配と逆向きに進む理由**　$f : \mathbb{R}^p \to \mathbb{R}$ を微分可能とし、点 $\boldsymbol{w}$ で $\nabla f(\boldsymbol{w}) \neq \boldsymbol{0}$ とする。長さ 1 の方向ベクトル $\boldsymbol{u}$（$\|\boldsymbol{u}\| = 1$）に対して、方向微分 $D_{\boldsymbol{u}} f(\boldsymbol{w}) = \nabla f(\boldsymbol{w})^\top \boldsymbol{u}$ を考える。
   (a) コーシー・シュワルツの不等式を用いて $-\|\nabla f(\boldsymbol{w})\| \le D_{\boldsymbol{u}} f(\boldsymbol{w}) \le \|\nabla f(\boldsymbol{w})\|$ を示せ。
   (b) 上の不等式で等号が成り立つ $\boldsymbol{u}$ をそれぞれ求めよ。
   (c) 式 (5.8) を導け。$\eta > 0$ かつ $\nabla f(\boldsymbol{w}^{(t)}) \neq \boldsymbol{0}$ なら右辺が $f(\boldsymbol{w}^{(t)})$ より真に小さいことを説明せよ。
5. **標準化**　3 件のデータの特徴が $x = 10, 20, 30$ であるとする。
   (a) バイアス項を含む計画行列 $\boldsymbol{X}$ について $\boldsymbol{X}^\top\boldsymbol{X}$ を求め、その固有値と条件数を求めよ（固有値は小数第 2 位までででよい）。
   (b) x を標準化した z を求め、計画行列 $\boldsymbol{Z} = (\boldsymbol{1}\ \ \boldsymbol{z})$ について $\boldsymbol{Z}^\top\boldsymbol{Z}$ と条件数を求めよ。
   (c) (a) と (b) で勾配降下法の収束に必要な反復回数がおよそ何倍違うか、式 (5.15) をもとに述べよ。
6. **凸関数の判定**　次の関数が凸かどうかを、2 次条件（1 変数なら $f'' \ge 0$）で判定せよ。凸の場合は狭義凸かどうかも述べよ。

(a) $f(x) = e^x$

(b) $f(x) = x^3$

(c) $f(x) = -\log x$（$x > 0$）

(d) $f(\boldsymbol{w}) = \boldsymbol{w}^\top \boldsymbol{A}\boldsymbol{w}$、ただし $\boldsymbol{A} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$

(e) $f(\boldsymbol{w}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \lambda\|\boldsymbol{w}\|^2$（$\lambda > 0$、$\boldsymbol{X}$ は任意）

7. **凸関数の性質**　$f, g : \mathbb{R}^p \to \mathbb{R}$ を凸関数とする。定義 (5.18) に基づいて次を示せ。

(a) $f + g$ は凸関数である。

(b) $c > 0$ に対して cf は凸関数である。

(c) $h(\boldsymbol{x}) = \max\{f(\boldsymbol{x}), g(\boldsymbol{x})\}$ は凸関数である。

(d) (a)(b) を用いて、経験損失 $\frac{1}{N}\sum_i (y_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{w})^2$ が凸であることを、各項 $(y_i - \tilde{\boldsymbol{x}}_i^\top \boldsymbol{w})^2$ が凸であることから導け（各項が凸であることは、1 変数の u^2 が凸であることと u が $\boldsymbol{w}$ の 1 次式であることから認めてよい）。

8. **局所的最小点**　$f(w) = w^4 - 4w^3 + 4w^2 + 1 = w^2(w-2)^2 + 1$ について答えよ。

(a) $f'(w) = 0$ となる w をすべて求めよ。

(b) それぞれの点が極小・極大のどちらかを f'' の符号で判定せよ。

(c) この f は凸か。理由とともに述べよ。

(d) $w^{(0)} = 1.2$ から小さな学習率で勾配降下法を始めたとき、どの点に収束するか。$w^{(0)} = 0.8$ ならどうか。初期値によって結果が変わる理由を述べよ。

9. **モメンタムと Adam**

(a) 式 (5.21) を $\boldsymbol{v}^{(0)} = \boldsymbol{0}$ から展開して式 (5.22) を導け。

(b) 勾配がずっと同じ $\boldsymbol{g}$ であるとき、$t \to \infty$ で $\boldsymbol{v}^{(t)}$ が $-\eta\boldsymbol{g}/(1-\beta)$ に近づくことを示せ。$\beta = 0.9$ のとき実効的な学習率は何倍になるか。

(c) 勾配が $\boldsymbol{g}, -\boldsymbol{g}, \boldsymbol{g}, -\boldsymbol{g}, \ldots$ と反転を繰り返すとき、$\boldsymbol{v}^{(t)}$ の大きさが $t \to \infty$ で $\eta\|\boldsymbol{g}\|/(1+\beta)$ に近づくことを示せ。

(d) 問 1 の $f(w) = 3w^2 - 12w + 5$ に対して、$w^{(0)} = 0$、$\eta = 0.1$、$\beta = 0.5$ のモメンタム法で $w^{(1)}, w^{(2)}, w^{(3)}$ を計算し、問 1(b) の勾配降下法と比べよ。

(e) Adam の更新則 (5.25) で $t = 1$ のとき、ϵ を無視すれば $\boldsymbol{w}^{(1)} = \boldsymbol{w}^{(0)} - \eta\,\mathrm{sign}(\boldsymbol{g}^{(0)})$ となることを示せ（sign は成分ごとの符号）。これが「勾配の大きさによらず各成分が η だけ動く」ことを意味する理由を述べよ。

6　正則化と汎化

第 4 回と第 5 回で、経験損失 $L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ を最小にするパラメータを求める方法が 2 通り揃った。しかし第 1 回で述べたとおり、学習の真の目標は訓練データへの当てはまりではなく、**未知のデータに対する誤差**（汎化誤差）を小さくすることである。経験損失を限界まで小さくすると、かえって汎化誤差が増える。これが**過学習**であった（第 1.5 節）。

本章では、過学習に対する最も基本的で、現在の深層学習でも使われ続けている処方箋、**正則化**（regularization）を学ぶ。考え方は単純で、経験損失に「パラメータが大きいことへの罰則」を加えて最小化する。第 4 回・第 5 回で何度も顔を出した $\lambda\|\boldsymbol{w}\|^2$ という項が、その主役である。

本章の流れは次のとおりである。まず、なぜ正則化が必要なのかを、過学習と多重共線性という 2 つの症状から確認する（第 6.1 節）。次に、L2 正則化を加えた最小二乗法である**リッジ回帰**を定義し、解を導き、固有値の目で「何が起きているのか」を理解する（第 6.2 節）。正則化の強さ λ をどう選ぶかという実務上の問題（第 6.3 節）を経て、正則化がなぜ汎化誤差を減らせるのかを**バイアスとバリアンス**の分解で説明する（第 6.4 節）。最後に、罰則を「制約」として読み替える**制約付き最適化**の見方を導入し、ノルムの形が解の形を決めること（L1 正則化と疎な解）を見る（第 6.5 節）。この見方は第 10 回・第 11 回のサポートベクターマシンへの準備でもある。

6.1　なぜ正則化が必要か

6.1.1　経験損失を最小にすると何が起きるか

第 1 回の図 1.1 を思い出そう。11 個の訓練データに 10 次多項式を当てはめると、曲線はすべての点をほぼ通過するが、点と点の間で激しく波打ち、真の関係からは遠ざかった。訓練誤差は最小なのに汎化誤差は大きい。これが過学習である。

このとき、パラメータの**値**に何が起きているかを見てみよう。図 6.1 の左は同じ当てはめであり、係数ベクトルの大きさは $\|\boldsymbol{w}\| \approx 10^6$ に達している（多項式の特徴 $x, x^2, \ldots, x^{10}$ を標準化した上での値）。隣り合う次数の係数が巨大な正と負の値をとり、互いに打ち消し合いながら、訓練データの点だけを正確に通るように曲線を曲げているのである。

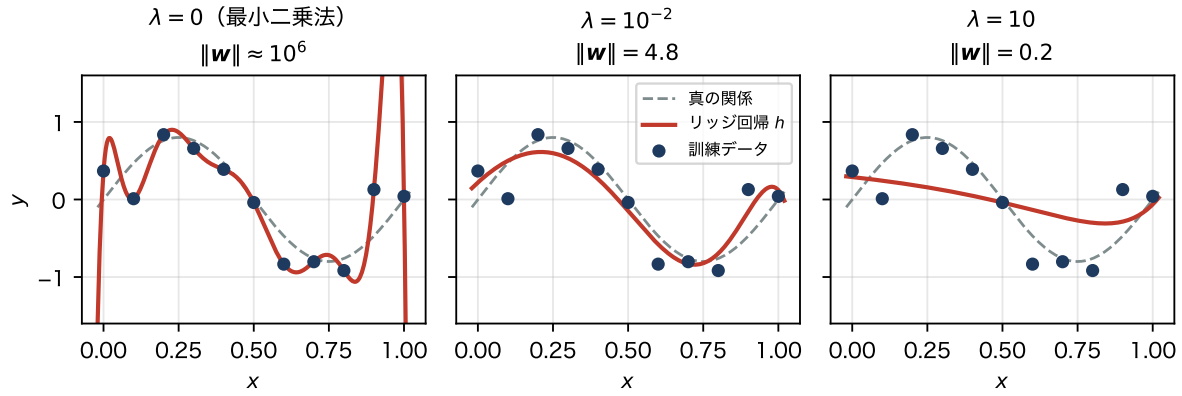


図 6.1　第 1 回と同じ 11 点のデータに 10 次多項式を当てはめたもの。左：最小二乗法（$\lambda = 0$）。すべての点を通ろうとして係数が 10^6 の桁まで膨らみ、点の間で暴れる。中：罰則 $\lambda\|\boldsymbol{w}\|^2$（$\lambda = 10^{-2}$）を加えると、係数は $\|\boldsymbol{w}\| = 4.8$ に収まり、真の関係に近い滑らかな曲線になる。右：罰則が強すぎる（$\lambda = 10$）と係数が小さくなりすぎ、構造を捉えられない（未学習）。

6.1.2　もう一つの症状：解が定まらない

第 3.5.5 項の家賃の例では、別の形の困難を見た。「広さ」と「部屋数」のように強く相関した特徴が並ぶと（多重共線性）、経験損失の谷はある方向にほぼ平らになり（図 3.7）、家賃に 0.3 万円程度の誤差を加えただけで最適解が谷に沿って大きく滑った。「広さ中心のモデル」にも「部屋数中心のモデル」にもなりうる、つまり**推定が不安定**なのである。完全に線形従属なら、解はそもそも一意に定まらない（第 4.7 節）。

一見すると、過学習（データのノイズまで再現する）と多重共線性（解が定まらない）は別の問題に見える。しかし両者には共通の原因がある。**モデルの自由度が、データが決められる量に比べて過剰である**ことである。多項式の例では「11 点を決めるのに 11 個の係数」があり、家賃の例では「ほとんど同じ情報をもつ 2 つの列に別々の係数」があった。データが決めきれない自由度は、ノイズが決めることになる。そして、ノイズに合わせて動いたパラメータは、どちらの例でも**不必要に大きな値**をとっていた。

6.1.3　重みが大きいことの害

パラメータが大きいこと自体がなぜ悪いのか。線形モデル $h(\boldsymbol{x};\boldsymbol{w}) = \boldsymbol{w}^\top \tilde{\boldsymbol{x}}$ では、入力が $\Delta\boldsymbol{x}$ だけ変わると出力は $\boldsymbol{w}^\top \Delta\boldsymbol{x}$ だけ変わる。コーシー・シュワルツの不等式（第 2.4.1 項）より

$$|\boldsymbol{w}^\top \Delta\boldsymbol{x}| \le \|\boldsymbol{w}\|\,\|\Delta\boldsymbol{x}\| \tag{6.1}$$

であり、$\|\boldsymbol{w}\|$ は「入力のわずかな違いが出力にどれだけ増幅されるか」の上限である。$\|\boldsymbol{w}\|$ が大きいモデルは、入力のノイズや訓練データにない微妙な違いに過敏に反応する。図 6.1 左の曲線が点の間で暴れるのは、まさにこの増幅の現れである。逆に、**同じ程度に当てはまるなら、$\|\boldsymbol{w}\|$ が小さいモデルのほうが滑らかで、未知のデータに対して安全**である。第 4.7.5 項で最小ノルム解を選んだ理由も、同じ考えに基づいていた。

6.1.4 正則化の考え方

以上から、処方箋は自然に導かれる。経験損失だけを最小にするのではなく、「当てはまりの良さ」と「パラメータの小ささ」を**同時に**要求するのである。

定義：正則化

経験損失 $L_D(\boldsymbol{w})$ に、パラメータの大きさや複雑さを測る**正則化項**（regularization term、罰則項）$R(\boldsymbol{w}) \geq 0$ を加えた

$$J_\lambda(\boldsymbol{w}) = L_D(\boldsymbol{w}) + \lambda R(\boldsymbol{w}), \qquad \lambda \geq 0 \tag{6.2}$$

を最小化することを**正則化**（regularization）と呼ぶ。λ は**正則化係数**であり、当てはまりと単純さのどちらをどれだけ重視するかを決める。

$\lambda = 0$ なら元の経験損失最小化に戻り、λ を大きくするほど「小さい $\boldsymbol{w}$」が優先される。$R(\boldsymbol{w})$ の選び方はいくつかあるが、最も基本的なのは

$$R(\boldsymbol{w}) = \|\boldsymbol{w}\|^2 = \sum_j w_j^2 \tag{6.3}$$

とする **L2 正則化**である。これを線形回帰に適用したものを次節で詳しく調べる。なお「正則化」という語は、第 4.5.3 項の「正則な行列」（逆行列をもつ行列）と無関係ではない。次節で見るとおり、罰則を加えると正規方程式の係数行列がつねに正則になるからである。

6.2 L2 正則化：リッジ回帰

6.2.1 定義

定義：リッジ回帰

計画行列 $\boldsymbol{X} \in \mathbb{R}^{N \times (d+1)}$、出力 $\boldsymbol{y} \in \mathbb{R}^N$、正則化係数 $\lambda \geq 0$ に対して、

$$J_\lambda(\boldsymbol{w}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \lambda \|\boldsymbol{w}\|^2 \tag{6.4}$$

を最小にする $\boldsymbol{w} \in \mathbb{R}^{d+1}$ を求める問題を**リッジ回帰**（ridge regression）または **L2 正則化付き最小二乗法**と呼ぶ。最小解を $\boldsymbol{w}_\lambda$ と書く。

いくつか注意しておく。

- 式 (6.4) では経験損失の $1/N$ を省いた。$1/N$ を付けた定義 $L_D + \lambda' \|\boldsymbol{w}\|^2$ と比べると $\lambda = N\lambda'$ の違いがあるだけで、解の性質は変わらない。文献やライブラリによって流儀が異なるので、λ の値を比べるときは定義を確認する必要がある。
- 実務では、バイアス項 w_0 は罰則に含めないのが普通である。w_0 は出力全体の平均的な水準を表すだけで、モデルの複雑さとは無関係だからである。扱いは第 6.3.4 項で述べる。本節の数値例では、式を簡単にするため w_0 も含めて罰する。
- 「リッジ」（ridge、尾根）という名前は、次項で見るように $\boldsymbol{X}^\top \boldsymbol{X}$ の対角成分（行列の尾根）に λ を足すことに由来する。

6.2.2 解の導出

第 4.3 節の手順をそのまま使う。J_λ を展開すると、第 4.3.4 項の式に $\lambda \boldsymbol{w}^\top \boldsymbol{w}$ が加わるだけで

$$J_\lambda(\boldsymbol{w}) = \boldsymbol{y}^\top \boldsymbol{y} - 2\boldsymbol{y}^\top \boldsymbol{X}\boldsymbol{w} + \boldsymbol{w}^\top \boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} + \lambda \boldsymbol{w}^\top \boldsymbol{w} \tag{6.5}$$

である。公式 (4.11) と (4.12) を用いると（最後の項は $\boldsymbol{A} = \boldsymbol{I}$ とした式 (4.12)）

$$\nabla J_\lambda(\boldsymbol{w}) = -2\boldsymbol{X}^\top \boldsymbol{y} + 2\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} + 2\lambda \boldsymbol{w} = 2\left\{(\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})\boldsymbol{w} - \boldsymbol{X}^\top \boldsymbol{y}\right\} \tag{6.6}$$

となる。$\nabla J_\lambda = \boldsymbol{0}$ とおけば

$$(\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})\, \boldsymbol{w} = \boldsymbol{X}^\top \boldsymbol{y} \tag{6.7}$$

を得る。正規方程式 (4.9) の $\boldsymbol{X}^\top \boldsymbol{X}$ が $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I}$ に置き換わった形である。

定理：リッジ回帰の解

$\lambda > 0$ ならば、$\boldsymbol{X}$ のランクによらず $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I}$ は正則であり、リッジ回帰の解はただ一つ

$$\boldsymbol{w}_\lambda = (\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})^{-1} \boldsymbol{X}^\top \boldsymbol{y} \tag{6.8}$$

で与えられる。

正則性の理由は第 4.7.5 項で見た。任意の $\boldsymbol{v} \neq \boldsymbol{0}$ に対して

$$\boldsymbol{v}^\top (\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})\boldsymbol{v} = \|\boldsymbol{X}\boldsymbol{v}\|^2 + \lambda \|\boldsymbol{v}\|^2 > 0 \tag{6.9}$$

なので $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I}$ は正定値であり、正定値行列は正則である（第 4.5.3 項）。同じ理由で J_λ のヘッセ行列 $2(\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I})$ は正定値、すなわち J_λ は狭義凸であり、停留点 (6.7) は唯一の大域的最小点である（第 5.4.4 項）。式 (6.9) の第 2 項 $\lambda \|\boldsymbol{v}\|^2$ が、$\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる方向（零空間、第 4.7.1 項）でも値を正に保っている点が要である。罰則を加えた瞬間、ランク落ちによる「解が無数にある」問題は消える。

6.2.3 数値例

第 4 回演習問題 1 のデータ

$$\boldsymbol{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}, \qquad \boldsymbol{y} = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}, \qquad \boldsymbol{X}^\top \boldsymbol{X} = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}, \qquad \boldsymbol{X}^\top \boldsymbol{y} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$$

で計算してみよう。最小二乗解は $\boldsymbol{w}^* = (7/6, 1/2)^\top \approx (1.167, 0.5)^\top$ であった。$\lambda = 1$ とすると

$$\boldsymbol{X}^\top \boldsymbol{X} + \boldsymbol{I} = \begin{pmatrix} 4 & 3 \\ 3 & 6 \end{pmatrix}, \qquad (\boldsymbol{X}^\top \boldsymbol{X} + \boldsymbol{I})^{-1} = \frac{1}{15}\begin{pmatrix} 6 & -3 \\ -3 & 4 \end{pmatrix}$$

なので

$$\boldsymbol{w}_1 = \frac{1}{15}\begin{pmatrix} 6 & -3 \\ -3 & 4 \end{pmatrix}\begin{pmatrix} 5 \\ 6 \end{pmatrix} = \frac{1}{15}\begin{pmatrix} 12 \\ 9 \end{pmatrix} = \begin{pmatrix} 0.8 \\ 0.6 \end{pmatrix}$$

となる。表 6.1 に λ を変えたときの解をまとめた。

表 6.1　数値例におけるリッジ回帰の解。λ を増やすと当てはまり $\|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}_\lambda\|^2$ は悪くなり、$\|\boldsymbol{w}_\lambda\|^2$ は小さくなる。

λ	$\boldsymbol{w}_\lambda$	$\|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}_\lambda\|^2$	$\|\boldsymbol{w}_\lambda\|^2$	$J_\lambda(\boldsymbol{w}_\lambda)$
0	$(1.167,\ 0.500)^\top$	0.167	1.611	0.167
1	$(0.800,\ 0.600)^\top$	0.400	1.000	1.400
10	$(0.306,\ 0.339)^\top$	3.349	0.209	5.436
100	$(0.047,\ 0.056)^\top$	7.899	0.005	8.431

表から読み取れることを整理する。

- λ が大きいほど $\|\boldsymbol{w}_\lambda\|$ は小さく、$\lambda\to\infty$ で $\boldsymbol{w}_\lambda\to\boldsymbol{0}$ となる。罰則だけが効いて「何も予測しないモデル」に近づく。
- 引き換えに当てはまりは悪くなる。$\lambda=1$ では残差の二乗和が 0.167 から 0.400 に増えた。これは正則化の本質であり、**訓練データへの当てはまりを少し犠牲にする**代わりに、小さく安定したパラメータを得ている。
- $\boldsymbol{w}_\lambda$ は $\boldsymbol{w}^*$ と $\boldsymbol{0}$ を結ぶ直線上を動くわけではない。図 6.2 左のように、等高線の形（$=\boldsymbol{X}^\top\boldsymbol{X}$ の固有ベクトル）に沿って曲がった軌跡を描く。この理由は第 6.2.5 項で明らかになる。

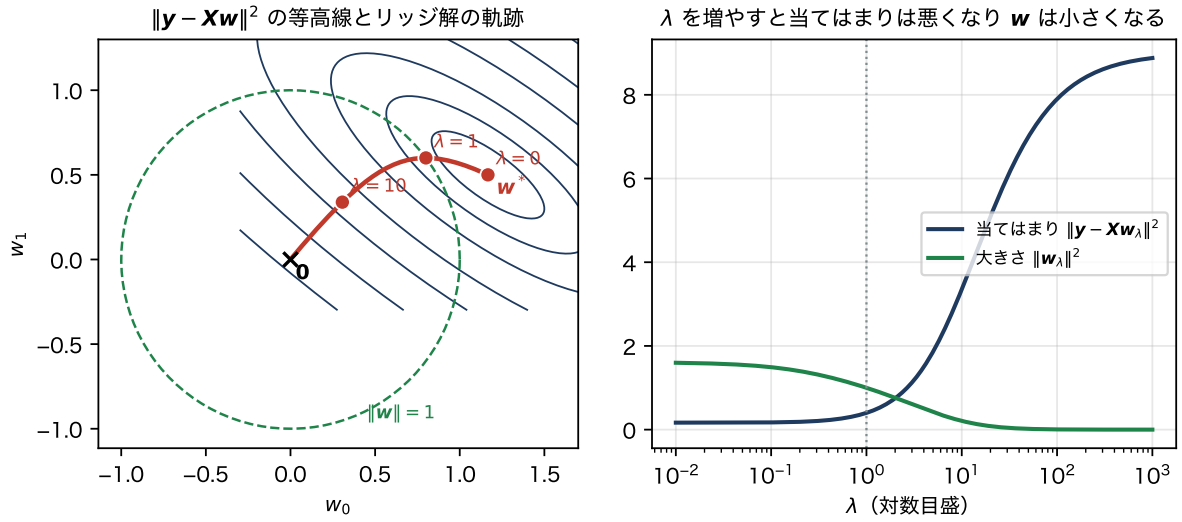


図 6.2　数値例のリッジ回帰。左：$\|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}\|^2$ の等高線と、λ を 0 から大きくしたときの解 $\boldsymbol{w}_\lambda$ の軌跡（赤）。$\lambda=1$ の解は原点中心の円 $\|\boldsymbol{w}\|=1$ の上にあり、その円と等高線が接している（第 6.5 節）。右：当てはまりと $\|\boldsymbol{w}_\lambda\|^2$ の λ 依存性。

6.2.4　多重共線性への効果

第 3.5.5 項の家賃の例（広さと部屋数、$N=4$）にリッジ回帰を適用した結果が図 6.3 である（図 3.7 と同じく切片を除いた 2 係数で描いている）。誤差のない家賃に標準偏差 0.3 万円の正規乱数を加えた 2 通りのデータ（データ 1・データ 2。誤差の値は図の説明を参照）に対し、最小二乗解は $(0.55,-1.05)$ と $(0.16,6.80)$

で、部屋数の係数の符号さえ一致しなかった。ところが $\lambda = 1$ で $(0.50, 0.00)$ と $(0.49, 0.19)$、$\lambda = 10$ では $(0.498, 0.022)$ と $(0.495, 0.041)$ となり、2 つの解はほとんど一致する。しかも予測値は $\lambda = 0$ のときと 0.1 万円程度しか違わない。当てはまりをほぼ保ったまま、推定の不安定さだけが消えたのである。

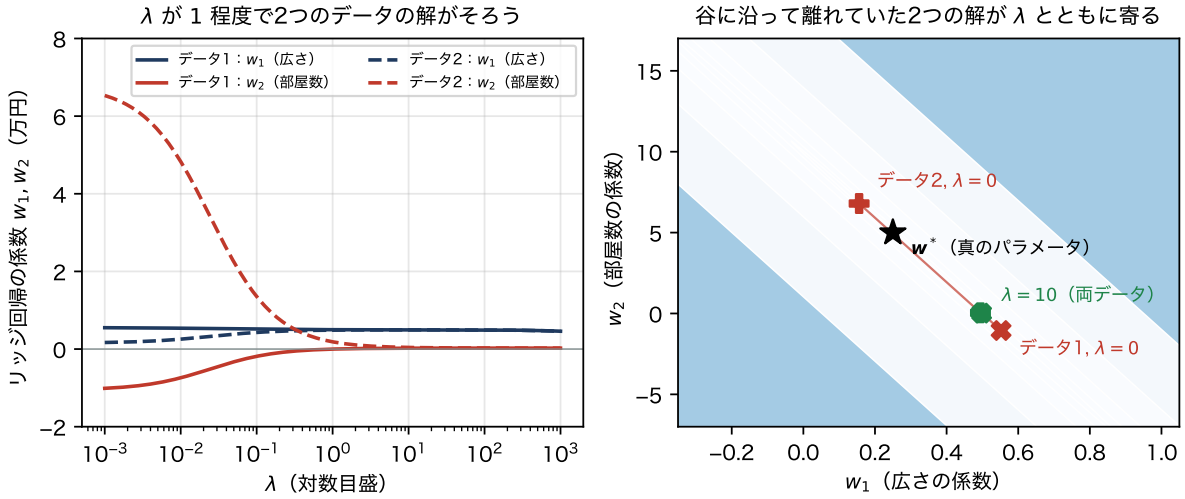


図 6.3　家賃の例（第 3.5.5 項）にリッジ回帰を適用した結果。2 通りのデータは、真のパラメータ $\boldsymbol{w}^* = (0.25, 5.0)^\top$（右図の星印）から作った誤差のない家賃 $\boldsymbol{X}\boldsymbol{w}^* = (10.5, 19.5, 30.25, 39.75)^\top$（万円）に、4 件の物件それぞれ独立に平均 0・標準偏差 0.3 万円の正規乱数を加えたものである（図 3.7 右と同じデータ）。家賃に加えた誤差は、物件 1〜4 の順に、データ 1 が $(0.61, -0.77, 0.13, -0.17)$、データ 2 が $(-0.14, -0.06, -0.61, -0.07)$ である（例えばデータ 1 の物件 1 の家賃は $10.5 + 0.61 = 11.11$ 万円）。左：2 通りのデータに対するリッジ回帰の解 $\boldsymbol{w}_\lambda = (w_1, w_2)^\top$ の各成分の λ 依存性。w_1 は広さ 1 m^2 あたりの家賃（万円）、w_2 は部屋数 1 室あたりの家賃（万円）の係数である。$\lambda = 0$（最小二乗解）付近で大きく食い違っていた部屋数の係数 w_2 が、λ が 1 程度で一致する。右：図 3.7 と同じ経験損失の等高線の上に描いた解の位置。赤の $\times$ はデータ 1、赤の $+$ はデータ 2 の最小二乗解（$\lambda = 0$）で、谷に沿って大きく離れている。各点から伸びる線は $\lambda = 0.1, 1, 10$ と増やしたときの解の軌跡で、終点の緑の印が $\lambda = 10$ の解である。2 つのデータの $\lambda = 10$ の解は $(0.498, 0.022)$ と $(0.495, 0.041)$ でほぼ重なるため、緑の印は一つに見える。星印は真のパラメータ $\boldsymbol{w}^*$。

なぜ安定するのかは、条件数で見るとはっきりする。$\boldsymbol{X}^\top\boldsymbol{X}$ の固有値を $d_1 \geq d_2 \geq \cdots \geq d_{d+1} \geq 0$ とすると、$\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I}$ の固有値は $d_i + \lambda$ である（固有ベクトル $\boldsymbol{v}_i$ に対して $(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I})\boldsymbol{v}_i = d_i\boldsymbol{v}_i + \lambda\boldsymbol{v}_i$）。したがって条件数は

$$\kappa(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I}) = \frac{d_1 + \lambda}{d_{d+1} + \lambda} \tag{6.10}$$

となり、λ を足すことで**最小固有値が λ だけ持ち上がり**、条件数が改善する（第 4.8.3 項で予告した事実である）。家賃の例では固有値が $d_1 \approx 1.2 \times 10^4$、$d_2 \approx 0.024$ で $\kappa \approx 4.9 \times 10^5$ だったものが、$\lambda = 1$ で $\kappa \approx 1.2 \times 10^4$、$\lambda = 10$ で $\kappa \approx 1.2 \times 10^3$ まで下がる。

条件数が改善すると何がよいのか。条件数は「入力のわずかな誤差が解の誤差にどれだけ増幅されるか」の上限であった（第 4.8.1 項）。方程式 (6.7) の右辺 $\boldsymbol{X}^\top\boldsymbol{y}$ は家賃 $\boldsymbol{y}$ の誤差をそのまま受け取るので、その誤差が解 $\boldsymbol{w}_\lambda$ に現れるときの増幅率が、係数行列の条件数で決まる。最小二乗法（$\lambda = 0$）では増幅率が 10^5 倍の桁であり、家賃の 0.3 万円程度の誤差が係数の数単位の違いになって現れた。$\lambda = 10$ ではこれが 10^3 倍の

桁に下がり、同じ誤差に対する解の変動は 100 分の 1 程度になる。図 6.3 で 2 つの解が一致したのは、この増幅率の低下そのものである。増幅率が小さいことは、計算機の丸め誤差の影響も小さいことを意味し（第 4.8.1 項）、さらに勾配降下法で解く場合には反復回数が条件数に比例して減る（第 5.3.2 項）という利点もある。固有値の言葉で言い直せば、小さいほうの固有値は「ほぼ平らな谷」の方向の曲率であり、その方向では損失がほとんど変わらないため解がどこにでも滑ってしまう。λ はその谷に「お椀の底」を作り、解を一か所に留めているのである。

なお、リッジ回帰が選んだのは「広さ中心」のモデル（$w_2 \approx 0$）であった。これは偶然ではない。同じ予測を与える $\boldsymbol{w}^{(\mathrm{A})} = (0.5, 0)$ と $\boldsymbol{w}^{(\mathrm{B})} = (0, 10)$ のうち、罰則 $\|\boldsymbol{w}\|^2$ が小さいのは前者だからである。ただしこの選択は特徴の**単位**に依存する。広さを m^2 ではなく cm^2 で測れば係数は 10^{-4} 倍になり、罰則はほとんど効かなくなる。正則化を使う前に特徴を標準化すべき理由がここにある（第 6.3.4 項）。

6.2.5　固有値で見るリッジ回帰

リッジ回帰が「何を縮めているのか」を正確に述べよう。$\boldsymbol{X}^\top \boldsymbol{X}$ は対称なので固有値分解 $\boldsymbol{X}^\top \boldsymbol{X} = \boldsymbol{Q} \boldsymbol{D} \boldsymbol{Q}^\top$（$\boldsymbol{Q}$ は固有ベクトル $\boldsymbol{v}_i$ を並べた直交行列、$\boldsymbol{D} = \mathrm{diag}(d_1, \dots, d_{d+1})$）をもつ（第 3.7 節、付録 A.1）。すると $\boldsymbol{X}^\top \boldsymbol{X} + \lambda \boldsymbol{I} = \boldsymbol{Q}(\boldsymbol{D} + \lambda \boldsymbol{I}) \boldsymbol{Q}^\top$ であり、逆行列は $\boldsymbol{Q}(\boldsymbol{D} + \lambda \boldsymbol{I})^{-1} \boldsymbol{Q}^\top$ である。$\boldsymbol{X}$ がフルランクなら最小二乗解 $\boldsymbol{w}^*$ は $\boldsymbol{X}^\top \boldsymbol{y} = \boldsymbol{X}^\top \boldsymbol{X} \boldsymbol{w}^* = \boldsymbol{Q} \boldsymbol{D} \boldsymbol{Q}^\top \boldsymbol{w}^*$ を満たすので、

$$\boldsymbol{w}_\lambda = \boldsymbol{Q}(\boldsymbol{D} + \lambda \boldsymbol{I})^{-1} \boldsymbol{Q}^\top \cdot \boldsymbol{Q} \boldsymbol{D} \boldsymbol{Q}^\top \boldsymbol{w}^* = \boldsymbol{Q}\, \mathrm{diag}\left(\frac{d_1}{d_1 + \lambda}, \dots, \frac{d_{d+1}}{d_{d+1} + \lambda} \right) \boldsymbol{Q}^\top \boldsymbol{w}^* \tag{6.11}$$

を得る。

式 (6.11) を読み解くために、$\boldsymbol{Q}^\top \boldsymbol{w}^*$ が何を表すかを確認しておく。$\boldsymbol{Q} = (\boldsymbol{v}_1 \cdots \boldsymbol{v}_{d+1})$ の列は互いに直交する単位ベクトルなので、$\boldsymbol{Q}^\top \boldsymbol{w}^*$ の第 i 成分は内積 $\boldsymbol{v}_i^\top \boldsymbol{w}^*$ である。第 2.4.3 項で見たとおり、単位ベクトルとの内積は**その向きへの正射影の長さ**であり、$c_i = \boldsymbol{v}_i^\top \boldsymbol{w}^*$ は「$\boldsymbol{w}^*$ が $\boldsymbol{v}_i$ の向きにどれだけ伸びているか」を表す。固有ベクトルは $\mathbb{R}^{d+1}$ の直交する座標軸をなすので、$\boldsymbol{w}^*$ はこれらの軸に沿った成分の和

$$\boldsymbol{w}^* = c_1 \boldsymbol{v}_1 + c_2 \boldsymbol{v}_2 + \cdots + c_{d+1} \boldsymbol{v}_{d+1}, \qquad c_i = \boldsymbol{v}_i^\top \boldsymbol{w}^* \tag{6.12}$$

として一通りに書ける（両辺に $\boldsymbol{v}_i^\top$ を掛けると、直交性から右辺は c_i だけが残ることで確かめられる）。$\boldsymbol{Q}^\top \boldsymbol{w}^*$ はこの係数 $(c_1, \dots, c_{d+1})^\top$ を並べたベクトル、すなわち **$\boldsymbol{w}^*$ を固有ベクトルの座標軸で測り直したもの**である。通常の座標 $(w_0, w_1, \dots)$ が「標準基底の向きにどれだけ伸びているか」であるのに対し、c_i は「固有ベクトルの向きにどれだけ伸びているか」であり、同じベクトルを別の軸で表しているにすぎない。図 6.2 左でいえば、楕円の長軸と短軸の向きが $\boldsymbol{v}_1, \boldsymbol{v}_2$ であり、c_1, c_2 はその軸に沿って $\boldsymbol{w}^*$ の位置を読んだ値である。

式 (6.11) は、まず $\boldsymbol{Q}^\top$ で $\boldsymbol{w}^*$ をこの座標に直し、各成分 c_i に $d_i/(d_i + \lambda)$ を掛け、最後に $\boldsymbol{Q}$ で元の座標に戻す、という 3 段階の操作を表している。すなわち

$$\boldsymbol{w}_\lambda = \sum_{i=1}^{d+1} \frac{d_i}{d_i + \lambda}\, c_i\, \boldsymbol{v}_i \tag{6.13}$$

であり、式 (6.12) と比べると、**各軸の成分がそれぞれ別の倍率で縮められている**ことが分かる。式 (6.11) の意味は次のとおりである。

リッジ回帰の正体

リッジ回帰は、最小二乗解 $\boldsymbol{w}^*$ の $\boldsymbol{v}_i$ 方向の成分を、それぞれ

$$\frac{d_i}{d_i+\lambda} \quad (0<\cdot\leq 1) \tag{6.14}$$

倍に縮める操作である。固有値 d_i が λ より十分大きい向きはほとんど縮まず、d_i が λ より小さい向きはほぼ 0 に潰される。

固有値 d_i の意味を思い出そう。$d_i=\|\boldsymbol{X}\boldsymbol{v}_i\|^2$ は、パラメータを $\boldsymbol{v}_i$ の向きに動かしたときに**予測がどれだけ変わるか**を表す（$\boldsymbol{v}_i^\top\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{v}_i=\|\boldsymbol{X}\boldsymbol{v}_i\|^2$、式 (4.18)。第 3.5.5 項で谷の細さを測ったのと同じ量である）。d_i が大きい向きは、データがパラメータをしっかり決めている向きである。d_i が小さい向きは、動かしても予測がほとんど変わらない「平らな谷」の向きであり、データからはほとんど決まらず、ノイズが決めてしまう向きである。リッジ回帰は、**データが決めている成分は残し、ノイズが決めている成分だけを削る**（図 6.4 左）。図 6.2 左の軌跡が曲がっていたのは、2 つの固有ベクトルの向きで縮み方が違うからである。

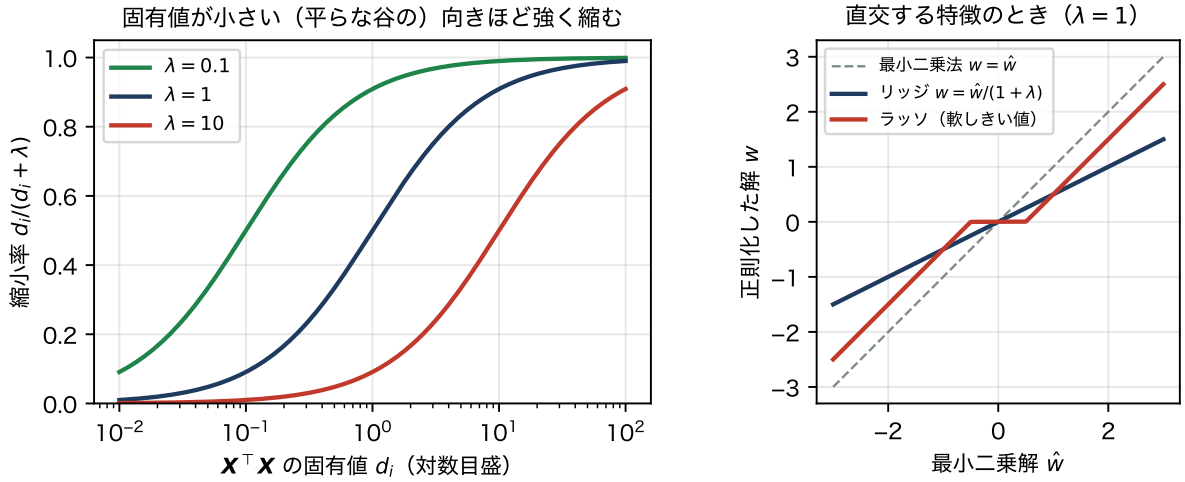


図 6.4　左：縮小率 $d_i/(d_i+\lambda)$。固有値 d_i が λ より大きい向きはほぼそのまま残り、小さい向きは 0 に近づく。右：特徴が直交している（$\boldsymbol{X}^\top\boldsymbol{X}=\boldsymbol{I}$）ときの、最小二乗解 $\hat{w}$ と正則化した解 w の関係。リッジ回帰は一律に $1/(1+\lambda)$ 倍に縮め、ラッソ（第 6.5.3 項）は $\lambda/2$ だけ引いて小さいものを 0 にする。

この見方から、第 4.7.5 項で予告した事実も読み取れる。ランクが落ちて $d_i=0$ となる向きがあれば、その成分の縮小率は $\lambda>0$ である限り $0/(0+\lambda)=0$ である。$\lambda\to 0$ としても、零空間の成分は 0 のまま、他の成分は 1 倍に戻る。したがって $\boldsymbol{w}_\lambda$ の極限は「零空間の成分をもたない解」、すなわち最小ノルム解 $\boldsymbol{w}^+$ である。

6.2.6　自由度

第 4.6.3 項で、ハット行列のトレース $\mathrm{tr}(\boldsymbol{H})=d+1$ をモデルの自由度と呼んだ。そこでは「パラメータの個数と一致する」という計算結果を述べただけだったので、なぜトレースが「データに合わせて回せるつまみの数」を表すのかを、ここで 2 つの見方から説明しておく。正則化では後者の見方が本質的になる。

■6.2.6.1 (1) **射影として見る** $\boldsymbol{H} = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top$ は $\boldsymbol{y}$ を列空間（$d+1$ 次元）へ射影する行列であり、対称性 $\boldsymbol{H}^\top = \boldsymbol{H}$ と冪等性 $\boldsymbol{H}^2 = \boldsymbol{H}$ をもつのであった（第 4.6.2 項）。ここから、**$\boldsymbol{H}$ の固有値は 1 か 0 しかない**ことが分かる。$\boldsymbol{H}\boldsymbol{v} = \mu\boldsymbol{v}$（$\boldsymbol{v} \neq \boldsymbol{0}$）とすると、冪等性より

$$\mu\boldsymbol{v} = \boldsymbol{H}\boldsymbol{v} = \boldsymbol{H}^2\boldsymbol{v} = \boldsymbol{H}(\mu\boldsymbol{v}) = \mu\boldsymbol{H}\boldsymbol{v} = \mu^2\boldsymbol{v}$$

なので $\mu^2 = \mu$、すなわち $\mu \in \{0, 1\}$ である。「一度影を落としたものにもう一度影を落としても変わらない」という性質が、固有値を 0 と 1 に限定しているのである。どのベクトルがどちらの固有値をもつかも具体的に分かる。

- 列空間の中のベクトル $\boldsymbol{v} = \boldsymbol{X}\boldsymbol{a}$ は、$\boldsymbol{H}\boldsymbol{X}\boldsymbol{a} = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{X}\boldsymbol{a} = \boldsymbol{X}\boldsymbol{a}$ より**固有値** 1。すでに列空間にあるので射影しても動かない。列空間は $d+1$ 次元なので、このようなベクトルは独立に $d+1$ 本ある
- 列空間と直交するベクトル（$\boldsymbol{X}^\top\boldsymbol{v} = \boldsymbol{0}$）は、$\boldsymbol{H}\boldsymbol{v} = \boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X})^{-1}\boldsymbol{X}^\top\boldsymbol{v} = \boldsymbol{0}$ より**固有値** 0。射影すると影が消える。このようなベクトルは独立に $N-(d+1)$ 本ある（$\mathbb{R}^N$ の次元 N から列空間の次元 $d+1$ を引いた分）

したがって $\boldsymbol{H}$ の固有値は「1 が $d+1$ 個、0 が $N-(d+1)$ 個」である。対称行列のトレースは固有値の和に等しいので（第 3.7 節）、

$$\mathrm{tr}(\boldsymbol{H}) = \underbrace{1+\cdots+1}_{d+1\text{ 個}} + \underbrace{0+\cdots+0}_{N-(d+1)\text{ 個}} = d+1$$

となり、式 (4.24) の計算結果が固有値の側から再現される。つまりトレースは、**予測 $\hat{\boldsymbol{y}}$ が自由に動ける方向の数**（固有値 1 の方向の数 = 列空間の次元）を数えている。予測を動かせる独立な方向が $d+1$ 本あるということが、「つまみが $d+1$ 個ある」ということの正確な意味である。

■6.2.6.2 (2) **データへの追従度として見る** もう一つの見方は、$\boldsymbol{H}$ の対角成分に注目するものである。$\hat{y}_i = \sum_j H_{ij}y_j$ なので、対角成分 H_{ii} は「i 番目のデータの値 y_i を少し動かしたとき、その点での当てはめ値 $\hat{y}_i$ がどれだけ追いかけて動くか」という感度 $\partial\hat{y}_i/\partial y_i$ である。極端な場合を考えると意味がはっきりする。データを丸暗記するモデル（$\hat{\boldsymbol{y}} = \boldsymbol{y}$、$\boldsymbol{H} = \boldsymbol{I}$）では $H_{ii} = 1$ がすべての i で成り立ち、トレースは N になる。N 個のデータすべてに自由に合わせているので、自由度 N である。逆に、データによらず同じ値を返すモデルでは $H_{ii} = 0$ で、自由度は 0 である。その中間として、$\mathrm{tr}(\boldsymbol{H}) = \sum_i H_{ii}$ は**モデルが訓練データを「何個分」追いかけているか**を測る量になっている。第 4.6.3 項の数値例では $H_{11} = H_{33} = 5/6$、$H_{22} = 1/3$ であり、両端の点は自分の値を強く反映し、中央の点はそれほどでもない、という当てはめの性格まで読み取れる。合計は $2 = d+1$ である。

この第 2 の見方は、$\boldsymbol{H}$ が射影でなくても通用する。リッジ回帰の予測は

$$\hat{\boldsymbol{y}}_\lambda = \boldsymbol{X}\boldsymbol{w}_\lambda = \underbrace{\boldsymbol{X}(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I})^{-1}\boldsymbol{X}^\top}_{\boldsymbol{H}_\lambda}\boldsymbol{y} \tag{6.15}$$

と書け、$\boldsymbol{H}_\lambda$ のトレースは、$\mathrm{tr}(\boldsymbol{A}\boldsymbol{B}) = \mathrm{tr}(\boldsymbol{B}\boldsymbol{A})$ と式 (6.11) の計算から

$$\mathrm{df}(\lambda) = \mathrm{tr}(\boldsymbol{H}_\lambda) = \mathrm{tr}\left((\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I})^{-1}\boldsymbol{X}^\top\boldsymbol{X}\right) = \sum_{i=1}^{d+1}\frac{d_i}{d_i+\lambda} \tag{6.16}$$

となる。これを**有効自由度**（effective degrees of freedom）と呼ぶ。$\boldsymbol{H}_\lambda$ はもはや射影ではなく、固有値は 1 か 0 ではなく $d_i/(d_i+\lambda) \in (0,1]$ である。すなわち各方向を「完全に追いかける（1）」か「無視する（0）」かではなく、**方向ごとに $d_i/(d_i+\lambda)$ の割合だけ部分的に追いかける**モデルになっており、その割合の合計が有効自由度である。$\lambda=0$ で $d+1$、$\lambda\to\infty$ で 0 に向かい、その間を連続的に動く。対角成分で見ても同じことで、数値例で $\lambda=1$ とすると $(H_\lambda)_{11}=0.400$、$(H_\lambda)_{22}=0.267$、$(H_\lambda)_{33}=0.667$ であり、どの点も $\lambda=0$ のとき（$5/6, 1/3, 5/6$）より自分の値を追いかけなくなっている。数値例では $d_1\approx 7.16$、$d_2\approx 0.84$ であり、$\mathrm{df}(1)\approx 0.88+0.46=1.33$、$\mathrm{df}(10)\approx 0.42+0.08=0.49$ となる。「$\lambda=1$ のリッジ回帰は、パラメータ 2 個のモデルというより 1.3 個分のモデルである」と読める。正則化とは、パラメータの**個数**を変えずに、データに合わせて動かせる**実質的な自由度**を減らす操作なのである。第 1 回の図 1.2 の横軸「モデルの複雑さ」は、λ を通じて連続的に調整できる量になった。

6.2.7 勾配降下法で見る：重み減衰

リッジ回帰の解は閉じた式 (6.8) で求まるが、ニューラルネットワークのように閉じた式が使えないモデルでも正則化は必要である。そこで勾配降下法（第 5 回）に正則化を組み込んでみよう。式 (6.6) より、罰則の勾配は $2\lambda\boldsymbol{w}$ である。経験損失 L_D に $\lambda\|\boldsymbol{w}\|^2$ を加えた目的関数の勾配降下法は

$$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\left(\nabla L_D(\boldsymbol{w}^{(t)}) + 2\lambda\boldsymbol{w}^{(t)}\right) = (1-2\eta\lambda)\,\boldsymbol{w}^{(t)} - \eta\nabla L_D(\boldsymbol{w}^{(t)}) \tag{6.17}$$

となる。

定義：重み減衰

各更新のたびにパラメータを $(1-2\eta\lambda)$ 倍（1 よりわずかに小さい定数倍）に縮めてから勾配の方向へ進む操作を**重み減衰**（weight decay）と呼ぶ。L2 正則化を勾配降下法で実行したものにほかならない。

更新式 (6.17) の読み方は単純である。勾配の項がなければ $\boldsymbol{w}$ は毎回一定の割合で $\boldsymbol{0}$ に向かって減衰する。勾配の項は、損失を減らすために必要な向きへ $\boldsymbol{w}$ を押し戻す。両者が釣り合う点が停留点であり、$\boldsymbol{w}^{(t+1)}=\boldsymbol{w}^{(t)}$ とおけば $\nabla L_D + 2\lambda\boldsymbol{w}=\boldsymbol{0}$、すなわちリッジ回帰の解である。

ニューラルネットワークではパラメータは行列 $\boldsymbol{W}$ であり、罰則にはフロベニウスノルム $\|\boldsymbol{W}\|_F^2$（第 3.6.3 項）を用いる。成分ごとに見れば $\sum_{jk} W_{jk}^2$ なので、更新式は式 (6.17) と全く同じ形になる。深層学習のライブラリで weight decay という引数を指定したとき、内部で起きているのはこの操作である。また第 5.6 節の Adam のように歩幅を成分ごとに変える手法では、罰則の勾配を損失の勾配に足してから歩幅を調整する流儀と、減衰 $(1-2\eta\lambda)\boldsymbol{w}$ を歩幅調整の外で別に掛ける流儀（AdamW と呼ばれる）があり、後者のほうが性能がよいことが知られている。

コラム：早期終了は正則化である

勾配降下法には、罰則を加えなくても正則化と同じ効果を生む側面がある。$\boldsymbol{w}^{(0)}=\boldsymbol{0}$ から出発した勾配降下法を、収束する前に t 回で**止めて**しまう操作を**早期終了**（early stopping）と呼ぶ。

付録 A.1 の計算を $J=\|\boldsymbol{y}-\boldsymbol{X}\boldsymbol{w}\|^2$ に適用すると、$\boldsymbol{w}^{(t)}$ の固有ベクトル $\boldsymbol{v}_i$ 方向の成分は、最小二乗解の同じ成分の

$$1-(1-2\eta d_i)^t$$

倍である（演習問題 6）。d_i が大きい向きはこの値がすぐに 1 に達する（速く収束する）が、d_i が小さい向きは t が小さいうちはほぼ $2\eta t\,d_i$ にとどまる。これをリッジ回帰の縮小率 $d_i/(d_i+\lambda)$ と見比べると、d_i が小さいときの d_i/λ と同じ

形であり、$\lambda \approx 1/(2\eta t)$ と対応する。つまり t **回で止めた勾配降下法は、**$\lambda \approx 1/(2\eta t)$ **のリッジ回帰とほぼ同じ解を与える**。反復回数を増やすことは λ を小さくすることに相当し、「十分に収束させない」ことが、データが決めきれない向き（小さい d_i）の成分を小さく保っているのである。

深層学習で、検証誤差が増え始めたところで学習を打ち切る早期終了が標準的に使われるのは、この理由による。第 6.3 節で述べる検証データが、ここでも止めどきを決める役割を担う。

6.3 正則化係数の選び方

6.3.1 ハイパーパラメータ

λ は、学習によって決まるパラメータ $\boldsymbol{w}$ とは性格の異なる量である。

定義：ハイパーパラメータ

学習アルゴリズムが訓練データから決めるパラメータ（$\boldsymbol{w}$）に対して、学習を始める前に人が与えておく設定値を**ハイパーパラメータ**（hyperparameter）と呼ぶ。正則化係数 λ、多項式の次数 M、学習率 η、ミニバッチの大きさ、反復回数などがこれにあたる。

λ を「訓練誤差が最小になるように」選ぶことはできない。訓練誤差は $\lambda = 0$ で最小になる（罰則がないほうが当てはまりは必ず良い）ので、その基準で選べば正則化は常に無意味と判定されてしまう。λ は**汎化誤差**を小さくするために入れたのだから、汎化誤差の推定値で選ぶ必要がある。

6.3.2 検証データ

定義：検証データ

手元のデータを、パラメータの学習に使う**訓練データ**と、ハイパーパラメータの選択に使う**検証データ**（validation data）に分ける。検証データに対する誤差を**検証誤差**と呼ぶ。候補となる各 λ について訓練データでパラメータを学習し、検証誤差が最小となる λ を選ぶ。

検証データは学習に使われていないので、その誤差は汎化誤差の近似になる。図 6.5 は、10 次多項式のリッジ回帰について訓練誤差と検証誤差を λ の関数として描いたものである。訓練誤差は λ について単調に増えるだけだが、検証誤差は U 字型になり、$\lambda \approx 10^{-2}$ で最小になる。左端（λ が小さすぎる）が過学習、右端（大きすぎる）が未学習であり、第 1 回の図 1.2 の横軸を λ に置き換えたものになっている。

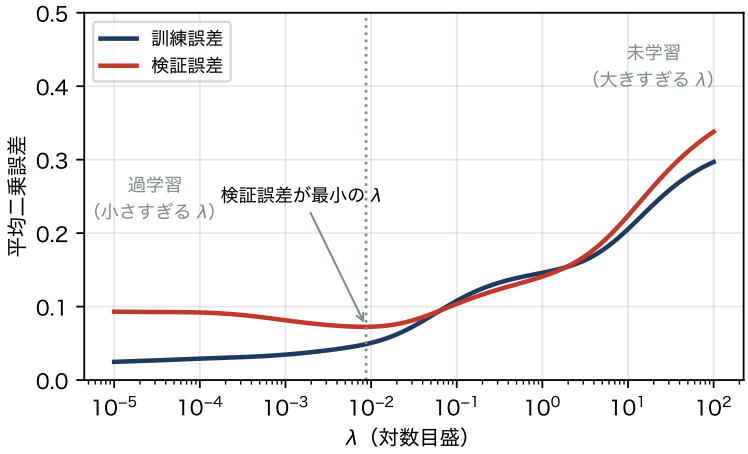


図 6.5　10 次多項式のリッジ回帰（図 6.1 のデータ）における訓練誤差と検証誤差。訓練誤差は λ が小さいほど小さいが、検証誤差は $\lambda \approx 10^{-2}$ で最小となる。λ の候補は対数目盛で等間隔（$10^{-5}, 10^{-4}, \ldots$）にとるのが普通である。

ここで、第 1 回で導入したテストデータとの役割の違いに注意する。検証データで λ を選ぶと、その検証誤差は「候補の中で最も小さかった値」であり、やや楽観的に偏っている（選択にデータを使った時点で、もはや完全に未知のデータではない）。最終的な性能の見積もりには、λ の選択にも使っていない**テストデータ**を残しておき、最後に一度だけ使う。すなわち、データは「訓練・検証・テスト」の 3 つに分ける。

6.3.3　交差検証

データが少ないとき、検証用に一部を取り分けると訓練データがさらに減り、検証誤差も少数のデータに左右されてしまう。これを緩和するのが交差検証である。

定義：k 分割交差検証

データを k 個のブロックに等分し、$j = 1, \ldots, k$ について「ブロック j を検証データ、残りの $k-1$ ブロックを訓練データ」として検証誤差を求め、k 個の検証誤差の平均を λ の評価値とする（図 6.6）。これを k **分割交差検証**（k-fold cross-validation）と呼ぶ。$k = 5$ または 10 がよく使われる。

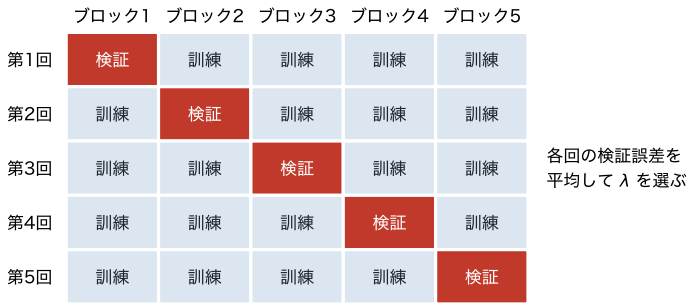


図 6.6　5 分割交差検証。すべてのデータが一度ずつ検証に使われ、訓練にも 4/5 が使える。

すべてのデータが一度は検証に使われるので評価が安定し、訓練にも各回 $(k-1)/k$ のデータが使える。代

償は計算量で、λ の候補 1 つにつき k 回の学習が必要になる。$k = N$（1 件ずつ検証する）とした極端な場合を一つ抜き交差検証（leave-one-out）と呼ぶ。交差検証で λ を決めた後は、全データで学習し直した $\boldsymbol{w}_\lambda$ を最終的なモデルとする。

コラム：ハイパーパラメータ探索の実際：グリッドサーチから Optuna まで

本文では λ を対数目盛で等間隔に並べ、各候補の検証誤差を比べた。候補をあらかじめ格子状に並べて全部試すこの方法を**グリッドサーチ**（grid search）と呼ぶ。ハイパーパラメータが λ 一つなら十分だが、実際のモデルでは λ、多項式の次数 M、学習率 η、ミニバッチの大きさ、ニューラルネットワークの層数や幅など、複数のハイパーパラメータを同時に決めなければならない。各 10 通りで 5 個あれば 10^5 通りの組合せになり、1 組ごとに交差検証（k 回の学習）を行うのは現実的でない。

対処の第一歩は**ランダムサーチ**（random search）である。格子を全部試す代わりに、各ハイパーパラメータを範囲内からランダムに選んだ組を一定数だけ試す。一見乱暴だが、「本当に効くハイパーパラメータは少数」という状況では、グリッドサーチより効率がよいことが知られている。格子では効かない軸にも同じ数の試行を費やすのに対し、ランダムサーチは効く軸について格子より多くの異なる値を試せるからである。

さらに進んだ方法が**ベイズ最適化**（Bayesian optimization）であり、「これまでに試した組とその検証誤差」から「次にどこを試せば誤差が小さそうか」を推定して、試行を有望な領域に集中させる。Python のライブラリ **Optuna** はこの考え方を実装したもので、使い方は次のように単純である。

```
import optuna

def objective(trial):
    # Each call draws one candidate setting (a "trial").
    lam = trial.suggest_float("lambda", 1e-5, 1e2, log=True)
    M = trial.suggest_int("degree", 1, 12)
    return cross_validation_error(lam, M)   # mean validation MSE over k folds

study = optuna.create_study(direction="minimize")
study.optimize(objective, n_trials=100)
print(study.best_params)   # e.g. {'lambda': 0.0083, 'degree': 9}
```

`suggest_float` の `log=True` は、本文と同じく λ を対数目盛で探すという指定である。Optuna の標準の方法（TPE）は、試行結果を「誤差が小さかった組」と「大きかった組」に分け、前者が多く後者が少ない領域を次の候補として選ぶ。また、交差検証の途中で明らかに悪い候補を打ち切る**枝刈り**（pruning）も備えており、深層学習のように 1 回の学習が重い場合に効く。

どの方法を使うにせよ、評価の基準が**検証誤差**（交差検証）であり、最終的な性能の見積もりには探索に使っていないテストデータを残す、という本文の原則は変わらない。探索を何百回も行うほど「検証誤差が最小だった候補」の値は楽観的に偏るので、テストデータを最後に一度だけ使う意味はむしろ大きくなる。

6.3.4 特徴の標準化と切片の扱い

罰則 $\|\boldsymbol{w}\|^2$ は、すべての係数を同じ重みで足している。これが意味をもつのは、**すべての特徴が同程度のスケール**で測られているときだけである。ある特徴 x_j の単位を変えて 10 倍の値にすると、同じ予測を与える係数は $w_j/10$ になり、罰則への寄与は $1/100$ になる。単位の選び方で正則化の効き方が変わるのは不合理なので、リッジ回帰を使う前には各特徴を標準化（平均 0、分散 1 にそろえる。第 5.3.4 項）しておく。第 5 回では勾配降下法の収束を速めるための標準化であったが、正則化では**罰則の公平さ**のために必要になる。図

6.1 や図 6.5 でも、多項式の特徴 x^k を標準化してから罰している。

バイアス項 w_0 については、罰則に含めないのが標準である。w_0 は出力の平均的な水準を表すだけで、これを 0 に引き寄せる理由はない（家賃の平均が 20 万円なら、$w_0 \approx 20$ であるべきで、小さいほうが単純というわけではない）。実装は簡単で、出力 $\boldsymbol{y}$ と各特徴をそれぞれの平均で引いて中心化した上で、定数列のない $\boldsymbol{X}$ に対してリッジ回帰を行う。中心化したデータでは最適な切片は 0 になり、元のスケールに戻すときに $w_0 = \bar{y} - \sum_j w_j \bar{x}_j$ を付け直せばよい。

6.4 バイアスとバリアンス

正則化は当てはまりを悪くするのに、なぜ汎化誤差を減らせるのか。この問いに定量的に答えるのが、バイアスとバリアンスの分解である。

6.4.1 思考実験：データを取り直す

訓練データ D は、真の関係にノイズが乗って生成されたものである。同じ状況でデータを取り直せば、別のノイズが乗った別の D' が得られ、学習結果 $\boldsymbol{w}$ も変わる。つまり学習したパラメータや予測は、**データの取り方に応じてばらつく確率的な量**である。このばらつきを「データを何度も取り直したときの平均」で測るのが本節の方法である。

以下、入力 x は固定し、出力は

$$y = f(x) + \varepsilon \tag{6.18}$$

で生成されるとする。f が真の関係、ε は平均 0、分散 σ^2 のノイズであり、データごとに独立に乗る。データ D から学習した予測を $\hat{h}(x) = h(x; \boldsymbol{w}(D))$ と書き、$\mathbb{E}[\cdot]$ で「データを取り直したときの平均」を表す。確率変数と期待値の厳密な扱いは第 7 回（第 7.6 節）で学ぶので、ここでは「たくさんのデータセットで学習をくり返し、結果を平均する」という操作だと理解しておけばよい。$\mathbb{E}[\varepsilon] = 0$、$\mathbb{E}[\varepsilon^2] = \sigma^2$、および独立な量の積の平均は平均の積になる、という 3 つの事実だけを使う。

コラム：データの取り直しを手元で再現する：ブートストラップ法

本節の思考実験「同じ状況でデータを何度も取り直す」は、現実には一度しかデータが取れないので、そのままでは実行できない。これを手元のデータだけで近似的に再現する方法が**ブートストラップ法**（bootstrap）である。手順は次のとおりである。

1. 手元の N 件のデータから、**重複を許して** N 件をランダムに選び直し、新しいデータセット $D^{(1)}$ を作る（同じデータが 2 回選ばれることも、一度も選ばれないこともある）
2. $D^{(1)}$ で学習し、パラメータ $\boldsymbol{w}^{(1)}$ と予測を得る
3. これを B 回（$B = 100 \sim 1000$ 程度）くり返し、$\boldsymbol{w}^{(1)}, \ldots, \boldsymbol{w}^{(B)}$ を得る

得られた B 個のパラメータの**ばらつき**が、「データを取り直したときのばらつき」すなわちバリアンスの推定値になる。各成分の標準偏差を計算すれば係数の信頼区間が得られ、家賃の例（図 6.3）であれば「部屋数の係数は $\lambda = 0$ ではブートストラップ標本ごとに符号すら変わるが、$\lambda = 1$ ではほぼ一定である」という事実を、データを取り直さずに確かめられる。重複を許して選ぶと、各回でおよそ 63%（$1 - 1/e$）のデータだけが使われ、残りの約 37% は選ばれない。選ばれなかったデータを検証に使う **out-of-bag 誤差**は、交差検証と並ぶ汎化誤差の推定法である。

ブートストラップにはもう一つの使い道がある。B 個の予測を**平均**すると、個々の予測のばらつきが打ち消し合い、バリアンスが減る。これを**バギング**（bagging、bootstrap aggregating）と呼び、決定木という不安定な（バリアンスの大きい）モデルにバギングを施したものが**ランダムフォレスト**である。正則化が「一つのモデルのバリアンスを縮める」方

法だとすれば、バギングは「多数のモデルを平均してバリアンスを消す」方法であり、どちらも式 (6.19) のバリアンス項を狙っている点で同じ思想に立っている。

6.4.2 バイアス–バリアンス分解

新しいデータ (x, y) に対する二乗誤差 $(y - \hat{h}(x))^2$ の平均を計算する。$\bar{h}(x) = \mathbb{E}[\hat{h}(x)]$（予測の平均）とおき、

$$y - \hat{h}(x) = \underbrace{\varepsilon}_{\text{ノイズ}} + \underbrace{\big(f(x) - \bar{h}(x)\big)}_{\text{平均のずれ}} + \underbrace{\big(\bar{h}(x) - \hat{h}(x)\big)}_{\text{平均からのばらつき}}$$

と 3 つに分ける。二乗して平均をとると、3 つの項の二乗の平均と、互いの積（交差項）の平均が現れる。交差項はすべて消える。ε は新しいデータのノイズであり、訓練データから作った $\hat{h}$ とは独立で平均 0 なので、ε を含む積の平均は 0 である。残る積 $(f - \bar{h})(\bar{h} - \hat{h})$ は、$f - \bar{h}$ がデータによらない定数で、$\mathbb{E}[\bar{h} - \hat{h}] = \bar{h} - \bar{h} = 0$ なので平均は 0 である。したがって

定理：バイアス–バリアンス分解

$$\mathbb{E}\left[(y - \hat{h}(x))^2\right] = \underbrace{\sigma^2}_{\text{ノイズ}} + \underbrace{\big(f(x) - \bar{h}(x)\big)^2}_{\text{バイアス}^2} + \underbrace{\mathbb{E}\left[(\hat{h}(x) - \bar{h}(x))^2\right]}_{\text{バリアンス}} \tag{6.19}$$

3 つの項の意味は次のとおりである。

ノイズ σ^2　データ自体に含まれる誤差。どんなモデルでも減らせない下限。

バイアス（偏り）　予測の**平均**が真の関係からどれだけずれているか。モデルが単純すぎて真の関係を表現できないときに大きい（**未学習**）。

バリアンス（分散）　予測がデータの取り方によってどれだけ**ばらつく**か。モデルが複雑すぎてノイズに追随するときに大きい（**過学習**）。

図 6.7 の左と中央は、30 通りのデータセットで 10 次多項式のリッジ回帰を学習した結果である。λ が小さいと、予測の平均（赤）は真の関係にほぼ重なる（バイアス小）が、個々の予測は大きくばらつく（バリアンス大）。λ が大きいと、ばらつきは小さい（バリアンス小）が、平均そのものが真の関係からずれる（バイアス大）。正則化は、**バイアスを少し増やす代わりにバリアンスを大きく減らす**操作であり、その差し引きで合計が減るときに汎化誤差が改善する。第 1 回の図 1.2 で汎化誤差が U 字型になるのは、複雑さを増すとバイアスが減りバリアンスが増える、という 2 つの単調な変化の和だからである。

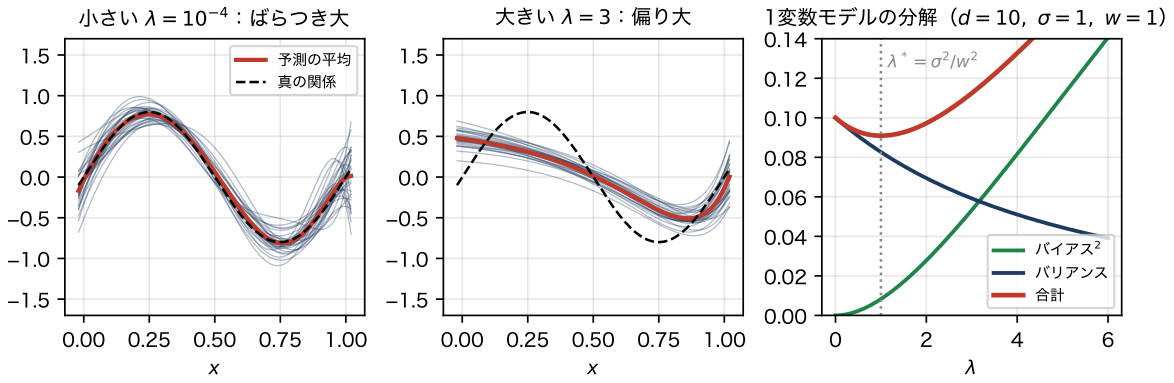


図 6.7　左・中：30 通りの訓練データ（細線はそれぞれの予測、赤は平均、破線は真の関係）に対する 10 次多項式リッジ回帰。λ が小さいとばらつきが大きく（バリアンス大）、大きいと平均がずれる（バイアス大）。右：1 変数モデル（第 6.4.3 項）におけるバイアス^2・バリアンス・合計の λ 依存性。合計は $\lambda^* = \sigma^2/w^2$ で最小となる。

6.4.3　1 変数モデルで計算する

分解を実際に計算できる最も簡単な設定で、リッジ回帰の効果を定量的に見よう。切片のない 1 変数モデル $y_i = w x_i + \varepsilon_i$（$i = 1, \dots, N$）を考える。$w$ が真のパラメータ、ε_i は独立で平均 0、分散 σ^2 とする。$d = \sum_i x_i^2$ とおく（$\boldsymbol{X}^\top \boldsymbol{X}$ にあたる量で、1×1 なので固有値そのものである）。

最小二乗解は正規方程式より

$$\hat{w} = \frac{\sum_i x_i y_i}{\sum_i x_i^2} = \frac{\sum_i x_i (w x_i + \varepsilon_i)}{d} = w + \frac{1}{d} \sum_i x_i \varepsilon_i \tag{6.20}$$

である。第 2 項はノイズの線形結合で、平均は 0、分散は $\frac{1}{d^2} \sum_i x_i^2 \sigma^2 = \sigma^2/d$ である（独立なノイズの和の分散は分散の和、という第 7.6.4 項の性質を使った）。よって

$$\mathbb{E}[\hat{w}] = w \ \ (\text{バイアス } 0), \qquad \mathrm{Var}[\hat{w}] = \frac{\sigma^2}{d} \tag{6.21}$$

最小二乗法は「平均的には正しい」が、d が小さい（データが少ない、x の広がりが小さい）とばらつきが大きい。

リッジ回帰の解は式 (6.8) より $\hat{w}_\lambda = \frac{\sum_i x_i y_i}{d + \lambda} = \frac{d}{d+\lambda} \hat{w}$ であり、式 (6.14) の縮小率がそのまま現れる。定数倍の平均と分散はそれぞれ定数倍・定数の二乗倍なので

$$\text{バイアス} = \mathbb{E}[\hat{w}_\lambda] - w = -\frac{\lambda}{d+\lambda} w, \qquad \mathrm{Var}[\hat{w}_\lambda] = \left(\frac{d}{d+\lambda}\right)^2 \frac{\sigma^2}{d} = \frac{\sigma^2 d}{(d+\lambda)^2} \tag{6.22}$$

となる。λ を増やすとバイアスの大きさは 0 から $|w|$ へ増え、バリアンスは σ^2/d から 0 へ減る。パラメータの推定誤差の平均（バイアス^2 + バリアンス）は

$$\mathrm{MSE}(\lambda) = \frac{\lambda^2 w^2 + \sigma^2 d}{(d+\lambda)^2} \tag{6.23}$$

である。λ で微分して 0 とおくと（演習問題 7）、最小を与えるのは

$$\lambda^* = \frac{\sigma^2}{w^2}, \qquad \mathrm{MSE}(\lambda^*) = \frac{\sigma^2}{d + \sigma^2/w^2} < \frac{\sigma^2}{d} = \mathrm{MSE}(0) \tag{6.24}$$

である（図 6.7 右）。ここから 2 つの重要な結論が得られる。

1. **適切な $\lambda > 0$ をとれば、リッジ回帰は最小二乗法より必ず推定誤差が小さい。**不等式 (6.24) は w、σ、d の値によらず成り立つ。バイアスを少し入れることでバリアンスを減らす交換が、つねに得になるのである。
2. 最適な λ^* はノイズが大きいほど（σ^2 大）、真のパラメータが小さいほど（w^2 小）大きい。「信号に比べてノイズが大きいときほど強く正則化せよ」という直感に一致する。ただし λ^* は未知の w と σ に依存するので、実際には第 6.3 節の方法で選ぶ。

6.4.4 多次元での見方

多次元の場合も、第 6.2.5 項の固有ベクトルの向きごとに同じ計算が成り立つ。$\boldsymbol{v}_i$ 方向の成分について、最小二乗法のバリアンスは σ^2/d_i、リッジ回帰では $\sigma^2 d_i/(d_i+\lambda)^2$ になる。平らな谷の向き（d_i が小さい）では最小二乗法のバリアンス σ^2/d_i が巨大になり、家賃の例で解が谷に沿って滑ったのは、まさにこの項が大きかったからである。リッジ回帰はその向きの成分を縮めて、バリアンスを $\sigma^2 d_i/(d_i+\lambda)^2 \le \sigma^2/(4\lambda)$ 以下に抑える。一方、d_i が大きい向きはほとんど縮まず、バイアスもほとんど生じない。**データが決めている向きには手を付けず、ノイズが決めている向きのばらつきだけを削る。**これが、リッジ回帰が汎化誤差を減らす仕組みである。

6.5 制約付き最適化の導入

6.5.1 罰則から制約へ

ここまで正則化を「罰則を足す」形で扱ってきたが、同じことを「$\boldsymbol{w}$ の大きさに**上限を課す**」形で書くこともできる。

$$\min_{\boldsymbol{w}} \ \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 \qquad \text{subject to} \qquad \|\boldsymbol{w}\|^2 \le r^2 \tag{6.25}$$

「$\|\boldsymbol{w}\|$ が r 以下の範囲で、最も当てはまりの良い $\boldsymbol{w}$ を探せ」という問題である。このように、変数の動ける範囲が条件で制限された最小化問題を制約付き最適化問題と呼ぶ。

定義：制約付き最適化問題

関数 $f, g : \mathbb{R}^p \to \mathbb{R}$ に対して、

$$\min_{\boldsymbol{w}} \ f(\boldsymbol{w}) \qquad \text{subject to} \qquad g(\boldsymbol{w}) \le 0 \tag{6.26}$$

の形の問題を**制約付き最適化問題**（constrained optimization problem）と呼ぶ。f を目的関数、$g(\boldsymbol{w}) \le 0$ を制約、これを満たす $\boldsymbol{w}$ の集合 $\{\boldsymbol{w} : g(\boldsymbol{w}) \le 0\}$ を**実行可能領域**（feasible region）と呼ぶ。

式 (6.25) は $g(\boldsymbol{w}) = \|\boldsymbol{w}\|^2 - r^2$ の場合であり、実行可能領域は原点中心・半径 r の球である。第 5 回では定義域をつねに $\mathbb{R}^p$ 全体として凸関数を扱ったが（第 5.4.1 項）、制約付き問題では実行可能領域が凸集合であることが本質的な役割を果たす。球は凸集合である。

6.5.2 幾何学：等高線と制約領域の接点

図 6.8 左に、2 次元での様子を描いた。楕円は $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ の等高線で、中心が最小二乗解 $\boldsymbol{w}^*$ である。緑の円板が実行可能領域 $\|\boldsymbol{w}\| \leq r$ である。

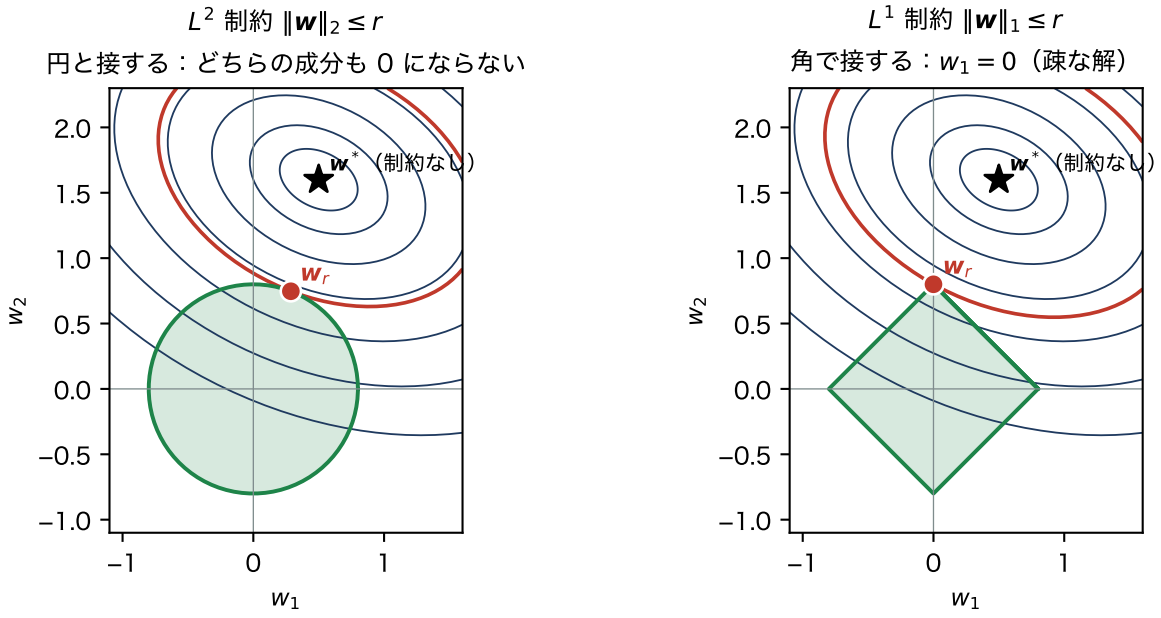


図 6.8　制約付き最適化としての正則化。楕円は $\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ の等高線、緑の領域が実行可能領域である。左：L^2 制約 $\|\boldsymbol{w}\|_2 \leq r$。解 $\boldsymbol{w}_r$ は円と等高線が接する点で、一般にどの成分も 0 にならない。右：L^1 制約 $\|\boldsymbol{w}\|_1 \leq r$。実行可能領域はひし形で、等高線は角（座標軸上）で接しやすい。この例では $w_1 = 0$ となる。

$\boldsymbol{w}^*$ が円板の外にあるなら（$\|\boldsymbol{w}^*\| > r$、すなわち制約が効いている場合）、解は**円の境界上**にある。円板の内部の点は、$\boldsymbol{w}^*$ に向かって少し動かせば損失が減り、かつまだ円板の中にいられるので、最小ではないからである。境界上のどこかというと、$\boldsymbol{w}^*$ を中心に等高線を少しずつ広げていき、**初めて円に触れる点**である。その点で等高線と円は**接している**。交差していれば、交点の内側にもっと損失の小さい点があるはずだからである。

6.5.3 接点の条件とラグランジュ乗数

「接している」を式で書こう。曲線 $f(\boldsymbol{w}) = c$ の各点で、勾配 ∇f は曲線に垂直である（第 4.3.2 項：勾配は等高線と直交する）。同様に、円 $g(\boldsymbol{w}) = 0$ 上では $\nabla g = 2\boldsymbol{w}$ が円に垂直である。2 つの曲線が接する点では、垂直な向きが共通、すなわち **2 つの勾配が平行**である：

$$\nabla f(\boldsymbol{w}) = -\mu \nabla g(\boldsymbol{w}), \qquad \mu \geq 0 \tag{6.27}$$

符号について補足する。$-\nabla f$ は損失の減る向き、すなわち円の外の $\boldsymbol{w}^*$ に向かう向きであり、∇g は円の外向きである。両者が同じ向きなので $\mu \geq 0$ となる（$\mu < 0$ なら、円の内側に進んで損失を減らせる余地があ

ることになり、接点が最小ではない)。

$f = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$、$g = \|\boldsymbol{w}\|^2 - r^2$ で式 (6.27) を書き下すと

$$2(\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} - \boldsymbol{X}^\top \boldsymbol{y}) = -2\mu \boldsymbol{w} \quad \Longleftrightarrow \quad (\boldsymbol{X}^\top \boldsymbol{X} + \mu \boldsymbol{I})\boldsymbol{w} = \boldsymbol{X}^\top \boldsymbol{y}$$

となる。これはリッジ回帰の方程式 (6.7) で $\lambda = \mu$ としたものにほかならない。

罰則形式と制約形式の対応

制約付き問題 (6.25) の解は、ある $\lambda = \mu \geq 0$ に対するリッジ回帰の解 $\boldsymbol{w}_\lambda$ に一致する。逆に、リッジ回帰の解 $\boldsymbol{w}_\lambda$ は $r = \|\boldsymbol{w}_\lambda\|$ とした制約付き問題の解である。r を小さくすることと λ を大きくすることは同じ操作であり、μ は「制約をどれだけ強く感じているか」を表す。

第 6.2.3 項の数値例（$\boldsymbol{X}^\top \boldsymbol{X} = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}$、$\boldsymbol{X}^\top \boldsymbol{y} = (5, 6)^\top$）で確かめよう。表 6.1 より $\lambda = 1$ のリッジ回帰の解は $\boldsymbol{w}_1 = (0.8, 0.6)^\top$ であり、$\|\boldsymbol{w}_1\| = \sqrt{0.64 + 0.36} = 1$ を満たす。そこで $r = 1$ とした制約付き問題を考えると、$\boldsymbol{w}_1$ は円 $\|\boldsymbol{w}\| = 1$ の上にある。この点での損失 $f = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ の勾配は

$$\nabla f(\boldsymbol{w}_1) = 2(\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w}_1 - \boldsymbol{X}^\top \boldsymbol{y}) = 2\left\{ \begin{pmatrix} 3 \cdot 0.8 + 3 \cdot 0.6 \\ 3 \cdot 0.8 + 5 \cdot 0.6 \end{pmatrix} - \begin{pmatrix} 5 \\ 6 \end{pmatrix} \right\} = 2 \begin{pmatrix} 4.2 - 5 \\ 5.4 - 6 \end{pmatrix} = \begin{pmatrix} -1.6 \\ -1.2 \end{pmatrix} = -2\,\boldsymbol{w}_1$$

であり、一方 $\nabla g(\boldsymbol{w}_1) = 2\boldsymbol{w}_1 = (1.6, 1.2)^\top$ である。確かに $\nabla f = -\mu \nabla g$ が $\mu = 1$ で成り立ち、リッジ回帰の $\lambda = 1$ がそのままラグランジュ乗数になっている。図 6.2 左で、$\lambda = 1$ の点において等高線と円 $\|\boldsymbol{w}\| = 1$ が接していたのは、この条件の現れである。

式 (6.27) の μ を**ラグランジュ乗数**（Lagrange multiplier）と呼ぶ。条件 (6.27) は、新しい関数

$$\mathcal{L}(\boldsymbol{w}, \mu) = f(\boldsymbol{w}) + \mu\, g(\boldsymbol{w}) \tag{6.28}$$

（**ラグランジュ関数**）の $\boldsymbol{w}$ についての勾配が $\boldsymbol{0}$ であること、と言い換えられる。制約付き問題を「罰則付きの制約なし問題」に変換する、というのがラグランジュ乗数法の核心であり、正則化の罰則 $\lambda\|\boldsymbol{w}\|^2$ はまさにそのようにして生まれた項であると読める。$\boldsymbol{w}^*$ が最初から円板の内側にある場合（制約が効いていない場合）は $\mu = 0$ で、解は $\boldsymbol{w}^*$ そのものである。「制約が効いているときだけ $\mu > 0$」というこの規則（相補性条件）を含めた一般論（KKT 条件）は、第 10 回・第 11 回のサポートベクターマシンで扱う。そこでは、マージンを最大化する問題が $\|\boldsymbol{w}\|^2$ の最小化として定式化され、本節と同じ図式が再び現れる。

6.5.4 ノルムの形と解の形：L1 正則化

制約形式で見ると、**実行可能領域の形が解の形を決める**ことが分かる。罰則に $\|\boldsymbol{w}\|^2$ ではなく、別のノルムを使ってみよう。

定義：L^1 ノルム

$\boldsymbol{w} = (w_1, \ldots, w_p)^\top \in \mathbb{R}^p$ に対して

$$\|\boldsymbol{w}\|_1 = |w_1| + |w_2| + \cdots + |w_p| = \sum_{j=1}^{p} |w_j| \tag{6.29}$$

を L^1 ノルム（マンハッタン距離、絶対値ノルム）と呼ぶ。これに対して第 2.2 節のユークリッドノルムを $\|\boldsymbol{w}\|_2$ と書いて区別することがある。

L^1 ノルムも第 2.2.2 項の 3 つの性質（非負性、斉次性、三角不等式）を満たす。$\|\boldsymbol{w}\|_1 \le r$ の実行可能領域は、2 次元では頂点が座標軸上にあるひし形である（図 6.8 右）。ひし形には**角**がある。等高線（楕円）を $\boldsymbol{w}^*$ から広げていくと、円のときのように滑らかな境界に接するのではなく、**角で先に触れる**ことが多い。角は座標軸上にあるので、そこでは一部の成分が**ちょうど** 0 になる。図の例では解は $w_1 = 0$ であり、特徴 1 はモデルから完全に落とされる。

定義：L1 正則化（ラッソ）

$$J_\lambda(\boldsymbol{w}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \lambda\|\boldsymbol{w}\|_1 \tag{6.30}$$

の最小化を **L1 正則化**または**ラッソ**（lasso）と呼ぶ。解の多くの成分が 0 になる性質を**疎性**（sparsity）といい、0 でない成分が少ない解を**疎な解**と呼ぶ。

疎な解には実用上の大きな価値がある。係数が 0 の特徴は予測に使われないので、ラッソは**特徴選択**（どの特徴が必要かの判定）を学習と同時に行う。特徴が数千あって、本当に効いているのは数十だけ、という状況（遺伝子データや文書データなど）で特に有効である。一方、リッジ回帰は図 6.8 左のように解の成分を小さくはするが、ちょうど 0 にはしない。

ラッソの目的関数は $|w_j|$ が $w_j = 0$ で微分できないので、閉じた式では解けず、勾配降下法もそのままでは使えない（座標ごとに解く座標降下法などが使われる）。ただし特徴が互いに直交している場合（$\boldsymbol{X}^\top\boldsymbol{X} = \boldsymbol{I}$）には、問題が成分ごとに分かれて手で解ける。このとき最小二乗解を $\hat{w}_j$ とすると、j 番目の成分についての目的関数は定数を除いて $(\hat{w}_j - w_j)^2 + \lambda|w_j|$ であり、その最小解は

$$w_j = \operatorname{sign}(\hat{w}_j)\,\max\!\left(|\hat{w}_j| - \frac{\lambda}{2},\, 0\right) \tag{6.31}$$

となる（**軟しきい値処理**、soft thresholding。演習問題 9）。同じ設定でリッジ回帰の解は $w_j = \hat{w}_j/(1+\lambda)$ である。図 6.4 右に両者を描いた。リッジ回帰は大きい成分も小さい成分も**同じ比率**で縮めるのに対し、ラッソはすべての成分から**同じ量** $\lambda/2$ を引き、$\lambda/2$ に満たない成分は 0 にする。「小さい成分は切り捨て、大きい成分はあまり縮めない」というラッソの性質は、特徴選択の目的に合っている。

実務では両者を混ぜた $\lambda_1\|\boldsymbol{w}\|_1 + \lambda_2\|\boldsymbol{w}\|_2^2$（**弾性ネット**、elastic net）も使われる。どの正則化を使うかは、「係数がどんな形をしていると期待するか」という**事前の想定**の表明である。この見方は第 9 回で、正則化項を事前分布として読み直すときに主役になる。

6.6 正則化の広がり

本章で学んだ考え方は、線形回帰を越えて機械学習全体に広がっている。本章の締めくくりとして、見取り図を描いておく。

重み減衰　式 (6.17) のとおり、ニューラルネットワークの学習ではほぼ例外なく使われる。第 12 回で扱う誤差逆伝播法で求めた勾配に、$2\lambda\boldsymbol{W}$ を足すだけである。

早期終了　コラムで見たとおり、反復を途中で止めること自体が正則化になる。検証誤差を監視して止めどきを決める。

データを増やす　バリアンスは「データが決めきれない自由度」から生じるので、データを増やせば減る（1 変数モデルでは $d = \sum x_i^2$ が増え、バリアンス σ^2/d が減る）。画像を回転・反転させて訓練データを水増しする**データ拡張**（data augmentation）は、この原理に基づく。

モデル自体の制限　ニューラルネットワークで学習中にニューロンをランダムに無効化する**ドロップアウト**（dropout）など、モデルの実質的な自由度を下げる工夫も正則化の一種である。

ベイズ的な解釈　罰則 $\lambda\|\boldsymbol{w}\|^2$ は「$\boldsymbol{w}$ は小さいはずだ」という事前の想定を数式にしたものと読める。第 9 回では、リッジ回帰が「ガウス分布を事前分布とした最大事後確率推定」に一致することを示し、λ の意味を確率の言葉で捉え直す。

サポートベクターマシン　第 10 回のマージン最大化は $\|\boldsymbol{w}\|^2$ の最小化として定式化され、第 6.5 節の制約付き最適化とラグランジュ乗数が本格的に活躍する。

正則化の本質を一言でまとめれば、**「データが決められること以上をモデルに決めさせない」**ことである。訓練データへの当てはまりを少し手放し、その見返りに未知のデータへの安定した予測を得る。機械学習が「暗記」ではなく「汎化」であるための、最も基本的な仕組みである。

6.7　まとめ

- 過学習と多重共線性はどちらも**モデルの自由度の過剰**から生じ、症状として重みが不必要に大きくなる。$\|\boldsymbol{w}\|$ は入力の違いが出力に増幅される上限であり、同じ当てはまりなら小さい $\boldsymbol{w}$ が安全である
- **正則化**：経験損失に罰則 $\lambda R(\boldsymbol{w})$ を加えて最小化する。$R=\|\boldsymbol{w}\|^2$ が **L2 正則化**で、線形回帰に適用したものが**リッジ回帰**
- リッジ回帰の解は $\boldsymbol{w}_\lambda=(\boldsymbol{X}^\top\boldsymbol{X}+\lambda\boldsymbol{I})^{-1}\boldsymbol{X}^\top\boldsymbol{y}$。$\lambda>0$ なら $\boldsymbol{X}$ のランクによらず正定値・正則で、解はつねに一意。$\lambda\to 0$ で最小ノルム解に収束する
- 固有値で見ると、リッジ回帰は最小二乗解の $\boldsymbol{v}_i$ 方向の成分を $d_i/(d_i+\lambda)$ 倍に縮める。データが決めている向き（d_i 大）は残し、ノイズが決めている平らな谷の向き（d_i 小）を潰す。条件数は $(d_1+\lambda)/(d_{d+1}+\lambda)$ に改善し、有効自由度は $\sum_i d_i/(d_i+\lambda)$ に減る
- 勾配降下法では、L2 正則化は各更新で $\boldsymbol{w}$ を $(1-2\eta\lambda)$ 倍する**重み減衰**になる。早期終了も $\lambda\approx 1/(2\eta t)$ の正則化と同じ効果をもつ
- λ は**ハイパーパラメータ**であり、訓練誤差では選べない。**検証データ**または**交差検証**で検証誤差が最小になるものを選び、最終評価にはテストデータを残す。正則化の前に特徴を標準化し、切片は罰しない
- **バイアス–バリアンス分解**：二乗誤差の平均 $=$ ノイズ $+$ バイアス^2 $+$ バリアンス。正則化はバイアスを少し増やしてバリアンスを大きく減らす。1 変数モデルでは $\lambda^*=\sigma^2/w^2$ で、リッジ回帰は最小二乗法より必ず推定誤差が小さい
- **制約付き最適化**：罰則 $\lambda\|\boldsymbol{w}\|^2$ は制約 $\|\boldsymbol{w}\|\le r$ と同値。解は等高線と制約領域の接点にあり、そこで $\nabla f=-\mu\nabla g$（ラグランジュ乗数 $\mu=\lambda$）が成り立つ
- **L1 正則化（ラッソ）**：実行可能領域がひし形になり、角で接するため成分が 0 になる**疎な解**を与える。特徴選択に使われる。直交する特徴では軟しきい値処理 $\operatorname{sign}(\hat{w})\max(|\hat{w}|-\lambda/2,0)$

第 1 回から本章までで、頻度論的な枠組み（損失最小化とその正則化）が一通り揃った。次回（第 7 回）からは確率とベイズの定理を学び、第 9 回で本章の正則化を「事前分布」として捉え直す。$\lambda\|\boldsymbol{w}\|^2$ という項に、もう一つの顔があることが分かるだろう。

6.8 演習問題

1. **リッジ回帰の解の導出**　$J_\lambda(\boldsymbol{w}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \lambda\|\boldsymbol{w}\|^2$ について答えよ。
   (a) J_λ を展開し、公式 (4.11) と (4.12) を用いて ∇J_λ を求めよ。
   (b) $\nabla J_\lambda = \boldsymbol{0}$ から式 (6.7) を導け。
   (c) $\lambda > 0$ のとき、任意の $\boldsymbol{v} \neq \boldsymbol{0}$ に対して $\boldsymbol{v}^\top(\boldsymbol{X}^\top\boldsymbol{X} + \lambda\boldsymbol{I})\boldsymbol{v} > 0$ となることを示せ。$\boldsymbol{X}$ がランク落ちしていて $\boldsymbol{X}\boldsymbol{v} = \boldsymbol{0}$ となる $\boldsymbol{v}$ があっても成り立つ理由を述べよ。
   (d) J_λ のヘッセ行列を求め、J_λ が狭義凸であることを述べよ。
2. **数値例**　$\boldsymbol{X} = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$、$\boldsymbol{y} = (1, 2, 2)^\top$ について答えよ。
   (a) $\lambda = 3$ のリッジ回帰の解 $\boldsymbol{w}_3$ を求めよ。
   (b) $\boldsymbol{w}_3$ に対する残差 $\boldsymbol{r} = \boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}_3$ を求め、$\|\boldsymbol{r}\|^2$ と $\|\boldsymbol{w}_3\|^2$ を計算せよ。表 6.1 の $\lambda = 1$ の行と比べ、どちらがどう変わったか述べよ。
   (c) 最小二乗法では $\boldsymbol{X}^\top\boldsymbol{r} = \boldsymbol{0}$（残差と列の直交性）が成り立った。$\boldsymbol{w}_3$ の残差について $\boldsymbol{X}^\top\boldsymbol{r}$ を計算し、$\boldsymbol{0}$ にならないこと、および $\boldsymbol{X}^\top\boldsymbol{r} = \lambda\boldsymbol{w}_3$ となることを確かめよ。この等式を式 (6.7) から説明せよ。
3. **固有値で見る**　問 2 の $\boldsymbol{X}^\top\boldsymbol{X} = \begin{pmatrix} 3 & 3 \\ 3 & 5 \end{pmatrix}$ について答えよ。
   (a) 固有値 $d_1 > d_2$ を特性方程式から求めよ（$4 \pm \sqrt{10}$ の形になる）。
   (b) $\lambda = 1$ と $\lambda = 10$ について、縮小率 $d_i/(d_i + \lambda)$ を 2 つの固有値それぞれについて求めよ。
   (c) 条件数 $\kappa = d_1/d_2$ と、$\lambda = 1, 10$ のときの $(d_1 + \lambda)/(d_2 + \lambda)$ を求めよ。
   (d) 有効自由度 $\mathrm{df}(\lambda) = \sum_i d_i/(d_i + \lambda)$ を $\lambda = 0, 1, 10$ について求めよ。
4. **単位と標準化**　切片のない 1 変数のリッジ回帰 $\min_w \sum_i (y_i - w x_i)^2 + \lambda w^2$ を考える。x_i の単位を変えて $x_i' = c\,x_i$（$c > 0$）としたときの解を w_λ' とする。
   (a) w_λ と w_λ' をそれぞれ $\sum_i x_i y_i$、$\sum_i x_i^2$、c、λ で表せ。
   (b) 予測 $w_\lambda x_i$ と $w_\lambda' x_i'$ は一致するか。一致しないなら、λ を変えずに単位だけ変えると正則化の強さがどう変わるか説明せよ。
   (c) 単位を変えた後に同じ予測を得るには λ をどう変えればよいか。
5. **重み減衰**　$L_D(\boldsymbol{w}) = \frac{1}{N}\|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ に罰則 $\lambda\|\boldsymbol{w}\|^2$ を加えた目的関数を勾配降下法で最小化する。
   (a) 更新式が $\boldsymbol{w}^{(t+1)} = (1 - 2\eta\lambda)\boldsymbol{w}^{(t)} - \eta\nabla L_D(\boldsymbol{w}^{(t)})$ となることを示せ。
   (b) 問 2 のデータで $\lambda = 1$、$\eta = 0.1$、$\boldsymbol{w}^{(0)} = \boldsymbol{0}$ として $\boldsymbol{w}^{(1)}, \boldsymbol{w}^{(2)}$ を計算せよ。
   (c) この反復の停留点（$\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)}$ となる点）が、$\frac{1}{N}$ を含めた定義でのリッジ回帰の解 $(\boldsymbol{X}^\top\boldsymbol{X} + N\lambda\boldsymbol{I})^{-1}\boldsymbol{X}^\top\boldsymbol{y}$ に一致することを示せ。
   (d) 目的関数のヘッセ行列の最大固有値を用いて、この反復が収束する学習率の範囲を書け（第 5.3.2 項）。罰則を加えると収束の上限はどう変わるか。
6. **早期終了**　$J(\boldsymbol{w}) = \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ に対する勾配降下法 $\boldsymbol{w}^{(t+1)} = \boldsymbol{w}^{(t)} - \eta\nabla J(\boldsymbol{w}^{(t)})$ を $\boldsymbol{w}^{(0)} = \boldsymbol{0}$ から始める。$\boldsymbol{X}$ はフルランクとし、$\boldsymbol{X}^\top\boldsymbol{X} = \boldsymbol{Q}\boldsymbol{D}\boldsymbol{Q}^\top$、最小二乗解を $\boldsymbol{w}^*$ とする。
   (a) 誤差 $\boldsymbol{e}^{(t)} = \boldsymbol{w}^{(t)} - \boldsymbol{w}^*$ が $\boldsymbol{e}^{(t+1)} = (\boldsymbol{I} - 2\eta\boldsymbol{X}^\top\boldsymbol{X})\boldsymbol{e}^{(t)}$ を満たすことを示せ。

(b) $\boldsymbol{v}_i$ 方向の成分 $u_i^{(t)} = \boldsymbol{v}_i^\top \boldsymbol{w}^{(t)}$ が $u_i^{(t)} = \{1-(1-2\eta d_i)^t\}\, u_i^*$ となることを示せ（$u_i^* = \boldsymbol{v}_i^\top \boldsymbol{w}^*$）。

(c) $2\eta d_i t \ll 1$ のとき $1-(1-2\eta d_i)^t \approx 2\eta t\, d_i$ であることを用いて、t 回で止めた解がリッジ回帰の縮小率 $d_i/(d_i+\lambda)$ とどう対応するか述べよ。

7. **バイアスとバリアンス**　第 6.4.3 項の 1 変数モデル $y_i = w x_i + \varepsilon_i$ について答えよ。

(a) 式 (6.23) を λ で微分し、$\lambda^* = \sigma^2/w^2$ で最小になることを示せ。

(b) $\mathrm{MSE}(\lambda^*) = \sigma^2/(d + \sigma^2/w^2)$ を導き、これが $\mathrm{MSE}(0) = \sigma^2/d$ より小さいことを確かめよ。

(c) $d = 10$、$\sigma = 1$、$w = 0.5$ のとき、$\lambda = 0, 1, 4, 10$ についてバイアス ^{2}、バリアンス、MSE を計算せよ。

(d) 真のパラメータが $w = 0$（その特徴は実は無関係）だったとき、λ^* はどうなるか。この結果の意味を説明せよ。

8. **制約形式との対応**　問 2 のデータについて答えよ。

(a) $\lambda = 10$ の解 $\boldsymbol{w}_{10} \approx (0.306, 0.339)^\top$ について、$\nabla \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 = 2(\boldsymbol{X}^\top \boldsymbol{X}\boldsymbol{w} - \boldsymbol{X}^\top \boldsymbol{y})$ を $\boldsymbol{w} = \boldsymbol{w}_{10}$ で計算し、$-2\mu \boldsymbol{w}_{10}$ の形になることを確かめて μ を求めよ。

(b) 制約付き問題 $\min \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2$ subject to $\|\boldsymbol{w}\|^2 \le r^2$ の解が $\boldsymbol{w}_{10}$ となる r を求めよ。

(c) $r = 2$ としたとき、制約付き問題の解は何か。ラグランジュ乗数 μ の値とともに答えよ（ヒント：$\|\boldsymbol{w}^*\|$ と r を比べる）。

9. **軟しきい値処理**　1 変数の関数 $\phi(w) = (\hat{w} - w)^2 + \lambda |w|$（$\lambda > 0$）の最小点を求める。

(a) $w > 0$ の範囲で ϕ を微分し、停留点 $w = \hat{w} - \lambda/2$ を得よ。これが $w > 0$ の範囲に入る条件を述べよ。

(b) $w < 0$ の範囲で同様に考えよ。

(c) $|\hat{w}| \le \lambda/2$ のとき最小点が $w = 0$ であることを、$\phi(w) \ge \phi(0)$ を示すことで確かめよ（ヒント：$(\hat{w} - w)^2 - \hat{w}^2 = w^2 - 2\hat{w}w \ge -2|\hat{w}||w|$）。

(d) 以上をまとめて式 (6.31) を導け。$\hat{w} = (2, 0.3, -1)^\top$、$\lambda = 1$ のときのラッソの解と、同じ設定でのリッジ回帰の解 $\hat{w}_j/(1+\lambda)$ を比べよ。

10. **交差検証**　あるデータを 5 分割して交差検証を行い、各 λ について次の検証誤差（平均二乗誤差）が得られた。

λ	第 1 回	第 2 回	第 3 回	第 4 回	第 5 回
0	0.35	0.12	0.41	0.18	0.29
0.1	0.20	0.14	0.22	0.16	0.18
1	0.17	0.18	0.18	0.19	0.16
10	0.30	0.33	0.29	0.34	0.31

(a) 各 λ について検証誤差の平均を求め、選ぶべき λ を答えよ。

(b) $\lambda = 0$ の行は平均だけでなくばらつきも大きい。この理由をバイアスとバリアンスの言葉で説明せよ。

(c) 訓練誤差が最小になる λ を選んではいけない理由を述べよ。

(d) 選んだ λ で全データを使って学習し直したモデルの性能を見積もるには、どのデータを使うべきか。交差検証の平均値をそのまま使うことの問題点を述べよ。

7　確率とベイズの定理

第 1 回から第 6 回までは、損失を最小にするパラメータを求めることを学習と捉えてきた。しかしその途中で、確率の言葉が何度も顔を出していた。汎化誤差は「データの分布 $P(\boldsymbol{x}, y)$ に関する損失の期待値」として定義された（第 1.4.2 項）。ミニバッチの勾配は「平均すれば」真の勾配に一致した（第 5.5.2 項）。バイアス–バリアンス分解では、学習したパラメータを「データを取り直すたびにばらつく量」として扱った（第 6.4 節）。いずれも、確率の扱いは「直感で十分」として先送りにしてきた。

本章では、その先送りを清算する。確率の基本公式を公理から導き、**条件付き確率**と**ベイズの定理**を学ぶ。ベイズの定理は「データを見る前の考え（事前確率）を、データを見て更新する（事後確率）」ための式であり、第 8 回のナイーブベイズ分類器、第 9 回の「正則化＝事前分布」という見方の土台になる。

本章の流れは次のとおりである。まず、機械学習に確率がなぜ必要なのかを確認する（第 7.1 節）。確率の公理と基本公式（第 7.2 節）、条件付き確率と独立性（第 7.3 節）を経て、ベイズの定理を導き、事前確率・尤度・事後確率という 3 つの役者を紹介する（第 7.4 節）。後半では、数値をとる確率的な量（**確率変数**）と、その平均・ばらつきを表す**期待値**と**分散**を学び（第 7.5 節、第 7.6 節）、これまで先送りにしてきた事実を証明する。最後に、パラメータそのものを確率で表す**ベイズ推定**の考え方を、コインの例で見る（第 7.7 節）。

7.1　なぜ確率が必要か

7.1.1　機械学習に現れる不確かさ

機械学習には、少なくとも 3 種類の不確かさが現れる。

1. **データのノイズ**：同じ $\boldsymbol{x}$ でも y は毎回少しずつ違う。第 6 回では $y = f(x) + \varepsilon$ と書き、ε を平均 0、分散 σ^2 のノイズとした（式 (6.18)）。
2. **データの取り方**：手元の訓練データは、起こりうる多数のデータのうちの一組にすぎない。データが違えば学習結果も違う。ミニバッチの選び方もこの一種である。
3. **パラメータについての知識**：データが少ないうちは、どのパラメータが正しいのか確信が持てない。データが増えるにつれて確信が強まる。

1 と 2 は「世界が毎回ばらつく」ことによる不確かさ、3 は「私たちが知らない」ことによる不確かさである。確率は、この両方を同じ規則で扱える言葉である。

7.1.2　確率の 2 つの解釈

確率には 2 つの読み方がある。

- **頻度としての確率**：サイコロを何度も振ったとき、1 の目が出る割合は 1/6 に近づく。確率とは「同じ試行をくり返したときの長期的な割合」である。
- **信念の度合いとしての確率**：「明日雨が降る確率は 30%」のように、くり返せない一回限りの事柄についても確率を語る。確率とは「その命題をどの程度確からしいと考えているか」の数値である。

前者を**頻度論**、後者を**ベイズ的**な解釈と呼ぶ。第 1 回から第 6 回の損失最小化は頻度論的な枠組みであり、第 7 回から第 9 回ではベイズ的な見方を導入する。重要なのは、**どちらの解釈でも計算規則は同じ**だということ

である。次節の公理と、そこから導かれる公式は、解釈によらずそのまま使える。

7.2 確率の基本

7.2.1 標本空間と事象

定義：標本空間と事象

試行の結果として起こりうるもの全体の集合を**標本空間**（sample space）と呼び、Ω で表す。Ω の部分集合を**事象**（event）と呼ぶ。

サイコロを 1 回振る試行なら $\Omega = \{1, 2, 3, 4, 5, 6\}$ であり、「偶数の目が出る」は事象 $A = \{2, 4, 6\}$、「4 以上の目が出る」は事象 $B = \{4, 5, 6\}$ である。事象は集合なので、集合の演算がそのまま使える（第 5.4.1 項の集合の記号を思い出そう）。

- $A \cap B$（**積事象**）：A と B が両方起こる。例では $\{4, 6\}$
- $A \cup B$（**和事象**）：A または B が起こる。例では $\{2, 4, 5, 6\}$
- $A^c = \Omega \setminus A$（**余事象**）：A が起こらない。例では $\{1, 3, 5\}$
- $A \cap B = \emptyset$ のとき、A と B は**互いに排反**（同時には起こらない）という。例えば A と $C = \{1, 3\}$ は互いに排反である

これらを図 7.1 に示す。事象は標本空間の中の「囲み」であり、確率はその囲みに割り当てる「大きさ」だと考えるとよい。

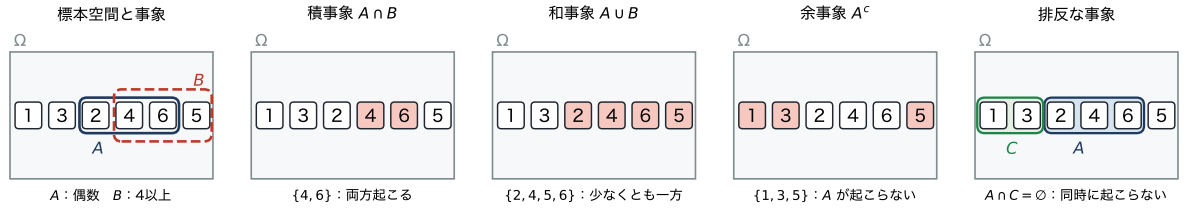


図 7.1　サイコロを 1 回振る試行の標本空間 $\Omega = \{1, \ldots, 6\}$ と事象。左から、事象 A（偶数）と B（4 以上）、積事象 $A \cap B$、和事象 $A \cup B$、余事象 A^c（色を付けた結果がその事象に含まれる）、互いに排反な事象 A と $C = \{1, 3\}$（共通部分がない）。A と B をそれぞれひと続きに囲めるよう、結果を $1, 3, 2, 4, 6, 5$ の順に並べている。

7.2.2 確率の公理

確率とは、各事象に 0 以上の数を割り当てる規則である。どんな割り当てが「確率」と呼ぶにふさわしいかを、次の 3 つの条件で定める。

定義：確率の公理（コルモゴロフ）

事象 $A \subseteq \Omega$ に実数 $P(A)$ を対応させる関数 P が次の 3 条件を満たすとき、P を**確率**と呼ぶ。

1.（非負性）すべての事象 A について $P(A) \geq 0$
2.（全体の確率）$P(\Omega) = 1$
3.（加法性）互いに排反な事象 $A_1, A_2, \ldots$ について $P(A_1 \cup A_2 \cup \cdots) = P(A_1) + P(A_2) + \cdots$

公理はたったこれだけである。確率についての他のすべての公式は、この 3 つから導かれる。いくつか導いておこう。

■7.2.2.1　**余事象の確率**　A と A^c は互いに排反で、$A \cup A^c = \Omega$ である。公理 2 と 3 より $P(A) + P(A^c) = P(\Omega) = 1$、すなわち

$$P(A^c) = 1 - P(A) \tag{7.1}$$

特に $A = \Omega$ とすれば $P(\emptyset) = 0$ である。「少なくとも 1 回は〜」という確率は、余事象「1 回も〜ない」から計算すると楽になることが多い。

■7.2.2.2　**確率は 1 以下**　式 (7.1) と公理 1 より $P(A) = 1 - P(A^c) \leq 1$ である。

■7.2.2.3　**和事象の確率（加法定理）**　公理 3 は「排反な事象」についてしか足し算を許していない。A と B に共通部分があるときはどうなるか。図 7.2 のサイコロの例で考えよう。$A = \{2, 4, 6\}$、$B = \{4, 5, 6\}$ なので $P(A) + P(B) = 3/6 + 3/6 = 6/6$ だが、$A \cup B = \{2, 4, 5, 6\}$ の確率は $4/6$ である。差の $2/6$ は、共通部分 $A \cap B = \{4, 6\}$ を $P(A)$ と $P(B)$ で **2 回数えた**ぶんにあたる。

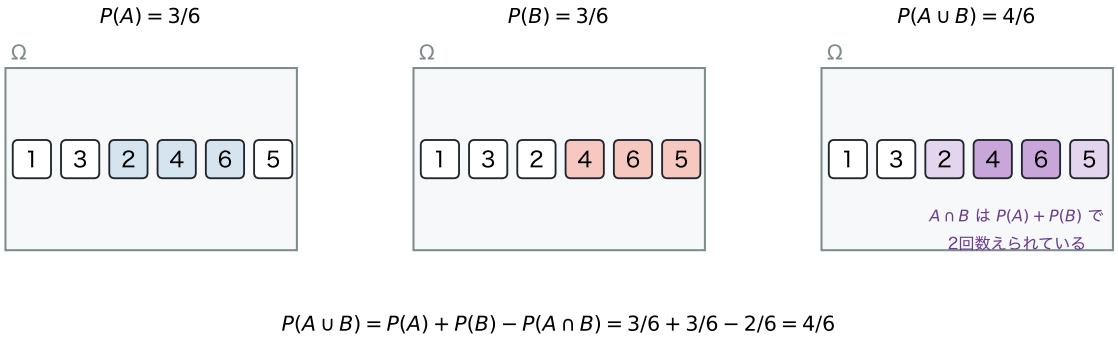


図 7.2　加法定理。$P(A) + P(B)$ では $A \cap B = \{4, 6\}$（右の濃い色）が 2 回数えられているので、1 回分を引くと $P(A \cup B)$ になる。

これを公理から導く。$A \cup B$ を、互いに排反な 3 つの部分に分ける。

$$A \cup B = \underbrace{(A \cap B^c)}_{A \text{ だけ}} \cup \underbrace{(A \cap B)}_{\text{両方}} \cup \underbrace{(A^c \cap B)}_{B \text{ だけ}}$$

サイコロの例では順に $\{2\}$、$\{4,6\}$、$\{5\}$ である。3 つは互いに排反なので、公理 3 より

$$P(A \cup B) = P(A \cap B^c) + P(A \cap B) + P(A^c \cap B)$$

である。一方、A 自身も B 自身も、同じ部品で排反に分けられる。

$$P(A) = P(A \cap B^c) + P(A \cap B), \qquad P(B) = P(A \cap B) + P(A^c \cap B)$$

この 2 式を足すと $P(A) + P(B) = P(A \cap B^c) + 2\,P(A \cap B) + P(A^c \cap B)$ となり、$P(A \cup B)$ の式と比べると $P(A \cap B)$ が 1 つ余分である。したがって

$$P(A \cup B) = P(A) + P(B) - P(A \cap B) \tag{7.2}$$

を得る。サイコロの例では $3/6 + 3/6 - 2/6 = 4/6$ であり、直接数えた結果と一致する。

7.2.3 同時確率と周辺確率

2 つの観点でデータを分類すると、確率を表の形で整理できる。例として、ある受信箱の 1000 通のメールを「迷惑メールか否か」と「本文に『無料』という単語を含むか否か」で数えた結果を表 7.1 に示す。各セルの割合を**同時確率**（joint probability）と呼び、$P(\text{迷惑}, \text{無料あり}) = P(\text{迷惑} \cap \text{無料あり})$ のように書く。ここで「迷惑」「無料あり」は、1000 通を標本空間 Ω としたときの事象（迷惑メールの集合、『無料』を含むメールの集合）であり、本来は A、B のような記号で表すべきものである。本章では読みやすさのため、**事象を表す言葉をそのまま P の中に書く略記**を用いる。$P(\text{迷惑})$ は「事象『迷惑メール』の確率」の意味である。

表 7.1　1000 通のメールの分類（括弧内は全体に対する割合）。この例は第 8 回のナイーブベイズ分類器でも使う。

	「無料」あり	「無料」なし	計
迷惑メール	120 (0.12)	80 (0.08)	200 (0.20)
通常メール	40 (0.04)	760 (0.76)	800 (0.80)
計	160 (0.16)	840 (0.84)	1000 (1.00)

表の右端と下端の「計」は、一方の観点だけで見た確率であり、**周辺確率**（marginal probability）と呼ばれる。表の余白（margin）に書かれることからこの名がある。周辺確率は同時確率を足し合わせて得られる。「『無料』あり」と「『無料』なし」は互いに排反で、合わせると全体になるので、公理 3 より

$$P(\text{迷惑}) = P(\text{迷惑}, \text{無料あり}) + P(\text{迷惑}, \text{無料なし}) = 0.12 + 0.08 = 0.20 \tag{7.3}$$

である。この操作を**周辺化**（marginalization）と呼ぶ。「知りたくない方の観点について、すべての場合を足し合わせて消す」操作であり、本章で何度も使う。表 7.1 を面積で描いたものが、次節の図 7.3 中央である。横幅が「無料」あり／なしの割合、各列の中の縦の割合が迷惑／通常の割合で、各セルの面積が同時確率になっている。赤いセルの面積を全部足したものが $P(\text{迷惑}) = 0.20$ である。

7.3 条件付き確率と独立性

7.3.1 条件付き確率

表 7.1 で、「『無料』を含むメールのうち、迷惑メールの割合はいくらか」を考えよう。『無料』を含むメールは 160 通、そのうち迷惑メールは 120 通なので、割合は $120/160 = 0.75$ である。全体での迷惑メールの割合 0.20 に比べてずっと高い。「『無料』を含む」という情報が、迷惑メールである確からしさを変えたのである。

定義：条件付き確率

$P(B) > 0$ のとき、事象 B が起きたという条件のもとでの事象 A の**条件付き確率**を

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} \tag{7.4}$$

で定める。「B のもとでの A の確率」と読む。

例では

$$P(\text{迷惑} \mid \text{無料あり}) = \frac{P(\text{迷惑} \cap \text{無料あり})}{P(\text{無料あり})} = \frac{0.12}{0.16} = \frac{120/1000}{160/1000} = \frac{120}{160} = 0.75$$

であり、上の数え方と一致する。分母と分子の $1/1000$ が約分されて、結局「160 通のうちの 120 通」という割合になる。

図 7.3 のように、条件付き確率は**標本空間を B に縮めて、その中で A が占める割合を測る**ことにあたる。右の図では、「無料」ありの列だけに注目し、その列の中で迷惑メールの占める高さの割合を読んでいる。分母の $P(B)$ は、縮めた新しい全体の大きさを 1 にそろえるための正規化である。実際、$P(\cdot \mid B)$ は事象の関数として確率の公理をすべて満たす（演習問題 1）。したがって、前節の公式は条件付き確率についてもそのまま成り立つ。例えば $P(A^c \mid B) = 1 - P(A \mid B)$ であり、図の右では「無料」ありの列の残り $40/160 = 0.25$ がそれにあたる。

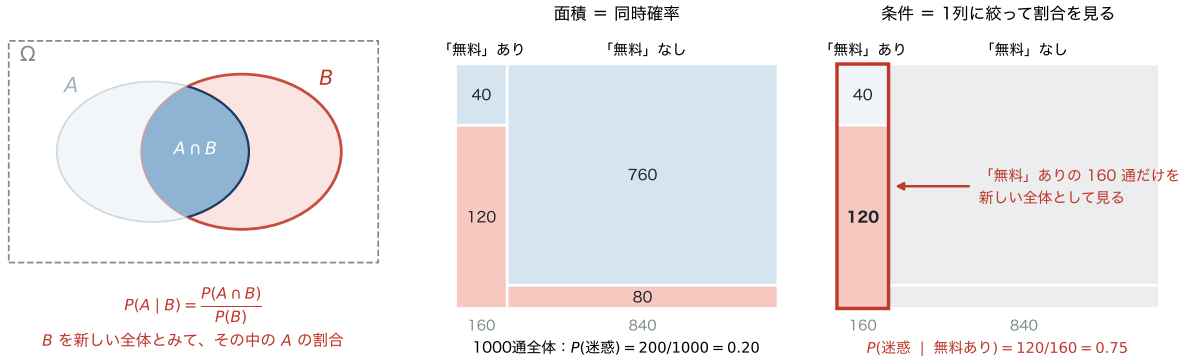


図 7.3　条件付き確率。左：$P(A \mid B)$ は B を新しい全体とみなし、その中で $A \cap B$ が占める割合。中央：表 7.1 を面積で描いたもの。横幅が「無料」あり／なしの割合、各列の中の縦の割合が迷惑／通常の割合で、各セルの面積が同時確率。右：「無料」ありの列だけを新しい全体とみると、迷惑メールの割合は $120/160 = 0.75$ になる。

条件付き確率で特に注意すべきは、$P(A \mid B)$ **と** $P(B \mid A)$ **は別物**だということである。例では

$$P(\text{迷惑} \mid \text{無料あり}) = \frac{120}{160} = 0.75, \qquad P(\text{無料あり} \mid \text{迷惑}) = \frac{120}{200} = 0.60$$

であり、分母が違う。前者は「『無料』を含むメールのうち迷惑メールの割合」、後者は「迷惑メールのうち『無料』を含むものの割合」である。この 2 つを取り違える誤りは日常でも頻繁に起き、第 7.4.2 項で見るように深刻な判断ミスにつながる。

7.3.2 乗法定理

条件付き確率の定義 (7.4) を、積事象の確率 $P(A \cap B)$ について解いてみよう。定義は $P(A \mid B) = P(A \cap B)/P(B)$ であったから、両辺に $P(B)$ を掛けて左右を入れ替えると

$$P(A \cap B) = P(A \mid B)\, P(B)$$

を得る。次に、同じ定義を A と B の役割を入れ替えて書くと（$P(A) > 0$ とする）

$$P(B \mid A) = \frac{P(B \cap A)}{P(A)}$$

である。積事象は順序によらない（$B \cap A = A \cap B$、「B と A が両方起こる」と「A と B が両方起こる」は同じ事象）ので、両辺に $P(A)$ を掛ければ $P(A \cap B) = P(B \mid A)\, P(A)$ となる。2 つをまとめると

$$P(A \cap B) = P(A \mid B)\, P(B) = P(B \mid A)\, P(A) \tag{7.5}$$

である。これを**乗法定理**（product rule）と呼ぶ。同じ $P(A \cap B)$ を、「B を先に考える」か「A を先に考える」かの 2 通りに分解しているのである。なお $P(B) = 0$ のときは $P(A \mid B)$ が定義されないが、$P(A \cap B) \leq P(B) = 0$ なので左辺も 0 であり、右辺を 0 と読めば式はそのまま成り立つ。

表 7.1 で確かめておこう。A を「迷惑メール」、B を「『無料』あり」とすると

$$P(A \mid B)\, P(B) = \frac{120}{160} \times \frac{160}{1000} = \frac{120}{1000} = 0.12,$$
$$P(B \mid A)\, P(A) = \frac{120}{200} \times \frac{200}{1000} = \frac{120}{1000} = 0.12$$

であり、どちらも表の同時確率 $P(A \cap B) = 0.12$ に一致する。分母と分子で 160（または 200）が約分され、結局「両方に当てはまる 120 通」を全体 1000 通で割っていることが分かる。「A と B が両方起こる確率」を「まず B が起こり、そのうえで A が起こる」と 2 段階に分けて計算できる、という意味である。乗法定理は、3 つ以上の事象にもくり返し使える。鍵は、**いくつかの事象の積事象を、まとめて 1 つの事象とみなす**ことである。

■7.3.2.1 3 つの事象の場合 $A_1 \cap A_2 \cap A_3$ を、2 つの事象 $(A_1 \cap A_2)$ と A_3 の積事象と見る。式 (7.5) の 1 つ目の形で、A を A_3、B を $A_1 \cap A_2$ に置き換えると

$$P(A_1 \cap A_2 \cap A_3) = P\big(A_3 \cap (A_1 \cap A_2)\big) = P(A_3 \mid A_1 \cap A_2)\, P(A_1 \cap A_2)$$

となる。右辺に残った $P(A_1 \cap A_2)$ に、もう一度乗法定理を使って $P(A_1 \cap A_2) = P(A_2 \mid A_1)\, P(A_1)$ と分解すれば

$$P(A_1 \cap A_2 \cap A_3) = P(A_3 \mid A_1 \cap A_2)\, P(A_2 \mid A_1)\, P(A_1)$$

を得る。掛け算の順序を入れ替えて、起こる順に並べると $P(A_1)\, P(A_2 \mid A_1)\, P(A_3 \mid A_1 \cap A_2)$ である。「まず A_1 が起こり、A_1 のもとで A_2 が起こり、A_1 と A_2 のもとで A_3 が起こる」と、1 つずつ条件を増やしながら積み重ねている。

■7.3.2.2　**一般の場合**　n 個の場合も同じである。最後の事象 A_n と、それ以前の積事象 $A_1 \cap \cdots \cap A_{n-1}$ に分けて乗法定理を使うと

$$P(A_1 \cap \cdots \cap A_n) = P(A_n \mid A_1 \cap \cdots \cap A_{n-1})\, P(A_1 \cap \cdots \cap A_{n-1})$$

となり、事象の個数が 1 つ減った $P(A_1 \cap \cdots \cap A_{n-1})$ が残る。これに同じ操作をくり返すと、事象は 1 つずつ減っていき、最後に $P(A_1)$ が残る。はがした条件付き確率をすべて掛け合わせれば

$$P(A_1 \cap A_2 \cap \cdots \cap A_n) = P(A_1)\, P(A_2 \mid A_1)\, P(A_3 \mid A_1 \cap A_2) \cdots P(A_n \mid A_1 \cap \cdots \cap A_{n-1}) \tag{7.6}$$

を得る（**連鎖律**）。k 番目の因子は「1 番目から $k-1$ 番目までがすべて起きたという条件のもとで、k 番目が起こる確率」である。厳密には、この「くり返し」は n についての数学的帰納法で示される。なお、各条件付き確率が定義されるためには、条件となる積事象 $A_1 \cap \cdots \cap A_{k-1}$ の確率が正である必要がある。

例えば、52 枚のトランプから 3 枚を続けて（戻さずに）引いて、全部ハートである確率を求めよう。A_k を「k 枚目がハート」とすると、連鎖律より

$$P(A_1 \cap A_2 \cap A_3) = \underbrace{\frac{13}{52}}_{P(A_1)} \cdot \underbrace{\frac{12}{51}}_{P(A_2 \mid A_1)} \cdot \underbrace{\frac{11}{50}}_{P(A_3 \mid A_1 \cap A_2)} \approx 0.013$$

である。1 枚目は 52 枚中 13 枚がハート。1 枚目がハートだったという条件のもとでは、残り 51 枚中ハートは 12 枚。1 枚目と 2 枚目がともにハートだったという条件のもとでは、残り 50 枚中ハートは 11 枚である。各因子が「それまでに起きたことを条件とする確率」になっていることが、具体的な数で確かめられる。もし引いたカードを毎回戻すなら、各回は前の結果と独立になり（第 7.3.4 項）、確率は $(13/52)^3 = 1/64$ である。この連鎖律は、文章の確率を単語ごとの条件付き確率の積に分解する言語モデル（第 13 回）の出発点でもある。

7.3.3　全確率の定理

周辺化（式 (7.3)）と乗法定理を組み合わせると、次の定理が得られる。

定理：全確率の定理

事象 $B_1, \ldots, B_K$ が互いに排反で、$B_1 \cup \cdots \cup B_K = \Omega$ を満たす（Ω **の分割**である）とき、任意の事象 A について

$$P(A) = \sum_{k=1}^{K} P(A \mid B_k)\, P(B_k) \tag{7.7}$$

が成り立つ。

■7.3.3.1　**証明**　3 段階で示す。

1. A **を分割する。** $B_1, \ldots, B_K$ は全体 Ω を隙間なく重なりなく覆っているので、A の各要素はちょうど 1 つの B_k に属する。したがって A は、「A のうち B_1 に入る部分」「A のうち B_2 に入る部分」……に分かれる：
$$A = (A \cap B_1) \cup (A \cap B_2) \cup \cdots \cup (A \cap B_K)$$

2. **公理 3 で足す。** B_k どうしが排反なので、$A \cap B_k$ どうしも排反である。公理 3 より

$$P(A) = P(A \cap B_1) + P(A \cap B_2) + \cdots + P(A \cap B_K) = \sum_{k=1}^{K} P(A \cap B_k)$$

3. **各項に乗法定理を使う。** 式 (7.5) より $P(A \cap B_k) = P(A \mid B_k)\, P(B_k)$ なので、これを代入すれば式 (7.7) になる。

■

全確率の定理は「場合分けして、各場合の確率で重み付けして足す」ことを言っている。図 7.4 左は、迷惑メールの例をこの形で読んだものである。A を「迷惑メール」、B_1 を「無料」あり、B_2 を「無料」なしとすると、

$$P(A) = \underbrace{P(A \mid B_1)}_{0.75}\,\underbrace{P(B_1)}_{0.16} + \underbrace{P(A \mid B_2)}_{80/840 \approx 0.095}\,\underbrace{P(B_2)}_{0.84} = 0.12 + 0.08 = 0.20$$

であり、周辺化 (7.3) と同じ値になる。図で言えば、各列の幅 $P(B_k)$ に、その列の中の赤の高さ $P(A \mid B_k)$ を掛けると各列の赤の面積 $P(A \cap B_k)$ になり、それを列ごとに足したものが赤の面積全体 $P(A)$ である。

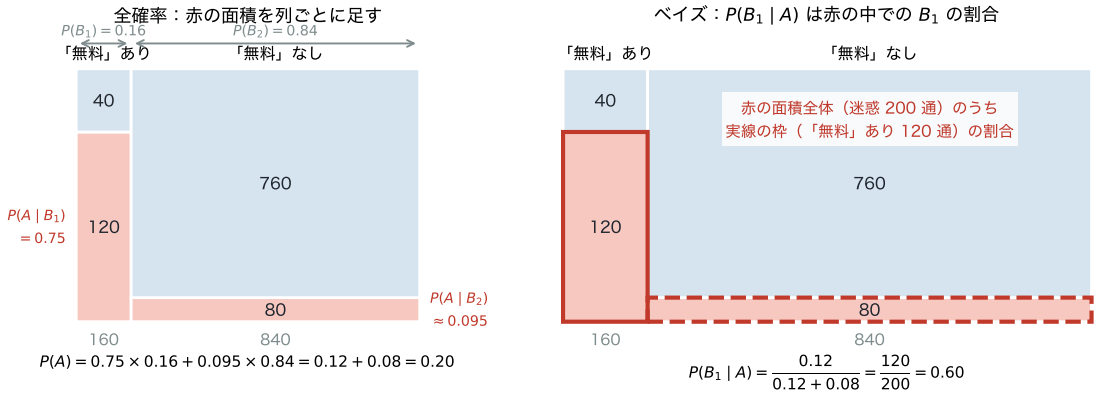


図 7.4　全確率の定理とベイズの定理を面積で見る（A：迷惑メール、B_1：「無料」あり、B_2：「無料」なし）。左：列の幅 $P(B_k)$ × 列内の赤の高さ $P(A \mid B_k)$ = 列ごとの赤の面積。足すと $P(A)$。右：ベイズの定理 $P(B_1 \mid A)$ は、赤の面積全体のうち B_1 の列にある部分の割合。

もう一つ例を挙げる。ある部品を 3 つの工場 B_1, B_2, B_3 が $50\%, 30\%, 20\%$ の割合で作り、不良品の割合がそれぞれ $1\%, 2\%, 3\%$ なら、無作為に選んだ部品が不良品である確率は $0.01 \times 0.5 + 0.02 \times 0.3 + 0.03 \times 0.2 = 0.005 + 0.006 + 0.006 = 0.017$ である。

7.3.4　独立性

「『無料』を含む」という情報は、迷惑メールである確率を 0.20 から 0.75 に変えた。逆に、情報を得ても確率が変わらないとき、2 つの事象は無関係だと言える。

定義：独立

事象 A と B が

$$P(A \cap B) = P(A)\,P(B) \tag{7.8}$$

を満たすとき、A と B は**独立** (independent) であるという。$P(B) > 0$ なら、これは $P(A \mid B) = P(A)$（B を知っても A の確率が変わらない）と同値である。

サイコロを 2 回振るとき、「1 回目が偶数」と「2 回目が 6」は独立であり、両方が起こる確率は $\frac{1}{2} \cdot \frac{1}{6} = \frac{1}{12}$ である。一方、表 7.1 では $P(\text{迷惑}, \text{無料あり}) = 0.12$ に対して $P(\text{迷惑})P(\text{無料あり}) = 0.2 \times 0.16 = 0.032$ なので、独立ではない。独立でないからこそ、「無料」という単語が迷惑メールの手がかりになる。

独立性は「互いに排反」とは全く違う概念であることに注意する。排反な事象（$P(A \cap B) = 0$）は、一方が起きれば他方は決して起きないので、むしろ強く依存している。

さらに、第 3 の事象 C を条件としたときに

$$P(A \cap B \mid C) = P(A \mid C)\,P(B \mid C) \tag{7.9}$$

が成り立つとき、A と B は C **のもとで条件付き独立**であるという。「迷惑メールであることが分かっていれば、『無料』を含むかどうかと『当選』を含むかどうかは無関係」という仮定がその例であり、第 8 回のナイーブベイズ分類器はこの仮定の上に組み立てられる。

7.4 ベイズの定理

7.4.1 定理の導出

乗法定理 (7.5) には、同じ $P(A \cap B)$ を表す 2 通りの書き方があった。

$$P(A \mid B)\,P(B) = P(B \mid A)\,P(A)$$

両辺を $P(B)$ で割れば、条件の向きを入れ替える公式が得られる。

定理：ベイズの定理

$P(B) > 0$ のとき

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)} \tag{7.10}$$

が成り立つ。分母は全確率の定理 (7.7) より $P(B) = P(B \mid A)P(A) + P(B \mid A^c)P(A^c)$ と書ける。

導出は 2 行であるが、この式の価値は計算の簡単さではなく、使い方にある。多くの場面で、手元にあるのは「原因 A のもとで結果 B が起こる確率」$P(B \mid A)$ である。病気の人が検査で陽性になる確率、迷惑メールに『無料』が含まれる確率、あるパラメータのもとでデータが観測される確率。一方で知りたいのは逆向きの「結果 B を見たときに原因が A である確率」$P(A \mid B)$ である。ベイズの定理は、**原因から結果への確率を、結果から原因への確率に変換する**式である。

表 7.1 で確かめておこう。$P(\text{無料あり} \mid \text{迷惑}) = 0.6$、$P(\text{迷惑}) = 0.2$、$P(\text{無料あり}) = 0.16$ から

$$P(\text{迷惑} \mid \text{無料あり}) = \frac{0.6 \times 0.2}{0.16} = \frac{0.12}{0.16} = 0.75$$

であり、直接数えた値と一致する。分子の $0.6 \times 0.2 = 0.12$ は乗法定理で作った同時確率 $P(\text{迷惑} \cap \text{無料あり})$ であり、それを $P(\text{無料あり})$ で割っているのだから、これは条件付き確率の定義 (7.4) そのものである。逆

向きの $P(\text{無料あり} \mid \text{迷惑})$ も同じ要領で、図 7.4 右のように「赤の面積全体 $0.12+0.08$ のうち、『無料』ありの列にある 0.12 の割合」として 0.60 が得られる。ベイズの定理の分母を全確率の定理で書き下した形 $P(B)=\sum_k P(B \mid A_k)P(A_k)$ は、まさにこの「面積を列ごとに足す」計算である。

7.4.2 数値例：検査の陽性は何を意味するか

ある病気の検査を考える。

- 有病率：人口の 1% がこの病気にかかっている。$P(\text{病気})=0.01$
- 感度：病気の人が陽性になる確率は 99%。$P(\text{陽性} \mid \text{病気})=0.99$
- 偽陽性率：病気でない人が誤って陽性になる確率は 5%。$P(\text{陽性} \mid \text{健康})=0.05$

ここで「病気」「陽性」は、集団から 1 人を選んだとき「その人が病気である」「検査結果が陽性である」という事象であり、「健康」は「病気」の余事象である（第 7.4.3 項で集合として書き下す）。ある人が陽性と判定された。この人が本当に病気である確率はいくらか。感度 99% の検査で陽性なのだから、病気である確率も 99% 近い、と考えたくなる。ベイズの定理 (7.10) で A を「病気」、B を「陽性」として計算しよう。

$$P(\text{病気} \mid \text{陽性}) = \frac{P(\text{陽性} \mid \text{病気})\,P(\text{病気})}{P(\text{陽性})}$$

分子は、感度と有病率の積 $0.99\times0.01=0.0099$ である（「病気で、かつ陽性」の同時確率）。分母の $P(\text{陽性})$ は直接は与えられていないので、全確率の定理で「病気」「健康」に場合分けして求める。$P(\text{健康})=1-0.01=0.99$ なので

$$P(\text{陽性}) = \underbrace{P(\text{陽性} \mid \text{病気})\,P(\text{病気})}_{0.99\times0.01=0.0099} + \underbrace{P(\text{陽性} \mid \text{健康})\,P(\text{健康})}_{0.05\times0.99=0.0495} = 0.0594$$

である。分母の 2 つの項が「病気で陽性」と「健康なのに陽性」の 2 通りの陽性に対応していることに注意する。したがって、分子と分母を設定の数値で書き下すと

$$\begin{aligned} P(\text{病気} \mid \text{陽性}) &= \frac{P(\text{陽性} \mid \text{病気})\,P(\text{病気})}{P(\text{陽性} \mid \text{病気})\,P(\text{病気}) + P(\text{陽性} \mid \text{健康})\,P(\text{健康})} \\ &= \frac{0.99\times0.01}{0.99\times0.01+0.05\times0.99} = \frac{0.0099}{0.0099+0.0495} = \frac{0.0099}{0.0594} \approx 0.167 \end{aligned} \tag{7.11}$$

である。**陽性でも、本当に病気である確率は約 17% にすぎない**。分母で「健康なのに陽性」の 0.0495 が「病気で陽性」の 0.0099 の 5 倍もあることが原因である。

図 7.5 のように、確率を人数（**自然頻度**）に直すと理由がはっきりする。10000 人のうち病気の人は 100 人で、そのうち 99 人が陽性になる。病気でない 9900 人のうち 5%、つまり 495 人も陽性になる。陽性の 594 人のうち、本当に病気なのは 99 人だけである。偽陽性率 5% は小さく見えるが、それが掛かる「病気でない人」がはるかに多いため、偽陽性の人数が真の陽性を上回るのである。$P(\text{陽性} \mid \text{病気})=0.99$ と $P(\text{病気} \mid \text{陽性})=0.167$ の違いは、前節で注意した「条件の向きの取り違え」の典型例である。

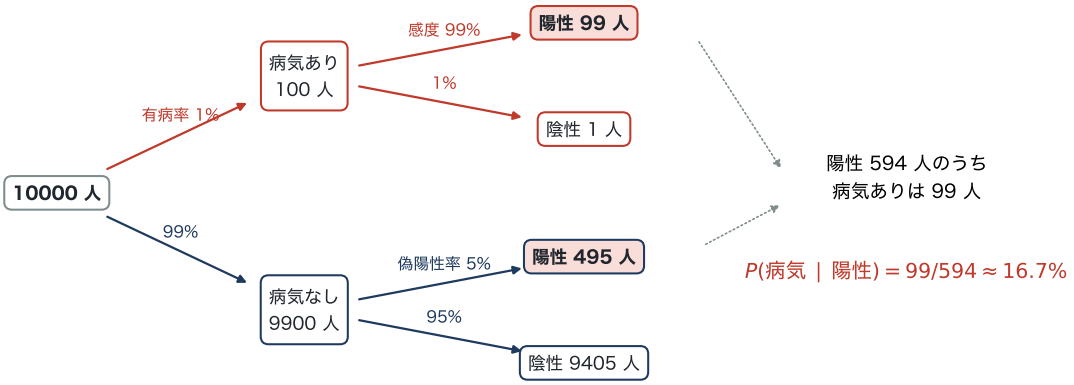


図 7.5　検査の例を 10000 人の人数で表したもの（自然頻度）。陽性 594 人のうち、病気の人は 99 人にすぎない。

この結果を大きく左右しているのは、検査の性能よりも**もともとの有病率** 1% である。有病率が 10% の集団（例えば症状のある人だけを検査する場合）なら、同じ検査でも

$$P(\text{病気} \mid \text{陽性}) = \frac{0.99 \times 0.1}{0.99 \times 0.1 + 0.05 \times 0.9} = \frac{0.099}{0.099 + 0.045} \approx 0.69$$

になる。データ（陽性という結果）の意味は、それを見る前の想定に依存する。これがベイズの定理の最も重要な教訓である。

7.4.3　事前確率・尤度・事後確率

ベイズの定理の各項には名前がついている。原因の候補（仮説）を H、観測したデータを D とすると

$$\underbrace{P(H \mid D)}_{\text{事後確率}} = \frac{\overbrace{P(D \mid H)}^{\text{尤度}}\ \overbrace{P(H)}^{\text{事前確率}}}{\underbrace{P(D)}_{\text{周辺尤度（エビデンス）}}} \tag{7.12}$$

- **事前確率**（prior）$P(H)$：データを見る前に、仮説 H をどの程度確からしいと考えているか
- **尤度**（likelihood）$P(D \mid H)$：仮説 H が正しいとしたとき、観測されたデータ D がどの程度起こりやすいか
- **事後確率**（posterior）$P(H \mid D)$：データ D を見たあとの、仮説 H の確からしさ
- **周辺尤度**（エビデンス）$P(D)$：仮説について周辺化した、データそのものの起こりやすさ

ここで H と D は、第 7.2.1 項の A や B と同じく**標本空間 Ω の部分集合（事象）**である。「仮説」「データ」という呼び名は、ベイズの定理の中でその事象が果たす役割を表しているだけで、集合としての扱いは何も変わらない。したがって、ベイズの定理を使うときは、まず「何が Ω で、H と D はどの部分集合か」を決めなければならない。

検査の例で実際にやってみよう。集団から 1 人を無作為に選ぶ試行を考えると、1 人について「病気か健康か」と「陽性か陰性か」の 2 つの結果が定まるので、標本空間はその組

$$\Omega = \{\,\text{病}, \text{健}\,\} \times \{\,\text{陽}, \text{陰}\,\} = \{(\text{病}, \text{陽}),\ (\text{病}, \text{陰}),\ (\text{健}, \text{陽}),\ (\text{健}, \text{陰})\}$$

表 7.2　検査の例の標本空間 Ω の 4 つの結果と、その同時確率（括弧内は 10000 人あたりの人数、図 7.5 と同じ）。行が仮説 H（病気）と H^c（健康）、列がデータ D（陽性）と D^c（陰性）に対応する。

	D：陽性	D^c：陰性	計
H：病気	0.0099 (99 人)	0.0001 (1 人)	$P(H) = 0.01$ (100 人)
H^c：健康	0.0495 (495 人)	0.9405 (9405 人)	$P(H^c) = 0.99$ (9900 人)
計	$P(D) = 0.0594$ (594 人)	$P(D^c) = 0.9406$ (9406 人)	1 (10000 人)

表 7.3　検査の例（第 7.4.2 項）におけるベイズの定理の各項の対応。H は事象「病気」（仮説）、D は事象「陽性」（データ）で、値は表 7.2 から読み取れる。

名称	記号	検査の例での意味	値	値の根拠
事前確率	$P(H)$	病気である割合（有病率）	0.01	設定で与えられた。検査を受ける前の確率
尤度	$P(D \mid H)$	病気の人が陽性になる割合（感度）	0.99	設定で与えられた。病気と仮定したときの陽性の出やすさ
周辺尤度	$P(D)$	陽性になる割合	0.0594	全確率の定理で計算：$0.99 \times 0.01 + 0.05 \times 0.99$
事後確率	$P(H \mid D)$	陽性の人が病気である割合（答え）	0.167	ベイズの定理で計算：式 (7.11)

である（4 通りの結果）。知りたいが直接は見えないもの（病気かどうか）を仮説 H、実際に観測できたもの（陽性という結果）をデータ D とすると、

$$H = \text{「病気」} = \{(\text{病}, \text{陽}),\ (\text{病}, \text{陰})\}, \qquad H^c = \text{「健康」} = \{(\text{健}, \text{陽}),\ (\text{健}, \text{陰})\},$$
$$D = \text{「陽性」} = \{(\text{病}, \text{陽}),\ (\text{健}, \text{陽})\}, \qquad H \cap D = \text{「病気で陽性」} = \{(\text{病}, \text{陽})\}$$

である。これまで $P(\text{病気})$ と書いてきたのは $P(H)$ の略記であり、$P(\text{陽性} \mid \text{病気})$ は $P(D \mid H)$ の略記である。4 つの結果それぞれの確率（同時確率）を、表 7.1 と同じ形に並べたものが表 7.2 である。各セルの値は第 7.4.2 項の設定から乗法定理で求まる（例えば $P(H \cap D) = P(D \mid H)P(H) = 0.99 \times 0.01 = 0.0099$）。

この表の上で、式 (7.12) の 4 つの量は次のように読める。

- 事前確率 $P(H) = 0.01$ は、行 H の**周辺確率**（行の合計）。検査結果を見る前の、病気の割合そのもの
- 尤度 $P(D \mid H) = P(H \cap D)/P(H) = 0.0099/0.01 = 0.99$ は、**行 H の中で** D が占める割合。条件付き確率の定義 (7.4) そのものであり、「病気の人だけに世界を縮めて、陽性の割合を測る」
- 周辺尤度 $P(D) = 0.0099 + 0.0495 = 0.0594$ は、列 D の**周辺確率**（列の合計）。「周辺」という名前は、この周辺化（H と H^c について足す＝全確率の定理）から来ている
- 事後確率 $P(H \mid D) = P(H \cap D)/P(D) = 0.0099/0.0594 \approx 0.167$ は、**列 D の中で** H が占める割合。「陽性の人だけに世界を縮めて、病気の割合を測る」

尤度と事後確率は、同じ同時確率 $P(H \cap D) = 0.0099$ を、行の合計で割るか列の合計で割るかの違いである。どちらに当たるかは**条件記号 $\mid$ の向き**で見分けられる。尤度 $P(D \mid H)$ は「仮説を仮定してデータを見る」向き、事後確率 $P(H \mid D)$ は「データを見て仮説を判断する」向きである。以上をまとめたものが表 7.3 である。事前確率と尤度は問題の設定として**与えられる**量、周辺尤度と事後確率はそれらから**計算される**量であることにも注意する。

表には現れていないが、偽陽性率 $P(D \mid H^c) = 0.05$ も使っている。これは「対立仮説 H^c（健康）のもと

での尤度」であり、周辺尤度 $P(D)$ を全確率の定理で計算するときに、$P(H^c) = 0.99$ とともに分母の第 2 項として入っている。つまり、ベイズの定理の分母は「すべての仮説についての尤度 × 事前確率の和」である。

「尤」は「もっともらしい」と読む字であり、尤度は「データから見た仮説のもっともらしさ」を表す。ここで、尤度 $P(D \mid H)$ は**データ D を固定して仮説 H を動かす関数**として読むことに注意する。H について足し合わせても 1 になるとは限らない（例では $0.99 + 0.05 \neq 1$）ので、H についての確率分布ではない。

周辺尤度 $P(D)$ は、仮説 H によらない定数である。そのため、複数の仮説の事後確率を比べるだけなら分母は不要で、

$$P(H \mid D) \propto P(D \mid H)\, P(H) \tag{7.13}$$

と書くことが多い（$\propto$ は「比例する」）。**事後確率は、尤度と事前確率の積に比例する**。すべての仮説について右辺を計算し、合計が 1 になるように割れば事後確率が得られる。ベイズの定理を使う計算の大半は、この「掛けて、正規化する」の 2 段階である。

7.4.4 逐次的な更新

陽性と判定された人が、念のため同じ検査をもう一度受け、再び陽性になったとする。1 回目の陽性を事象 D_1（これまでの D）、2 回目の陽性を事象 D_2 とすると、知りたいのは $P(H \mid D_1 \cap D_2)$ である。2 回の検査結果は、病気の有無を条件として条件付き独立（第 7.3.4 項）であるとする。すなわち、病気かどうかが分かっていれば 1 回目の結果を知っても 2 回目の陽性の出やすさは変わらない：$P(D_2 \mid H \cap D_1) = P(D_2 \mid H) = 0.99$、$P(D_2 \mid H^c \cap D_1) = P(D_2 \mid H^c) = 0.05$。このとき、条件付き確率の定義 (7.4) から

$$P(H \mid D_1 \cap D_2) = \frac{P(H \cap D_1 \cap D_2)}{P(D_1 \cap D_2)} \tag{7.14}$$

である。分子と分母をそれぞれ、既に分かっている量で書き直す。

分子は、乗法定理 (7.5) を 2 回使って分解する。まず $H \cap D_1$ をひとまとまりの事象と見て D_2 を切り出し、次に $H \cap D_1$ を D_1 と H に分ける。

$$P(H \cap D_1 \cap D_2) = P(D_2 \mid H \cap D_1)\, P(H \cap D_1) = P(D_2 \mid H \cap D_1)\, P(H \mid D_1)\, P(D_1) \tag{7.15}$$

分母は、全確率の定理 (7.7) で H と H^c に場合分けし、各項を分子と同じように分解する。

$$\begin{aligned} P(D_1 \cap D_2) &= P(H \cap D_1 \cap D_2) + P(H^c \cap D_1 \cap D_2) \\ &= P(D_2 \mid H \cap D_1)\, P(H \mid D_1)\, P(D_1) + P(D_2 \mid H^c \cap D_1)\, P(H^c \mid D_1)\, P(D_1) \end{aligned} \tag{7.16}$$

式 (7.15) と (7.16) を式 (7.14) に代入すると、分子・分母に共通の $P(D_1)$ が約分されて

$$P(H \mid D_1 \cap D_2) = \frac{P(D_2 \mid H \cap D_1)\, P(H \mid D_1)}{P(D_2 \mid H \cap D_1)\, P(H \mid D_1) + P(D_2 \mid H^c \cap D_1)\, P(H^c \mid D_1)} \tag{7.17}$$

を得る。これを式 (7.11) の 1 行目と見比べると、尤度 $P(D \mid H)$ が $P(D_2 \mid H \cap D_1)$ に、事前確率 $P(H)$ が $P(H \mid D_1)$ に置き換わっただけで、形はベイズの定理そのものである。さらに条件付き独立の仮定で $P(D_2 \mid H \cap D_1) = 0.99$、$P(D_2 \mid H^c \cap D_1) = 0.05$ となるので、尤度は 1 回目と同じ値である。つまり、**1 回目の検査結果を見たあとの事後確率 $P(H \mid D_1) = 0.167$ を、2 回目にとっての事前確率として使えばよい**。式 (7.11) の計算で、事前確率 0.01 を $P(H \mid D_1) = 0.167$ に、$P(H^c) = 0.99$ を $P(H^c \mid D_1) = 1 - 0.167 = 0.833$ に置き換えるだけである。

$$P(H \mid D_1 \cap D_2) = \frac{0.99 \times 0.167}{\underbrace{0.99 \times 0.167}_{0.165} + \underbrace{0.05 \times 0.833}_{0.042}} = \frac{0.165}{0.207} \approx 0.80$$

1 回の陽性では 17% だった確率が、2 回目の陽性で 80% まで上がる。分母を見ると、今度は「病気で陽性」の項 0.165 が「健康なのに陽性」の項 0.042 を大きく上回っている。1 回目の陽性で事前確率が 0.01 から 0.167 に上がったため、2 回目では偽陽性が少数派になったのである。このように、**今日の事後確率が明日の事前確率になる**。データが届くたびに確信を少しずつ更新していくという見方は、第 5 回でデータが逐次的に届く場合に反復計算を使ったこと（第 5.1.1 項）と通じる。

2 回分のデータをまとめて「尤度 $P(D_1 \cap D_2 \mid H) = 0.99^2$、事前確率 0.01」として一度に計算しても、同じ 0.80 が得られる（演習問題 3）。更新の順序や分け方によらず、最後に得られる事後確率は同じである。

コラム：オッズで見るベイズの定理

2 つの仮説（病気か健康か）を比べるときは、確率の代わりに**オッズ**（odds）を使うとベイズの定理がさらに単純になる。オッズとは 2 つの確率の比である。例えば確率 0.2 はオッズ $0.2 : 0.8 = 1 : 4$、逆にオッズ $1 : 4$ は確率 $1/(1+4) = 0.2$ である。ベイズの定理を H（病気）と H^c（健康）のそれぞれについて書くと

$$P(H \mid D) = \frac{P(D \mid H)\,P(H)}{P(D)}, \qquad P(H^c \mid D) = \frac{P(D \mid H^c)\,P(H^c)}{P(D)}$$

である。辺々割ると、共通の分母 $P(D)$ が約分されて消え、

$$\underbrace{\frac{P(H \mid D)}{P(H^c \mid D)}}_{\text{事後オッズ}} = \underbrace{\frac{P(D \mid H)}{P(D \mid H^c)}}_{\text{尤度比}} \times \underbrace{\frac{P(H)}{P(H^c)}}_{\text{事前オッズ}}$$

となる。検査の例では、事前オッズは $1 : 99$、陽性の尤度比は $0.99/0.05 = 19.8$ なので、事後オッズは $19.8 : 99 = 1 : 5$、確率に直すと $1/6 \approx 0.167$ である。2 回目の陽性でさらに 19.8 倍され、オッズは $19.8 : 5 \approx 4 : 1$、確率は約 0.80 になる。**データは尤度比を掛けるという形で効く**。対数をとれば掛け算が足し算になり、「証拠の重み」を足し合わせていく見方になる。第 8 回のナイーブベイズ分類器は、単語ごとの対数尤度比を足し合わせて迷惑メールかどうかを判定する。

7.5 確率変数と確率分布

ここまでは「事象」の確率を扱ってきた。機械学習で扱う量の多くは、サイコロの目、ノイズ ε、学習したパラメータ $\hat{w}$ のように**数値**である。試行の結果に応じて値が決まる数値を**確率変数**（random variable）と呼び、大文字 X, Y で表す（計画行列 $\boldsymbol{X}$ は太字であり、確率変数 X とは区別する）。確率変数がとる具体的な値は小文字 x, y で表す。

7.5.1 離散確率変数

とりうる値が $x_1, x_2, \ldots$ のように数え上げられる確率変数を**離散確率変数**と呼ぶ。

定義：確率質量関数

離散確率変数 X について、各値 x をとる確率

$$p(x) = P(X = x) \tag{7.18}$$

を X の**確率質量関数**（probability mass function）と呼ぶ。$p(x) \geq 0$、$\sum_x p(x) = 1$ を満たす。

確率変数がどの値をどの確率でとるかの全体を、その**確率分布**（probability distribution）と呼ぶ。代表的な離散分布を挙げる。

- **ベルヌーイ分布**：$X \in \{0, 1\}$ で、$P(X = 1) = \theta$、$P(X = 0) = 1 - \theta$。まとめて $p(x) = \theta^x (1 - \theta)^{1-x}$ と書ける。コインの表裏、メールが迷惑か否か、2 クラス分類のラベルを表す
- **カテゴリ分布**：$X \in \{1, \ldots, K\}$ で、$P(X = k) = \theta_k$（$\sum_k \theta_k = 1$）。サイコロの目、K クラス分類のラベル、言語モデルが予測する次の単語を表す

7.5.2 連続確率変数

ノイズ ε や身長のように、実数の区間の値を連続的にとる確率変数を**連続確率変数**と呼ぶ。連続確率変数では、特定の 1 点 $X = x$ をとる確率は 0 である（身長がちょうど $170.000\cdots$ cm である確率は 0）。そこで、確率を「区間に入る確率」として扱う。

定義：確率密度関数

連続確率変数 X について、関数 $p(x) \geq 0$ が任意の区間 $[a, b]$ に対して

$$P(a \leq X \leq b) = \int_a^b p(x)\, dx \tag{7.19}$$

を満たすとき、$p(x)$ を X の**確率密度関数**（probability density function）と呼ぶ。$\int_{-\infty}^{\infty} p(x)\, dx = 1$ を満たす。

確率は密度関数のグラフの下の**面積**である。密度 $p(x)$ そのものは確率ではないので、1 を超えてもよい。例えば区間 $[0, 0.5]$ 上の一様分布（どの点も同じ起こりやすさ）の密度は、全体の面積が 1 になるように $p(x) = 2$ である（幅 $0.5 \times$ 高さ $2 = 1$、図 7.6 左）。このとき $P(0.1 \leq X \leq 0.3)$ は幅 $0.2 \times$ 高さ $2 = 0.4$ であり、確率はきちんと 1 以下になる。$p(x)\, dx$ が「x の近くの幅 dx の区間に入る確率」であり、密度とは「単位幅あたりの確率」である。以下では、離散の場合の和 $\sum_x$ を連続の場合は積分 $\int dx$ に読み替えれば、同じ公式が成り立つ。

7.5.3 同時分布・周辺分布・条件付き分布

2 つの確率変数 X, Y を同時に考えるときは、**同時分布** $p(x, y)$ を使う。第 7.2 節と第 7.3 節の公式は、事象を確率変数の値に置き換えてそのまま成り立つ。

$$p(x) = \sum_y p(x, y) \quad \left(\text{連続なら } \int p(x, y)\, dy\right) \qquad \text{（周辺化）} \tag{7.20}$$

$$p(y \mid x) = \frac{p(x, y)}{p(x)} \qquad \text{（条件付き分布）}$$

$$p(x, y) = p(y \mid x)\, p(x) \qquad \text{（乗法定理）}$$

$$p(x \mid y) = \frac{p(y \mid x)\, p(x)}{\sum_{x'} p(y \mid x')\, p(x')} \qquad \text{（ベイズの定理）} \tag{7.21}$$

X と Y が**独立**であるとは、すべての x, y について $p(x, y) = p(x)\, p(y)$ が成り立つことである。

第 1 回で汎化誤差を定義したときの「入力と出力の組 $(\boldsymbol{x}, y)$ が同時分布 $P(\boldsymbol{x}, y)$ に従う」とは、この意味である。乗法定理で $p(\boldsymbol{x}, y) = p(y \mid \boldsymbol{x})\, p(\boldsymbol{x})$ と分解すると、$p(\boldsymbol{x})$ は「どんな入力が現れるか」、$p(y \mid \boldsymbol{x})$ は「入

力 $\boldsymbol{x}$ のもとで出力がどうばらつくか」を表す。回帰や分類で学習したいのは、本質的には後者の条件付き分布である。第 8 回では、どちらの分解に注目するかによって、**生成モデル**と**判別モデル**という 2 つの立場が生まれることを見る。

7.5.4　正規分布

連続分布の中で最も重要なのが**正規分布**（ガウス分布）である。以下に出てくる確率密度関数は第 7.5.2 項の定義 (7.19) の意味であり、X が区間 $[a, b]$ に入る確率は密度の曲線の下の面積 $\int_a^b p(x)\,dx$ で与えられる（密度の値そのものは確率ではない）。

定義：正規分布

実数 μ と $\sigma > 0$ について、確率密度関数（第 7.5.2 項）

$$\mathcal{N}(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} \right) \tag{7.22}$$

をもつ分布を、平均 μ、分散 σ^2 の**正規分布**と呼び、$\mathcal{N}(\mu, \sigma^2)$ と書く。X がこの分布に従うことを $X \sim \mathcal{N}(\mu, \sigma^2)$ と書く。

式 (7.22) を部品に分けて読もう。指数の中の $-(x-\mu)^2/(2\sigma^2)$ は、$x = \mu$ のとき 0（最大）で、x が μ から離れるほど負に大きくなる。したがって $\exp(\cdot)$ は $x = \mu$ で最大値 1 をとり、離れるほど 0 に近づく。これが釣鐘型の正体である。σ が大きいほど「離れたときの減り方」が緩やかになり、山は低く幅広になる。前の係数 $1/\sqrt{2\pi\sigma^2}$ は x によらない定数で、全体の面積を 1 にするためのものである（正規化定数）。図 7.6 中央のように、正規分布は μ を中心とする左右対称の釣鐘型で、σ が幅を決める。平均から $\pm\sigma$ の範囲に約 68%、$\pm 2\sigma$ の範囲に約 95% の確率（面積）が集まる（図右）。σ が小さいと山が高くなり、密度は 1 を超える（図中央の赤い曲線、$\sigma = 0.5$ で最大値 0.80、$\sigma = 0.1$ なら 4.0）。

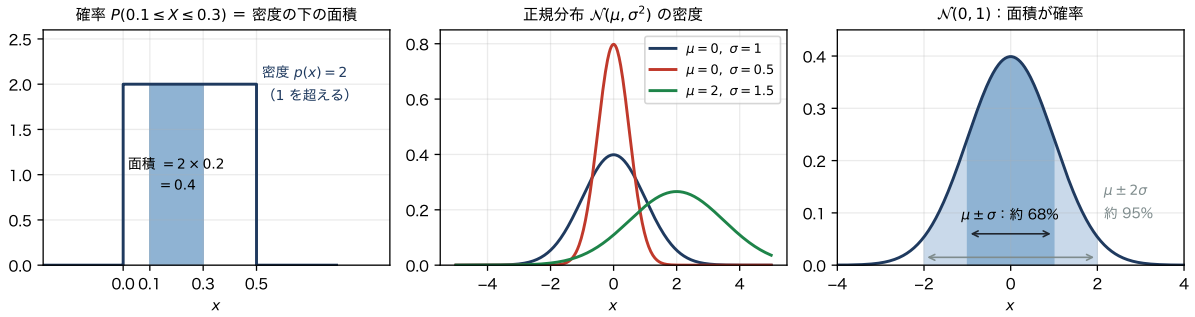


図 7.6　確率密度。左：区間 $[0, 0.5]$ 上の一様分布。密度は 2 で 1 を超えるが、確率は面積なので 1 以下である。中央：平均 μ と標準偏差 σ を変えた正規分布の密度。右：標準正規分布 $\mathcal{N}(0, 1)$ で、$\pm\sigma$ の範囲に約 68%、$\pm 2\sigma$ の範囲に約 95% の面積がある。

正規分布が機械学習で特別な理由は 2 つある。第一に、多数の小さな独立な要因が足し合わさった量は、近似的に正規分布に従う（**中心極限定理**）。測定誤差やノイズを正規分布でモデル化するのは、このためである。第二に、式 (7.22) の指数の中身は $(x-\mu)^2$、つまり**二乗誤差**である。密度の対数をとってみよう。log は積を

和に、$\log\exp(u) = u$ に、$\log(1/a) = -\log a$ に変える。

$$\begin{aligned}\log \mathcal{N}(x \mid \mu, \sigma^2) &= \log \frac{1}{\sqrt{2\pi\sigma^2}} + \log\exp\!\left(-\frac{(x-\mu)^2}{2\sigma^2}\right) \\ &= -\frac{1}{2}\log(2\pi\sigma^2) - \frac{(x-\mu)^2}{2\sigma^2}\end{aligned}$$

($\log\sqrt{a} = \frac{1}{2}\log a$ を使った)。符号を反転すれば

$$-\log \mathcal{N}(x \mid \mu, \sigma^2) = \frac{(x-\mu)^2}{2\sigma^2} + \frac{1}{2}\log(2\pi\sigma^2) \tag{7.23}$$

となる。第 2 項は x にも μ にもよらない定数なので、「正規分布の負の対数」は「二乗誤差 $\div 2\sigma^2$ ＋定数」である。密度が高い（起こりやすい）ほど負の対数は小さく、それは二乗誤差が小さいことと同じ、という対応になっている。この事実が、第 7.7.3 項で最小二乗法と確率をつなぐ鍵になる。

p 次元のベクトル $\boldsymbol{x} \in \mathbb{R}^p$ についての正規分布（**多変量正規分布**）は、平均ベクトル $\boldsymbol{\mu} \in \mathbb{R}^p$ と正定値な共分散行列 $\boldsymbol{\Sigma} \in \mathbb{R}^{p\times p}$ を用いて

$$\mathcal{N}(\boldsymbol{x} \mid \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{p/2}\det(\boldsymbol{\Sigma})^{1/2}} \exp\!\left(-\frac{1}{2}(\boldsymbol{x}-\boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\boldsymbol{x}-\boldsymbol{\mu})\right) \tag{7.24}$$

と定義される（$\boldsymbol{\Sigma}$ の意味は第 7.6.5 項で述べる）。指数の中身は 2 次形式なので、密度の等高線は $\boldsymbol{\Sigma}$ の固有ベクトルを軸とする楕円になる（第 5.3 節のコラムと同じ構造である）。特に $\boldsymbol{\Sigma} = \sigma^2\boldsymbol{I}$ のときは $\mathcal{N}(\boldsymbol{x} \mid \boldsymbol{0}, \sigma^2\boldsymbol{I}) \propto \exp\!\big(-\|\boldsymbol{x}\|^2/(2\sigma^2)\big)$ となり、等高線は原点を中心とする円になる。指数の中に $\|\boldsymbol{x}\|^2$ が現れていることに注目してほしい。第 9 回では、この形がリッジ回帰の罰則項 $\lambda\|\boldsymbol{w}\|^2$ の正体であることを見る。

7.6 期待値と分散

7.6.1 期待値

確率変数の「平均的な値」を表すのが期待値である。

定義：期待値

確率変数 X の**期待値**（expectation）を

$$\mathbb{E}[X] = \sum_x x\,p(x) \quad \left(\text{連続なら } \int x\,p(x)\,dx\right) \tag{7.25}$$

で定める。関数 g について $\mathbb{E}[g(X)] = \sum_x g(x)\,p(x)$ である。

期待値は「とりうる値を、その確率で重み付けして平均したもの」である。サイコロの目なら、各値の確率が $1/6$ なので

$$\mathbb{E}[X] = 1\cdot\tfrac{1}{6} + 2\cdot\tfrac{1}{6} + \cdots + 6\cdot\tfrac{1}{6} = \frac{21}{6} = 3.5$$

であり、正規分布 $\mathcal{N}(\mu, \sigma^2)$ の期待値は μ である。期待値 3.5 のように、確率変数が実際にはとらない値になることもある。図 7.7 左のように、数直線上の各値 x に重さ $p(x)$ を置いたときの**重心**が期待値である。

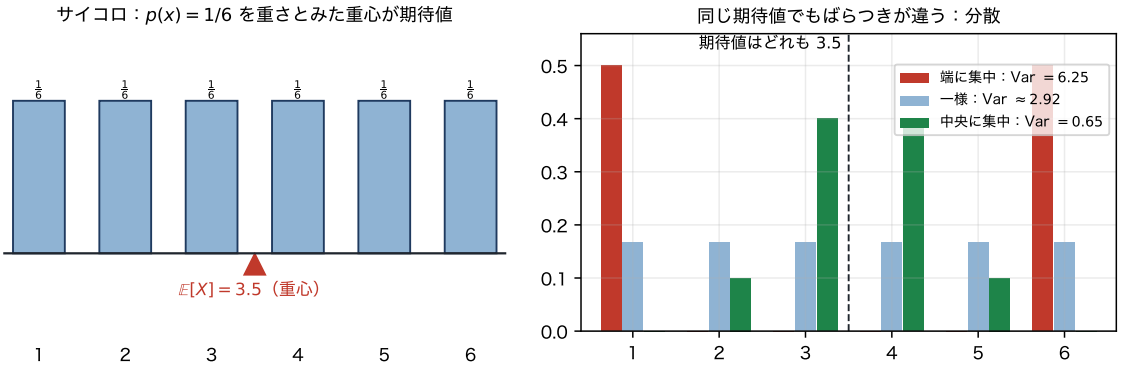


図 7.7　期待値と分散。左：各値に確率の重さを置いたときの重心が期待値 $\mathbb{E}[X]$。右：期待値が同じ 3.5 でも、値が端に集まる分布はばらつき（分散）が大きく、中央に集まる分布は小さい。

期待値は「何度もくり返したときの平均」とも一致する。同じ分布から独立に取り出した $X_1, \ldots, X_n$ の**標本平均** $\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ は、n を大きくすると $\mathbb{E}[X]$ に近づく（**大数の法則**、図 7.8 左）。第 1 回の経験損失 $L_D = \frac{1}{N}\sum_i L(y_i, h(\boldsymbol{x}_i))$ は、汎化誤差 $\mathbb{E}[L(y, h(\boldsymbol{x}))]$ を訓練データの標本平均で近似したものだったのである。近づく速さは次節で求める。

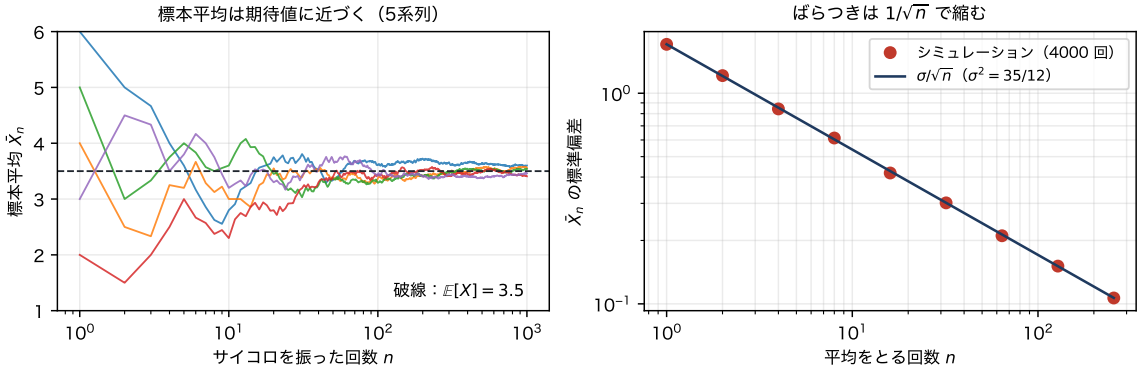


図 7.8　大数の法則。左：サイコロを振るたびに標本平均 $\bar{X}_n$ を計算した 5 つの系列。どの系列も期待値 3.5 に近づく。右：$\bar{X}_n$ の標準偏差は $\sigma/\sqrt{n}$ に従って縮む（式 (7.34)）。

7.6.2　期待値の線形性

期待値の最も重要な性質は、線形性である。

定理：期待値の線形性

確率変数 X, Y と定数 a, b, c について

$$\mathbb{E}[aX + bY + c] = a\,\mathbb{E}[X] + b\,\mathbb{E}[Y] + c \tag{7.26}$$

が成り立つ。X **と** Y **が独立でなくても成り立つ**。

■7.6.2.1　**証明**　離散の場合を示す。$aX+bY+c$ は (X,Y) の関数なので、その期待値は同時分布 $p(x,y)$ で重み付けした和である。

$$\mathbb{E}[aX+bY+c]=\sum_{x,y}(ax+by+c)\,p(x,y)$$

括弧を開いて、和を 3 つに分ける（定数 a,b,c は和の外に出せる）。

$$=a\sum_{x,y}x\,p(x,y)+b\sum_{x,y}y\,p(x,y)+c\sum_{x,y}p(x,y)$$

第 1 項では、x は y によらないので、先に y について足せる。周辺化 (7.20) より $\sum_y p(x,y)=p(x)$ なので

$$\sum_{x,y}x\,p(x,y)=\sum_x x\Big(\sum_y p(x,y)\Big)=\sum_x x\,p(x)=\mathbb{E}[X]$$

第 2 項も同様に $\sum_y y\,p(y)=\mathbb{E}[Y]$ になる。第 3 項は、同時確率をすべて足すと 1 なので $c\cdot 1=c$ である。3 つを合わせて $a\,\mathbb{E}[X]+b\,\mathbb{E}[Y]+c$ を得る。途中で使ったのは「和の分配」と「周辺化」だけで、独立性 $p(x,y)=p(x)p(y)$ はどこにも使っていない。■

■7.6.2.2　**応用：ミニバッチの勾配は不偏である**　第 5.5.2 項で、ミニバッチの勾配は「平均的には真の勾配に一致する」と述べ、証明を本章に先送りした。データ i の損失の勾配を $\boldsymbol{g}_i=\nabla\ell_i(\boldsymbol{w})$ とし、全データの平均を $\nabla L_D=\frac{1}{N}\sum_{i=1}^{N}\boldsymbol{g}_i$ とする。まず、ミニバッチが 1 件だけ（$|B|=1$）の場合を考える。N 件から 1 件を一様ランダムに選び、その番号を I とする。I は $\{1,\dots,N\}$ の値をとる確率変数で、$P(I=i)=1/N$ である。選ばれたデータの勾配 $\boldsymbol{g}_I$ は、I の値に応じて $\boldsymbol{g}_1,\dots,\boldsymbol{g}_N$ のどれかになる確率変数であり、その期待値は定義 (7.25)（$g(I)=\boldsymbol{g}_I$ の期待値）より

$$\mathbb{E}[\boldsymbol{g}_I]=\sum_{i=1}^{N}P(I=i)\,\boldsymbol{g}_i=\sum_{i=1}^{N}\frac{1}{N}\,\boldsymbol{g}_i=\nabla L_D$$

である（ベクトルの期待値は成分ごとにとる）。1 件だけでも、平均すれば真の勾配になる。ミニバッチ B が、このような選び方を $|B|$ 回くり返した $I_1,\dots,I_{|B|}$ からなるとすれば、線形性 (7.26) より

$$\mathbb{E}\Big[\frac{1}{|B|}\sum_{k=1}^{|B|}\boldsymbol{g}_{I_k}\Big]=\frac{1}{|B|}\sum_{k=1}^{|B|}\mathbb{E}[\boldsymbol{g}_{I_k}]=\frac{1}{|B|}\cdot|B|\cdot\nabla L_D=\nabla L_D \tag{7.27}$$

となる。ミニバッチの勾配の期待値は真の勾配に等しい。このように、期待値が推定したい量に一致する推定量を**不偏**（unbiased）であるという。重複を許さずに選ぶ（エポックごとにシャッフルする）場合も、各 i が B に含まれる確率が $|B|/N$ であることから同じ結論が得られる（演習問題 7）。

7.6.3　分散

期待値が「中心」を表すのに対し、分散は「ばらつき」を表す。

定義：分散と標準偏差

$\mu=\mathbb{E}[X]$ とおく。X の**分散**（variance）を

$$\mathrm{Var}[X]=\mathbb{E}\big[(X-\mu)^2\big] \tag{7.28}$$

で定め、その平方根 $\sqrt{\mathrm{Var}[X]}$ を**標準偏差**（standard deviation）と呼ぶ。

分散は「平均からのずれの二乗の期待値」である。二乗しているので単位も二乗になる（長さの分散は面積の単位）。元の単位に戻したものが標準偏差である。正規分布 $\mathcal{N}(\mu, \sigma^2)$ の分散は σ^2、標準偏差は σ であり、記号の意味が名前と一致している。図 7.7 右のように、期待値が同じでも分散は違いうる。分散を計算するときは、定義の中身 $(X-\mu)^2$ を展開して線形性を使うと楽になる。μ は定数であることに注意して

$$\begin{aligned}
\mathrm{Var}[X] &= \mathbb{E}[X^2 - 2\mu X + \mu^2] && \text{（展開）} \\
&= \mathbb{E}[X^2] - 2\mu\,\mathbb{E}[X] + \mu^2 && \text{（線形性：定数は外に出せ、定数の期待値は定数）} \\
&= \mathbb{E}[X^2] - 2\mu\cdot\mu + \mu^2 = \mathbb{E}[X^2] - \mu^2 && (\mathbb{E}[X]=\mu)
\end{aligned} \tag{7.29}$$

「二乗の平均から平均の二乗を引く」と覚える。サイコロでは $\mathbb{E}[X^2] = (1+4+9+16+25+36)/6 = 91/6$ なので $\mathrm{Var}[X] = 91/6 - (7/2)^2 = 91/6 - 49/4 = 182/12 - 147/12 = 35/12 \approx 2.92$ である。また、定数倍と定数の加算については

$$\mathrm{Var}[aX + c] = a^2\,\mathrm{Var}[X] \tag{7.30}$$

が成り立つ。実際、線形性より $\mathbb{E}[aX+c] = a\mu + c$ なので、平均からのずれは $(aX+c) - (a\mu+c) = a(X-\mu)$ であり、その二乗の期待値は $a^2\,\mathbb{E}[(X-\mu)^2] = a^2\,\mathrm{Var}[X]$ である。c だけずらしても平均からのずれは変わらず、a 倍するとずれが a 倍、その二乗が a^2 倍になる。第 6.4.3 項で「定数倍の分散は定数の二乗倍」として使ったのはこの性質である。

7.6.4 共分散と独立な和の分散

2 つの確率変数の和の分散を計算しよう。$\mu_X = \mathbb{E}[X]$、$\mu_Y = \mathbb{E}[Y]$ とおく。線形性より $\mathbb{E}[X+Y] = \mu_X + \mu_Y$ なので、$X+Y$ の平均からのずれは $(X+Y) - (\mu_X+\mu_Y) = (X-\mu_X) + (Y-\mu_Y)$ と、2 つのずれの和に書ける。$u = X - \mu_X$、$v = Y - \mu_Y$ と略記して、分散の定義に入れる。

$$\begin{aligned}
\mathrm{Var}[X+Y] &= \mathbb{E}\big[(u+v)^2\big] = \mathbb{E}\big[u^2 + 2uv + v^2\big] && \text{（展開）} \\
&= \mathbb{E}[u^2] + 2\,\mathbb{E}[uv] + \mathbb{E}[v^2] && \text{（線形性）} \\
&= \mathrm{Var}[X] + \mathrm{Var}[Y] + 2\,\mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big]
\end{aligned} \tag{7.31}$$

となる。$\mathbb{E}[u^2]$ と $\mathbb{E}[v^2]$ はそれぞれ X、Y の分散の定義そのものである。残った交差項に現れる量を**共分散**（covariance）と呼ぶ。

$$\mathrm{Cov}[X, Y] = \mathbb{E}\big[(X-\mu_X)(Y-\mu_Y)\big] = \mathbb{E}[XY] - \mu_X\mu_Y \tag{7.32}$$

共分散は、X が平均より大きいときに Y も平均より大きい傾向があれば正、逆の傾向があれば負になる。これを両者の標準偏差で割ったものが**相関係数**であり、第 5.3.4 項で標準化した特徴の相関 r として登場した。

X と Y が独立なら、$p(x,y) = p(x)p(y)$ より

$$\begin{aligned}
\mathbb{E}[XY] &= \sum_{x,y} xy\,p(x,y) = \sum_{x,y} xy\,p(x)\,p(y) \\
&= \sum_x x\,p(x)\Big(\sum_y y\,p(y)\Big) = \Big(\sum_x x\,p(x)\Big)\Big(\sum_y y\,p(y)\Big) = \mathbb{E}[X]\,\mathbb{E}[Y]
\end{aligned}$$

となる（**独立な量の積の期待値は期待値の積**）。2 つ目の等号で独立性を使い、3 つ目は $x\,p(x)$ が y によらないので y の和の外に出せる、という操作である。このとき式 (7.32) より $\mathrm{Cov}[X,Y] = \mathbb{E}[X]\mathbb{E}[Y] - \mu_X\mu_Y = 0$ なので、式 (7.31) の交差項が消えて $\mathrm{Var}[X+Y] = \mathrm{Var}[X] + \mathrm{Var}[Y]$ になる。3 つ以上の和でも同じで、

$(u_1 + \cdots + u_n)^2$ を展開すると各 u_i^2 と、相異なる組の積 $2u_iu_j$ が現れ、独立なら後者の期待値がすべて 0 になる。係数 a_i を付けた場合は式 (7.30) を併用すればよく、次の定理を得る。

定理：独立な確率変数の和の分散

$X_1, \ldots, X_n$ が互いに独立なら、定数 $a_1, \ldots, a_n$ について

$$\mathrm{Var}\Big[\sum_{i=1}^{n} a_i X_i\Big] = \sum_{i=1}^{n} a_i^2 \,\mathrm{Var}[X_i] \tag{7.33}$$

が成り立つ。**独立な量の和の分散は、分散の和**である。

期待値の線形性と違って、こちらは独立性（正確には共分散が 0 であること）が必要である。例えば $Y = X$ なら $\mathrm{Var}[X + Y] = \mathrm{Var}[2X] = 4\,\mathrm{Var}[X]$ であり、$2\,\mathrm{Var}[X]$ にはならない。

この定理から、いくつもの重要な事実がすぐに出てくる。

■7.6.4.1　標本平均のばらつき　同じ分布（分散 σ^2）から独立に取り出した n 個の標本平均 $\bar{X}_n = \frac{1}{n}X_1 + \cdots + \frac{1}{n}X_n$ は、式 (7.33) で $a_i = 1/n$、$\mathrm{Var}[X_i] = \sigma^2$ とおいた形なので

$$\mathrm{Var}[\bar{X}_n] = \sum_{i=1}^{n} \left(\frac{1}{n}\right)^2 \sigma^2 = n \cdot \frac{\sigma^2}{n^2} = \frac{\sigma^2}{n}, \qquad \text{標準偏差 } \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}} \tag{7.34}$$

となる。標本平均は n を増やすと期待値のまわりに集中し、その幅は $1/\sqrt{n}$ で縮む（図 7.8 右）。これが大数の法則の定量的な中身である。精度を 10 倍にするにはデータが 100 倍必要になる、という「$\sqrt{n}$ の法則」もここから来る。ミニバッチの勾配のばらつきも同様に $1/|B|$ に比例する（演習問題 7）。バッチサイズを 4 倍にすると勾配のノイズの標準偏差は半分になるが、計算量は 4 倍になる。

■7.6.4.2　第 6 回の 1 変数モデル　第 6.4.3 項の最小二乗解 $\hat{w} = w + \frac{1}{d}\sum_i x_i\varepsilon_i$（式 (6.20)）で、ノイズ ε_i は独立で平均 0、分散 σ^2 であった。線形性より $\mathbb{E}[\hat{w}] = w + \frac{1}{d}\sum_i x_i\,\mathbb{E}[\varepsilon_i] = w$、式 (7.33) で $a_i = x_i/d$ とすれば $\mathrm{Var}[\hat{w}] = \sum_i \frac{x_i^2}{d^2}\sigma^2 = \frac{\sigma^2}{d}$ である。第 6 回で「第 7 回で学ぶ性質」として先送りにした計算は、これで完結する。

7.6.5　共分散行列

ベクトル $\boldsymbol{x} = (X_1, \ldots, X_p)^\top$ の値をとる確率変数（**確率ベクトル**）について、平均ベクトル $\boldsymbol{\mu} = \mathbb{E}[\boldsymbol{x}]$（成分ごとの期待値）と**共分散行列**

$$\boldsymbol{\Sigma} = \mathrm{Cov}[\boldsymbol{x}] = \mathbb{E}\big[(\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^\top\big] \in \mathbb{R}^{p \times p} \tag{7.35}$$

を定める。(j, k) 成分は $\mathrm{Cov}[X_j, X_k]$、対角成分は各成分の分散である。共分散行列は対称であり、さらに**半正定値**である。実際、任意の定数ベクトル $\boldsymbol{a} \in \mathbb{R}^p$ について、内積 $\boldsymbol{a}^\top\boldsymbol{x}$ は 1 次元の確率変数であり、その平

均は線形性より $\boldsymbol{a}^\top \boldsymbol{\mu}$ である。よって分散は

$$\begin{aligned}
\mathrm{Var}[\boldsymbol{a}^\top \boldsymbol{x}] &= \mathbb{E}\big[(\boldsymbol{a}^\top(\boldsymbol{x}-\boldsymbol{\mu}))^2\big] \\
&= \mathbb{E}\big[\boldsymbol{a}^\top(\boldsymbol{x}-\boldsymbol{\mu})\,(\boldsymbol{x}-\boldsymbol{\mu})^\top \boldsymbol{a}\big] && \text{（スカラー } s=\boldsymbol{a}^\top\boldsymbol{d} \text{ は } s^2 = s\,s^\top = \boldsymbol{a}^\top\boldsymbol{d}\,\boldsymbol{d}^\top\boldsymbol{a}\text{）} \\
&= \boldsymbol{a}^\top\, \mathbb{E}\big[(\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^\top\big]\, \boldsymbol{a} && \text{（定数 } \boldsymbol{a} \text{ は期待値の外に出せる）} \\
&= \boldsymbol{a}^\top \boldsymbol{\Sigma}\, \boldsymbol{a} \geq 0
\end{aligned}$$

となる。最後の不等号は、分散が二乗の期待値なので負にならないことによる。これは第 4 回で学んだ半正定値の定義（任意の $\boldsymbol{a}$ で $\boldsymbol{a}^\top\boldsymbol{\Sigma}\boldsymbol{a} \geq 0$）そのものである。データ $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_N$ から計算した標本の共分散行列は、平均を引いた計画行列 $\boldsymbol{X}_c$ を使って $\frac{1}{N}\boldsymbol{X}_c^\top \boldsymbol{X}_c$ と書ける。付録 A.3 の白色化で使った $\boldsymbol{\Sigma}$ はこれであり、その固有ベクトルが「データが最も散らばる向き」を表すのは、$\boldsymbol{a}^\top\boldsymbol{\Sigma}\boldsymbol{a}$ が向き $\boldsymbol{a}$ への射影の分散だからである。

7.7 パラメータを確率で表す：ベイズ推定の入口

最後に、ベイズの定理を機械学習の問題、すなわち**データからパラメータを推定する**問題に使ってみよう。そのために、パラメータの扱い方を一つ変える。

考え方：パラメータ自身を確率変数とみなす

第 1 回から第 6 回までは、パラメータ θ（あるいは $\boldsymbol{w}$）は「未知だが固定された一つの数」であり、データから推定値 $\hat{\theta}$ を求めてきた。ランダムなのはデータの側だけであった。

ベイズ推定では、**パラメータ θ 自体を確率変数とみなす**。これは「θ の値がくり返しのたびに変わる」という意味ではない。コインの偏りは一つに決まっているが、**私たちはその値を知らない**。第 7.1.2 項の「信念の度合いとしての確率」を使い、この**知識の不確かさ**（第 7.1.1 項の 3 番目の不確かさ）を θ の確率分布で表すのである。したがって $p(\theta)$ は「θ がどの値である可能性がどれくらい高いと考えているか」を表す密度であり、例えば「θ が 0.6 と 0.8 の間にある」と考える確率は $\int_{0.6}^{0.8} p(\theta)\,d\theta$ である。

記法について一言注意しておく。第 7.5 節の約束では、確率変数は大文字、その値は小文字で書き分けるので、パラメータを確率変数とみなすなら Θ と書き、その密度を $p_\Theta(\theta)$、「Θ が $[a,b]$ に入る確率」を $P(a \leq \Theta \leq b) = \int_a^b p_\Theta(\theta)\,d\theta$ と書くのが筋である。しかし慣例では、確率変数と値の両方に同じ小文字 θ を使い、密度を単に $p(\theta)$ と書く。本書もこの慣例に従う。同様に、$p(D \mid \theta)$ は「確率変数 θ が特定の値をとったという条件のもとでのデータ D の確率」、$p(\theta \mid D)$ は「データ D を条件とした確率変数 θ の条件付き分布」であり、いずれも第 7.5.3 項の条件付き分布の記法である。θ が式の中で「確率変数」として現れているのか「ある一つの値」として現れているのかは、文脈で読み分けてほしい。

7.7.1 コインの偏りを推定する

表の出る確率が θ のコインがある。θ は未知で、0 から 1 のどこかにある。このコインを n 回投げて、表が k 回出た（データ D）。θ について何が言えるか。

各回の結果はベルヌーイ分布に従い、θ を条件として互いに独立とする。例えば 3 回投げて「表、表、裏」の順に出る確率は、独立性（式 (7.9) を 3 回分に広げたもの）より各回の確率の積で $\theta \times \theta \times (1-\theta) = \theta^2(1-\theta)$ である。一般に、特定の順序で表 k 回、裏 $n-k$ 回が出る確率は、θ を k 個、$(1-\theta)$ を $n-k$ 個掛けて

$$p(D \mid \theta) = \theta^k (1-\theta)^{n-k} \tag{7.36}$$

である（図 7.9 左）。

式 (7.36) を**尤度**と呼ぶ理由を、第 7.4.3 項の定義に戻って確かめよう。尤度とは「仮説 H が正しいとしたとき、観測されたデータ D がどの程度起こりやすいか」$P(D \mid H)$ であった。コインの問題では、仮説は「表の出る確率は θ である」という主張であり、θ の値ごとに一つの仮説がある（0 から 1 まで連続無限個の仮説の族）。データ D は実際に観測した表裏の列である。式 (7.36) はまさに「θ を仮定したときに D が起こる確率」$p(D \mid \theta)$ を計算しているので、検査の例の $P(D \mid H) = P(\text{陽性} \mid \text{病気})$ と同じ役割、すなわち尤度である。違いは、仮説が「病気か健康か」の 2 つではなく、θ という連続な値で指定されることだけである。

同じ式 $\theta^k(1-\theta)^{n-k}$ には 2 通りの読み方がある（図 7.9 中央・右）。θ を固定して D を動かせば、起こりうる結果（3 回なら $2^3 = 8$ 通り）の確率分布であり、全部足すと 1 になる。逆に、観測された D（つまり n と k）を固定して θ を動かせば、θ の関数になる。これを**尤度関数**と呼び、$L(\theta) = p(D \mid \theta)$ と書く。$\theta = 0.7$ なら「表、表、裏」の尤度は $0.7^2 \times 0.3 = 0.147$、$\theta = 0.5$ なら 0.125、$\theta = 0.2$ なら 0.032 で、このデータは $\theta = 0.7$ のもとで最も起こりやすい（最大は $\theta = 2/3$）。第 7.4.3 項で注意したように、尤度関数は θ についての確率分布ではない。実際 $\int_0^1 \theta^2(1-\theta)\,d\theta = 1/12$ であり、面積は 1 にならない。なお、表裏の順序を区別せず「n 回中 k 回が表」という事象をデータと考えると、順序の数 $\binom{n}{k}$ が掛かるが、これは θ によらない定数なので、θ の関数としての形（したがって以下の議論）は変わらない。

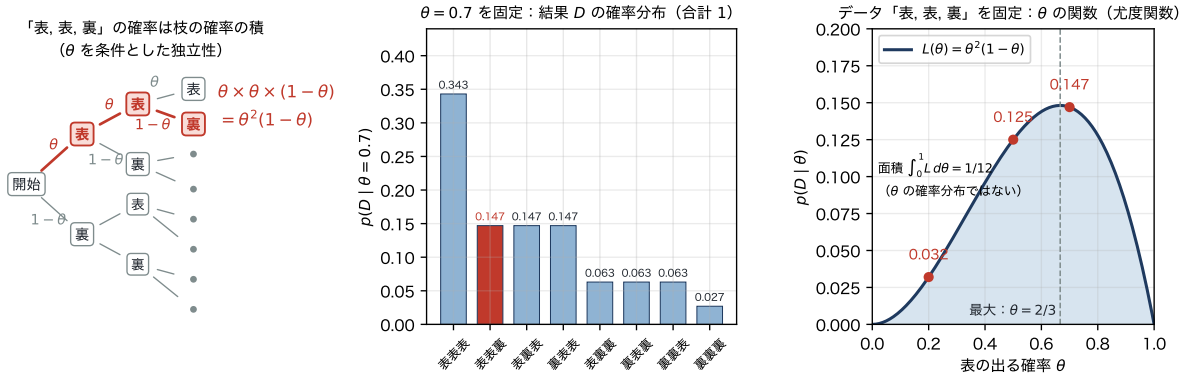


図 7.9　式 (7.36) が尤度である理由。左：3 回投げて「表、表、裏」が出る確率は、θ を条件とした独立性により、枝の確率の積 $\theta^2(1-\theta)$ である。中央：$\theta = 0.7$ を固定すると、8 通りの結果の確率分布になる（合計 1）。右：観測された「表、表、裏」を固定して θ を動かすと、θ の関数（尤度関数 $L(\theta) = \theta^2(1-\theta)$）になる。$\theta = 0.2, 0.5, 0.7$ での値を点で示す。面積は $1/12$ で、θ の確率分布ではない。

ここで、本節冒頭の考え方に従って θ を確率変数とみなし、データを見る前の θ についての知識を、区間 $[0,1]$ 上の確率密度 $p(\theta)$（**事前分布**）で表す。$p(\theta)$ は、θ の各値をどの程度確からしいと考えているかの分布である。特に何も知らなければ、どの値も同程度に確からしいとして一様分布 $p(\theta) = 1$ とするのが自然である。ベイズの定理 (7.21) より、データを見たあとの**事後分布**は

$$p(\theta \mid D) = \frac{p(D \mid \theta)\,p(\theta)}{\int_0^1 p(D \mid \theta')\,p(\theta')\,d\theta'} \propto \theta^k(1-\theta)^{n-k}\,p(\theta) \tag{7.37}$$

である。分母は θ について積分し終わっているので、θ によらない定数である。したがって事後分布の**形**は分子だけで決まり、分母は「全体の面積を 1 にする」ための正規化定数にすぎない。一様な事前分布 $p(\theta) = 1$ なら、事後分布は尤度関数 $\theta^k(1-\theta)^{n-k}$ を面積 1 に正規化したものである。例えば $n = 3$、$k = 2$ なら $p(\theta \mid D) \propto \theta^2(1-\theta)$ で、$\theta = 2/3$ で最大になる。

式 (7.37) は n 回分をまとめて計算しているが、第 7.4.4 項と同じく、**1 回投げるごとに更新する**こともできる。i 回目の結果を x_i（表なら 1、裏なら 0）、i 回目までの結果をまとめて $x_{1:i} = (x_1, \ldots, x_i)$ と書く。各回は θ を条件として独立なので、i 回目の尤度は過去の結果によらず $p(x_i \mid \theta, x_{1:i-1}) = p(x_i \mid \theta)$ であり、表なら θ、裏なら $1-\theta$ である。ベイズの定理を、$i-1$ 回目までの事後分布を事前分布として適用すると

$$p(\theta \mid x_{1:i}) \propto p(x_i \mid \theta)\, p(\theta \mid x_{1:i-1}) \tag{7.38}$$

となる。**今回の尤度を掛けて、面積が 1 になるように正規化する**、の繰り返しである。「表、表、裏」の例を一様な事前分布 $p(\theta) = 1$ から始めて追うと

1 回目（表）： $p(\theta \mid x_{1:1}) \propto \theta \times 1 = \theta$, $\displaystyle\int_0^1 \theta\, d\theta = \tfrac{1}{2} \;\Rightarrow\; 2\theta$

2 回目（表）： $p(\theta \mid x_{1:2}) \propto \theta \times 2\theta \propto \theta^2$, $\displaystyle\int_0^1 \theta^2\, d\theta = \tfrac{1}{3} \;\Rightarrow\; 3\theta^2$

3 回目（裏）： $p(\theta \mid x_{1:3}) \propto (1-\theta) \times 3\theta^2 \propto \theta^2(1-\theta)$, $\displaystyle\int_0^1 \theta^2(1-\theta)\, d\theta = \tfrac{1}{12} \;\Rightarrow\; 12\theta^2(1-\theta)$

（$\Rightarrow$ の右は、積分値で割って面積を 1 にした事後分布）となる。3 回目の結果は、式 (7.37) で $n=3$、$k=2$ として一度に計算した $\theta^2(1-\theta)$ の正規化と一致する。掛け算の順序は結果に影響しないので、1 回ずつ更新しても、まとめて更新しても、同じ事後分布に到達する。図 7.10 は、この更新を最初の 6 回について描いたものである。各パネルで、灰色の破線（前回の事後分布＝今回の事前分布）に赤の点線（今回の尤度 θ または $1-\theta$）を掛けて正規化したものが、青の実線（今回の事後分布）である。表が出ると分布は右（θ の大きい方）へ、裏が出ると左へ押され、回を重ねるごとに幅が狭くなっていく。

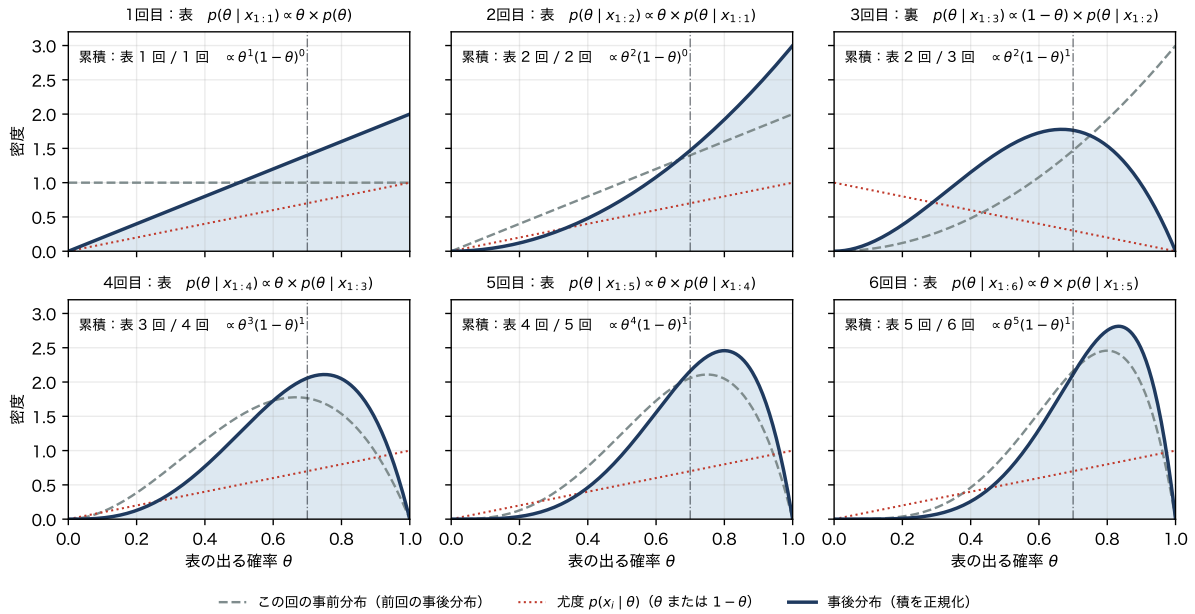


図 7.10　1 回投げるごとの事後分布の更新（式 (7.38)）、一様な事前分布から開始、真の値 $\theta = 0.7$ のコイン）。各パネルは、前回の事後分布（灰の破線）に今回の尤度（赤の点線、表なら θ、裏なら $1-\theta$）を掛けて正規化し、今回の事後分布（青の実線）を得る様子。左上の「累積」は、ここまでの結果をまとめて計算した場合の式で、1 回ずつ更新した結果と一致する。縦の一点鎖線は真の値 0.7。

図 7.11 は、この更新を続け、真の値 $\theta = 0.7$ のコインを投げ続けたときの事後分布の変化である。左の一様な事前分布から始めると、3 回（表 2 回）では事後分布はまだ広く、θ についてほとんど何も言えない。10 回、30 回、100 回と投げるにつれて、事後分布は真の値 0.7 のまわりに鋭く集中していく。**データが増えるほど、パラメータについての不確かさが減る**ことが、分布の幅として目に見える。

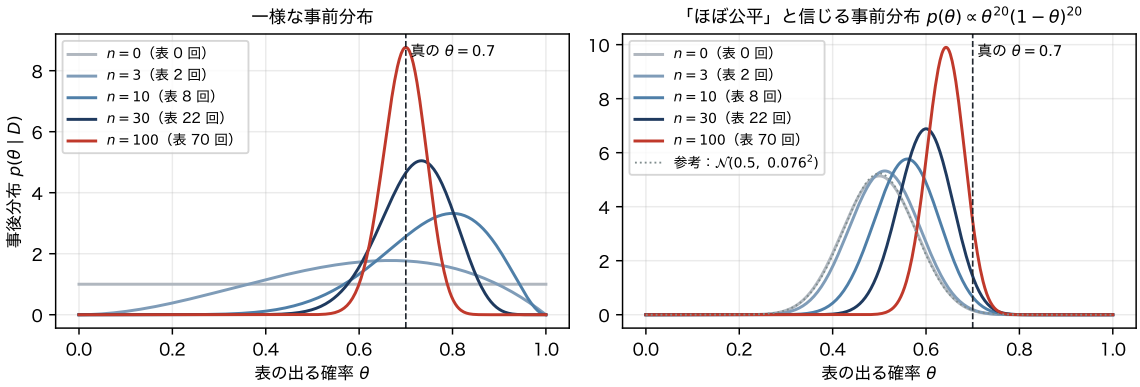


図 7.11　表の出る確率 θ の事後分布（真の値 0.7 のコインを n 回投げた後）。左：一様な事前分布から始めた場合。右：$\theta \approx 0.5$ を強く信じる事前分布 $p(\theta) \propto \theta^{20}(1-\theta)^{20}$（0.5 を中心とする釣鐘型、点線は参考の正規分布 $\mathcal{N}(0.5, 0.076^2)$）から始めた場合。データが少ないうちは事前分布に引っ張られるが、データが増えると真の値に近づく。

右は「このコインはほぼ公平なはずだ」と強く信じる事前分布から始めた場合である。ここでは事前分布として

$$p(\theta) \propto \theta^{20}(1-\theta)^{20}$$

を用いた。これは $\theta = 0.5$ を中心とする左右対称の釣鐘型で、平均 0.5、標準偏差約 0.076 であり、正規分布 $\mathcal{N}(0.5, 0.076^2)$ とほとんど同じ形をしている（図右の点線）。正規分布そのものを使わないのは、θ が $[0,1]$ の外の値をとることはないので、$[0,1]$ の外に確率を置かない分布が望ましいからである。この形は尤度 $\theta^k(1-\theta)^{n-k}$ と同じ形をしており、「このコインを事前に 40 回投げて表 20 回・裏 20 回を見た」のと同じ知識に相当する（**ベータ分布**と呼ばれる。詳しくは第 9 回で扱う）。事前分布と尤度の形が同じなので、事後分布も $\theta^{20+k}(1-\theta)^{20+n-k}$ という同じ形になり、事前分布の「40 回分」とデータの「n 回分」が足し合わさる。

データが少ないうちは、事後分布は事前分布の 0.5 付近にとどまり、データに引っ張られにくい。100 回投げても、ピークは真の値 0.7 より 0.5 寄りの 0.64 付近にある。事前分布は「データが少ないときに推定を一定の方向に引き寄せる」働きをし、その影響はデータが増えるにつれて薄れる。この「引き寄せ」は、第 6 回の正則化が推定値を $\mathbf{0}$ の方向に縮めたこととよく似ている。

7.7.2　事後分布から一つの値を選ぶ

事後分布はパラメータについての知識をまるごと表すが、予測などに使うために一つの値を選びたいこともある。代表的な選び方は 3 つある。一様な事前分布の場合に計算すると次のようになる（演習問題 10）。

- **最尤推定**（maximum likelihood estimation, MLE）：尤度 $p(D \mid \theta)$ を最大にする θ。事前分布を使わない。コインの例では $\hat{\theta}_{\mathrm{MLE}} = k/n$（表が出た割合）
- **最大事後確率推定**（maximum a posteriori, MAP）：事後分布 $p(\theta \mid D)$ を最大にする θ。一様な事前

分布では尤度の最大化と同じになり、k/n である

- **事後平均**：事後分布の期待値 $\mathbb{E}[\theta \mid D] = \int_0^1 \theta\, p(\theta \mid D)\, d\theta$。一様な事前分布では $(k+1)/(n+2)$ となる（ラプラスの継起則）

例えば 3 回投げて 3 回とも表なら、最尤推定は $\hat{\theta} = 1$、すなわち「このコインは必ず表が出る」と結論する。これはたった 3 回のデータに対して明らかに言い過ぎであり、第 1 回で見た過学習と同じ現象である。事後平均は $(3+1)/(3+2) = 0.8$ であり、データの割合 1 を 1/2 の方向へ少し引き戻している。事前分布が、少ないデータへの過剰な適合を和らげているのである。

7.7.3 最小二乗法を確率の言葉で読む（予告）

本章の道具を使うと、第 4 回の最小二乗法を確率の言葉で読み直せる。線形モデルの出力に正規分布のノイズが乗っている、すなわち

$$y_i = \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i + \varepsilon_i, \qquad \varepsilon_i \sim \mathcal{N}(0, \sigma^2) \quad (\text{互いに独立})$$

と仮定する。y_i は「定数 $\boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i$ に正規分布のノイズを足したもの」なので、平均 $\boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i$、分散 σ^2 の正規分布に従う。すなわち $p(y_i \mid \boldsymbol{w}) = \mathcal{N}(y_i \mid \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i, \sigma^2)$ である。N 件は独立なので、データ全体の尤度は各件の密度の積になる。

$$p(D \mid \boldsymbol{w}) = \prod_{i=1}^{N} \mathcal{N}(y_i \mid \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i, \sigma^2)$$

積のままでは扱いにくいので負の対数をとる。log は積を和に変えるので、各項に式 (7.23)（$x \to y_i$、$\mu \to \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i$）を使って

$$\begin{aligned} -\log p(D \mid \boldsymbol{w}) &= \sum_{i=1}^{N} \Big[-\log \mathcal{N}(y_i \mid \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i, \sigma^2) \Big] = \sum_{i=1}^{N} \left[\frac{(y_i - \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i)^2}{2\sigma^2} + \frac{1}{2}\log(2\pi\sigma^2) \right] \\ &= \frac{1}{2\sigma^2} \sum_{i=1}^{N} (y_i - \boldsymbol{w}^\top \tilde{\boldsymbol{x}}_i)^2 + \frac{N}{2}\log(2\pi\sigma^2) = \frac{1}{2\sigma^2} \|\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}\|^2 + \text{定数} \end{aligned} \tag{7.39}$$

となる。最後は、N 個の二乗誤差の和が残差ベクトル $\boldsymbol{y} - \boldsymbol{X}\boldsymbol{w}$ のノルムの二乗であること（第 3 回）を使った。$\boldsymbol{w}$ によらない第 2 項は、最小化には関係ない定数である。**尤度を最大にすることは、二乗誤差を最小にすることと同じである**。第 4 回で「なんとなく」選んだ二乗誤差は、「ノイズが正規分布に従う」という仮定のもとでの最尤推定だったのである。第 8 回では、この最尤推定と最大事後確率推定を分類問題に用いる。第 9 回では、パラメータに正規分布の事前分布 $\boldsymbol{w} \sim \mathcal{N}(\boldsymbol{0}, \tau^2 \boldsymbol{I})$ を置くと、最大事後確率推定がちょうどリッジ回帰になり、$\lambda = \sigma^2/\tau^2$ という意味をもつことを示す。本章の図 7.11 右で見た「事前分布による引き寄せ」が、正則化の正体である。

7.8 まとめ

- 機械学習には、データのノイズ、データの取り方、パラメータについての知識という 3 種類の不確かさがある。確率は頻度としても信念の度合いとしても読めるが、**計算規則は同じ**である
- 確率は 3 つの公理（非負性、$P(\Omega) = 1$、排反な事象の加法性）で定義され、余事象 $P(A^c) = 1 - P(A)$、加法定理 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$ などはすべて公理から導かれる

- **条件付き確率** $P(A \mid B) = P(A \cap B)/P(B)$ は、標本空間を B に縮めて測った確率。$P(A \mid B)$ と $P(B \mid A)$ は別物である
- **乗法定理** $P(A \cap B) = P(A \mid B)P(B)$、**全確率の定理** $P(A) = \sum_k P(A \mid B_k)P(B_k)$、**独立** $P(A \cap B) = P(A)P(B)$。周辺化は「不要な変数について足して消す」操作
- **ベイズの定理** $P(H \mid D) = P(D \mid H)P(H)/P(D)$：事後確率 $\propto$ 尤度 $\times$ 事前確率。原因から結果への確率を、結果から原因への確率に変換する。検査の例のように、結論は事前確率（有病率）に強く依存する。今日の事後確率が明日の事前確率になる
- 確率変数の分布は、離散なら確率質量関数、連続なら確率密度関数で表す。密度の面積が確率である。**正規分布** $\mathcal{N}(\mu, \sigma^2)$ の負の対数は二乗誤差＋定数
- **期待値**は確率で重み付けした平均で、**線形性**は独立性なしに成り立つ。ミニバッチの勾配は期待値が真の勾配に等しい（不偏）
- **分散** $\mathrm{Var}[X] = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2$。独立な量の和の分散は分散の和で、標本平均の分散は σ^2/n（ばらつきは $1/\sqrt{n}$ で縮む）。共分散行列は対称・半正定値
- パラメータを確率変数とみなすと、ベイズの定理で**事後分布**が得られ、データが増えるほど集中する。最尤推定・最大事後確率推定・事後平均。ノイズが正規分布なら**最尤推定＝最小二乗法**

本章で、確率の言葉と、ベイズの定理という「データで知識を更新する」ための式が揃った。次回（第 8 回）は、ベイズの定理を分類問題に適用した**ナイーブベイズ分類器**を作り、最尤推定と最大事後確率推定を本格的に扱う。本章の迷惑メールの表（表 7.1）が、そこでの出発点になる。

7.9 演習問題

1. **公理から導く**　確率の公理だけを用いて次を示せ。
   (a) $A \subseteq B$ ならば $P(A) \le P(B)$
   (b) 加法定理 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$（本文の証明を、3 つの排反な部分への分割を明示して書け）
   (c) $P(A \cup B) \le P(A) + P(B)$
   (d) $P(B) > 0$ を固定したとき、$Q(A) = P(A \mid B)$ で定めた関数 Q が確率の公理の 3 条件を満たすこと
2. **同時確率の表**　ある大学の学生 200 人について、「朝食を食べるか」と「1 限の講義に出席したか」を調べた結果が次の表である。

	出席した	欠席した
朝食を食べる	90	30
朝食を食べない	40	40

   無作為に 1 人を選ぶとき、次を求めよ。
   (a) 周辺確率 $P(\text{朝食を食べる})$ と $P(\text{出席した})$
   (b) 条件付き確率 $P(\text{出席した} \mid \text{朝食を食べる})$ と $P(\text{朝食を食べる} \mid \text{出席した})$。両者が異なる理由を述べよ
   (c)「朝食を食べる」と「出席した」は独立か。式 (7.8) を用いて判定せよ
   (d) (b) の 2 つの値と (a) の周辺確率が、ベイズの定理を満たしていることを確かめよ

(e) この表から「朝食を食べると出席するようになる」と結論してよいか。理由とともに述べよ

3. **検査とベイズの定理**　感度 98%、偽陽性率 2% の検査がある。
   (a) 有病率 0.1% の集団で陽性と判定された人が、本当に病気である確率を求めよ
   (b) 有病率が 10% の集団ではどうか。(a) と比べ、結果が大きく変わる理由を自然頻度（10000 人あたりの人数）を使って説明せよ
   (c) (a) の集団で、陽性の人がもう一度検査を受けて再び陽性だった。2 回の結果は病気の有無を条件として独立とする。1 回目の事後確率を事前確率として更新する方法と、尤度 0.98^2 と 0.02^2 を使って一度に計算する方法の両方で、病気である確率を求め、一致することを確かめよ
   (d) オッズの形（本文のコラム）で (a) と (c) を計算し直せ
4. **全確率の定理**　ある部品を工場 B_1, B_2, B_3 がそれぞれ $50\%, 30\%, 20\%$ の割合で生産しており、各工場の不良率は $1\%, 2\%, 3\%$ である。
   (a) 無作為に選んだ部品が不良品である確率を求めよ
   (b) 選んだ部品が不良品だった。それが工場 B_3 で作られた確率を求めよ
   (c) (b) の値は、B_3 の生産割合 20% より大きいか小さいか。その理由を述べよ
5. **モンティ・ホール問題**　3 つの扉のうち 1 つの後ろに賞品がある（どの扉かは等確率）。あなたが扉 1 を選ぶと、賞品の位置を知っている司会者が、残りの 2 つのうち賞品のない扉を 1 つ開ける（扉 2 と扉 3 のどちらにも賞品がないときは、等確率でどちらかを開ける）。司会者は扉 3 を開けた。扉 1 のままにするか、扉 2 に変えるか。
   (a) 賞品が扉 j にあるという仮説を H_j（$j = 1, 2, 3$）とし、事前確率 $P(H_j)$ を書け
   (b)「司会者が扉 3 を開ける」というデータ D について、尤度 $P(D \mid H_1)$、$P(D \mid H_2)$、$P(D \mid H_3)$ を求めよ
   (c) ベイズの定理で事後確率 $P(H_1 \mid D)$、$P(H_2 \mid D)$ を求め、扉を変えるべきかどうか答えよ
6. **期待値と分散**　サイコロを振ったときの目を X とする。
   (a) $\mathbb{E}[X]$、$\mathbb{E}[X^2]$、$\mathrm{Var}[X]$ を求めよ
   (b) 2 つのサイコロを独立に振ったときの目の和 $S = X_1 + X_2$ について、$\mathbb{E}[S]$ と $\mathrm{Var}[S]$ を求めよ
   (c) $\mathrm{Var}[2X]$ を求め、(b) の $\mathrm{Var}[S]$ と比べよ。どちらも期待値は 7 なのに分散が異なる理由を述べよ
   (d) 式 (7.29) を、期待値の線形性を用いて導け
7. **ミニバッチの勾配**　第 5.5.2 項の記号で、N 個の勾配 $\boldsymbol{g}_1, \dots, \boldsymbol{g}_N$ の平均を $\bar{\boldsymbol{g}} = \nabla L_D$ とする。
   (a) N 件から重複を許さずに $|B|$ 件を選ぶとき（すべての選び方が等確率）、各データ i が B に含まれる確率が $|B|/N$ であることを示せ
   (b) (a) を用いて、ミニバッチの勾配 $\frac{1}{|B|}\sum_{i \in B} \boldsymbol{g}_i$ の期待値が $\bar{\boldsymbol{g}}$ であることを示せ（ヒント：$\sum_{i \in B} \boldsymbol{g}_i = \sum_{i=1}^{N} \mathbf{1}[i \in B]\, \boldsymbol{g}_i$ と書き、指示関数 $\mathbf{1}[i \in B]$ の期待値を使う）
   (c) 重複を許して 1 件ずつ独立に $|B|$ 回選ぶ場合を考える。1 次元の場合（g_i がスカラー）に、$\sigma_g^2 = \frac{1}{N}\sum_i (g_i - \bar{g})^2$ とおいて、ミニバッチの勾配の分散が $\sigma_g^2/|B|$ であることを示せ
   (d) バッチサイズを 32 から 128 に増やすと、勾配のノイズの標準偏差と 1 回の更新の計算量はそれぞれ何倍になるか
8. **第 6 回の 1 変数モデル**　$y_i = w x_i + \varepsilon_i$（$i = 1, \dots, N$）、$\varepsilon_i$ は独立で平均 0、分散 σ^2、x_i は定数とする。$d = \sum_i x_i^2$ とおく。
   (a) 最小二乗解 $\hat{w} = \frac{1}{d}\sum_i x_i y_i$ について、$\mathbb{E}[\hat{w}] = w$ を示せ。どの性質を使ったか述べよ
   (b) $\mathrm{Var}[\hat{w}] = \sigma^2/d$ を示せ。どの性質を使ったか、またノイズの独立性がどこで必要かを述べよ

(c) リッジ回帰の解 $\hat{w}_\lambda = \frac{d}{d+\lambda}\hat{w}$ について、期待値と分散を求めよ（第 6.4.3 項の式と一致することを確かめよ）

9. **正規分布**
   (a) $\mathcal{N}(x \mid \mu, \sigma^2)$ の最大値を求めよ。$\sigma = 0.1$ のとき最大値は 1 を超えることを確かめ、それでも矛盾しない理由を「密度」と「確率」の違いから説明せよ
   (b) 式 (7.23) を導け
   (c) 独立に $\mathcal{N}(\mu, \sigma^2)$ に従う観測 $y_1, \dots, y_N$ が得られたとき、尤度 $\prod_i \mathcal{N}(y_i \mid \mu, \sigma^2)$ を最大にする μ が標本平均 $\frac{1}{N}\sum_i y_i$ であることを示せ（ヒント：負の対数をとり、μ で微分して 0 とおく）
10. **コインのベイズ推定**　表の出る確率 θ が 0.2、0.5、0.8 のいずれかであるコインがあり、事前確率はそれぞれ 1/3 とする。このコインを 3 回投げたら、表、表、裏の順に出た。
    (a) 各 θ について尤度 $p(D \mid \theta)$ を求めよ
    (b) 事後確率 $p(\theta \mid D)$ を求めよ。どの θ が最も確からしいか
    (c) 4 回目に表が出る確率を、全確率の定理を用いて $\sum_\theta P(\text{表} \mid \theta)\, p(\theta \mid D)$ として求めよ（**事後予測確率**）
    (d) 最尤推定（3 つの候補のうち尤度が最大のもの）で選んだ θ を使って 4 回目に表が出る確率を答えるのと比べ、(c) との違いを述べよ
    (e)（発展）θ が区間 $[0, 1]$ 上で一様な事前分布をもつとき、n 回中 k 回表が出たあとの最尤推定が k/n、事後平均が $(k+1)/(n+2)$ であることを示せ。ただし $\int_0^1 \theta^a (1-\theta)^b \, d\theta = \frac{a!\, b!}{(a+b+1)!}$（$a, b$ は非負整数）を用いてよい

付録 A　勾配降下法の収束解析

第 5.3 節で結果だけを述べた事柄の導出をまとめる。記号は第 5.3 節と同じく、$\boldsymbol{A} = \frac{2}{N}\boldsymbol{X}^\top\boldsymbol{X}$（$L_D$ のヘッセ行列）、$\boldsymbol{w}^*$ を最適解、$\boldsymbol{e}^{(t)} = \boldsymbol{w}^{(t)} - \boldsymbol{w}^*$ を誤差とする。

A.1　誤差の漸化式と固有値分解

式 (5.12) より、誤差は 1 回の更新ごとに同じ行列 $\boldsymbol{I} - \eta\boldsymbol{A}$ を掛けられるので、

$$\boldsymbol{e}^{(t)} = (\boldsymbol{I} - \eta\boldsymbol{A})^t\,\boldsymbol{e}^{(0)} \tag{A.1}$$

である。$\boldsymbol{A}$ は対称かつ半正定値なので、固有値分解 $\boldsymbol{A} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^\top$（$\boldsymbol{Q} = (\boldsymbol{v}_1 \cdots \boldsymbol{v}_p)$ は直交行列、$\boldsymbol{\Lambda} = \mathrm{diag}(\lambda_1, \ldots, \lambda_p)$、$\lambda_1 \geq \cdots \geq \lambda_p \geq 0$）をもつ。$\boldsymbol{Q}^\top\boldsymbol{Q} = \boldsymbol{I}$ より

$$\boldsymbol{I} - \eta\boldsymbol{A} = \boldsymbol{Q}(\boldsymbol{I} - \eta\boldsymbol{\Lambda})\boldsymbol{Q}^\top, \qquad (\boldsymbol{I} - \eta\boldsymbol{A})^t = \boldsymbol{Q}(\boldsymbol{I} - \eta\boldsymbol{\Lambda})^t\boldsymbol{Q}^\top$$

であり（$\boldsymbol{Q}^\top\boldsymbol{Q}$ が間で消えるため）、$(\boldsymbol{I} - \eta\boldsymbol{\Lambda})^t$ は対角成分が $(1 - \eta\lambda_i)^t$ の対角行列である。$c_i = \boldsymbol{v}_i^\top\boldsymbol{e}^{(0)}$（誤差の $\boldsymbol{v}_i$ 方向の成分）とおけば $\boldsymbol{Q}^\top\boldsymbol{e}^{(0)} = (c_1, \ldots, c_p)^\top$ なので、

$$\boldsymbol{e}^{(t)} = \boldsymbol{Q}(\boldsymbol{I} - \eta\boldsymbol{\Lambda})^t\boldsymbol{Q}^\top\boldsymbol{e}^{(0)} = \sum_{i=1}^{p} c_i\,(1 - \eta\lambda_i)^t\,\boldsymbol{v}_i$$

となる。これが式 (5.13) である。

A.1.1　定理（式 (5.14)）の証明

固有ベクトルは正規直交なので、三平方の定理により

$$\|\boldsymbol{e}^{(t)}\|^2 = \sum_{i=1}^{p} c_i^2\,(1 - \eta\lambda_i)^{2t}$$

である。すべての i で $|1 - \eta\lambda_i| < 1$ なら各項が 0 に向かうので、任意の $\boldsymbol{e}^{(0)}$ に対して $\boldsymbol{e}^{(t)} \to \boldsymbol{0}$ となる（十分性）。逆に、ある i で $|1 - \eta\lambda_i| \geq 1$ なら、$\boldsymbol{e}^{(0)} = \boldsymbol{v}_i$ から出発したとき $\|\boldsymbol{e}^{(t)}\| = |1 - \eta\lambda_i|^t \geq 1$ で、いつまでも収束しない（必要性）。$\lambda_i > 0$ のとき $|1 - \eta\lambda_i| < 1$ は $0 < \eta < 2/\lambda_i$ と同値であり、これがすべての i で成り立つ条件は、最も厳しい $\lambda_{\max}$ に対する $0 < \eta < 2/\lambda_{\max}$ である。

A.2　最適な学習率と減衰率

$\boldsymbol{A}$ を正定値とする。学習率 η に対する誤差の減衰率を

$$\rho(\eta) = \max_i |1 - \eta\lambda_i|$$

と定めると、式 (5.13) より $\|\boldsymbol{e}^{(t)}\| \leq \rho(\eta)^t\,\|\boldsymbol{e}^{(0)}\|$ であり、最悪の初期値ではこの上界が達成される。$1 - \eta\lambda$ は λ について単調なので、最大値は両端 $\lambda_{\min}, \lambda_{\max}$ のどちらかでとられ、

$$\rho(\eta) = \max\bigl(\,|1 - \eta\lambda_{\min}|,\ |1 - \eta\lambda_{\max}|\,\bigr)$$

である。$0 < \eta < 2/\lambda_{\max}$ の範囲では $1-\eta\lambda_{\min}$ は正で η とともに減少し、$|1-\eta\lambda_{\max}|$ は $\eta > 1/\lambda_{\max}$ で $\eta\lambda_{\max}-1$ となって η とともに増加する。一方が減り他方が増えるので、$\rho(\eta)$ が最小になるのは両者が等しいとき、すなわち

$$1-\eta\lambda_{\min} = \eta\lambda_{\max} - 1 \quad\Longleftrightarrow\quad \eta^{*} = \frac{2}{\lambda_{\max}+\lambda_{\min}}$$

である。このとき

$$\rho^{*} = 1-\eta^{*}\lambda_{\min} = \frac{\lambda_{\max}-\lambda_{\min}}{\lambda_{\max}+\lambda_{\min}} = \frac{\kappa-1}{\kappa+1}$$

となり、式 (5.15) を得る。

A.2.1 必要な反復回数

$\rho^{t} \le \varepsilon$ となる t は $t \ge \log(1/\varepsilon)/\log(1/\rho)$ である。κ が大きいとき $\rho = 1-2/(\kappa+1)$ であり、$\log(1-x) \approx -x$（x が小さいとき）より $\log(1/\rho) \approx 2/(\kappa+1)$ なので、

$$t \approx \frac{\kappa+1}{2}\,\log\frac{1}{\varepsilon}$$

となる。必要な反復回数は条件数 κ に比例する。数値例（$\kappa \approx 46$）で誤差を $1/100$ にするには $t \approx 23.5 \times \log 100 \approx 108$ 回であり、第 5.3.2 項で $\log(1/\rho)$ を直接計算して得た約 107 回とよく合う。なお、モメンタム（第 5.6.1 項）に同様の解析を行うと、η と β を最適に選んだときの減衰率が式 (5.23) の $(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$ になる。

A.3 相関と白色化

第 5.3.4 項の標準化がそろえるのは $\boldsymbol{X}^{\top}\boldsymbol{X}$ の**対角成分**だけである。2 つの特徴が強く相関していると（第 3.5.5 項の多重共線性）、標準化しても非対角成分が残り、等高線は斜めに細長い楕円のまま、条件数は 1 にならない。例えば標準化済みの 2 つの特徴の相関係数が r なら

$$\frac{1}{N}\boldsymbol{Z}^{\top}\boldsymbol{Z} = \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix}, \qquad \text{固有値は } 1+r,\ 1-r, \qquad \kappa = \frac{1+r}{1-r}$$

であり、$r = 0.9$ なら $\kappa = 19$、$r = 0.99$ なら $\kappa = 199$ である。

非対角成分まで消すのが**白色化**（whitening）である。平均を引いた計画行列（バイアス列を除く）を $\boldsymbol{X}_c \in \mathbb{R}^{N\times d}$ とし、その共分散行列 $\boldsymbol{\Sigma} = \frac{1}{N}\boldsymbol{X}_c^{\top}\boldsymbol{X}_c \in \mathbb{R}^{d\times d}$ を第 3.7 節の固有値分解 $\boldsymbol{\Sigma} = \boldsymbol{Q}\boldsymbol{\Lambda}\boldsymbol{Q}^{\top}$（$\boldsymbol{Q}$ は直交行列、$\boldsymbol{\Lambda}$ は固有値の対角行列）で表す。$\boldsymbol{\Sigma}^{-1/2} = \boldsymbol{Q}\boldsymbol{\Lambda}^{-1/2}\boldsymbol{Q}^{\top}$ とおいて

$$\boldsymbol{Z} = \boldsymbol{X}_c\,\boldsymbol{\Sigma}^{-1/2} \tag{A.2}$$

と変換すると、

$$\frac{1}{N}\boldsymbol{Z}^{\top}\boldsymbol{Z} = \boldsymbol{\Sigma}^{-1/2}\Big(\frac{1}{N}\boldsymbol{X}_c^{\top}\boldsymbol{X}_c\Big)\boldsymbol{\Sigma}^{-1/2} = \boldsymbol{\Sigma}^{-1/2}\,\boldsymbol{\Sigma}\,\boldsymbol{\Sigma}^{-1/2} = \boldsymbol{I}$$

となる。変換後の特徴は分散が 1 で互いに無相関、ヘッセ行列は $2\boldsymbol{I}$、条件数はちょうど 1 である。等高線が真円になるので、勾配降下法は 1 回の更新で最小点に着く。「白色」の名は、すべての方向に等しい分散を持つ白色雑音にちなむ。

ただし、白色化には $\boldsymbol{\Sigma}$ の固有値分解（d^{3} に比例する計算）が必要であり、これは正規方程式を解くのと同程度の手間である。したがって最小二乗法に限れば、白色化してから勾配降下法を回すより最初から正規方程

式を解けばよい。白色化の意義はむしろ、「標準化で取り切れない条件数の悪化は特徴間の相関から来る」ことを明らかにする点と、固有ベクトル $\boldsymbol{Q}$ の向き（データが最も散らばる方向、第 3.7.3 項の主成分）に座標を取り直せば問題が単純になる、という見方を与える点にある。深層学習では、各層の入力を標準化し直す**バッチ正規化**（batch normalization）として、同じ発想が学習の内側に組み込まれている。